편집 안내: 문장과 캡션을 한국어로 옮긴 텍스트판입니다. 그림 이미지는 연결된 원문을 보십시오. 수식은 원문 기호 또는 TeX 표기를 유지하며, 참고문헌은 원문 서지를 유지합니다. 저자가 검토한 공식 번역이 아닙니다.

C-RADIOv4 (기술 보고서) — 한국어 본문 번역

원제: C-RADIOv4 (Tech Report)

원저자: Mike Ranzinger, Greg Heinrich, Collin McCarthy, Jan Kautz, Andrew Tao, Bryan Catanzaro, Pavlo Molchanov

저자 주: * 동등 기여(Equal Contribution).

번역 기준: arXiv:2601.17237v1, 2026년 1월 24일 제출. 원문 PDF 머리말의 날짜 표기는 2026-1-27이다.

정확한 원문: arXiv HTML v1 (https://arxiv.org/html/2601.17237v1) · arXiv PDF v1 (https://arxiv.org/pdf/2601.17237v1) · 로컬 원문 PDF

원문 라이선스: Creative Commons Attribution 4.0 International — CC BY 4.0 (https://creativecommons.org/licenses/by/4.0/). 라이선스 표시는 arXiv 논문 페이지 (https://arxiv.org/abs/2601.17237)에서 확인할 수 있다.

번역 고지: 이 문서는 원문을 한국어로 옮긴 비공식 AI 번역이며, 원저자의 검토·승인을 받은 공식 번역이 아니다. 번역·문단 나눔·표 머리글의 한국어화가 이루어졌다. 원문의 수식, 절 번호, 표 수치와 모델 표기를 보존했다. 아래의 '우리'는 원저자를 가리킨다. 논문 라이선스 표시는 코드·모델 가중치의 이용 조건을 대신하지 않는다.

수록 범위: 초록, 본문 전체, 수식 1–7, 표 1–5와 모든 데이터, 그림 1–9의 설명, 참고문헌 25개. 원문에 부록은 없다. 참고문헌의 서지정보는 영문을 유지했다. 그림 이미지는 복제하지 않았으며, 각 설명의 링크와 원문 PDF에서 볼 수 있다.

번역 작성일: 2026-09-28

초록

여러 교사 모델로부터 증류하는 방식을 활용하면, 통합형(agglomerative) 비전 백본은 여러 교사의 고유한 능력을 유지하고 개선하는 하나의 통합 학생 모델을 제공할 수 있다. 이 기술 보고서에서는 C-RADIO 모델 계열의 최신 릴리스인 C-RADIOv4를 설명한다. C-RADIOv4는 설계 측면에서 AM-RADIO/RADIOv2.5를 바탕으로 하며, 동일한 계산 복잡도에서 주요 다운스트림 과제의 성능을 크게 개선한다. 우리는 -SO400M(파라미터 412M)과 -H(631M) 모델 변형을 공개한다. 두 모델 모두 SigLIP2, DINOv3, SAM3로 갱신된 교사 집합으로 학습했다. C-RADIOv4 모델 계열은 핵심 지표의 개선과 SAM3를 모방함으로써 얻는 새로운 능력뿐 아니라, 임의 해상도 지원을 한층 개선하고, 고해상도에서 효율을 크게 높이는 ViTDet 옵션을 다시 도입하며, 허용적인 라이선스로 제공된다.

링크: 코드 — GitHub (https://github.com/NVlabs/RADIO) · 모델 — Hugging Face (https://huggingface.co/collections/nvidia/radio-669f77f1dd6b153f007dd1c6)

1 설명

AM-RADIO [17]는 서로 다른 종류의 모델에서 특징 표현을 증류하여 새로운 파운데이션 모델을 만드는 방법인 통합형 파운데이션 모델의 개념을 도입했다. 최초 구성에서는 DFN CLIP [11], DINOv2 [8], SAM [13]을 핵심 교사 집합으로 사용했다. 또한 DFN CLIP과 DINOv2는 한 해상도에서 증류하고 SAM은 더 높은 해상도에서 증류하는 방식의 다중 해상도 학습을 도입했다. 우리는 학생 모델이 학습 손실을 최소화하기 위해 해상도에 따라 표현을 바꾸도록 학습하는 현상을 발견하고 이를 '모드 전환(mode switching)'이라고 불렀다. 이 현상은 추론 때 사용하는 해상도에 따라 동작이 매우 일관되지 않게 되는 원인이었다.

PHI-S [16]에서는 교사 분포의 균형 조절이 강력한 통합형 모델을 학습하는 데 중요한 요소임을 확인했다. RADIOv2.5 [12]에서는 두 해상도 모두에서 모든 교사를 대상으로 학습하는 것만으로 모드 전환 문제를 극복할 수 있음을 발견했다. FeatSharp [18]에서는 DFN CLIP과 SigLIP [24, 21]처럼 특정한 고정 해상도 모델에 적합하며, 쌍선형 재표본화보다 더 나은 업샘플링 방법을 제안했다.

최초 AM-RADIO에서 제시한 핵심 사항 중 하나는 교사가 개선되면 학생도 개선되는 경향이 있다는 것이며, 이 경향은 여전히 유효하다. 이전 연구 이후 SigLIP2 [21]는 최전선의 텍스트–이미지 파운데이션 인코더가 되었고, DINOv3 [19]는 자기지도학습(SSL)과 밀집 표현의 경계를 확장하여 매우 강력한 밀집 인지 모델을 만들어 냈다. SAM은 SAM3 [6]로 발전하며 컴퓨터 비전 문제 해결을 향해 큰 진전을 이루었다. 우리는 처음의 전제에 맞추어 통합형 모델을 개선하고자 핵심 교사 집합을 [SigLIP2, DINOv3, SAM3]로 갱신했다. 이를 통해 DINOv3의 향상된 의미 분할 능력과 SigLIP2의 향상된 텍스트 정렬 능력을 물려받는다.

SAM3를 교사로 사용하는 것은 우리가 선택한 벤치마크의 지표를 개선하지는 않지만, 교사에 포함함으로써 SAM3의 비전 인코더 백본을 교체할 수 있게 된다. 또한 RADSeg [3]의 사례처럼 통합형 모델의 특성을 활용하는 창의적인 사용 사례를 가능하게 한다. 교사 집합을 갱신하는 데 그치지 않고, 임의 해상도에서 동작하는 능력을 개선하여 범용성에 대한 우리의 목표를 더 진전시킨다. 아울러 대부분의 트랜스포머 블록을 윈도 방식으로 동작시킬 수 있는 'ViTDet 모드'를 다시 도입한다. 이 모드는 고해상도 이미지의 추론 속도에 매우 큰 영향을 준다(그림 9 참조).

표 1. 서로 다른 비전 인코더의 비교. C-RADIOv4는 DINOv3보다 훨씬 적은 파라미터로 밀집 과제에서 경쟁력 있는 성능을 보인다. 원문의 'Summary'는 아래의 제로샷·kNN 열을, 'Segmentation'은 ADE20k·VOC 열을, 'Probe3d'는 NAVI·SPair 열을 묶는다. 빈칸과 -는 원문 표기를 유지했다.

같은 표의 열을 나누어 표시: 1/2

모델 이름	변형	파라미터	요약: 제로샷	요약: kNN	분할: ADE20k	분할: VOC
SigLIP2	SO400M	412M	83.88	85.76	44.0	
SigLIP2	g	1,164M	84.75	86.39	42.7	72.7
DINOv3	H+	841M	-	85.77	54.8	
DINOv3	7B	6,716M	-	85.42	55.9	86.6
RADIOv2.5	H	631M	82.51	85.81	51.58	85.97
C-RADIOv3	H	631M	82.65	86.23	52.75	86.41
C-RADIOv4	SO400M	412M	82.01	85.76	55.14	87.22
C-RADIOv4	H	631M	83.09	86.59	55.20	87.24

같은 표의 열을 나누어 표시: 2/2

모델 이름	변형	Probe3d: NAVI	Probe3d: SPair
SigLIP2	SO400M	48.8	38.7
SigLIP2	g	49.40	42.60
DINOv3	H+	63.3	56.3
DINOv3	7B	64.4	58.7
RADIOv2.5	H	60.89	56.24
C-RADIOv3	H	62.10	58.54
C-RADIOv4	SO400M	62.44	60.01
C-RADIOv4	H	63.44	60.57

그림 1. C-RADIOv3-H와 C-RADIOv4-H를 비교한 PCA 특징 시각화. 객체 경계가 이제 훨씬 더 선명하다. 원문 그림 1 보기 (https://arxiv.org/html/2601.17237v1#S1.F1)

2 방법의 변경 사항

통합형 모델은 여러 비전 파운데이션 모델로부터의 증류에 의존한다. RADIO 모델 계열에서는 밀집 특징 공간과 요약 토큰 모두를 대상으로 증류한다. 이 절에서는 RADIOv2.5 [12]에서 방법을 상세히 설명한 이후 무엇이 달라졌는지를 중심으로, 이전 변형보다 개선된 C-RADIOv4를 개발하는 데 사용한 새로운 기법을 설명한다.

2.1 갱신된 교사 모델

C-RADIOv4에서는 교사 집합을 다음과 같이 갱신한다.

- SigLIP2-g-384 [21]

- DINOv3-7B [19]

- SAM3 [6]

계산 요구량을 줄이기 위해 이번 릴리스에서는 DFN CLIP [11] 지원을 중단하고, 더 널리 쓰이는 SigLIP2 [21]를 선택했다. SigLIP2는 Qwen3 VL [4] 등의 더 많은 곳에 도입되고 있으며, 두 모델의 표현과 응용 영역이 비슷하기 때문이다.

2.2 확률적 해상도

RADIOv2.5 [12]처럼 서로 다른 2개 해상도에서 학습하는 대신, 저해상도 구간에서는 $\{128, 192, 224, 256, 384, 432\}$, 고해상도 구간에서는 $\{512, 768, 1024, 1152\}$에서 표본을 뽑는다. 이렇게 하면 해상도에 따른 성능 변화 곡선이 한층 부드러워지고, 저해상도에서 품질도 상당히 좋아진다. SigLIP2 [21]의 경우 고해상도 학습 구간에서는 FeatSharp [18]를 사용하여 384px에서 1152px로 3 × 업샘플링한다. 저해상도 구간에서는 원래 출력을 사용한다. 마지막으로 SAM3는 1152×1152 크기의 입력만 지원하므로, RADIOv2.5 [12]에서 제안한 모자이크 증강을 사용한다.

그림 3과 4는 다중 해상도 지원이 시간에 따라 어떻게 발전했는지 보여 준다. 그림 4에서는 역시 다중 해상도를 지원하는 DINOv2/3와 RADIO 모델을 비교한다. 표 2는 C-RADIOv4가 의미 분할에서 해상도를 높이는 데 매우 강건하며, 학습 때보다 높은 해상도에서도 그렇다는 것을 보여 준다. C-RADIOv4-H의 파라미터 수가 DINOv3-7B보다 한 자릿수 규모, 즉 약 10배 적다는 점을 고려하면 매우 경쟁력 있는 성능이다.

표 2. DINOv3-7B와 C-RADIOv4-H의 ADE20k [25] 선형 프로브에서 해상도 확장 특성 비교. 두 모델 모두 해상도를 높였을 때 우수한 특성을 보인다. † DINOv3-7B의 지표는 [19]의 그림 11에서 가져왔으며, 소수점 이하 값은 근삿값이다.

모델	ADE20k: 512px	ADE20k: 1024px	ADE20k: 1536px
DINOv3-7B	55.9	57.3†	57.8†
C-RADIOv4-H	55.20	57.02	57.72

2.3 평행이동 등변성

PHI-S [16] 이후 특징 손실은 $\frac{1}{Z}\sum_i (x - \hat{y})^2$의 형태였다. 여기서 $\hat{y}$는 PHI-S로 정규화한 교사 특징, x는 학생 예측, Z는 정규화 상수이다. 이 접근의 단점은 학생이 교사의 유용한 특징뿐 아니라 고정 패턴 잡음까지 학습한다는 점이다. DVT [23]의 저자들은 이 모든 비전 파운데이션 모델에 이런 잡음이 있음을 발견하고, 모델 출력을 $ViT(x) \approx f(x) + g(E_{pos}) + h(x, E_{pos})$로 분리하도록 학습한다. 여기서 f는 입력에 의존하는 의미 정보, g는 데이터에 따라 변하지 않는 편향, h는 서로 얽힌 잔차이다.

FeatSharp [18] 연구에서도 동일한 잡음 패턴을 확인했다. 특히 SigLIP2 모델은 출력 특징 맵의 가장자리에 이런 '구멍'이 있다. SAM [13]에는 ViTDet [14] 윈도의 경계에서 강한 인공 흔적이 생긴다. DINOv3-H+에는 크기가 큰 잡음 패치가 비교적 자주 나타난다. 이러한 경우를 모두 그대로 두면 모델은 MLP 어댑터에서 이 잡음을 모방하도록 학습하고, 잡음은 백본 특징으로까지 스며든다. 우리는 손실 정의에 두 가지 형태의 평행이동 등변성을 적용하여 이 문제에 대응한다. 두 방식 모두 학생이 자신과 교사 사이에서 대응시키는 패치의 정확한 위치를 알 수 없게 한다. 그림 2에서 이 인공 흔적을 시각화한다. 다른 부분은 대체로 균일한 이미지 영역인데도 높은 에너지의 표현이 나타나는 경우가 많다.

그림 2. DINOv3와 C-RADIOv4(어댑터)의 예측 시각화. DINOv3가 만들어 내는, 주변과 어울리지 않는 점 모양의 잡음에 주목하라. 1열: 입력 이미지. 2열: DINOv3의 PCA 시각화. 3열: C-RADIOv4 어댑터의 PCA 시각화. 4열: 학생 어댑터 예측과 DINOv3 교사 사이의 오차 열지도. 원문 그림 2 보기 (https://arxiv.org/html/2601.17237v1#S2.F2)

2.3.1 평행이동 등변 손실

학생이 명시적으로 입력 의존적인 의미 정보가 아닌 교사의 밀집 특징 [23]까지 맞추지 않도록, 주어진 이미지에서 학생이 보는 크롭과 각 교사가 보는 크롭을 무작위로 이동한다. 교사들의 이동은 서로 간에 독립적이며, 학생의 이동과도 독립적이다. 학생이 생성한 특징을 교사와 공간적으로 정렬하도록 변환하는 사상 $\mathcal{F}_{S\to T}$를 추적한다. 이동량은 패치 크기의 배수 단위로 표본 추출하여, 가능한 경우 보간의 영향을 없앤다. 이에 따라 다음의 새로운 손실 정의를 사용한다.

$$L_{\text{spatial}}(\mathbf{x}, \hat{\mathbf{y}}) = \frac{1}{|\Omega|} \sum_{u \in \Omega} \left(\mathcal{F}_{S\to T}[\mathbf{x}]_u - \hat{\mathbf{y}}_u\right)^2.$$

식 (1)

여기서 Ω는 학생과 교사가 공통으로 보는 공간 위치의 집합, $\mathbf{x}$는 학생 출력, $\hat{\mathbf{y}}$는 PHI-S [16]로 정규화한 교사 출력이다.

2.3.2 평행이동 등변 MESA

MESA [9]는 분류 모델 학습에 필수적인 도구이다. 입력의 교란이 출력의 혼란스러운 변화를 일으키지 않는 평탄한 영역으로 가중치를 수렴시키려 하며, 일반화를 개선한다. 학생 모델에서 고정 패턴 잡음이 생기는 것을 더 억제하기 위해, 학생 모델의 지수이동평균(EMA)에 맞추는 MESA의 정의를 적용한다. 여기에 학생과 그 EMA에 서로 다른 크롭을 입력하고, $\mathcal{F}_{S\to\tilde{S}}$ 변환을 통해 둘을 연결하는 변경을 더하여 다음 정의를 사용한다.

$$L_{mesa}(\mathbf{x}, \tilde{\mathbf{x}}) = \frac{1}{|\Omega|} \sum_{u \in \Omega} \left(\mathcal{F}_{S\to\tilde{S}}[LN(\mathbf{x})]_u - LN(\tilde{\mathbf{x}})_u\right)^2$$

식 (2)

여기서 LN은 학습 가능한 아핀 사영을 사용하지 않는 층 정규화이며, $\tilde{S}$와 $\tilde{\mathbf{x}}$는 각각 EMA 학생 모델의 크롭과 출력이다.

2.4 DAMP

모델의 강건성을 더욱 높이기 위해, 학습 중 모델의 가중치에 곱셈 잡음을 적용하는 DAMP [20]를 사용한다.

2.5 균형을 맞춘 요약 손실

PHI-S [16] 연구 전체는 큰 활성값이 손실을 지배하지 않도록 각 교사의 공간 특징 분포를 정규화하는 데 초점을 맞추었다. 그러나 요약 특징에는 주의를 기울이지 않았다. 요약 특징은 본질적으로 정규화된 코사인 유사도를 사용하여 맞추었기 때문이다. 하지만 이후 관찰한 바에 따르면, 요약 특징의 크기는 단위 초구 위로 정규화되지만 방향의 분산은 정규화되지 않는다.

교사가 단위 초구 전체에서 균일하게 분포하는 특징을 생성한다면 이것은 중요하지 않을 것이다. 그러나 실제로 발견한 것은 특징들이 원뿔 안에 모이는 경향이 있고, 이 원뿔의 반지름이 교사마다 다르다는 점이다. 그 결과 반지름이 큰 원뿔은 작은 원뿔보다 더 큰 손실을 만든다. 더 나아가 중요한 것은 학생과 교사 사이의 각도 자체라기보다, 다른 모든 임베딩과의 관계에서 그 각도가 갖는 상대적인 의미이다. 이를 완화하기 위해 요약 손실로 코사인 거리를 더 이상 사용하지 않고, 대신 다음을 채택한다.

$$\cos(\mathbf{x}, \mathbf{y}) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\|\|\mathbf{y}\|}$$

식 (3)

$$\Theta(\mathbf{x}, \mathbf{y}) = \arccos(\cos(\mathbf{x}, \mathbf{y}))$$

식 (4)

$$\boldsymbol{\mu}_{\mathbf{y}} = \frac{\mathbb{E}[\mathbf{y}]}{\|\mathbb{E}[\mathbf{y}]\|}$$

식 (5)

$$\text{Disp}(\Theta_{\mathbf{y}}) = \mathbb{E}\left[\Theta(\mathbf{y}, \boldsymbol{\mu}_{\mathbf{y}})^2\right]$$

식 (6)

$$L_{angle}(\mathbf{x}, \mathbf{y}) = \frac{\Theta(\mathbf{x}, \mathbf{y})^2}{\mathrm{Disp}(\Theta_{\mathbf{y}})}$$

식 (7)

여기서 $\mathbf{x}$는 학생 예측, $\mathbf{y}$는 교사 예측, $\boldsymbol{\mu}_{\mathbf{y}}$는 $\mathbf{y}$의 기대 방향, $\mathrm{Disp}(\Theta_{\mathbf{y}})$는 $\mathbf{y}$의 각도 산포이다. 이 산포를 사용하여 교사 사이의 원뿔 반지름을 정규화함으로써 학생이 상대적인 각도에 집중하게 하고, 한 교사가 다른 교사를 지배하지 못하게 한다. 표 3에는 우리가 관찰한 각도 산포를 보고하며, SigLIP2와 DINOv3 사이에 상당한 차이가 있음을 보여 준다. 이를 완화하지 않으면 DINOv3가 손실 항을 지배하여, 학생이 SigLIP2를 맞추는 것을 희생하면서 DINOv3에 맞추는 쪽으로 치우치게 된다.

표 3. 주요 교사 모델의 요약 토큰 각도 산포.

모델	$\mathrm{Disp}(\Theta_{\mathbf{y}})$
SigLIP2-g-384	0.694
DINOv3-H+	2.120
DINOv3-7B	2.186

3 결과

3.1 지표

그림 3에는 RADIOv2.5와 여러 버전의 C-RADIO의 제로샷 정확도를 제시한다. RADIOv2.5와 C-RADIOv2에는 SigLIP2에 정렬된 헤드가 없으므로, 이 모델들의 DFN CLIP 헤드를 사용한 정확도를 보고한다. 일반적으로 학생 모델은 DFN CLIP을 더 쉽게 맞출 수 있다. 따라서 C-RADIOv4가 나오기 전까지는 이전 RADIOv2.5 모델의 제로샷 정확도에 도달할 수 없었다. 제시한 모든 모델은 해상도 확장에 대해 우수한 특성을 보이지만, C-RADIOv4는 이전 세대 모델보다 저해상도 분류를 크게 개선한다. 종횡비를 보존하는 크기 조정을 사용했을 때 1024px 해상도에서 최대 제로샷 점수를 얻는다.

DINOv2와 이전 RADIO 연구에서 사용한 k-NN(k-최근접 이웃) 분류를 이용하면 DINOv2/3 모델과 직접 비교할 수 있다. 그림 4의 결과를 보면 DINOv3는 DINOv2보다 k-NN에서 큰 향상을 이루었지만, 해상도 변화에 따른 우수한 성능은 192–256px 주변에 집중되어 있고 더 높은 해상도에서는 성능이 저하된다. RADIO의 경우 C-RADIO 모델들은 RADIOv2.5보다 크게 개선되었으며, C-RADIOv4는 대체로 C-RADIOv3보다 조금 더 좋다. 이는 C-RADIOv3의 제로샷 문제가 전반적으로 좋은 표현을 갖추지 못해서라기보다, 특히 SigLIP2에 맞추는 데 문제가 있었기 때문일 가능성이 높음을 시사한다. 그럼에도 C-RADIOv4는 두 과제 모두에서 개선을 이룬다. 흥미롭게도 DINOv3의 H+ 모델은 7B 모델보다 kNN 분류를 더 잘한다. 256px부터 C-RADIOv4-H는 DINOv3에 필적하거나 이를 넘어설 수 있다.

그림 3. 입력 해상도에 따른 ImageNet-1K 제로샷 정확도. 원문 그림 3 보기 (https://arxiv.org/html/2601.17237v1#S3.F3)

그림 4. 입력 해상도에 따른 ImageNet-1K kNN 정확도. 원문 그림 4 보기 (https://arxiv.org/html/2601.17237v1#S3.F4)

표 4. 여러 RADIO 모델에 대한 전체 Probe3d [10] 평가. 모든 지표에서 값이 클수록 좋다.

모델	깊이	표면 법선	NAVI	SPair
RADIOv2.5-H	85.69	62.46	60.89	56.24
C-RADIOv2-H	85.02	60.10	59.82	53.98
C-RADIOv3-H	86.18	62.52	62.10	58.54
C-RADIOv4-SO440M	85.29	61.91	62.44	60.01
C-RADIOv4-H	85.55	61.70	63.44	60.57

번역자 주: 표 4의 C-RADIOv4-SO440M은 원문 표기를 그대로 보존했다. 본문과 다른 표에서 사용하는 SO400M과 표기가 다르며, 번역 과정에서 임의로 고치지 않았다.

3.2 SAM3

이전 RADIO 버전은 SAM [13] 어댑터를 지원했다. 이를 통해 RADIO가 SAM의 비전 인코더를 대체하고, SAM의 디코딩 및 메모리 스택을 사용하여 분할을 수행할 수 있었다. 이 능력은 RADSeg [3]와 같은 연구에서 영리하게 활용되었다. RADSeg는 SAM 헤드로 분할 마스크를 정제하여 개방 어휘 의미 분할에서 새로운 최고 성능을 달성한다. C-RADIOv4는 SAM 지원을 SAM3 [6]로 갱신하여, 핵심 비전 모델을 다시 교체할 수 있게 한다. 우리는 이 교체 방법을 보여 주는 SAM3 코드베이스의 포크 (https://github.com/mranzinger/sam3-radio)를 제공한다.

그림 6과 7에서는 비전 인코더를 교체하는 RADIO의 능력을 보여 준다. 먼저 SAM3가 제공하는 이미지 데모를 사용하고, 다음으로 자체 이미지에 서로 다른 질의를 사용한다. 정성적으로 RADIO는 SAM3의 Perception Encoder [5] 백본을 대신하는 데 문제가 없다. 표 5는 SA-Co/Gold [6] 인스턴스 분할의 벤치마크 결과를 보여 준다. C-RADIOv4는 두 번째로 좋은 모델이 되지만, SAM3의 비전 인코더를 대체하는 능력은 세부 영역별로 고르지 않다. 자연 이미지가 대부분인 'metaclip_nps'와 'sa1b_nps'에서는 RADIO가 꽤 잘 동작하며 SAM3와의 차이가 작다. 그러나 'fg_sports_equipment'와 'wiki_common'에서는 차이가 훨씬 커진다. SAM3에 더 잘 맞추는 능력을 개선하는 것은 아직 열려 있는 연구 방향이다.

C-RADIOv4는 'ViTDet 모드' [14]를 지원한다. 이 모드에서는 전체 전역 어텐션으로 동작하거나(즉, ViTDet 모드를 끈 경우), 대부분 윈도 어텐션을 사용하면서 중간중간 소수의 전역 어텐션 층을 배치할 수 있다. 모델을 구성할 때 vitdet_window_size 플래그로 이를 제어한다. SAM3는 ViT-L+ 구조를 사용하며, 4개 층은 전역 어텐션이고 나머지는 24×24 토큰의 윈도를 사용한다. 효율을 높이기 위해 C-RADIOv4는 6×6부터 32×32 토큰까지의 윈도를 지원한다. 유일한 제한은 윈도 크기와 패치 크기를 곱한 값으로 입력 이미지 해상도가 나누어떨어져야 한다는 것이다.

작은 윈도는 자기 어텐션 [22]의 이차 비용을 줄이므로 더 빠를 가능성이 있다. 다만 하드웨어에 따라 비슷한 윈도 크기 사이의 속도 차이가 줄거나 사라질 수 있고, 작은 윈도는 약간의 품질 저하를 동반할 수 있다. 그림 9에는 A100 GPU에서 단일 이미지를 추론할 때의 시간을 제시한다. SO400M 모델은 윈도 크기가 ≤ 12이면 SAM3의 인코더보다 빠르다. ViT-H RADIO도 윈도 크기가 8이면 거의 그만큼 빠르다. 그림 5에는 두 C-RADIOv4 모델에 대해 ViTDet를 사용할 때와 사용하지 않을 때, 256px부터 4096px까지의 해상도에서 지연시간을 제시한다. 여전히 4개 층이 전역 어텐션을 사용하므로 ViTDet가 모델의 복잡도를 $O(T^2)$에서 다른 것으로 바꾸지는 않지만(T는 토큰 수), 증가 계수를 상당히 줄여 준다.

그림 5. 두 C-RADIOv4 버전에 대해, 지정한 윈도 크기의 ViTDet를 사용할 때와 사용하지 않을 때 A100에서 측정한 지연시간 분석. 윈도 크기 8과 16의 ViTDet 모드 사이의 지연시간 차이는 무시할 만하다. 원문 그림 5 보기 (https://arxiv.org/html/2601.17237v1#S3.F5)

'person'의 흥미로운 사례

SAM3 GitHub에는 2026년 1월 14일 기준으로, SAM3의 GitHub 예제가 'person' 질의에서 제대로 동작하지 않는다고 지적하는 이슈 253 (https://github.com/facebookresearch/sam3/issues/253)이 있다. 우리는 이 동작을 재현할 수 있었다. 그러나 C-RADIOv4를 비전 백본으로 사용하면 질의가 예상대로 동작한다. 그림 8에서 이 동작을 보여 준다. RADIO 변형은 전역 어텐션 모드와 윈도 크기 8인 ViTDet에서 모두 동작한다. 다른 설정도 아마 동작하겠지만, 우리가 시험한 것은 이 두 가지뿐이다. 이는 두 비전 인코더 사이의 약간의 표현 차이가 이 특정 질의에서 임계값에 따른 효과를 일으킨다는 점을 시사하는 것으로 보인다.

그림 6. 일반 SAM3를 사용하거나 비전 인코더를 RADIO로 교체했을 때, SAM3 이미지 데모에서 얻은 마스크 결과. RADIO는 SAM3의 결과를 재현할 수 있다. 원문 그림 6 보기 (https://arxiv.org/html/2601.17237v1#S3.F6)

그림 7. 디코더는 그대로 두고 RADIO가 SAM3의 비전 인코더를 대체했을 때의 텍스트 질의 결과. 원문 그림 7 보기 (https://arxiv.org/html/2601.17237v1#S3.F7)

그림 8. SAM3 데모(GitHub 이슈)는 'person' 질의로 마스크를 만들지 못하지만, C-RADIOv4-[SO400M,H]는 잘 동작한다. 원문 그림 8 보기 (https://arxiv.org/html/2601.17237v1#S3.F8)

그림 9. SAM3와 RADIO의 비전 인코더에 대한 A100 단일 이미지 벤치마크 결과. RADIO는 SO400M과 Huge 크기를 모두 제시한다. SAM3는 윈도 크기 24인 ViT-L+ 구조를 사용한다. 윈도 크기 72는 완전한 전역 어텐션과 같다. 원문 그림 9 보기 (https://arxiv.org/html/2601.17237v1#S3.F9)

표 5. SA-Co/Gold [6] 인스턴스 분할 결과(cgF1). ‘VDT’는 ViTDet의 윈도 크기 W를, ‘G’는 전체에 걸쳐 전역 어텐션을 사용함을 뜻한다. 원문의 모델 그룹과 변형 열을 읽기 쉽게 하나의 열로 합쳤다. 빈칸은 원문에서 수치가 제공되지 않은 칸이다.

같은 표의 열을 나누어 표시: 1/2

모델	metaclip_nps	sa1b_nps	crowded	fg_food	fg_sports_equipment	attributes
Human						
OWLv2						
DINO-X						
Gemini 2.5						
SAM3	47.3	53.7	61.1	53.4	65.5	54.9
C-RADIOv4-SO400M-VDT8	43.0	44.5	54.9	38.4	38.4	40.3
C-RADIOv4-SO400M-G	43.8	45.7	55.9	40.1	39.8	41.6
C-RADIOv4-H-VDT8	45.2	48.1	56.6	40.3	45.3	44.0
C-RADIOv4-H-VDT12	45.6	48.4	57.3	40.2	46.1	45.2
C-RADIOv4-H-G	45.9	48.8	57.4	40.9	46.5	45.9

같은 표의 열을 나누어 표시: 2/2

모델	metaclip_nps	wiki_common	평균(Avg)
Human			72.8
OWLv2			24.6
DINO-X			21.3
Gemini 2.5			13.0
SAM3	47.3	42.5	54.1
C-RADIOv4-SO400M-VDT8	43.0	22.2	40.3
C-RADIOv4-SO400M-G	43.8	23.1	41.4
C-RADIOv4-H-VDT8	45.2	26.2	43.7
C-RADIOv4-H-VDT12	45.6	26.7	44.2
C-RADIOv4-H-G	45.9	27.3	44.7

4 결론

기반 파운데이션 모델, 특히 DINOv3 [19]의 개선과 증류 알고리즘의 개선 덕분에 C-RADIOv4는 이전 모델보다 크게 향상되었다. 이전 릴리스와 달리 SO400M [1] 버전을 포함한다. 이 버전은 비용이 더 낮으면서도 ViT-H와 경쟁력 있는 성능을 보이는 경우가 많다. 우리는 C-RADIOv4를 사용하여 SAM3 [6]의 비전 인코더를 교체할 수 있음을 보여 준다. SO400M 변형에서 ViTDet 윈도 크기를 ≤ 12로 설정하면, SAM3가 사용하는 ViT-L+ Perception Encoder [5]보다도 더 빠르다.

이전 RADIO 모델은 Nemotron Nano V2 VL [15] 비전–언어 모델, 자율주행차, 로봇, OCR 문서 파싱 [7], 개방 어휘 의미 분할 [3, 2] 등 많은 곳에서 널리 사용되어 왔다. 상업적으로 허용적인 라이선스로 제공되는 만큼, 학계와 산업계 모두 이 파운데이션 모델을 활용하여 훌륭한 결과물을 만들 수 있기를 바란다.

참고문헌 — 영문 서지정보 유지

아래 25개 참고문헌의 저자·제목·발행 정보는 원문의 영문 표기를 유지했다. 웹 페이지의 역방향 인용 위치 안내(“Cited by”)만 제외하고, 서지정보와 외부 문헌 링크를 수록했다.

[1] I. Alabdulmohsin, X. Zhai, A. Kolesnikov, and L. Beyer (2023) Getting vit in shape: scaling laws for compute-optimal model design. In Thirty-seventh Conference on Neural Information Processing Systems, External Links: Link (https://openreview.net/forum?id=en4LGxpd9E)

[2] O. Alama, A. Bhattacharya, H. He, S. Kim, Y. Qiu, W. Wang, C. Ho, N. Keetha, and S. Scherer (2025) RayFronts: open-set semantic ray frontiers for online scene understanding and exploration. In 2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), Vol. , pp. 5930–5937. External Links: Document (https://dx.doi.org/10.1109/IROS60139.2025.11245813)

[3] O. Alama, D. Jariwala, A. Bhattacharya, S. Kim, W. Wang, and S. Scherer (2025) RADSeg: unleashing parameter and compute efficient zero-shot open-vocabulary segmentation using agglomerative models. External Links: 2511.19704, Link (https://arxiv.org/abs/2511.19704)

[4] S. Bai, Y. Cai, R. Chen, K. Chen, X. Chen, Z. Cheng, L. Deng, W. Ding, C. Gao, C. Ge, W. Ge, Z. Guo, Q. Huang, J. Huang, F. Huang, B. Hui, S. Jiang, Z. Li, M. Li, M. Li, K. Li, Z. Lin, J. Lin, X. Liu, J. Liu, C. Liu, Y. Liu, D. Liu, S. Liu, D. Lu, R. Luo, C. Lv, R. Men, L. Meng, X. Ren, X. Ren, S. Song, Y. Sun, J. Tang, J. Tu, J. Wan, P. Wang, P. Wang, Q. Wang, Y. Wang, T. Xie, Y. Xu, H. Xu, J. Xu, Z. Yang, M. Yang, J. Yang, A. Yang, B. Yu, F. Zhang, H. Zhang, X. Zhang, B. Zheng, H. Zhong, J. Zhou, F. Zhou, J. Zhou, Y. Zhu, and K. Zhu (2025) Qwen3-vl technical report. External Links: 2511.21631, Link (https://arxiv.org/abs/2511.21631)

[5] D. Bolya, P. Huang, P. Sun, J. H. Cho, A. Madotto, C. Wei, T. Ma, J. Zhi, J. Rajasegaran, H. A. Rasheed, J. Wang, M. Monteiro, H. Xu, S. Dong, N. Ravi, S. Li, P. Dollar, and C. Feichtenhofer (2025) Perception encoder: the best visual embeddings are not at the output of the network. In The Thirty-ninth Annual Conference on Neural Information Processing Systems, External Links: Link (https://openreview.net/forum?id=INqBOmwIpG)

[6] N. Carion, L. Gustafson, Y. Hu, S. Debnath, R. Hu, D. Suris, C. Ryali, K. V. Alwala, H. Khedr, A. Huang, J. Lei, T. Ma, B. Guo, A. Kalla, M. Marks, J. Greer, M. Wang, P. Sun, R. Rädle, T. Afouras, E. Mavroudi, K. Xu, T. Wu, Y. Zhou, L. Momeni, R. Hazra, S. Ding, S. Vaze, F. Porcher, F. Li, S. Li, A. Kamath, H. K. Cheng, P. Dollár, N. Ravi, K. Saenko, P. Zhang, and C. Feichtenhofer (2025) SAM 3: segment anything with concepts. External Links: 2511.16719, Link (https://arxiv.org/abs/2511.16719)

[7] K. Chumachenko, A. S. Deshmukh, J. Seppanen, I. Karmanov, C. Chen, L. Voegtle, P. Fischer, M. Wawrzos, S. Motiian, R. Ageev, K. Wu, A. Milesi, M. Moosaei, K. Pawelec, P. Subramanian, M. Samadi, X. Yu, C. Dear, S. Stoddard, J. Diamond, J. Oliver, L. Chraghchian, P. Skelly, T. Balough, Y. Xu, J. P. Scowcroft, D. Korzekwa, D. Hanley, S. Bhaskar, T. Roman, K. Sapra, A. Tao, and B. Catanzaro (2025) NVIDIA nemotron parse 1.1. External Links: 2511.20478, Link (https://arxiv.org/abs/2511.20478)

[8] T. Darcet, M. Oquab, J. Mairal, and P. Bojanowski (2024) Vision transformers need registers. In Proceedings of the 12th International Conference on Learning Representations (ICLR),

[9] J. Du, Z. Daquan, J. Feng, V. Tan, and J. T. Zhou (2022) Sharpness-aware training for free. In Advances in Neural Information Processing Systems, A. H. Oh, A. Agarwal, D. Belgrave, and K. Cho (Eds.), External Links: Link (https://openreview.net/forum?id=xK6wRfL2mv7)

[10] M. El Banani, A. Raj, K. Maninis, A. Kar, Y. Li, M. Rubinstein, D. Sun, L. Guibas, J. Johnson, and V. Jampani (2024) Probing the 3D Awareness of Visual Foundation Models. In CVPR,

[11] A. Fang, A. M. Jose, A. Jain, L. Schmidt, A. Toshev, and V. Shankar (2023) Data filtering networks. External Links: 2309.17425, Link (https://arxiv.org/abs/2309.17425)

[12] G. Heinrich, M. Ranzinger, H. Yin, Y. Lu, J. Kautz, A. Tao, B. Catanzaro, and P. Molchanov (2025) RADIOv2.5: improved baselines for agglomerative vision foundation models. In Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR), pp. 22487–22497.

[13] A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A. C. Berg, W. Lo, P. Dollár, and R. B. Girshick (2023) Segment anything. 2023 IEEE/CVF International Conference on Computer Vision (ICCV), pp. 3992–4003. External Links: Link (https://api.semanticscholar.org/CorpusID:257952310)

[14] Y. Li, H. Mao, R. Girshick, and K. He (2022) Exploring plain vision transformer backbones for object detection. In Computer Vision – ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part IX, Berlin, Heidelberg, pp. 280–296. External Links: ISBN 978-3-031-20076-2, Link (https://doi.org/10.1007/978-3-031-20077-9_17), Document (https://dx.doi.org/10.1007/978-3-031-20077-9%5F17)

[15] NVIDIA, :, A. S. Deshmukh, K. Chumachenko, T. Rintamaki, M. Le, T. Poon, D. M. Taheri, I. Karmanov, G. Liu, J. Seppanen, G. Chen, K. Sapra, Z. Yu, A. Renduchintala, C. Wang, P. Jin, A. Goel, M. Ranzinger, L. Voegtle, P. Fischer, T. Roman, W. Ping, B. Wang, Z. Yang, N. Lee, S. Zhang, F. Liu, Z. Li, D. Zhang, G. Heinrich, H. Yin, S. Han, P. Molchanov, P. Mannan, Y. Xu, J. P. Scowcroft, T. Balough, S. Radhakrishnan, P. Zhang, S. Cha, R. Kumar, Z. P. Bhat, J. Zhang, D. Hanley, P. Biswas, J. Oliver, K. Vasques, R. Waleffe, D. Riach, O. Olabiyi, A. S. Mahabaleshwarkar, B. Kartal, P. Gundecha, K. Nguyen, A. Milesi, E. Khvedchenia, R. Zilberstein, O. Masad, N. Bagrov, N. Assaf, T. Asida, D. Afrimi, A. Zuker, N. Haber, Z. Cheng, J. Xin, D. Wu, N. Spirin, M. Moosaei, R. Ageev, V. A. Shah, Y. Wu, D. Korzekwa, U. K. Sreekumar, W. Jiang, P. Subramanian, A. Rico, S. Bhaskar, S. Motiian, K. Wu, A. Surla, C. Chen, H. Wolff, M. Feinberg, M. Corpuz, M. Wawrzos, E. Long, A. Jhunjhunwala, P. Hendricks, F. Memarian, B. Hall, X. Wang, D. Mosallanezhad, S. Singhal, L. Vega, K. Cheung, K. Pawelec, M. Evans, K. Luna, J. Lou, E. Galinkin, A. Hazare, K. Purandare, A. Guan, A. Warno, C. Cui, Y. Suhara, S. Likhite, S. Mard, M. Price, L. Sleiman, S. Kaji, U. Karpas, K. Briski, J. Conway, M. Lightstone, J. Kautz, M. Shoeybi, M. Patwary, J. Cohen, O. Kuchaiev, A. Tao, and B. Catanzaro (2025) NVIDIA nemotron nano v2 vl. External Links: 2511.03929, Link (https://arxiv.org/abs/2511.03929)

[16] M. Ranzinger, J. Barker, G. Heinrich, P. Molchanov, B. Catanzaro, and A. Tao (2024) PHI-s: distribution balancing for label-free multi-teacher distillation. External Links: 2410.01680, Link (https://arxiv.org/abs/2410.01680)

[17] M. Ranzinger, G. Heinrich, J. Kautz, and P. Molchanov (2024) AM-radio: agglomerative vision foundation model reduce all domains into one. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 12490–12500.

[18] M. Ranzinger, G. Heinrich, P. Molchanov, B. Catanzaro, and A. Tao (2025) FeatSharp: your vision model features, sharper. In Forty-second International Conference on Machine Learning, External Links: Link (https://openreview.net/forum?id=lioemOcq3H)

[19] O. Siméoni, H. V. Vo, M. Seitzer, F. Baldassarre, M. Oquab, C. Jose, V. Khalidov, M. Szafraniec, S. Yi, M. Ramamonjisoa, F. Massa, D. Haziza, L. Wehrstedt, J. Wang, T. Darcet, T. Moutakanni, L. Sentana, C. Roberts, A. Vedaldi, J. Tolan, J. Brandt, C. Couprie, J. Mairal, H. Jégou, P. Labatut, and P. Bojanowski (2025) DINOv3. External Links: 2508.10104, Link (https://arxiv.org/abs/2508.10104)

[20] T. Trinh, M. Heinonen, L. Acerbi, and S. Kaski (2024) Improving robustness to corruptions with multiplicative weight perturbations. In The Thirty-eighth Annual Conference on Neural Information Processing Systems, External Links: Link (https://openreview.net/forum?id=M8dy0ZuSb1)

[21] M. Tschannen, A. Gritsenko, X. Wang, M. F. Naeem, I. Alabdulmohsin, N. Parthasarathy, T. Evans, L. Beyer, Y. Xia, B. Mustafa, O. Hénaff, J. Harmsen, A. Steiner, and X. Zhai (2025) SigLIP 2: multilingual vision-language encoders with improved semantic understanding, localization, and dense features. External Links: 2502.14786, Link (https://arxiv.org/abs/2502.14786)

[22] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin (2017) Attention is all you need. In Proceedings of the 31st International Conference on Neural Information Processing

Systems, NIPS'17, Red Hook, NY, USA, pp. 6000–6010. External Links: ISBN 9781510860964

[23] J. Yang, K. Z. Luo, J. Li, C. Deng, L. J. Guibas, D. Krishnan, K. Q. Weinberger, Y. Tian, and Y. Wang (2024) DVT: denoising vision transformers.

[24] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer (2023) Sigmoid loss for language image pre-training. 2023 IEEE/CVF International Conference on Computer Vision (ICCV), pp. 11941–11952. External Links: Link (https://api.semanticscholar.org/CorpusID:257767223)

[25] B. Zhou, H. Zhao, X. Puig, S. Fidler, A. Barriuso, and A. Torralba (2016) Semantic understanding of scenes through the ade20k dataset. International Journal of Computer Vision 127, pp. 302 – 321. External Links: Link (https://api.semanticscholar.org/CorpusID:11371972)