# 한국어 본문 자동번역

## Emerging Properties in Self-Supervised Vision Transformers

비공식 Google 문서 자동번역 · 사람의 전문 교정 미완료

원문 저자: Caron, Mathilde; Touvron, Hugo; Misra, Ishan; Jégou, Hervé; Mairal, Julien; Bojanowski, Piotr; Joulin, Armand

원문 연도: 2021 · 다운로드/정리일: 2026-09-28

원 논문: https://arxiv.org/abs/2104.14294

번역에 사용한 원문 PDF: https://arxiv.org/pdf/2104.14294v2

라이선스: CC BY 4.0
https://creativecommons.org/licenses/by/4.0/

이 문서는 원문 전체 PDF를 Google 문서 번역에 입력해 얻은 결과입니다. 이 안내 한 쪽만 앞에 추가했으며, 뒤에 오는 자동번역 PDF의 본문·그림·수식은 수정하지 않았습니다.

번역은 원 저자나 출판사가 검토·승인한 공식 번역이 아닙니다. 전문을 사람이 대조·교정하지 않았습니다. 이미지 속 글자, 수식, 표, 참고문헌은 영어로 남거나 순서·배치가 흐트러질 수 있으므로 정확한 인용과 구현에는 원문을 함께 보십시오.

용어 읽기: Abstract는 ‘초록’, YOLO는 ‘You Only Look Once’, NMS는 ‘Non-Maximum Suppression(비최대 억제)’입니다. 번역문에 ‘추상적인’, ‘You Only Live Object’, ‘Non Machine System’으로 나오면 이 뜻으로 읽으십시오. 같은 이름의 TXT 파일에서 지정 제목·용어만 정정했으며 PDF 본문에는 반영하지 않았습니다.

업로드용 원문은 그림 해상도 최대 1800픽셀·JPEG 품질 90으로 압축했습니다. 수식·작은 글자는 보존된 영어 원본에서 확인하십시오.

한국어 번역과 이 안내를 추가한 변경을 표시하며, 이 번역·편집본은 CC BY 4.0으로 제공합니다. 별도 권리표시가 있는 제3자 자료의 조건은 유지됩니다.

본문 21쪽 + 안내 1쪽. 페이지 수·한글 텍스트 검사만 자동 수행했으며, 내용의 완전성·번역 정확성을 보증하는 검사가 아닙니다.

Machine Translated by Google

# 자기지도 학습 기반 비전 변환기의 새로운 특성

마틸드 카론1,2 휴고 투브론1,3 이샨 미스라1 에르베 제구 [1]
줄리앙 마이랄2 Piotr Bojanowski1 아르망 주랭1

[1] 페이스북 AI 연구 [2] 인리아 [3] 소르본 대학교



그림 1: 8×8 패치를 사용하여 무지도 학습된 Vision Transformer의 셀프 어텐션 . 마지막 레이어의 헤드에 있는 [CLS] 토큰 의 셀프 어텐션을 살펴봅니다 . 이 토큰은 어떤 레이블이나 지도 학습 데이터에도 연결되어 있지 않습니다. 이 맵은 모델이 클래스별 특징을 자동으로 학습하여 무지도 객체 분할을 수행함을 보여줍니다.

arXiv:2104.14294v2 [cs.CV] 2021년 5월 24일

## 추상적인

이 논문에서는 자기지도 학습이 합성 네트워크(convnets)와 비교하여 두드러지는 새로운 속성을 Vision Transformer(ViT) [19] 에 제공하는지 여부를 질문합니다.
자기지도 학습 방법을 이 아키텍처에 적용하는 것이 특히 효과적이라는 사실 외에도 다음과 같은 관찰 결과를 제시합니다 . 첫째, 자기지도 학습 ViT 특징은 이미지 의 의미론적 분할에 대한 명시적인 정보를 포함하고 있는데 , 이는 지도 학습 ViT나 컨볼루션 신경망에서는 명확하게 드러나지 않습니다 . 둘째, 이러한 특징은 k-NN 분류기에서도 우수한 성능을 보이며 , 작은 ViT를 사용하여 ImageNet에서 78.3%의 top-1 효율을 달성했습니다 . 본 연구는 또한 모멘텀 인코더 [33], 멀티 크롭 학습 [10], 그리고 ViT에 작은 패치를 사용하는 것의 중요성을 강조합니다. 우리는 이러한 연구 결과를 DINO라는 간단한 자기지도 학습 방법에 구현했는데, 이는 레이블이 없는 자기 증류 의 한 형태로 해석됩니다 .

본 연구에서는 ViT-Base를 사용한 선형 평가에서 ImageNet 데이터셋의 top-1 순위 80.1%를 달성함으로써 DINO와 ViTs 간의 시너지 효과를 입증합니다 .

*대학 Grenoble Alpes, Inria, CNRS, Grenoble INP, LJK, 38000 그르노블, 프랑스.

연락처: mathilde@fb.com 코드: https://github.com/facebookresearch/dino

## 1. 서론

최근 시각 인식을 위한 합성곱 신경망(convnet)의 대안으로 트랜스포머 [70] 가 등장했습니다 [19, 69, 83]. 트랜스포머의 도입은 자연어 처리(NLP)에서 영감을 받은 훈련 전략, 즉 대량의 데이터에 대한 사전 훈련과 대상 데이터 세트에 대한 미세 조정 과 결합되었습니다 [18, 55]. 결과적으로 Vision Transformers(ViT) [19] 는 convnet과 경쟁력이 있지만, 아직까지 convnet에 비해 명확한 이점을 제공하지는 못했습니다. ViT는 계산량이 더 많고, 더 많은 훈련 데이터가 필요하며, 특징이 고유한 속성을 나타내지 않습니다.

이 논문에서는 Transformers의 비전 분야에서의 저조한 성공이 사전 훈련에서의 지도 학습 사용으로 설명될 수 있는지 에 대해 의문을 제기합니다. 우리의 동기는 Transformers가 NLP 분야에서 성공을 거둔 주요 요인 중 하나가 BERT [18] 의 폐쇄 절차 또는 GPT[55]의 언어 모델링 과 같은 자기 지도 학습 사전 훈련의 사용 이었기 때문입니다 .

이러한 자기 지도 사전 훈련 목표는 문장의 단어를 사용하여 문장당 단일 레이블을 예측하는 지도 목표보다 더 풍부한 학습 신호를 제공하는 사전 작업(pretext task)을 생성합니다. 마찬가지로 이미지의 경우 이미지 수준 지도는 이미지에 포함된 풍부한 시각적 정보를 미리 정의된 수천 개의 객체 범주 집합 에서 선택된 단일 개념으로 축소하는 경우가 많습니다 [60].

자연어 처리에서 사용되는 자기 지도식 사전 작업(pretext tasks)은 다음과 같습니다.

Machine Translated by Google

텍스트 특성에 따라 기존의 많은 자기지도 학습 방법들은 다음과 같은 특징을 가지고 있습니다.
컨볼루션 신경망을 사용한 이미지에서 잠재력을 보여주었습니다 [10, 12, 30,
33]. 일반적으로 구조는 유사하지만, 사소한 해결책(붕괴)을 피하기 위
해 설계된 구성 요소가 다릅니다.
또는 성능을 향상시키기 위해 [16]. 본 연구에서는 다음에서 영감을 받았습니다.
본 연구에서는 이러한 방법들을 통해 자기지도 사전 학습이 ViT 특징에 미
치는 영향을 연구합니다. 특히, 다음과 같은 점에 주목하고자 합니다.
나타나지 않는 몇 가지 흥미로운 특성을 확인했습니다.
지도 학습 방식의 ViT에서도, 컨볼루션 신경망에서도 마찬가지입니다.

- 자기지도 ViT 특징은 명시적으로 다음을 포함합니다.
  장면 구성, 특히 객체 경계는 다음과 같습니다.
  그림 1에 나와 있습니다. 이 정보는 마지막 블록의 셀프 어텐션 모듈에서 직
  접 접근할 수 있습니다.

- 자체 지도 학습 방식의 ViT 특징이 특히 우수한 성능을 보입니다.
  기본 최근접 이웃 분류기 (k-NN)를 사용하지 않고
  미세 조정, 선형 분류기 또는 데이터 증강 기법은 사용하지 않습니다.
  ImageNet에서 78.3%의 top-1 정확도를 달성했습니다.

분할 마스크의 등장은 다음과 같은 현상으로 보입니다.
자기지도 학습 방법 전반에 걸쳐 공유되는 속성입니다. 그러나
k-NN을 사용한 우수한 성능은 모멘텀 인코더 [33] 와 같은 특정 구성
요소를 결합할 때만 나타납니다.
그리고 다중 작물 증강 [10]. 우리의 또 다른 발견은
본 연구는 ViTs와 함께 더 작은 패치를 사용하는 것의 중요성을 강조합니다.
결과 특징의 품질을 향상시키기 위해.

전반적으로, 이러한 요소들의 중요성에 대한 우리의 연구 결과는 다음과 같습니다.
구성 요소들을 통해 우리는 지식의 한 형태로 해석될 수 있는 간단한 자
기 지도 학습 방식을 설계할 수 있었습니다.
라벨이 없는 증류 [35] . 결과적 으로 생성된 프레임워크,
DINO는 표준 교차 엔트로피 손실을 사용하여 모멘텀 인코더로 구축된
교사 네트워크의 출력을 직접 예측함으로써 자기 지도 학습을 단순화합
니다.
흥미롭게도, 우리의 방법은 중심 맞춤만으로도 작동할 수 있습니다.
그리고 붕괴를 막기 위해 교사의 역량을 강화하는 동시에,
예측기 [30], 고급 과 같은 기타 인기 있는 구성 요소
정규화 [10] 또는 대조 손실 [33] 은 거의 이점을 제공하지 않습니다.
안정성이나 성능 측면에서 그렇습니다. 특히 중요한 것은 , 저희 프레임워크는
유연하며 컨볼루션 신경망(convnet) 모두에서 작동한다는 점입니다.
아키텍처를 수정할 필요 없이 ViT도 사용할 수 있습니다.
내부 정규화를 적용합니다 [58].

우리는 DINO와 ViT 간의 시너지 효과를 추가로 검증합니다.
기존의 자기지도 학습 특징들을 능가함으로써
ImageNet 선형 분류 벤치마크에서 80.1%의 top-1 성능을 달성했습니다.
작은 패치를 사용한 ViT-Base에서 정확도를 확인했습니다. 또한 상태
를 일치시켜 DINO가 컨볼루션 신경망에서 작동함을 확인했습니다.
ResNet-50 아키텍처를 사용한 예술 작품에 대해 논의합니다. 마지막으로, 이에 대해 자세히 살펴보겠습니다.
제한된 상황에서 ViT와 함께 DINO를 사용하는 다양한 시나리오
연산 능력과 메모리 용량. 특히 훈련
ViT를 사용한 DINO는 8GPU 서버 두 대만으로 3일 만에 실행할 수 있습니다.
ImageNet 선형 벤치마크에서 76.1%를 달성했습니다 .
컨볼루션 신경망 기반의 자기지도 학습 시스템보다 우수한 성능을 보입니다.
컴퓨팅 요구 사항 이 크게 줄어든 유사한 크기 [10, 30].

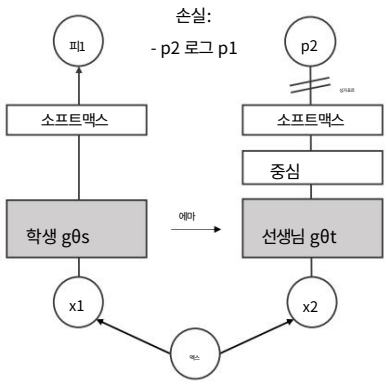



그림 2: 라벨이 없는 자체 증류. DINO를 그림 2에 나타냈습니다.
단순화를 위해 하나의 시점 쌍 (x1, x2) 만 고려합니다 .
모델은 입력에 대해 서로 다른 두 가지 무작위 변환을 적용합니다.
이미지를 학생 및 교사 네트워크에 공유합니다. 두 네트워크 모두 다음과 같은 특징을 가지고 있습니다.
동일한 아키텍처이지만 매개변수가 다릅니다. 출력은 다음과 같습니다.
교사 네트워크는 배치 전체에 걸쳐 계산된 평균을 중심으로 구성됩니다.
각 네트워크는 정규화된 K 차원 특징을 출력합니다.
특징 차원에 대한 온도 소프트맥스를 사용합니다.
유사성은 교차 엔트로피 손실을 사용하여 측정됩니다. 우리는 다음을 적용합니다.
기울기를 전파하기 위해 교사 객체에 stop-gradient(sg) 연산자를 적용합니다.
학생을 통해서만 가능합니다. 교사 매개변수는 다음과 같이 업데이트됩니다.
학생 매개변수의 지수 이동 평균(EMA).

## 2. 관련 연구

자기지도 학습. 자기지도 학습에 관한 많은 연구는 판별적 접근 방식에
초점을 맞추고 있습니다.
[12, 20, 33, 73] 에서 제시된 인스턴스 분류 는 각 이미지를 서로 다른 클래
스로 간주하고 모델을 학습시킵니다.
데이터 증강을 통해 이를 구별할 수 있습니다. 그러나 모든 이미지를 구
별하기 위해 명시적으로 분류기를 학습하는 것은 [20] 이미지 수에 따라
확장성이 떨어집니다. Wu et al. [73] 은 노이즈를 사용하는 방법을 제
안합니다.
대조 추정기(NCE) [32]를 사용하여 인스턴스를 분류하는 대신 비교합니
다. 이 접근 방식의 주의 사항은 다음과 같습니다.
이는 많은 수의 특징을 비교해야 함을 의미합니다.
이미지를 동시에 처리합니다. 실제로 이를 위해서는 대규모 저장 장치가 필요합니다.
배치 [12] 또는 메모리 뱅크 [33, 73]. 여러 변형
클러스터링 형태로 인스턴스의 자동 그룹화를 허용합니다 [2, 8, 9, 36, 42,
74, 80, 85].

최근 연구들은 비지도 학습이 가능하다는 것을 보여주었습니다.
이미지 간 구별 없이 특징을 추출합니다. 특히 Grill et al. [30] 은 메트
릭 학습을 제안합니다.
BYOL이라는 공식에서 특징은 다음과 같이 학습됩니다.
운동량을 이용하여 얻은 표현과 일치시킵니다.
인코더. BYOL과 같은 방법은 모멘텀 인코더 없이도 작동하지만 성능 저하가 발생합니다
[16, 30].
다른 여러 작품들도 이러한 방향을 반영하며, 하나는
더 정교한 표현과 일치시킬 수 있습니다 [26, 27]. 균일 분포에 맞춰 특징을
학습하거나 [6] 또는
미백 [23, 81]. 우리의 접근 방식은 다음에서 영감을 얻었습니다.
BYOL 방식이지만, 다른 유사도 매칭 손실 함수를 사용합니다.

Machine Translated by Google

그리고 학생과 교사에게 정확히 동일한 아키텍처를 사용합니다 . 이러한 방식으로 우리의 작업은 레이블이 없는 평균 교사 자체 증류 [65] 의 형태로 자기 지도 학습에 대한 BYOL에서 시작된 해석을 완성합니다 .

자체 학습 및 지식 증류. 자체 학습은 소수의 초기 주석 세트를 다수의 레이블이 지정되지 않은 인스턴스 세트로 전파하여 특징의 품질을 향상시키는 것을 목표로 합니다. 이러한 전파는 레이블의 하드 할당 [41, 78, 79] 또는 소프트 할당 [76]을 통해 수행할 수 있습니다. 소프트 레이블을 사용하는 접근 방식은 종종 지식 증류 [7, 35] 라고 하며 , 주로 모델을 압축하기 위해 더 큰 네트워크의 출력을 모방하도록 작은 네트워크를 학습시키는 데 사용됩니다. Xie et al. [76] 은 증류를 사용하여 자체 학습 파이프라인에서 소프트 의사 레이블을 레이블이 지정되지 않은 데이터로 전파할 수 있음을 보여주었고 , 자체 학습과 지식 증류 간의 중요한 연관성을 제시했습니다. 본 연구는 이러한 관계를 기반으로 레이블을 사용할 수 없는 경우로 지식 증류를 확장합니다 . 이전 연구에서도 자기지도 학습과 지식 증류를 결합하여 [25, 63, 13, 47] 자기지도 모델의 압축 과 성능 향상을 가능하게 했습니다. 그러나 이러한 연구들은 사전 학습된 고정된 교사 모델에 의존하는 반면, 본 연구에서는 교사 모델을 학습 중에 동적으로 구축합니다. 따라서 지식 증류는 자기지도 사전 학습의 사후 처리 단계로 사용되는 대신 , 자기지도 학습의 목표로 직접 적용됩니다 . 마지막으로, 본 연구는 학생과 교사가 동일한 아키텍처를 가지고 학습 중에 증류를 사용하는 공동 증류 [1] 와도 관련이 있습니다 . 그러나 공동 증류에서 교사 모델은 학생 모델로부터 증류를 수행하는 반면, 본 연구에서는 학생 모델의 평균값으로 교사 모델을 업데이트합니다.

## 3. 접근 방식

### 3.1. 지식 증류를 활용한 SSL

본 연구에서 사용된 프레임워크인 DINO는 최근의 자기지도 학습 접근법 [10, 16, 12, 30, 33]과 동일한 전체 구조를 공유합니다. 그러나 본 방법은 지식 증류 [35] 와도 유사점을 공유하며 , 이러한 관점에서 이를 제시합니다. 그림 2 에서 DINO를 설명하고 알고리즘 1에서 의사 코드 구현을 제안합니다 .

지식 증류는 학생 네트워크 gθs가 주어진 교사 네트워크 gθt 의 출력과 일치하도록 훈련하는 학습 패러다임이며 , 여기서 θs 와 θt 는 각각 매개변수로 정의됩니다.

입력 이미지 x가 주어졌을 때, 두 네트워크 모두 K 차원 에 대한 확률 분포 인 Ps 와 Pt를 출력합니다. 확률 P 는 네트워크 g 의 출력을 소프트맥스 함수로 정규화하여 얻습니다. 더 정확하게는,

$$P_s(x)^{(i)} = \frac{\exp(g_{\theta_s}(x)^{(i)}/\tau_s)}{\sum_{k=1}^{K} \exp(g_{\theta_s}(x)^{(k)}/\tau_s)}, \quad (1)$$

τs > 0 인 경우 , 이는 온도 매개변수로서 제어됩니다.

**알고리즘 1 DINO PyTorch 의사 코드 (다중 크롭 기능 없음).**

```
# gs, gt: 학생 및 교사 네트워크 # C: 중심(K) # tps, tpt: 학생 및 교사 온도 # l,
m: 네트워크 및 중심 모멘텀 비
율 gt.params = gs.params for x in loader: # n개의 샘플이 포함된 미니배치 x 로드 x1,
x2 = augment(x), augment(x) # 무작위 뷰

    s1, s2 = gs(x1), gs(x2) # 학생 출력 (n×K) t1, t2 = gt(x1), gt(x2) # 교사 출력 (n×K)

    손실 = H(t1, s2)/2 + H(t2, s1)/2 손실.backward() # 역전파

    # 학생, 교사 및 센터 업데이트 update(gs) # SGD gt.params = l*gt.params
    + (1-l)*gs.params C = m*C +
    (1-m)*cat([t1, t2]).mean(dim=0)

def H(t, s): t =
    t.detach() # 그라디언트 중지 s = softmax(s / tps, dim=1)
    t = softmax((t - C) / tpt, dim=1) # 중심화 + 선명화
    return - (t * log(s)).sum(dim=1).mean()
```

출력 분포의 날카로움과 유사한 공식이 온도 τt를 갖는 Pt 에도 적용됩니다 . 고정된 교사 네트워크 gθt 가 주어졌을 때, 학생 네트워크 θs 의 매개변수에 대한 교차 엔트로피 손실을 최소화함으로써 이러한 분포와 일치하도록 학습합니다 .

$$\min_{\theta_s} H(P_t(x), P_s(x)), \quad (2)$$

여기서 H(a, b) = a log b입니다.

다음에서는 식 (2)의 문제를 자기지도 학습에 적용하는 방법을 자세히 설명합니다. 먼저, 다중 크롭 전략 [10]을 사용하여 이미지의 다양한 왜곡된 뷰 또는 크롭을 구성합니다. 더 정확하게는, 주어진 이미지로부터 다양한 뷰 집합 V를 생성합니다. 이 집합에는 두 개의 전역 뷰 x 와 해상도가 더 낮은 여러 개의 지역 뷰가 포함됩니다 . 모든 크롭은 학생 학습자를 통과하는 반면 , 전역 뷰만 교사 학습자를 통과하므로 "지역-전역" 대응을 촉진합니다. 손실을 최소화합니다.

$$\min_{\theta_s} \sum_{x \in \{x^g_1, x^g_2\}} \sum_{x \in V, x \neq x} H(P_t(x), P_s(x)). \quad (3)$$

이 손실 함수는 일반적이며 뷰 개수에 제한 없이, 심지어 2개만 사용하더라도 적용 가능합니다. 하지만 본 논문에서는 원본 이미지 의 넓은 영역 (예: 50% 이상)을 커버하는 해상도 2242 의 전역 뷰 2개와 원본 이미지의 작은 영역(예: 50% 미만)만을 커버하는 해상도 962 의 지역 뷰 여러 개를 사용하는 표준 다중 크롭 설정을 따릅니다. 별도의 언급이 없는 한, 이 설정을 DINO의 기본 파라미터 설정이라고 합니다 .

두 네트워크는 서로 다른 매개변수 집합 θs 및 θt를 갖는 동일한 아키텍처 g를 공유합니다 . 우리는 확률적 경사 하강법을 사용하여 식 (3) 을 최소화함으로써 매개변수 θs를 학습합니다.

Machine Translated by Google

표 1: 네트워크 구성. "블록"은 블록 수를 나타냅니다.
트랜스포머 블록에서 "dim"은 채널 크기이고 "heads"는...
멀티헤드 어텐션의 헤드 수입니다. "#토큰"은 길이를 나타냅니다.
2242 해상도 입력을 고려할 때 토큰 시퀀스의 "#
"params"는 전체 매개변수 개수(단, 를 제외한 개수)입니다.
프로젝션 헤드)이며, "im/s"는 NVIDIA에서의 추론 시간입니다.
V100 GPU, 포워드당 128개 샘플.

| 모델 | 블록 딤 헤드 #토큰 #매개변수 im/s |
|---|---|
| ResNet-50 – 2048 – | – 23M 1237 |
| ViT-S/16 12 384 6 | 197 21M 1007 |
| ViT-S/8 12 384 6 | 785 21M 180 |
| ViT-B/16 12 768 12 | 197 85M 312 |
| ViT-B/8 12 768 12 | 785 85M 63 |

교사 네트워크. 지식 정제와는 달리, 우리는
사전에 교사가 정해져 있지 않으므로 , 우리는 교사를 직접 구성합니다.
학생 네트워크의 이전 반복으로부터 얻은 결과입니다. 5.2 절에서는 교사에 대
한 다양한 업데이트 규칙을 연구하고 다음과 같은 결과를 보여줍니다.
우리 프레임워크에서는 교사 네트워크를 일정 기간 동안 고정하는 것이 놀라울 정도로 효
과적이며, 동시에 학생 네트워크를 복제하는 것도 가능하다는 것을 보여줍니다.
교사에 대한 가중치는 수렴하지 않습니다. 특히 , 지수 이동 평균(EMA)을
사용하면 다음과 같은 결과가 나타납니다.
학생 가중치, 즉 모멘텀 인코더 [33]는 특히 우리 프레임워크에 적합합니
다. 업데이트 규칙은 다음과 같습니다.

$\theta_t \leftarrow \lambda\theta_t + (1 \quad \lambda)\theta_s$, $\lambda$ 는 코사인 일정을 따릅니다.

훈련 중 0.996 에서 1 까지 변화합니다 [30]. 원래 모멘텀 인코더는 큐
를 대체하기 위해 도입되었습니다.
대조 학습에서 [33]. 그러나 우리의 프레임워크에서는
대기열도 없고 대조적인 요소도 없기 때문에 역할이 다릅니다.
손실이며, 평균적인 교사의 역할에 더 가까울 수 있습니다.
자기 훈련에서 [65]. 실제로, 우리는 이 교사가 Polyak-Ruppert와 유사
한 형태의 모델 앙상블을 수행하는 것을 관찰했습니다.
지수적 감소를 이용한 평균화 [51, 59]. 모델 앙상블에 폴리악-루퍼트 평균
화를 사용하는 것은 모델 성능을 향상시키는 표준적인 방법 입니다 [38].
우리는 관찰했습니다 .
이 선생님의 실적이 학생보다 더 좋다는 것
훈련 전반에 걸쳐 지도하며, 따라서 훈련 과정을 이끌어갑니다.
학생들에게 더 높은 품질의 목표 기능을 제공함으로써.
동적 현상은 이전 연구에서는 관찰되지 않았습니다 [30, 58].

네트워크 아키텍처. 신경망 g 는 다음과 같이 구성됩니다 .
백본 f (ViT [19] 또는 ResNet [34])와 투영 헤드 h의 특징: g = h ◦ f.
다운스트림에서 사용되는 특징
작업은 출력 의 핵심입니다 . 프로젝션 헤드는 은닉층을 가진 3층 다층 퍼셉
트론(MLP)으로 구성됩니다.
차원 2048 에 이어 2개의 정규화와 가중치가 적용 됩니다.
K 차원 의 정규화된 완전 연결 계층 [61]
이는 SwAV [10]의 디자인과 유사합니다 . 우리는
다른 프로젝션 헤드를 테스트해 본 결과, 이 특정 디자인이 DINO에 가장 적합
한 것으로 나타났습니다(부록 C). 우리는 다른 방식을 사용하지 않습니다.
예측기 [30, 16], 결과적으로 정확히 동일한 아키텍처가 생성됩니다.

학생 네트워크와 교사 네트워크 모두에 관심이 있습니다. 특히, 우리는 다음과 같은 점에 주목합니다.
참고로, 일반적인 컨볼루션 신경망과는 달리 ViT 아키텍처는 다음과 같은 특징을 갖지 않습니다.
기본적으로 배치 정규화(BN)를 사용합니다. 따라서,
ViT에 DINO를 적용할 때 BN도 사용하지 않습니다.
프로젝션 헤드를 사용하여 시스템을 완전히 BN-free로 만듭니다.

붕괴 방지. 여러 자기 지도 학습 방법은 붕괴를 방지하기 위해 사용하는 방
식에 따라 차이가 있는데, 이는 다음과 같은 방법을 통해 이루어집니다.
대조 손실 [73], 클러스터링 제약 조건 [8, 10], 예측기 [ 30] 또는 배치 정규화 [30,
58]. 우리의 프레임 워크는 다중 정규화 [10] 를 통해 안정화될 수 있습니다 .

중심 맞추기와 날카롭게 하는 작업만으로도 작동할 수 있습니다.
모멘텀 교사 출력은 모델 붕괴를 방지하기 위한 것입니다.
섹션 5.3에서 실험적으로 보여준 바와 같이, 중심 맞춤은 다음을 방지합니다.
한 차원이 지배적이지만 붕괴를 조장합니다.
균일 분포를 유도하는 반면, 선명화는 정반대의 효과를 냅니다. 두 작업을
모두 적용하면 그 효과의 균형을 맞출 수 있습니다.
이는 모멘텀 교사가 있는 상황에서 붕괴를 피하기에 충분합니다 . 붕괴 거
래를 피하기 위해 이 방법을 선택합니다.
배치에 대한 의존도를 낮추는 안정성: 중심화
운영은 1차 배치 통계에만 의존합니다.
이는 교사에 대한 편향 항 c를 추가하는 것으로 해석될 수 있습니다.
$g_t(x) \leftarrow g_t(x) + c$. 중심 c 는 지수 이동 평균 으로 업데이트되므로 이 접근 방식이 작동
할 수 있습니다.
섹션 5.5 에 나와 있는 것처럼 다양한 배치 크기에 걸쳐 우수한 성능을 보입니다 .

$$c \leftarrow mc + (1 \quad m) \quad \frac{1}{\text{비}} \sum_{i=1}^{\text{비}} g_{\theta_t}(x_i), \tag{4}$$

여기서 m > 0 은 속도 매개변수이고 B 는 배치 크기입니다.
출력 선명도는 낮은 값을 사용하여 얻을 수 있습니다.
교사 소프트맥스 정규화에서 온도 $\tau_t$ .

## 3.2. 실행 및 평가 프로토콜

이 섹션에서는 구현 세부 정보를 제공합니다.
DINO를 사용하여 훈련하고 사용된 평가 프로토콜을 제시하십시오.
우리 실험에서.

비전 트랜스포머. 작동 원리를 간략하게 설명합니다.
Vision Transformer(ViT) [19, 70] 의 경우를 참조합니다.
변압기에 대한 자세한 내용은 Vaswani et al. [70] 을 참조하십시오.
Dosovitskiy et al. [19] 은 이미지에 대한 적응성을 보여주었습니다. 우리
는 DeiT [69] 에서 사용된 구현을 따릅니다 . 요약하면 다음과 같습니다.
본 논문에서 사용된 다양한 네트워크의 구성은 표 1에 나와 있습니다. ViT
아키텍처는 그리드를 입력으로 받습니다.
겹치지 않는 연속적인 해상도의 이미지 패치
N × N. 본 논문에서는 일반적으로 N = 16 (“/16”)을 사용합니다.
또는 N = 8 (“/8”). 그런 다음 패치는 다음을 통과합니다.
선형 레이어를 사용하여 임베딩 세트를 생성합니다. 여기에 추가 레이어를 더합니다.
학습 가능한 토큰을 시퀀스 [18, 19]에 추가합니다. 이것의 역할은 다음과 같습니다.
토큰은 전체 시퀀스에서 정보를 집계하는 데 사용됩니다.
그리고 우리는 출력단에 프로젝션 헤드 h를 부착합니다. 우리는 참조합니다.
일관성을 유지하기 위해 이 토큰을 클래스 토큰 [CLS] 로 지정합니다.

Machine Translated by Google

이전 연구[18, 19, 69]에서 비록 첨부되지는 않았지만
저희의 경우 어떤 레이블이나 감독도 없습니다. 패치 세트
토큰과 [CLS] 토큰은 표준 트랜스포머에 입력됩니다.
"사전 정규화" 레이어 정규화를 사용하는 네트워크 [11, 39].
Transformer는 자기주의적 주의와 피드포워드의 연속체입니다.
레이어는 스킵 연결과 병렬로 구성됩니다. 자기 주의
레이어는 다음을 살펴봄으로써 토큰 표현을 업데이트합니다.
주의 메커니즘을 사용하는 다른 토큰 표현 [4].

구현 세부 사항. 우리는 모델을 사전 학습합니다.
레이블이 없는 ImageNet 데이터셋 [60] 을 사용하여 학습합니다.
adamw 최적화기 [44] 와 1024 의 배치 크기를 사용 하여 분산 처리합니다 .
ViT-S/16을 사용할 때 16개 이상의 GPU를 활용합니다. 학습률은 다음과 같습니다.
처음 10 개 에포크 동안 선형적으로 증가하여 기준값에 도달 했습니다.
다음 선형 스케일링 규칙 [29]에 따라 결정된 값:
lr = 0.0005 배치 크기/256. 이 워밍업 후에 감쇠가 시작됩니다.
코사인 스케줄을 사용한 학습률 [43]. 가중치
감쇠 또한 0.04 에서 0.4 까지 코사인 함수 형태를 따른다 .
선형 예열을 사용하는 동안 온도 τs는 0.1 로 설정됩니다 .
처음 30 에포크 동안 τt 는 0.04 에서 0.07 사이였습니다 .
BYOL [30] 의 데이터 증강 (색상 떨림,
가우시안 블러 및 솔라리제이션) 및 멀티 크롭 [10]
위치 임베딩을 조정하기 위한 3차 보간법
척도 [19, 69]. 우리의 결과를 재현하기 위한 코드와 모델
결과는 공개적으로 확인할 수 있습니다.

평가 프로토콜. 자기지도 학습을 위한 표준 프로토콜은 선형 분류기를 학습
하는 것입니다.
고정된 특징 [82, 33] 에 대해 또는 특징을 미세 조정하기 위해
하위 작업에 적용됩니다. 선형 평가의 경우, 다음과 같이 적용합니다.
무작위 크기 조정 자르기 및 수평 뒤집기 증강
훈련 중에 중앙 작물에 대한 정확도를 보고합니다.
미세 조정 평가를 위해 다음과 같이 네트워크를 초기화합니다.
훈련 전에 설정된 무게를 활용하고 훈련 중에 이를 조정합니다.
하지만 두 평가 모두 하이퍼파라미터에 민감합니다.
그리고 실행 간 정확도에 큰 편차가 있음을 관찰했습니다.
예를 들어 학습률을 변경할 때처럼 말입니다. 따라서 우리도 마찬가지입니다.
간단한 가중치를 사용하여 특징의 품질을 평가합니다.
[73] 과 같이 최근접 이웃 분류기 (k-NN)를 사용합니다. 우리는 이를 고정합니다 .
모델의 특징을 계산하고 저장하기 위해 사전 학습된 모델
하위 작업의 훈련 데이터. 가장 가까운 이웃
분류기는 이미지의 특징을 k 와 일치시킵니다.
레이블에 투표하는 가장 가까운 저장된 특징을 찾습니다.
서로 다른 수의 최근접 이웃을 사용하여 다음을 찾습니다.
20 NN이 대부분의 경우에서 가장 효과적인 것으로 꾸준히 나타나고 있습니다.
실행됩니다. 이 평가 프로토콜은 다른 어떤 것도 요구하지 않습니다.
하이퍼파라미터 튜닝이나 데이터 증강도 아니며,
다운스트림 데이터셋에 대해 단 한 번의 패스만으로 실행되므로,
기능 평가를 간소화합니다.

표 2: ImageNet에서의 선형 및 k-NN 분류. 본 연구에서는 다음과 같이 보고합니다.
검증 데이터 셋에서 선형 및 k-NN 평가에 대한 최상위 정확도
다양한 자기지도 학습 방법을 위한 ImageNet 데이터셋을 분석합니다. 본 연구에서는 특히 다음 사항에 초점을 맞춥니다.
ResNet-50 및 ViT-small 아키텍처에서뿐만 아니라 최상의 결과도 보고합니다.
다양한 아키텍처에서 얻은 결과는 저희가 직접 실행합니다.
공식적으로 공개된 가중치를 사용한 모델에 대한 k-NN 평가.
처리량(im/s)은 128GHz NVIDIA V100 GPU에서 계산됩니다.
순방향당 샘플 수. 매개변수(M)는 특징 추출기의 것입니다.

| 방법 | 아치. | 매개변수 | im/s | 선형 | k-NN |
|---|---|---|---|---|---|
| 감독된 | RN50 | 23 | 1237 | 79.3 | 79.3 |
| SCLR [12] | RN50 | 23 | 1237 | 69.1 | 60.7 |
| MoCov2 [15] | RN50 | 23 | 1237 | 71.1 | 61.9 |
| InfoMin [67] | RN50 | 23 | 1237 | 73.0 | 65.3 |
| BarlowT [81] | RN50 | 23 | 1237 | 73.2 | 66.0 |
| OBoW [27] | RN50 | 23 | 1237 | 73.8 | 61.9 |
| BYOL [30] | RN50 | 23 | 1237 | 74.4 | 64.8 |
| DCv2 [10] | RN50 | 23 | 1237 | 75.2 | 67.1 |
| SwaAV [10] | RN50 | 23 | 1237 | 75.3 | 65.7 |
| 디노 | RN50 | 23 | 1237 | 75.3 | 67.5 |
| 감독된 | 비트-스 | 21 | 1007 | 79.8 | 79.8 |
| BYOL [30] | 비트-스 | 21 | 1007 | 71.4 | 66.6 |
| MoCov2 [15] | ViT-S | 21 | 1007 | 72.7 | 64.4 |
| SwaAV [10] | 비트-스 | 21 | 1007 | 73.5 | 66.3 |
| 디노 | 비트-스 | 21 | 1007 | 77.0 | 74.5 |
| 아키텍처 간 비교 | | | | | |
| SCLR [12] | RN50w4 | 375 | 117 | 76.8 | 69.3 |
| SwaAV [10] | RN50w2 | 93 | 384 | 77.3 | 67.3 |
| BYOL [30] | RN50w2 | 93 | 384 | 77.4 | – |
| 디노 | 비타민 B/16 | 85 | 312 | 78.2 | 76.1 |
| SwaAV [10] | RN50w5 | 586 | 76 | 78.5 | 67.1 |
| BYOL [30] | RN50w4 | 375 | 117 | 78.6 | – |
| BYOL [30] | RN200w2 | 250 | 123 | 79.6 | 73.9 |
| 디노 | ViT-S/8 | 21 | 180 | 79.7 | 78.3 |
| SCLRv2 [13] | RN152w3+SK | 794 | 46 | 79.8 | 73.1 |
| 디노 | 비타민 B/8 | 85 | 63 | 80.1 | 77.4 |

## 4. 주요 결과

먼저 본 연구에서 사용된 DINO 프레임워크를 검증합니다.
ImageNet에서 표준 자기지도 벤치마크를 사용했습니다.
다음으로, 결과로 얻어진 특징들의 속성을 연구합니다.
검색, 객체 발견 및 전이 학습.

### 4.1. ImageNet의 SSL 프레임워크와의 비교

우리는 두 가지 다른 상황을 고려합니다: 비교 대상과의 비교
동일한 아키텍처와 다양한 아키텍처 간에도 적용 가능합니다.

동일한 아키텍처와 비교했을 때, 상단 패널에서
표 2에서 DINO를 동일한 아키텍처를 가진 다른 자기지도 학습 방법
(ResNet-50 [34] 또는 기타 방법) 과 비교합니다.
ViT-small(DeiT-S [69] 의 설계를 따름 ).
ViT-S를 선택한 이유는 ResNet-50과의 유사성 때문입니다.
여러 축을 따라: 매개변수 개수(2100만 대 2300만),

Machine Translated by Google

표 3: 이미지 검색. 검색 성능을 비교합니다.
감독 하에 또는 DINO를 사용하여 사전 훈련된 기성 기능
ImageNet 및 Google Landmarks v2(GLDv2) 데이터셋을 사용했습니다.
재방문한 옥스퍼드와 파리의 mAP 보고서. DINO를 이용한 사전 학습
랜드마크 데이터셋에서 특히 뛰어난 성능을 보입니다. 참고로, 저희는
또한 기성 기능을 사용한 최상의 검색 방법을 보고합니다 [57].

| | | | ROx | RPar |
|---|---|---|---|---|
| 사전 훈련 아키텍처. | | MHMH 사전 학습 | | |
| Sup. [57] RN101+R-MAC ImNet 49.8 18.5 74.0 52.1 | | | | |
| 한모금. | ViT-S/16 | ImNet 33.5 8.9 63.0 37.2 | | |
| 디노 레스넷-50 | | ImNet 35.4 11.1 55.9 27.5 | | |
| 디노 비트-S/16 | | ImNet 41.8 13.7 63.1 34.4 | | |
| 디노 비트-S/16 | | GLDv2 51.5 24.3 75.3 51.6 | | |

[69] 의 훈련 절차를 사용한 ImageNet에서의 처리량(1237/초 VS 1007
im/초) 및 지도 성능.
(79.3% 대 79.8%). 부록 D에서 ViT-S의 변형을 살펴봅니다. 먼저 DINO가 동등
한 성능을 보이는 것을 확인했습니다.
ResNet-50의 최첨단 성능을 활용하여 DINO의 유효성을 검증합니다.
표준 설정에서는 잘 작동합니다. ViT로 전환하면
아키텍처 측면에서 DINO는 BYOL, MoCov2 및 SwAV보다 우수한 성능을 보입니다.
선형 분류에서는 +3.5%, k-NN 에서는 +7.9% 향상되었습니다.
평가 결과, 더욱 놀라운 것은 단순 k -NN 분류기의 성능이 선형 분류기의 성능과
거의 동등하다는 점입니다.
(74.5% 대 77.0%). 이 특성은 ViT 아키텍처와 함께 DINO를 사용할 때만
나타나며, 그렇지 않을 때는 나타나지 않습니다.
기존의 다른 자기지도 학습 방식이나 ResNet-50을 사용한 방식과 비교했을 때도 마찬가지입니다.

아키텍처 간 비교. 하단 패널 참조
표 2에서는 각 그룹에서 얻은 최상의 성능을 비교합니다.
건축 구조. 이 설정의 관심사는 비교하는 것이 아닙니다.
방법을 직접적으로 사용하는 것이 아니라, ViT 훈련을 받은 시스템의 한계를 평가하기 위해서입니다.
더 큰 아키텍처로 이동할 때 DINO를 사용합니다.
DINO를 사용하여 더 큰 ViT를 훈련시키면 성능이 향상됩니다.
패치 크기를 줄이는 것("/8" 변형)은 더 큰 이점을 제공합니다.
성능에 미치는 영향. 패치 크기를 줄이면 이러한 효과가 나타납니다.
매개변수를 추가하지 않아도 여전히 상당한 감소 효과가 나타납니다.
실행 시간이 길어지고 메모리 사용량이 증가합니다. 그럼에도 불구하고,
DINO로 학습된 8×8 패치를 사용하는 기본 ViT는 다음과 같은 결과를 얻습니다.
선형 분류에서 80.1%의 최고점수(top-1)를, k-NN 에서는 77.4%의 최고점수(top-1)를 기록했습니다.
매개변수 개수 는 10배 적고 실행 시간은 1.4배 빠른 분류기
이전 기술 수준보다 [13].

## 4.2. SSL로 학습된 ViT의 속성

우리는 DINO 특징의 속성을 다음과 같은 관점에서 평가합니다.
최근접 이웃 검색, 객체에 대한 정보 유지
위치 및 하위 작업으로의 이전 가능성.

표 4: 복제본 탐지. 복제본 탐지 시 mAP 성능을 보고합니다 .
Copydays의 "강력한" 부분집합 [21]에 대한 탐지. 참고로, 우리는
또한 훈련된 다중 입자 모델[5] 의 성능을 보고합니다 .
특히 특정 객체 검색을 위해.

| 방법 | 아치. | 어둑한. | 해상도 mAP | |
|---|---|---|---|---|
| 다립 [5] | ResNet-50 2048 75.1 | | 2242 | |
| 다립 [5] | ResNet-50 2048 최대 측면 800 82.5 | | | |
| 감독됨 [69] ViT-B/16 | | 1536 | 2242 | 76.4 |
| 디노 | 비타민 B/16 | 1536 | 2242 | 81.7 |
| 디노 | 비타민 B/8 | 1536 | 3202 | 85.5 |

### 4.2.1 DINO ViT를 이용한 최근접 이웃 검색

ImageNet 분류 결과는 다음과 같은 사실을 드러냈습니다.
최근접 이웃에 의존하는 작업에 대한 우리 기능의 잠재력
검색. 이번 실험에서는 검색 결과를 더욱 공고히 했습니다.
랜드마크 검색 및 복제 감지 작업에서 이러한 결과가 나타났습니다.

이미지 검색. 우리는 재검토된 [53] 옥스퍼드를 고려합니다.
그리고 파리 이미지 검색 데이터셋 [50]이 있습니다. 이 데이터셋에는 쿼리/데이터베이스 쌍
에 따라 난이도가 점진적으로 증가하는 3개의 서로 다른 분할이 포함되어 있습니다.
중간 크기에 대한 평균 정밀도(mAP)를 보고합니다.
(M) 및 (H) 난이도 분할. 표 3 에서는 (M)과 (H) 난이도 분할을 통해 얻
은 다양한 기성 기능의 성능을 비교합니다.
감독 또는 DINO 교육. 우리는 기능을 고정하고
k-NN을 검색에 직접 적용합니다 . DINO를 관찰했습니다.
특징 추출 방식은 레이블이 지정된 ImageNet 데이터셋으로 학습된 방식보다 우수한 성능을 보입니다.
SSL 방식의 장점은 다음과 같습니다.
DINO는 어떠한 형태의 어노테이션도 필요 없이 모든 데이터셋에서 학습할 수 있습니다 .
저희는 Google의 120만 개 클린 데이터셋을 사용하여 DINO를 학습시켰습니다.
Landmarks v2 (GLDv2) [72]는 검색 목적으로 설계된 랜드마크 데이터셋입니
다 . DINO ViT 특징은 다음을 기반으로 학습되었습니다.
GLDv2는 매우 훌륭하며 기성품 설명자를 기반으로 하는 이전에 발표된 방
법 보다 성능이 뛰어납니다 [68, 57].

복제 탐지. 또한 ViT의 성능도 평가합니다.
DINO를 사용하여 복사 탐지 작업을 수행했습니다. 본 논문에서는 다음 결과를 보고합니다.
INRIA의 "강력한" 하위 집합에 대한 평균 정밀도
Copydays 데이터셋 [21]. 작업은 이미지를 인식하는 것입니다.
흐릿함, 삽입, 인쇄 및 스캔으로 인해 왜곡된 이미지입니다.
등. 이전 연구 [5]를 따라 10,000개의 방해 이미지를 추가했습니다.
YFCC100M 데이터셋 [66] 에서 무작위로 샘플링 되었습니다 .
코사인 유사도를 사용하여 직접 복제본 탐지를 수행합니다.
사전 학습된 네트워크에서 얻은 특징들입니다.
출력 [CLS] 토큰 의 연결로 얻어집니다.
그리고 GeM 풀링된 [54] 출력 패치 토큰의 결과입니다.
ViT-B에 대한 1536d 디스크립터에서. [5]에 따라, 우리는 적용합니다.
얼굴 윤곽이 하얘집니다. 우리는 이러한 변화를 배우게 됩니다.
YFCC100M에서 가져온 추가 20,000개의 무작위 이미지, 고유한 특징
방해 요소로부터. 표 4 는 ViT가 훈련된 결과를 보여줍니다.
DINO는 복제본 탐지 분야에서 매우 경쟁력이 있습니다.

Machine Translated by Google

표 5: DAVIS 2017 비디오 객체 분할. 우리는 평가합니다.
비디오 인스턴스 추적에서 고정된 특징의 품질에 대해 보고합니다.
평균 영역 유사도 Jm 및 평균 윤곽 기반 정확도 Fm.
본 연구에서는 기존의 자기지도 학습 방법 및 지도 학습 방법과 비교합니다.
ViT-S/8은 ImageNet 데이터셋으로 학습되었습니다. 이미지 해상도는 480p입니다.

| 방법 | 데이터 | 아치. | (J &F)m | Jm Fm |
|---|---|---|---|---|
| 감독된 | | | | |
| 이미지넷 INet | | ViT-S/8 | 66.0 | 63.9 68.1 |
| STM [48] | 아이/디/이 | RN50 | 81.8 | 79.2 84.3 |
| 자기주도적 | | | | |
| CT [71] | 브이로그 RN50 | | 48.7 | 46.4 50.0 |
| MAST [40] YT-VOS RN18 | | | 65.5 | 63.3 67.6 |
| STC [37] | 키네틱스 RN18 | | 67.6 | 64.8 70.2 |
| 디노 | INet | ViT-S/16 | 61.8 | 60.2 63.4 |
| 디노 | INet | 비타민 B/16 | 62.3 | 60.7 63.9 |
| 디노 | INet | ViT-S/8 | 69.9 | 66.6 73.1 |
| 디노 | INet | 비타민 B/8 | 71.4 | 67.9 74.9 |

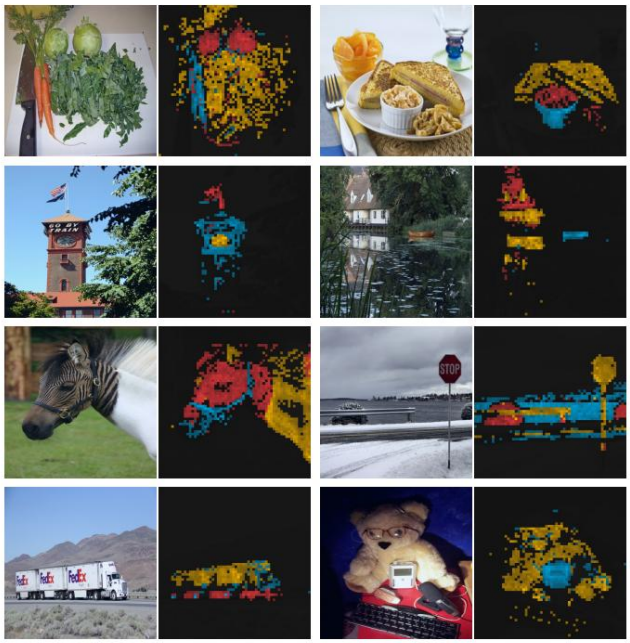


그림 3: 여러 헤드에서 얻은 어텐션 맵. 우리는 다음을 고려합니다 .
DINO로 훈련된 ViT-S/8의 마지막 레이어의 헤드
[CLS] 토큰 쿼리 에 대한 셀프 어텐션을 표시합니다 . 다른 헤드,
다양한 색상으로 구체화되고, 서로 다른 위치에 초점을 맞춥니다.
서로 다른 객체 또는 부분을 나타냅니다(더 많은 예는 부록 참조).

#### 4.2.2 장면의 의미론적 레이아웃 파악하기

그림 1에서 정성적으로 나타낸 바와 같이, 우리의 자기 주의 맵은
이미지 분할에 대한 정보를 포함합니다.
본 연구에서는 표준 벤치마크를 사용하여 이 속성을 측정합니다.
또한 생성된 마스크의 품질을 직접 조사함으로써
이러한 관심도 지도에서.
비디오 인스턴스 분할. 표 5에서 우리는 다음을 평가합니다.
DAVIS-2017 비디오 인스턴스 분할 벤치 마크 [52]에서 출력 패치 토큰을
사용합니다. Jabri et al. [37] 의 실험 프로토콜을 따르고 연속 프레임 간
의 최근접 이웃을 사용하여 장면을 분할합니다. 따라서 학습은 수행하지 않
습니다.
기능 외에 다른 모델을 추가하거나 가중치를 미세 조정할 필요가 없습니다.
해당 작업에 대해. 표 5 에서 볼 수 있듯이, 우리의 결과 는 비록 우리의 결과가 비록...
훈련 목표도 아니고, 저희 아키텍처도 고밀도 환경에 맞춰 설계되지 않았습니다.
이러한 작업에서 성능은 해당 벤치마크에서 경쟁력이 있습니다.
네트워크가 미세 조정되지 않았기 때문에 모델의 출력은
공간 정보를 어느 정도 유지했을 것입니다. 마지막으로,
이러한 밀집된 인식 작업에서 작은 패치를 사용한 변형
(“/8”)은 ViT-B의 경우 훨씬 더 나은 성능을 보입니다(+9.1%(J &F)m ).

자기 주의 맵 탐색. 그림 3에서 우리는 다음을 보여줍니다.
서로 다른 헤드가 하나의 의미 영역의 서로 다른 부분을 담당할 수 있습니다.
이미지, 심지어 가려져 있을 때에도 (세 번째의 덤불들)
(줄) 또는 작은 (두 번째 줄의 깃발). 시각화는 다음과 같습니다.
480p 이미지 로 얻은 결과 3601개의 시퀀스가 생성되었습니다.
ViT-S/8용 토큰. 그림 4에서 우리는 지도 학습을 보여줍니다.
ViT는 주변이 어수선한 환경에서는 사물에 집중하는 데 어려움을 겪습니다.
정성적 및 정량적 측면 모두에서 Jaccard 값을 보고합니다.
실제 데이터와 분할 마스크 간의 유사성
셀프 어텐션 맵을 임계값 처리하여 60%를 유지함으로써 얻은 결과입니다.
질량의 일부입니다. 자기 주의 맵이 매끄럽다는 점에 유의하십시오.
마스크를 생산하도록 최적화되어 있지 않습니다. 그럼에도 불구하고 우리는 볼 수 있습니다.
지도 학습 모델과 DINO 모델 간의 명확한 차이점
자카드 유사도 측면에서 상당한 차이가 있습니다. 참고
자기지도 학습 컨볼루션 신경망은 또한 다음과 같은 정보를 포함하고 있다는 것
분할이지만 이를 추출하려면 특별한 방법이 필요합니다.
그들의 무게로부터 [31].

#### 4.2.3 하위 작업에 대한 전이 학습

표 6에서는 사전 학습된 특징들의 품질을 평가합니다.
DINO를 사용하여 다양한 다운스트림 작업을 수행합니다. 우리는 이를 비교합니다.
ImageNet에서 지도 학습을 통해 동일한 아키텍처에서 얻은 특징을 사용합니
다 . Touvron et al. [69] 에서 사용된 프로토콜을 따르고 각 다운스트림에서
특징을 미세 조정합니다.
과제. ViT 아키텍처의 경우 자기지도 학습이 다음과 같다는 것을 관찰했습니다.
사전 학습된 특징은 감독 하에 학습된 특징보다 전이성이 더 우수하며, 이는 관
찰된 내용과 일치합니다.
컨볼루션 네트워크 [10, 33, 62]. 마지막으로, 자기 지도 학습
사전 학습은 ImageNet에서 결과를 크게 향상시킵니다(+1-2%).

## 5. DINO의 절제술 연구

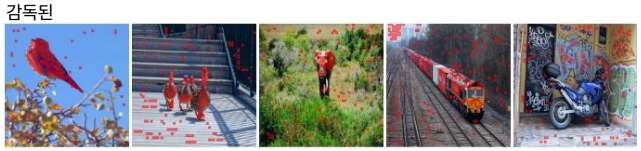
이 섹션에서는 DINO를 적용한 사례를 실증적으로 연구합니다.
ViT. 본 연구 전체에서 고려된 모델은 ViT-S입니다.
추가 연구는 부록을 참조하시기 바랍니다.

### 5.1. 각 구성 요소의 중요성

우리는 다양한 구성 요소를 추가했을 때의 영향을 보여줍니다.
저희 프레임워크로 학습된 ViT에 대한 자기지도 학습.

Machine Translated by Google

감독된



디노



| 무작위 감독 DINO | | | |
|---|---|---|---|
| ViT-S/16 | 22.0 | 27.3 | 45.9 |
| ViT-S/8 | 21.8 | 23.7 | 44.7 |

그림 4: 지도 학습과 DINO를 이용한 분할 결과 비교. 자기 주의 맵에 임계값을 적용하여 얻은 마스크를 시각화했습니다 .
질량의 60%를 유지합니다. 위쪽에는 결과 마스크를 보여줍니다.
ViT-S/8은 감독 및 DINO 교육을 받았습니다. 최고의 결과를 보여드리겠습니다.
두 모델 모두에 대한 헤드입니다. 아래 표는 실제 값과 이러한 마스크 간의 Jac-card 유사도를 비교합니다.
PASCAL VOC12 데이터셋의 검증 이미지.

표 6: 사전 학습된 모델을 미세 조정하여 전이 학습을 수행함
서로 다른 데이터셋을 사용했습니다. 최고 정확도(top-1 accuracy)를 보고합니다. 자기지도 학습 방식입니다.
DINO를 이용한 사전 학습은 지도 학습 기반 사전 학습보다 전이 성능이 더 좋습니다.

| | 시파르10 | 시파르100 | INat18 | INat19 | 꽃 | 자동차 | INet |
|---|---|---|---|---|---|---|---|
| ViT-S/16 | | | | | | | |
| Sup. [69] | 99.0 | DINO | 89.5 | 70.7 | 76.6 | 98.2 | 92.1 79.9 |
| | 99.0 | | 90.5 | 72.0 | 78.2 | 98.5 | 93.0 81.5 |
| 비타민 B/16 | | | | | | | |
| Sup. [69] | 99.0 | DINO | 90.8 | 73.2 | 77.7 | 98.4 | 92.1 81.8 |
| | 99.1 | | 91.7 | 72.6 | 78.6 | 98.8 | 93.0 82.8 |

표 7: 자기지도 ViT 사전 학습의 중요 구성 요소. 모델은 ViT-S/16을 사용하여 300 에포크 동안 학습되었습니다.
k-NN과 선형 모델 에 중요한 다양한 구성 요소를 연구합니다.
("린.") 평가. 다양한 변형에 대해 다음을 강조 표시합니다 .
기본 DINO 설정과의 차이점. 최적의 조합
이것은 다중 작물 증강 기능을 갖춘 모멘텀 인코더입니다.
교차 엔트로피 손실. 또한 BYOL [30]을 사용한 결과도 보고합니다.
MoCo-v2 [15] 및 SwAV [10].

| | 방법 | 엄마. | SK | MC | 손실 | 예측. | k-NN | 린. |
|---|---|---|---|---|---|---|---|---|
| 1 | 디노 | | | | CE | 72.8 | | 76.1 |
| 2 | | | | | CE | 0.1 | | 0.1 |
| 3 | | | | | CE | 72.2 | | 76.0 |
| 4 | | | | CE | | 67.9 | | 72.5 |
| 5 | | | | | MSE | 52.6 | | 62.4 |
| 6 | | | | | CE | | 71.8 | 75.6 |
| 7 | BYOL | | | MSE | | | 66.6 | 71.4 |
| 8 | MoCov2 | | INCE | 62.0 | 64.7 | | | 71.6 |
| 9 | 스와비브 | | | | CE | | | 71.8 |

SK: 싱크혼-크노프, MC: 다중 작물, Pred.: 예측 변수
CE: 교차 엔트로피, MSE: 평균 제곱 오차, INCE: InfoNCE

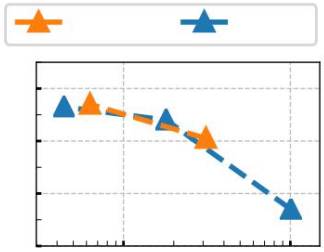


그림 5: 효과
패치 크기. k-NN 평가-
의 함수로서의 평가
다양한 입력 패치 크기
에 대한 처리량
ViT-B와 ViT-S를 함유하고 있습니다.
모델은 다음을 위해 훈련됩니다.
300 에포크.

표 7에서는 추가함에 따라 나타나는 다양한 모델 변형을 보고합니다.
또는 구성 요소를 제거합니다. 먼저, 없는 경우를 관찰해 보겠습니다.
운동량 측면에서 우리 프레임워크는 작동하지 않습니다( 2행).
예를 들어 SK와 같은 보다 고급 운영이 필요합니다.
붕괴를 피하세요(9행 ). 하지만 모멘텀을 사용하면
SK는 영향이 거의 없습니다( 3행). 또한 3 행을 비교해 보면
그리고 그림 9는 운동량 인코더의 중요성을 강조합니다.
성능 측면에서 그렇습니다. 둘째, 4 행 과 5행에서 다음과 같은 점을 확인할 수 있습니다.
DINO에서 다중 작물 훈련과 교차 엔트로피 손실은 다음과 같습니다.
좋은 특징을 얻기 위한 중요한 구성 요소들을 살펴보았습니다. 또한 학생 네트워크에 예측 변수를 추가해도 큰 차이가 없다는 것을 관찰했습니다.
BYOL에서 붕괴를 방지하는 것이 중요하기 때문에 영향(6행)이 있습니다
[ 16, 30]. 완전성을 위해 부록 B 에서 제안합니다.
본 절제술 연구의 확장 버전입니다.

패치 크기의 중요성. 그림 5에서 우리는 다음을 비교합니다.
ViT-S 모델을 학습시켜 얻은 k-NN 분류 성능

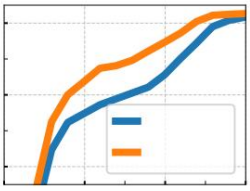
16×16, 8×8 , 5× 5 의 서로 다른 패치 크기를 사용했습니다.
또한 16×16 및 8×8 패치를 사용한 ViT-B와도 비교하십시오 . 모두
모델은 300 에포크 동안 학습되었습니다. 그 결과 다음과 같은 사실을 관찰했습니다.
크기를 줄일수록 성능이 크게 향상됩니다.
패치입니다. 성능이 크게 달라질 수 있다는 점이 흥미롭습니다.
추가 매개변수를 넣지 않고도 개선되었습니다. 하지만
더 작은 패치를 사용함으로써 얻는 성능 향상은 다음과 같습니다.
처리량 손실: 5×5 패치를 사용할 경우,
처리량은 8×8 패치의 180 im/s에 비해 44 im/s로 감소합니다.

## 5.2. 교사 네트워크 선택의 영향

이번 절제술에서는 서로 다른 교사를 사용하여 실험합니다.
DINO에서 네트워크의 역할을 이해하기 위해 모델을 비교합니다.
k-NN 프로토콜을 사용하여 300 에포크 동안 학습시켰습니다.

학생과 다른 유형의 교사를 양성합니다 .
그림 6(오른쪽)에서 우리는 구축을 위한 다양한 전략을 비교합니다.
학생의 이전 사례들을 고려했을 때, 교사는 그 외에도

Machine Translated by Google



| 선생님 | 탑1 |
|---|---|
| 학생용 사본 0.1 이전 반복 0.1 이전 에포크 66.6 모멘텀 72.8 | |

그림 6: k-NN 분류기를 사용한 ImageNet 검증에서의 Top-1 정확도 . (왼쪽) 훈련 중 모멘텀 티처와 스튜던트 의 성능 비교 . (오른쪽) 다양한 유형의 티처 네트워크 비교 . 모멘텀 인코더가 가장 우수한 성능을 보이지만 유일한 대안은 아니다.

모멘텀 교사. 먼저 이전 에포크의 학생 네트워크를 교사로 사용하는 것을 고려합니다. 이 전략은 메모리 뱅크 [73] 또는 클러스터링 하드 증류 [8, 2, 14] 의 한 형태로 사용되었습니다 . 둘째, 이전 반복의 학생 네트워크와 학생의 복사본을 교사로 사용하는 것을 고려합니다. 우리의 설정에서 최근 버전의 학생을 기반으로 하는 교사를 사용하는 것은 수렴하지 않습니다. 이 설정이 작동하려면 더 많은 정규화가 필요합니다.

흥미롭게도, 이전 에포크의 교사 모델을 사용하는 것이 성능 저하를 초래하지 않고, MoCo-v2나 BYOL 과 같은 기존 프레임워크와 경쟁력 있는 k-NN 평가 결과를 보여준다는 것을 확인했습니다 . 모멘텀 인코더를 사용하는 것이 이러한 단순 교사 모델보다 훨씬 우수한 성능을 제공하는 것은 분명하지만, 이 결과는 교사 모델에 대한 대안을 연구할 여지가 있음을 시사합니다 .

훈련 역학 분석. 모멘텀 교사가 본 프레임워크에서 잘 작동하는 이유를 더 자세히 이해하기 위해 그림 6의 왼쪽 패널에서 ViT 훈련 중 모멘텀 교사의 역학을 연구했습니다. 중요한 관찰 사항은 이 교사가 훈련 동안 학생보다 지속적으로 우수한 성능을 보인다는 것이며, ResNet-50으로 훈련할 때도 동일한 동작을 관찰할 수 있다는 것입니다(부록 D). 이러한 동작은 모멘텀을 사용하는 다른 프레임워크 [33, 30]나 이전 에포크에서 교사를 구축하는 경우에는 관찰 되지 않았습니다 .

우리는 DINO의 모멘텀 교사를 지수적으로 감소하는 폴리악-루퍼트 평균화[51, 59]의 한 형태로 해석하고자 합니다. 폴리악-루퍼트 평균화는 훈련 종료 시 네트워크 성능을 향상시키기 위해 모델 앙상블을 시뮬레이션하는데 자주 사용됩니다 [ 38 ] . 우리 의 방법은 훈련 중에 폴리악-루퍼트 평균화를 적용하여 우수한 성능을 가진 모델 앙상블을 지속적으로 구축하는 것으로 해석될 수 있습니다 . 이 모델 앙상블은 학생 네트워크의 훈련을 안내합니다 [65].

## 5.3. 붕괴 방지

우리는 붕괴를 방지하기 위해 중심화와 목표 명확화 의 상호보완적 역할을 연구합니다 . 여기에는 두 가지 형태가 있습니다.

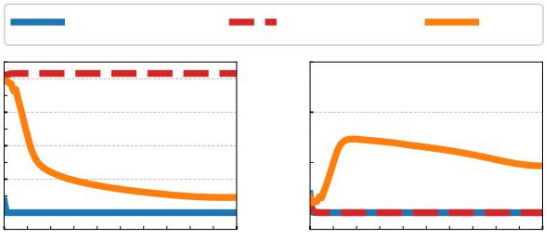


그림 7: 붕괴 연구. (왼쪽): 훈련 에포크에 따른 교사의 목표 엔트로피 변화; (오른쪽): 교사와 학생 출력 간의 KL 발산 변화 .

표 8: 시간 및 메모리 요구 사항. 8개의 GPU가 장착된 두 대의 컴퓨터에서 ViT-S/16 DINO 모델을 실행할 때의 총 실행 시간과 GPU당 최대 메모리 사용량("mem.")을 보여줍니다 . 각기 다른 수준의 연산 요구 사항을 갖는 여러 가지 멀티 크롭 변형에 대해 선형 평가를 사용한 ImageNet 최고 검증 정확도 (top-1 imageNet val acc)를 보고합니다 .

| | 100 에포크 | | 300 에포크 | | |
|---|---|---|---|---|---|
| 다작물 | 1위 | 시간 | 1위 | 시간 | 메모리 |
| 2×224 | 67.8 | 15.3h | 72.5 | 45.9h | 9.3G |
| 2×224 + 2×96 | 71.5 | 17.0h | 74.5 | 51.0h | 10.5G |
| 2×224 + 6×96 | 73.8 | 20.3h | 75.9 | 60.9h | 12.9G |
| 2×224 + 10×96 | 74.6 | 24.2h | 76.1 | 72.6h | 15.4G |

붕괴: 입력값에 관계없이 모델 출력값이 모든 차원에서 균일하거나 한 차원에 의해 지배되는 경우.
중심화는 지배적인 차원에 의해 유발되는 붕괴를 방지하지만 균일한 출력을 유도합니다. 선명화는 정반대의 효과를 유발합니다. 우리는 교차 엔트로피 H를 엔트로피 h와 쿨백-라이블러 발산("KL") DKL로 분해함으로써 이러한 상보성을 보여줍니다 .

$$H(P_t, P_s) = h(P_t) + D_{KL}(P_t|P_s). \quad (5)$$

KL 값이 0이면 출력이 일정하게 유지되어 모델이 붕괴되었음을 나타냅니다. 그림 7에서는 중심화 및 선명화 연산을 적용했을 때와 적용하지 않았을 때의 학습 과정 동안 엔트로피와 KL 값을 비교했습니다 . 두 연산 중 하나라도 누락되면 KL 값은 0으로 수렴하여 모델이 붕괴되었음을 알 수 있습니다. 그러나 엔트로피 h 는 중심화 연산이 없을 경우 0 으로, 선명화 연산이 없을 경우 -log(1/K) 로 수렴하는 등 서로 다른 값을 나타냅니다. 이는 두 연산이 각각 다른 형태 의 붕괴를 유발함을 보여줍니다. 두 연산을 모두 적용하면 이러한 효과의 균형을 맞출 수 있습니다 ( 부록 D의 선명화 매개변수 τt 연구 참조 ).

## 5.4. 계산 요구사항

표 8에서는 8개의 GPU를 탑재한 두 대의 컴퓨터에서 ViT-S/16 DINO 모델을 실행할 때 필요한 시간과 GPU 메모리 요구 사항을 자세히 보여줍니다 . 각기 다른 수준의 연산 요구 사항을 갖는 여러 가지 멀티 크롭 학습 변형에 대한 결과를 제시합니다. 표 8 에서 멀티 크롭을 사용하면 DINO 실행 시 정확도/실행 시간 균형이 개선됨을 확인할 수 있습니다.

Machine Translated by Google

예를 들어, 멀티 크롭(즉, 2×2242 ) 없이 46 시간 동안 학습했을 때 성능은 72.5% 인 반면, DINO는 2×2242+10×962 크롭 설정 에서 단 24 시간 만 에 74.6% 에 도달합니다 .

이는 2배의 시간 단축 과 함께 2% 의 성능 향상을 가져왔지만 , 메모리 사용량은 더 높습니다 (15.4G 대 9.3G). 2×2242 설정에서 멀티 크롭을 통한 성능 향상은 추가 학습으로는 따라잡을 수 없다는 것을 확인할 수 있으며 , 이는 "로컬 데이터를 글로벌 데이터로 변환하는" 증강 기법의 가치를 보여줍니다.

마지막으로, 학습 기간이 길어질수록 조회수를 늘려도 얻는 이득은 감소합니다(+0.2%, 6배에서 10배로 증가, 962 개 이미지 자르기).

전반적으로, Vision Transformers를 사용하여 DINO를 훈련하면 3일 동안 8-GPU 서버 두 대를 사용하여 76.1의 top-1 정확도를 달성합니다 . 이 결과는 유사한 크기의 컨볼루션 네트워크 기반의 최첨단 자기 지도 학습 시스템보다 우수 하며 계산 요구 사항을 크게 줄였습니다 [30, 10]. 저희 코드는 제한된 수의 GPU에서 자기 지도 ViT를 훈련하는 데 사용할 수 있습니다.

## 5.5. 소규모 그룹 훈련

| bs | 128 | 256 | 512 | 1024 |
|---|---|---|---|---|
| 탑1 | 57.9 | 59.1 | 59.6 | 59.9 |

표 9: 배치 효과

크기. 100개 모델에 대해 k-NN을 사용한 Top-1 결과 .

다중 작물 재배가 없는 시대.

표 9에서는 DINO로 얻은 특징에 대한 배치 크기의 영향을 연구합니다. 또한 부록 D 의 식 4 의 중심화 업데이트 규칙에 사용된 평활화 매개변수 m 의 영향도 연구합니다 . 학습률을 배치 크기에 따라 선형적으로 조정합니다 [29]: lr = 0.0005 batchsize/256.

표 9는 작은 배치 크기로도 높은 성능의 모델을 학습시킬 수 있음을 보여줍니다. 배치 크기 (bs = 128)를 사용한 결과는 기본 학습 설정 인 bs = 1024 보다 약간 낮 으며, 모멘텀 비율과 같은 하이퍼파라미터를 재조정해야 할 필요가 있습니다 . 배치 크기 128 을 사용한 실험은 GPU 1개에서만 실행되었음을 유의하십시오 .

배치 크기를 8로 설정하여 모델을 학습시킨 결과 , 50 에포크 후 35.2%의 효율을 달성했습니다. 이는 GPU당 이미지 하나가 겨우 들어갈 정도의 작은 크기에서도 대규모 모델을 학습시킬 수 있는 가능성을 보여줍니다 .

## 6. 결론

본 연구에서는 표준 ViT 모델의 자기 지도 사전 학습의 잠재력을 보여주었으며 , 이 설정을 위해 특별히 설계된 최고의 컨볼루션 신경망과 유사한 성능을 달성했습니다 . 또한 향후 응용 분야에서 활용될 수 있는 두 가지 특성을 발견했습니다. k-NN 분류 에서 특징의 품질은 ViT가 이미 유망한 결과를 보여주고 있는 이미지 검색 분야에서 잠재력을 가지고 있습니다 [22]. 특징에 포함된 장면 레이아웃 정보는 약지도 이미지 분할에도 도움이 될 수 있습니다. 그러나 본 논문의 주요 결과는 자기 지도 학습이 BERT와 유사한 모델을 개발하는 데 핵심적인 역할을 할 수 있다는 증거를 제시하는 것 입니다.

ViT. 향후에는 무작위로 선별되지 않은 이미지에 DINO를 사용하여 대규모 ViT 모델을 사전 학습하는 것이 시각적 특징의 한계를 확장 할 수 있는지 탐구할 계획입니다 [28].

승인. Mahmoud Assran, Matthijs Douze, Allan Jabri, Jure Zbontar, Alaaeldin El-Nouby, Y-Lan Boureau, Kaiming He, Thomas Lucas는 물론 Thoth 및 FAIR 팀의 도움, 지원 및 이 프로젝트에 대한 토론 에 감사드립니다 . Julien Mairal은 ERC 보조금 번호 714381(SOLARIS 프로젝트) 및 ANR 3IA MIAI@Grenoble Alpes(ANR-19-P3IA-0003)의 자금을 지원 받았습니다.

## 참고 자료

[1] Rohan Anil, Gabriel Pereyra, Alexandre Passos, Robert Ormandi , George E Dahl, and Geoffrey E Hinton. Large scale distributed neural network training through online distillation. arXiv preprint arXiv:1804.03235, 2018. 3

[2] Yuki Markus Asano, Christian Rupprecht, and Andrea Vedaldi. Self-labelling via simultaneous clustering and representation learning. In ICLR, 2020. 2, 9

[3] Mahmoud Assran, Nicolas Ballas, Lluis Castrejon 및 Michael Rabbat. 시각적 표현의 대조적 준지도 학습에서 페타플롭스 복구. preprint arXiv:2006.10803, 2020. 14 [4] Dzmitry Bahdanau, Kyunghyun Cho 및 Yoshua Bengio.

정렬과 번역을 공동으로 학습하는 신경 기계 번역. arXiv 사전 출판본: 1409.0473, 2014. 5 [5] Maxim Berman, Herve Jegou, Vedaldi Andrea, Iasonas Kokkinos 및 Matthijs Douze. MultiGrain: 클래스와 인스턴스를 위한 통합 이미지 임베딩. arXiv 사전 출판 본: 1902.05509, 2019. 6

[6] Piotr Bojanowski 및 Armand Joulin. 노이즈 예측을 통한 비지도 학습. ICML, 2017. 2 [7] Cristian Bucilua, Rich Caruana 및 Alexandru Niculescu-Mizil. 모델 압축. SIGKDD, 2006. 3 [8] Mathilde Caron, Piotr Bojanowski, Armand Joulin 및 Matthijs Douze. 시각적 특징의 비지도 학습을 위한 심층 클러스터링. ECCV, 2018. 2, 4, 9, 16

[9] Mathilde Caron, Piotr Bojanowski, Julien Mairal 및 Armand Joulin. 선별되지 않은 데이터에 대한 이미지 특징의 비지도 사전 훈련 . ICCV, 2019. 2, 16

[10] Mathilde Caron, Ishan Misra, Julien Mairal, Priya Goyal, Piotr Bojanowski, and Armand Joulin. 대조 클러스터 할당을 통한 시각적 특징의 비지도 학습. NeurIPS, 2020. 1, 2, 3, 4, 5, 7, 8 , 10, 14, 15, 16, 17, 18 [11] Mia Xu Chen, Orhan Firat, Ankur Bapna, Melvin Johnson, Wolfgang Macherey, George Foster, Llion Jones, Niki Parmar, Mike Schuster, Zhifeng Chen, et al. 두 가지 장점을 모두 활용: 신경 기계 번역의 최근 발전을 결합합니다. preprint arXiv:1804.09849, 2018. 5 [12] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geof- frey Hinton. A simple framework for contrastive learning of visual representations. preprint arXiv:2002.05709, 2020. 2, 3, 5, 16, 17

Machine Translated by Google

[13] 팅 첸, 사이먼 콘블리스, 케빈 스워스키, 모하마드
노로우지, 그리고 제프리 힌튼. 대규모 자기지도 학습 모델
강력한 준지도 학습기입니다. NeurIPS, 2020. 3, 5,
6, 14

[14] Weijie Chen, Shiliang Pu, Di Xie, Shicai Yang, Yilu Guo,
그리고 린뤄쥔. 딥러닝을 위한 비지도 이미지 분류
표현 학습. arXiv 사전 공개 논문 arXiv:2006.11480,
2020년 9월 15일

[15] Xinlei Chen, Haoqi Fan, Ross Girshick 및 Kaiming He.
모멘텀 대조 학습을 통해 기준선을 개선했습니다.
사전출판본 arXiv:2003.04297, 2020. 5, 8, 14, 15, 18

[16] Xinlei Chen 및 Kaiming He. 단순 샴쌍둥이 탐구
표현 학습. 사전 공개 논문 arXiv:2011.10566, 2020. 2,
3, 4, 8, 14, 16, 18

[17] 마르코 쿠투리. 싱크혼 거리: 광속 계산
최적 수송에 관하여. NeurIPS, 2013. 15

[18] Jacob Devlin, Ming-Wei Chang, Kenton Lee 및 Kristina
Toutanova. Bert: 언어 이해를 위한 심층 양방향 변환기 사전 훈련 . preprint
arXiv:1810.04805,
2018년 1, 4, 5, 19일

[19] 알렉세이 도소비츠키, 루카스 베이어, 알렉산더 콜레스니코프,
더크 와이센보른, 샤오후아 자이, 토마스 운터시너,
Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly 외.
이미지는 16x16 단어의 가치가 있다: 대규모 이미지 인식을 위한 변환기. 사전 출판 논
문 arXiv:2010.11929,
2020년 1, 4, 5, 13일

[20] Alexey Dosovitskiy, Philipp Fischer, Jost Tobias Springen-berg, Martin Riedmiller
및 Thomas Brox. 차별적
예제 컨볼루션을 이용한 비지도 특징 학습
신경망. TPAMI, 2016. 2

[21] Matthijs Douze, Herve Jegou, Harsimrat Sandhawalia, Laurent Amsaleg 및 Cordelia
Schmid. 웹 규모 이미지 검색을 위한 요약 설명자 평가 . CIVR, 2009. 6

[22] Alaaeldin El-Nouby, Natalia Neverova, Ivan Laptev 및
에르베 제구. 이미지 검색을 위한 비전 트랜스포머 훈련.
사전출판본 arXiv:2102.05644, 2021. 10

[23] Aleksandr Ermolov, Aliaksandr Siarohin, Enver Sangineto,
그리고 니쿠 세베. 자기주도적 표현을 위한 화이트닝
학습. 사전출판물 arXiv:2007.06346, 2020. 2

[24] 마크 에버링햄, 룩 반 굴, 크리스토퍼 KI 윌리엄스,
존 윈, 앤드류 지서먼. 파스칼 시각 객체
수업(어휘) 챌린지. IJCV, 2010. 13

[25] Zhiyuan Fang, Jianfeng Wang, Lijuan Wang, Lei Zhang,
양예저우, 류쯔청. Seed: 시각적 표현을 위한 자기지도 증류. 2021. 3

[26] 스피로스 기다리스, 안드레이 부르수크, 니코스 코모다키스, 패트릭
Perez, and Matthieu Cord. Learning representations by
prediction bags of visual words. In CVPR, 2020. 2

[27] Spyros Gidaris, Andrei Bursuc, Gilles Puy, Nikos Komodakis,
Matthieu Cord 및 Patrick Perez. 비지도 표현 학습을 위한 온라인 시각적
단어 모음 생성.
arXiv 사전 인쇄 arXiv:2012.11552, 2020. 2, 5

[28] Priya Goyal, Mathilde Caron, Benjamin Lefaudeux, Min
Xu, Pengchao Wang, Vivek Pai, Mannat Singh, Vitaliy
Liptchinsky, Ishan Misra, Armand Joulin 외. 실제 환경에서의 시각적 특
징에 대한 자기 지도 사전 학습. (사전 출판 논문)
arXiv:2103.01988, 2021. 10

[29] Priya Goyal, Piotr Dollar, Ross Girshick, Pieter Noord-huis, Lukasz Wesolowski,
Aapo Kyrola, Andrew Tulloch,
Yangqing Jia 및 Kaiming He. 정확하고 큰 미니배치
sgd: ImageNet 학습 1시간. 사전 공개 논문 arXiv:1706.02677,
2017년 5월 10일

[30] Jean-Bastien Grill, Florian Strub, Florent Altche, Corentin
Tallec, Pierre H Richemond, Elena Buchatskaya, Carl Do-ersch,
Bernardo Avila Pires, Zhaohan Daniel Guo, Mohammad Gheshlaghi
Azar, Bilal Piot, Koray Kavukcuoglu, Remi Munos 및 Michal Valko. 자신
만의 잠재성을 부트스트랩: 새로운
자기지도 학습에 대한 접근 방식. NeurIPS, 2020. 2, 3,
4, 5, 8, 9, 10, 14, 15, 16, 18

[31] Shir Gur, Ameen Ali 및 Lior Wolf. 속성 부여를 통한 지도 학습 및 자기 지도 학습 신경망 시각
화
유도 인수분해. 사전 출판 논문 arXiv:2012.02166, 2020. 7

[32] Michael Gutmann 및 Aapo Hyvarinen. 노이즈 대비 추정: 비정규화된 추정을 위한 새로운 추
정 원리
통계 모델. 인공지능에 관한 국제 학술대회에서
정보 및 통계, 2010. 2

[33] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie 및 Ross
Girshick. 비지도 시각 표현 학습을 위한 모멘텀 대비. CVPR, 2020. 1, 2, 3,
4, 5, 7, 9,
16

[34] Kaiming He, Xiangyu Zhang, Shaoqing Ren 및 Jian Sun.
심층 잔차 학습을 이용한 이미지 인식. CVPR, 2016.
4, 5

[35] Geoffrey Hinton, Oriol Vinyals 및 Jeff Dean. 증류
신경망의 지식. 사전 공개 논문 arXiv:1503.02531,
2015. 2, 3

[36] Jiabo Huang, Qi Dong, Shaogang Gong 및 Xiatian Zhu.
이웃 탐색을 통한 비지도 딥러닝.
ICML, 2019. 2

[37] Allan Jabri, Andrew Owens, Alexei A Efros. 시공간
대조적 무작위 행보로서의 대응. 2020. 7

[38] Sebastien Jean, Kyunghyun Cho, Roland Memisevic 및 Yoshua Bengio. 매우 큰 목표
어휘를 사용하는 것에 관하여
신경 기계 번역. 사전 출판 논문 arXiv:1412.2007, 2014.
4, 9

[39] 기욤 클라인, 김윤, 윤티안 덩, 장 세넬라르,
그리고 Alexander M Rush. Opennmt: 오픈 소스 툴킷
신경 기계 번역. 사전 공개 논문 arXiv:1701.02810, 2017.
5

[40] Zihang Lai, Erika Lu, Weidi Xie. 돛대(Mast): 기억력이 강화된 자가 감독 추적기입니다. CVPR
에서는 2020. 7

[41] 동현 리 등. 의사 라벨: 간단하고 효율적인
심층 신경망을 위한 준지도 학습 방법.
ICML에서 개최된 '표현 학습의 어려움에 관한 워크숍'에서,
2013년 3월

[42] Junnan Li, Pan Zhou, Caiming Xiong 및 Steven CH Hoi.
비지도 표현의 전형적인 대조 학습 . ICLR, 2021. 2

[43] Ilya Loshchilov와 Frank Hutter. Sgdr: 확률적 기울기
따뜻한 재시작을 통한 하강. 사전 출판 arXiv:1608.03983, 2016.
5

[44] Ilya Loshchilov 및 Frank Hutter. Adam에서 가중치 감소 정규화 수정 . 2018. 5

Machine Translated by Google

[45] Julien Mairal. Cyanure: 경험적 연구를 위한 오픈 소스 툴박스
파이썬, C++, 그리고 곧 더 많은 언어를 위한 위험 최소화. (사전 공개 논문)
arXiv:1912.08165, 2019. 13, 14

[46] Maria-Elena Nilsback 및 Andrew Zisserman. 자동화됨
꽃의 분류는 수많은 분류군에 걸쳐 이루어진다. 2008년에
제6회 인도 컴퓨터 비전, 그래픽 및 컴퓨터 그래픽 컨퍼런스
이미지 처리, 2008. 13

[47] 메디 노루지(Mehdi Noroozi), 아난스 빈지무어(Ananth Vinjimoor), 파올로 파바로(Paolo Favaro), 하메드(Hamed)
피르시아바쉬. 자식을 통한 자기지도 학습 강화
전송. CVPR, 2018. 3

[48] 오승욱, 이준영, 쉬닝, 선주
김. 시공간 메모리를 이용한 비디오 객체 분할
네트워크. ICCV, 2019. 7

[49] Hieu Pham, Qizhe Xie, Zihang Dai 및 Quoc V Le. 메타
의사 레이블. 사전 공개 논문 arXiv:2003.10580, 2020. 14

[50] 제임스 필빈, 온드레이 춤, 마이클 이사드, 조셉 시빅,
앤드류 지서먼. 양자화의 함정: 개선
대규모 이미지 데이터베이스에서 특정 객체 검색.
CVPR, 2008. 6

[51] Boris T Polyak 및 Anatoli B Juditsky. 가속
평균을 이용한 확률적 근사. SIAM 저널
제어 및 최적화, 30(4):838–855, 1992. 4, 9, 17

[52] Jordi Pont-Tuset, Federico Perazzi, Sergi Caelles, Pablo Arbelaez, Alex
Sorkine-Hornung 및 Luc Van Gool. 2017년 비디오 객체 분할에 관한 Davis
챌린지. 사전 출판물
arXiv:1704.00675, 2017. 7

[53] Filip Radenovic, Ahmet Iscen, Giorgos Tolias, Yannis Avrithis 및
Ondˇrej Chum. 옥스퍼드와 파리 재방문:
대규모 이미지 검색 벤치마킹. 2018. 6

[54] Filip Radenovic, Giorgos Tolias 및 Ondˇrej Chum. 인간 주석 없이
CNN 이미지 검색 미세 조정. IEEE
패턴 분석 및 기계 지능 관련 거래
2018년 6월

[55] Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario
아모데이와 일리야 수츠케버. 언어 모델은 비지도 다중 작업 학습기이다. 1

[56] Ilija Radosavovic, Raj Prateek Kosaraju, Ross Girshick, Kaiming
He 및 Piotr Dollar. 네트워크 디자인 공간을 디자인합니다.
CVPR, 2020. 13

[57] Jerome Revaud, Jon Almazan, Rafael S Rezende 및 Cesar Roberto de
Souza. 평균 정밀도를 이용한 학습: 훈련
리스트와이즈 손실을 이용한 이미지 검색. ICCV, 2019. 6

[58] 피에르 H 리치몬드, 장 바스티앙 그릴, 플로랑 알체,'
코렌틴 탈렉, 플로리안 스트럽, 앤드류 브록, 사무엘 스미스,
Soham De, Razvan Pascanu, Bilal Piot 등. 별이도 일한다
배치 통계 없음. 사전 공개 논문 arXiv:2010.10241, 2020. 2,
4

[59] David Ruppert. 느리게 수렴하는 Robbins-Monro 프로세스를 통한 효율적인 추
정. 기술 보고서, 1988. 4, 9

[60] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, San-
jeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy,
아디티야 코슬라, 마이클 번스타인, 알렉산더 C. 버그, 그리고 리
페이페이. Imagenet 대규모 시각 인식 챌린지.
IJCV, 2015. 1, 5, 13

[61] Tim Salimans 및 Diederik P Kingma. 가중치 정규화:
딥러닝 학습 속도를 높이기 위한 간단한 재매개변수화
신경망. NeurIPS, 2016. 4, 16

[62] Mert Bulent Sariyildiz, Yannis Kalantidis, Diane Larlus 및
Karteek Alahari. 시각적 표현 학습에서의 개념 일반화. arXiv 사전 출판본
arXiv:2012.05649, 2020. 7

[63] Zhiqiang Shen, Zechun Liu, Jie Qin, Lei Huang, Kwang-Ting Cheng 및
Marios Savvides. S2-bnn: 브리징
자기지도 학습 방식의 실제 신경망과 1비트 신경망 간의 격차를 유도 분포 보
정을 통해 분석함. arXiv 사전 공개 논문
arXiv:2102.08946, 2021. 3

[64] 손기혁, 데이비드 베르텔로트, 리춘량, 장쯔자오,
니콜라스 칼리니, 에킨 D 큐북, 알렉스 쿠라킨, 한 장,
그리고 Colin Raffel. Fixmatch: 준지도 학습 단순화
일관성과 자신감을 바탕으로 한 학습. NeurIPS, 2020.
14

[65] 안티 타르베넨(Antti Tarvainen)과 하리 발폴라(Harri Valpola). 평균 교사는
더 나은 롤모델: 가중평균 일관성 목표
준지도 학습 기반 딥러닝 결과 개선. (사전 공개 논문)
arXiv:1703.01780, 2017. 3, 4, 9, 17

[66] Bart Thomee, David A Shamma, Gerald Friedland, Benjamin
엘리잘데, 칼 니, 더글라스 폴란드, 데미안 보스, 리지아
Li. Yfcc100m: 멀티미디어 연구의 새로운 데이터. arXiv
사전출판본 arXiv:1503.01817, 2015. 6

[67] Yonglong Tian, Chen Sun, Ben Poole, Dilip Krishnan,
코델리아 슈미드와 필립 이솔라. 좋은 것을 만드는 것은 무엇인가?
대조 학습에 대한 관점. NeurIPS, 2020. 5

[68] Giorgos Tolias, Ronan Sicre 및 Herve Jegou. CNN 활성화의 적분 최대 풀링
을 사용한 특정 객체 검색.
arXiv 사전 인쇄 arXiv:1511.05879, 2015. 6

[69] Hugo Touvron, Matthieu Cord, Matthijs Douze, 프란시스코
Massa, Alexandre Sablayrolles, and Herve Jegou. Training data-
efficient image transformers & distillation through attention .
preprint arXiv:2012.12877, 2020. 1, 4, 5, 6, 7, 8, 13,
17

[70] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit ,
Llion Jones, Aidan N Gomez, ukasz Kaiser 및 Illia
폴로수킨. 당신에게 필요한 것은 관심뿐입니다. NeurIPS, 2017. 1, 4

[71] Xiaolong Wang, Allan Jabri 및 Alexei A Efros. 학습
시간의 주기적 일관성으로부터의 대응. CVPR에서,
2019년 7월

[72] Tobias Weyand, Andre Araujo, Bingyi Cao 및 Jack Sim.
Google 랜드마크 데이터셋 v2 - 대규모 벤치마크
인스턴스 수준 인식 및 검색. 2020. 6

[73] Zhirong Wu, Yuanjun Xiong, Stella X Yu 및 Dahua Lin.
비모수적 인스턴스를 통한 비지도 특징 학습
차별. CVPR, 2018. 2, 4, 5, 9, 18

[74] Junyuan Xie, Ross Girshick 및 Ali Farhadi. 비지도
클러스터링 분석을 위한 심층 임베딩. ICML, 2016. 2

[75] Qizhe Xie, Zihang Dai Dai, Eduard Hovy, Minh-Thang Lu-ong 및 Quoc
V. Le. 비지도 데이터 증강
일관성 훈련. 사전 공개 논문 arXiv:1904.12848, 2020. 14

[76] Qizhe Xie, Minh-Thang Luong, Eduard Hovy 및 Quoc V
Le. 소음이 있는 학생을 이용한 자체 학습은 ImageNet 분류 성능을 향상시킵니
다. CVPR, 2020. 3

[77] 쉬하오항, 장샤오펑, 리하오리, 링시시에, 홍카이
Xiong, Qi Tian. Seed the views: Hierarchical semantic
alignment for contrastive representation learning. arXiv
사전출판물 arXiv:2012.02733, 2021. 16

Machine Translated by Google

[78] Qiantong Xu, Tatiana Likhomanenko, Jacob Kahn, Awni
Hannun, Gabriel Synnaeve, and Ronan Collobert. 음성 인식을 위
한 반복적 의사 레이블링. (사전 공개 논문)
arXiv:2005.09267, 2020. 3

[79] I Zeki Yalniz, Herve J egou,Kan Chen, Manohar Paluri 및 Dhruv
Mahajan. 수십억 규모의 준지도 학습
이미지 분류. 사전 공개 논문 arXiv:1905.00546, 2019. 3

[80] Jianwei Yang, Devi Parikh 및 Dhruv Batra. 심층 표현과 이미지 클러스터의 공
동 비지도 학습. In
CVPR, 2016. 2

[81] Jure Zbontar, Li Jing, Ishan Misra, Yann LeCun 및 Stephane Deny. Barlow 쌍둥
이: 중복성을 통한 자기 지도 학습
감소. arXiv 사전 공개 논문 arXiv:2103.03230, 2021. 2, 5

[82] Richard Zhang, Phillip Isola 및 Alexei A Efros. 컬러풀
이미지 컬러화. ECCV, 2016. 5

[83] Hengshuang Zhao, Jiaya Jia 및 Vladlen Koltun. 탐색
이미지 인식을 위한 셀프 어텐션. CVPR, 2020. 1

[84] Bolei Zhou, Agata Lapedriza, Jianxiong Xiao, Antonio Torralba 및
Aude Oliva. 장면을 위한 딥 피처 학습
장소 데이터베이스를 이용한 인식. NeurIPS, 2014. 13

[85] Chengxu Zhuang, Alex Lin Zhai 및 Daniel Yamins. 현지의
시각적 임베딩의 비지도 학습을 위한 집계.
ICCV, 2019. 2

## 충수

### A. 추가 결과

k-NN 분류. 표 10 에서 우리는 고정된 데이터를 평가합니다.
ResNet-50 또는 ViT-small 사전 학습된 모델이 제공하는 표현
DINO는 선형 또는 k-NN의 두 가지 평가 프로토콜을 사용합니다.
두 평가 모두에서 데이터 증강을 사용하지 않고 사전 학습된 네트워크
에서 표현을 추출합니다 . 그런 다음,
우리는 가중 k-NN 또는 다른 방법을 사용하여 분류를 수행합니다.
cyanure 라이브러리 [45] 를 사용하여 학습된 선형 회귀 .
표 10 에서 볼 수 있듯이 ViT-S의 정확도는 선형 또는 k-NN을 사용한 RN50의 정
확도보다 더 우수합니다.

분류기입니다. 하지만, 사용 시 성능 차이가 발생합니다.
k-NN 평가는 선형 평가를 고려할 때보다 훨씬 더 중요합니다. 예를 들어
ImageNet 1%에서 ViT-S는 다음과 같습니다.
ResNet-50 보다 14.1% 라는 큰 차이로 우수한 성능을 보였습니다.
k-NN 평가 결과, DINO로 학습된 트랜스포머 아키텍처가 더 높은 모
델 유연성을 제공할 수 있음을 시사합니다.
이는 k-NN 평가에 도움이 됩니다. k-NN 분류기는 다음과 같은 특징을 가지고 있습니다.

빠르고 가볍게 배치할 수 있다는 큰 장점이 있습니다.
도메인 적응이 필요하지 않습니다. 전반적으로 ViT는 다음과 같이 훈련되었습니다.
DINO는 다음과 특히 잘 어울리는 기능을 제공합니다.
k-NN 분류기.

ViT의 ImageNet 자기지도 사전학습. 본 실험에서는 지도 학습 사전학습이 ViT에
미치는 영향을 연구합니다.
ViT 모델과 본 연구 방법을 비교했습니다. 표 11 에서 두 결과를 비교합니다 .
초기화된 지도 학습 ViT 모델의 성능
사전 훈련이나 훈련 중 지도 방식이 서로 다릅니다.
추가 사전 학습된 컨볼루션 신경망. 첫 번째 모델 세트는 다음과 같습니다.

표 10: ViT-S/16 및 ResNet에 대한 k-NN 및 선형 평가

DINO로 사전 학습된 50개의 ImageNet-1k [60] ("Inet")을 사용합니다 .
Places205 [84], PASCAL VOC [24] 및 Oxford-102 꽃
(“꽃”) [46]. DINO로 훈련된 ViT는 다음과 같은 기능을 제공합니다.
특히 k-NN 친화적인 것들입니다.

| | 물류 | | | k-NN | | |
|---|---|---|---|---|---|---|
| | RN50 | ViT-S | Δ RN50 | ViT-S | Δ | |
| Inet 100% | 72.1 | 75.7 | 3.6 | 67.5 | 74.5 | 7.0 |
| 순이익 10% | 67.8 | 72.2 | 4.4 | 59.3 | 69.1 | 9.8 |
| 순이익 1% | 55.1 | 64.5 | 9.4 | 47.2 | 61.3 | 14.1 |
| 10% | 53.4 | 52.1 | -1.3 | 46.9 | 48.6 | 1.7 |
| 1% | 46.5 | 46.3 | -0.2 | 39.2 | 41.3 | 2.1 |
| VOC07 | 88.9 | 89.2 | 0.3 | 84.9 | 88.0 | 3.1 |
| 꽃 95.6 | | 96.4 | 0.8 | 87.9 | 89.1 | 1.2 |
| 평균 Δ | | | 2.4 | | | 5.6 |

표 11: 다양한 사전 학습을 사용한 ImageNet 분류 결과.
지도 학습 ViT-B/16 모델의 ImageNet 데이터셋 최고 정확도
서로 다른 사전 학습을 사용하거나 추가적인 사전 학습된 컨볼루션 신경망을 사용하여
훈련을 안내합니다. 이 방법들은 서로 다른 이미지 해상도를 사용합니다.
("res.") 및 훈련 절차("tr. proc."), 즉 데이터 증강
및 최적화. "MPP"는 마스크 패치 예측(Masked Patch Prediction)을 의미합니다.

| 사전 훈련 | | | | |
|---|---|---|---|---|
| 방법 | 데이터 | 레스. | tr. proc. | Top-1 |
| 추가 데이터를 이용한 사전 학습 | | | | |
| 엠엠프 | JFT-300M | 384 | [19] | 79.9 |
| JFT-300M을 지도했습니다. | | 384 | [19] | 84.2 |
| 추가 모델을 사용하여 학습하세요 | | | | |
| 랜드. 이니셜. | - | 224 | [69] | 83.4 |
| 추가 데이터나 모델은 없습니다. | | | | |
| 랜드. 이니셜. | - | 224 | [19] | 77.9 |
| 랜드. 이니셜. | - | 224 | [69] | 81.8 |
| 감독된 DINO | 임넷 | 224 | [69] | 81.9 |
| | 임넷 | 224 | [69] | 82.8 |

대규모 큐레이션 데이터셋에서 감독 유무에 관계없이 사전 훈련됨
3억 개의 이미지로 구성된 데이터셋입니다. 두 번째 모델 세트는 사전 학습
된 지도 학습 RegNetY [56] 에서 얻은 하드 지식 증류를 사용하여 학습됩
니다 . 마지막 모델 세트는 다음과 같습니다.
추가 데이터나 모델을 사용하지 않으며, 무작위로 초기화되거나 ImageNet
에서 DINO를 사용한 사전 학습 후에 초기화됩니다.
무작위 초기화와 비교했을 때, DINO를 이용한 사전 학습
이로 인해 성능이 +1% 향상됩니다. 이는 다음으로 인해 발생하는 것이 아닙니다.
감독 하에 사전 교육을 받는 것보다 더 긴 교육
DINO는 성능을 향상시키지 않습니다. 자기지도 학습을 사용하면 성능이 향상됩니다.
사전 학습은 추가 데이터셋으로 사전 학습된 모델과의 격차를 줄여줍니다.
데이터 또는 컨볼루션 신경망에서 추출한 데이터.

Machine Translated by Google

표 12: 고정된 ViT 특징을 사용한 ImageNet에서의 로우샷 학습. 고정된 특징 (FROZEN)을 사용하여 로지스틱 회귀 모델을 학습합니다 .
참고로, 본 FROZEN 평가는 미세 조정이나 데이터 증강 없이 수행되었습니다. 최상위 1개 알고리즘에 대한 정확도를 보고합니다.
참고로, 우리는 미세 조정과 준지도 학습을 사용한 기존 연구 결과를 제시합니다 .

| 방법 | 아치 | 매개변수 | 1위 1% | 10% |
|---|---|---|---|---|
| 자기지도식 사전 학습 및 미세 조정 | | | | |
| UDA [75] | RN50 | 23 | – | 68.1 |
| SimCLRv2 [13] | RN50 | 23 | 57.9 | 68.4 |
| BYOL [30] | RN50 | 23 | 53.2 | 68.8 |
| SwaAV [10] | RN50 | 23 | 53.9 | 70.2 |
| SimCLRv2 [16] | RN50w4 | 375 | 63.0 | 74.4 |
| BYOL [30] | RN200w2 | 250 | 71.2 | 77.7 |
| 준지도 학습 방법 | | | | |
| SimCLRv2+KD [13] | RN50 | 23 | 60.0 | 70.5 |
| SwAV+CT [3] | RN50 | 23 | – | 70.8 |
| FixMatch [64] | RN50 | 23 | – | 71.5 |
| MPL [49] | RN50 | 23 | – | 73.9 |
| SimCLRv2+KD [13] | RN152w3+SK | 794 | | 76.6 80.9 |
| 냉동된 자체 관리 기능 | | | | |
| 디노 - 겨울왕국 | ViT-S/16 | 21 | 64.5 | 72.2 |

ImageNet에서의 로우샷 학습. ViT-S에 DINO를 적용하여 얻은 특징들을 로우샷 학습 환경에서 평가합니다.
학습. 표 12 에는 검증 정확도를 보고합니다.
FROZEN( Frozen Features)으로 학습된 로지스틱 회귀 모델
1%와 10%의 레이블을 사용하여 로지스틱 회귀 모델을 학습시켰습니다.
cyanure 라이브러리 [45] 를 사용하여 유사한 매개변수 수와 이미지/초를 가진 모델을 비교할 때 ,
저희 제품의 기능이 최첨단 기술과 동등한 수준임을 확인해 주십시오.
준지도 학습 모델. 흥미롭게도, 이러한 성능은
이는 다중 클래스 로지스틱 회귀 모델을 학습시켜 얻은 결과입니다.
데이터 확대나 미세 조정 없이 기능을 동결합니다.

## B. 방법론 비교

우리는 서로 다른 자기지도 학습 방식의 성능을 비교합니다.
프레임워크, MoCo-v2 [15], SwAV [10] 및 BYOL [30]
convnet 또는 ViT를 사용할 때. 표 13 에서 우리는 다음과 같은 경우를 볼 수 있습니다.
ResNet-50(컨볼루션 신경망)으로 학습된 DINO는 동등한 성능을 보입니다.
SwAV 및 BYOL과 비교했을 때 DINO는 ViT에서 잠재력을 발휘하며 MoCo-v2, SwAV 및 BYOL을 능가하는 성능을 보여줍니다.
선형 모델에서 +4.3%, k-NN 모델에서 +6.2%라는 큰 차이로 더 나은 결과를 보였습니다.
평가). 이 섹션의 나머지 부분에서는 절제술을 시행합니다.
ViT에 적용된 DINO의 성능을 더 잘 이해하기 위해서입니다.
특히, 본 논문에서는 모멘텀 인코더, 즉 MoCo-v2를 사용하는 방법들 과의 상세한 비교를 제공합니다.
BYOL 방식과 SwAV와 같은 다중 작물 재배 방법을 사용합니다.

표 13: DEIT-소규모 및 에 대한 방법론 비교
ResNet-50에 대한 ImageNet 선형 및 k-NN 평가 결과를 보고합니다 .
300 에포크 사전 학습 후 검증 정확도. 모든 수치는
저희가 직접 운영하며, 발표된 결과와 같거나 그 이상의 성과를 냅니다.

| | 레스넷-50 | | ViT-소형 | |
|---|---|---|---|---|
| 방법 | 선형 | k-NN | 선형 | k-NN |
| 모코-v2 | 71.1 | 62.9 | 71.6 | 62.0 |
| BYOL | 72.7 | 65.4 | 71.4 | 66.6 |
| 스와비 | 74.1 | 65.4 | 71.8 | 64.7 |
| 디노 | 74.5 | 65.6 | 76.1 | 72.8 |

MoCo-v2 및 BYOL과의 관계. 표 14 에서 우리는 다음을 제시합니다 .
DINO 간에 차이가 있는 구성 요소를 제거하는 것의 영향,
MoCo-v2와 BYOL: 손실 함수 선택, 예측 변수 선택
학생 헤드, 중심화 작업, 투영 헤드의 배치 정규화, 그리고 마지막으로 다중 크롭 증강이 포함됩니다 . DINO에서의 손실은 선명해진 이미지에 대한 교차 엔트로피입니다.
MoCo-v2는 InfoNCE 대비 손실 (INCE) 을 사용하고 BYOL은 평균 제곱 오차를 사용 합니다 .
l2 정규화 출력 (MSE). 샤프닝은 적용되지 않았습니다.
MSE 기준입니다. 하지만 놀랍게도 DINO는 여전히 작동합니다 .
손실 함수를 MSE 로 변경하면 성능이 크게 달라집니다(행 (1, 2) 및 (4, 9) 참조).
또한 예측 변수를 추가해도 영향이 거의 없다는 것을 확인했습니다 (1, 3) 그러나 BYOL의 경우 예측 변수가 매우 중요합니다.
붕괴를 방지하기 위해 (7, 8) 이는 이전과 일치합니다.
연구 [16, 30]. 흥미롭게도, 우리는 교사가
출력 중심화는 예측기나 배치 없이도 붕괴를 방지합니다.
BYOL (7, 9)에서의 정규화는 상당한 영향을 미치지만
성능 저하는 다음과 같은 사실로 설명될 수 있습니다.
우리의 중심 맞춤 연산자는 선명도 향상 기능과 함께 작동하도록 설계되었습니다 . 마지막으로, 다중 크롭 기능을 살펴보겠습니다.
DINO 및 MoCo-v2와 특히 잘 작동하며, 제거 기능을 제공합니다.
이는 성능을 2~4% 저하시킵니다 (1 대 4 , 5 대 6).
BYOL에 다중 작물 재배 기능을 추가하는 것은 기본적으로 작동하지 않습니다.
(7, 10) 부록 E 에 자세히 설명되어 있으며 추가적인 적응이 가능합니다.
필수적입니다.

SwAV와의 관계. 표 15 에서 차이점을 평가합니다 .
DINO와 SwAV 사이: 운동량의 존재
인코더와 교사 출력 위에 수행되는 연산.
운동량이 없는 경우, 정지 기울기를 갖는 학생 객체의 복사본이 사용됩니다. 우리는 교사 객체에 대한 세 가지 연산을 고려합니다.
출력: 센터링, 싱크혼-노프 또는 소프트맥스
배치 축을 따라. 소프트맥스 는 단일과 유사합니다.
다음 단락에 자세히 설명된 Sinkhorn-Knopp 반복법.
첫째, 이러한 절제 실험은 운동량 인코더를 사용하는 것이 효과적임을 보여줍니다.
ViT의 성능을 크게 향상시킵니다 (3 대 6,
둘째 , 모멘텀 인코더는 또한 다음 을 방지합니다.
가운데 정렬만 사용할 경우 ( 1행) 축소됩니다. 가운데 정렬이 없을 경우

Machine Translated by Google

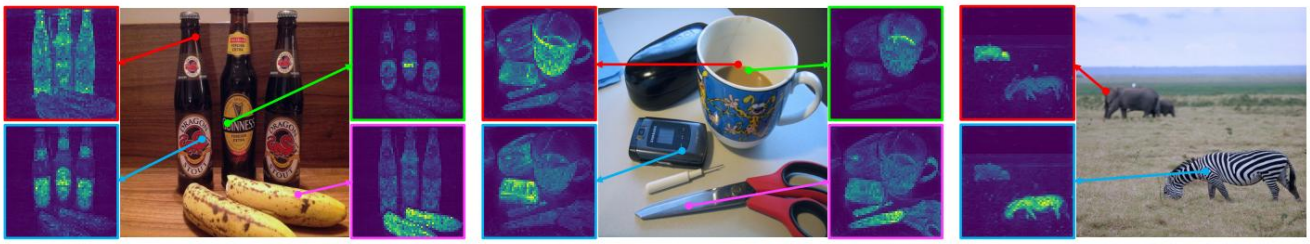


그림 8: 참조점 집합에 대한 셀프 어텐션. ViT-S/8 학습의 마지막 블록에서 얻은 셀프 어텐션 모듈을 시각화했습니다.
DINO. 이 신경망은 아무런 지도 학습 없이도 객체를 분리할 수 있습니다.

표 14: MoCo-v2 및 BYOL과의 관계. DINO, MoCo-v2 및 BYOL 간에 차이가 있는 구성 요소를 제거합니다 . 손실
함수(교차 엔트로피 (CE), InfoNCE (INCE), 평균 제곱 오차( MSE) 비교), 다중 작물 훈련, 중심화 연산자
프로젝션 헤드와 학생의 배치 정규화
예측 변수. 모델은 ViT-S/16을 사용하여 300 에포크 동안 실행되었습니다. 결과를 보고합니다.
ImageNet 선형 평가에서 최고 정확도를 달성했습니다.

| 방법 | 손실 | 다중 작물 | 센터. | BN | 예측. | Top-1 |
|---|---|---|---|---|---|---|
| 1 디노 | CE | | | | | 76.1 |
| 2 – | MSE | | | | | 62.4 |
| 3 – 4 – | CE | | | | | 75.6 |
| | CE | | | | | 72.5 |
| 5 MoCov2 INCE 6 | | | | | | 71.4 |
| | 그 이후로 | | | | | 73.4 |
| 7 BYOL MSE 8 – | | | | | | 71.4 |
| | MSE | | | | | 0.1 |
| 9 – 10 | MSE | | | | | 52.6 |
| – | MSE | | | | | 64.8 |

표 15: SwAV와의 관계. 우리는 교사에 대한 연산을 다양하게 적용합니다 .
중심화, 배치 차원에 적용된 소프트맥스, 그리고 싱크혼-노프 알고리즘 간의 출력 차이를 분석합니다. 또한, 우리는 다음을 제거합니다.
학생의 하드카피로 교체함으로써 모멘텀 인코더를 대체합니다.
SwAV에서와 같이 정지 경사를 사용합니다. 모델은 300 에포크 동안 실행됩니다.
ViT-S/16을 사용하여 ImageNet 선형 평가에서 최상위 정확도를 보고합니다 .

| 방법 | 모멘텀 | 작업 | 탑1 |
|---|---|---|---|
| 1 디노 2 – 3 | | Softmax(배치) | 76.1 |
| – 4 – 5 | | 중심화 75.8 | |
| – | | 싱크혼-크노프 76.0 | |
| | | 중심 0.1 | |
| | | 소프트맥스(배치) 72.2 | |
| 6 스와브 | | 싱크혼-크노프 71.8 | |

운동량의 경우 출력을 중앙에 배치하는 것은 효과가 없습니다 (4) .
보다 고급적인 작업이 필요합니다 (5, 6). 전반적으로 이러한
절제술은 성능 향상뿐만 아니라 훈련 안정화에도 있어 운동량 인코더의
중요성을 강조합니다 .

중심 맞춤 외에 추가적인 정규화가 필요하지 않게 됩니다.

Softmax(배치) 변형에 대한 세부 정보. SwAV [10] 에서 사용되는 반복
Sinkhorn-Knopp 알고리즘 [17] 은 다음과 같습니다.
다음과 같은 PyTorch 스타일 코드로 간단하게 구현할 수 있습니다.

```
# x는 n×K입니다
# tau는 싱크혼 정규화 매개변수입니다.
x = exp(x / tau)
for in range(num_iters): # 싱크혼의 1번째 반복
    # 차원(또는 클러스터)별 총 가중치
    c = sum(x, dim=0, keepdim=True)
    x /= c

    # 샘플당 총 중량
    n = sum(x, dim=1, keepdim=True)
    # 각 샘플(과제)에 대해 x의 합은 1입니다.
    x /= n
```

싱크혼(Sinkhorn) 반복을 한 번 수행할 때
(반복 횟수=1) 구현은 매우 어려울 수 있습니다.
단 두 줄의 코드로 간소화되었으며, 이것이 바로 저희의 목표입니다.
소프트맥스(배치) 변형:

```
x = 소프트맥스(x / tau, dim=0)
x /= sum(x, dim=1, keepdim=True)
```

표 15 에서 보듯이 , 이처럼 매우 단순화된 변형은
SwAV는 SwAV와 경쟁적으로 작동합니다. 직관적으로,
배치 축에 대한 소프트맥스 연산을 통해 선택할 수 있습니다.
각 차원(또는 "클러스터")은 배치에서 가장 잘 일치하는 항목을 찾습니다.

구현 유효성을 검증합니다. 표 13 에서 확인할 수 있습니다.
BYOL, MoCo-v2, SwAV의 재현 결과가 일치한다는 점
또는 해당 공개 수치를 능가합니다.
ResNet-50. 실제로, 우리는 BYOL에 대해 72.7%를 얻습니다 . [30]
300 에포크 설정 에서 72.5%를 보고했지만 , 우리는 71.1%를 얻었습니다.
[15] 는 300 에포크 훈련 후 MoCo에 대해 보고합니다.
800 에포크 훈련 후 71.1%의 향상률을 보였습니다. [15] 의 구현과
비교했을 때 우리의 개선점은 다음과 같이 설명할 수 있습니다.
더 큰 투영 헤드 사용(3층, 배치 정규화 사용 및 투영 차원 256).

다른 작품과의 관계. DINO는 다음 작품들과도 관련이 있습니다 .
UIC [14] 는 이전 에포크의 출력을 하드로 사용합니다.

Machine Translated by Google

"비지도 분류"를 위한 의사 레이블입니다. 하지만
우리는 붕괴를 방지하기 위해 중심 맞춤을 사용하지만 UIC는 다른 방법을 사용합니다.
[8] 과 같은 균형 샘플링 기법을 사용 합니다. 본 연구는 다음과 같습니다.
모멘텀 교사를 가진 부드러운 UIC 변형으로 해석됩니다.

동시 작업인 CsMI [77] 또한 ImageNet에서 간단한 k-NN 분류기를 사용하여 강력한 성능을 보여줍니다 .
컨볼루션 신경망을 사용합니다. DINO와 마찬가지로 CsMI는 모멘텀 네트워크와 멀티 크롭 학습을 결합하는데, 이는 우리가 이미 살펴본 바와 같습니다.
실험에서 k-NN의 우수한 성능에 매우 중요한 요소는 다음과 같습니다.
ViTs. 우리는 이 연구를 통해 좋은 k-NN 에 중요한 구성 요소를 더욱 정확하게 식별하는 데 도움이 될 것이라고 생각합니다.
성능 향상 및 이 조사는 향후 연구 과제로 남겨둡니다.

## C. 프로젝션 헤드

다른 자기지도 학습 프레임워크와 마찬가지로,
투영 헤드 [12] 는 우리의 정확도를 크게 향상시킵니다.
이 방법은 투영 헤드가 n개의 층으로 이루어진 다층 퍼셉트론(MLP)으로 시작한다는 것을 보여줍니다. 은닉층은 2048d이며,
가우시안 오차 선형 단위(GELU) 활성화 함수를 사용합니다.
MLP의 마지막 레이어에는 GELU가 없습니다. 그런 다음 적용합니다.
2 정규화 및 가중치 정규화된 완전 연결
K 차원 의 레이어 [16, 61] . 이 디자인은 영감을 받았습니다.
프로젝션 헤드에서 사용되는 "프로토타입 레이어"로부터
SwAV [10]. 우리는 배치 정규화를 적용하지 않습니다.

배치 정규화( BN)를 사용하지 않는 시스템. 일반적인 컨볼루션 신경망과 달리 ViT 아키텍처는 기본적으로 배치 정규화(BN)를 사용하지 않습니다. ViT-S는 100 에포크 동

| 안 BN을 사용하지 않은 헤드와 BN을 사용한 헤드를 비교합니다. | | |
|---|---|---|
| k-NN 탑-1 | 69.7 | 68.6 |

따라서 DINO를 ViT에 적용할 때 BN도 사용하지 않습니다.
프로젝션 헤드에서. 이 표에서는 그 영향을 평가합니다.
헤드에 BN을 첨가하면 다음과 같은 현상이 나타납니다. BN을 첨가하면 다음과 같은 현상이 관찰됩니다.
프로젝션 헤드의 영향은 미미하며, 이는 BN이 그렇지 않다는 것을 보여줍니다.
우리 프레임워크에서 중요합니다. 전반적으로 DINO를 적용할 때
ViT의 경우, 우리는 어떤 곳에서도 BN을 사용하지 않으므로 시스템이 제대로 작동하지 않습니다.
완전히 BN이 없습니다. 이것이 DINO + ViT의 큰 장점입니다.
최첨단 성능으로 작업하면서도 어떠한 추가 기능도 필요하지 않습니다.
BN. 실제로 BN을 이용한 훈련은 일반적으로 훈련 속도를 늦춥니다.
특히 이러한 BN 모듈이 필요할 때 상당히 그렇습니다.
프로세스 간에 동기화됨 [33, 10, 9, 30].

프로젝션 헤드의 L2 정규화 병목 현상. L2 정규화를 적용한 경우와 적용하지 않은 경우의 프로젝션 헤드 설계를 예시로 제시합니다 .
그림 9에서 정규화 병목 현상이 나타납니다. 우리는 정확도를 평가합니다.

| # 프로젝트 헤드 선형 레이어 | 1 | 2 | 3 | 4 |
|---|---|---|---|---|
| l2-norm 병목 현상 포함 l2-norm 병목 현상 미포함 | – 61.6 | 62.2 62.9 | 68.0 0.1 | 69.3 0.1 |

l2 정규화 유무에 따라 학습된 DINO 모델
병목 현상이 발생하며, 선형 레이어의 수를 변경합니다.
프로젝션 헤드. L2 병목 현상으로 인해 총 개수는 다음과 같습니다.

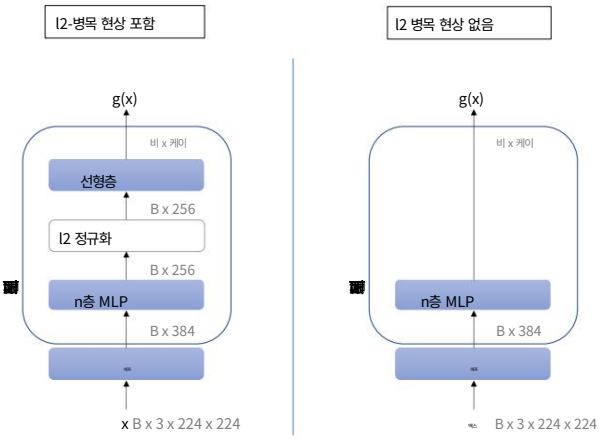



그림 9: l2-norm 병목 현상 유무에 따른 프로젝션 헤드 설계.

선형 레이어는 n + 1 입니다 (n은 MLP에서, 1은 ...에서).
가중치 정규화 레이어)가 있는 반면 병목 현상이 없는 경우 헤드 의 전체 선형 레이어 수는 n 입니다. 이 표에서,
우리는 ImageNet top-1 k-NN 평가 정확도를 보고합니다.
ViT-S/16 모델로 100 에포크 사전 학습을 수행했습니다. 이 실험에서 출력 차원 K 는 4096 으로 설정했습니다 . 관찰 결과는 다음과 같습니다.
투영 헤드의 깊이를 증가시킬 때 l2 정규화 병목 현상이 없으면 DINO 훈련이 실패한다는 것입니다.
L2 정규화 병목 현상이 DINO 학습을 안정화합니다.
깊은 투영 헤드를 사용합니다. 우리는 증가시키면서 관찰했습니다.
투영 헤드의 깊이가 정확도를 향상시킵니다. 기본 설정값은 다음과 같습니다.
총 4개의 선형 레이어를 사용합니다. 3개는 MLP에 있고 나머지 하나는 입니다.
l2 병목 현상 이후입니다.

출력 차원. 이 표에서는 그 효과를 평가합니다.
출력 차원 K를 변화시키면서 관찰한 결과 다음과 같은 사실을 확인했습니다.

| 케이 | 1024 | 4096 | 16384 | 65536 | 262144 |
|---|---|---|---|---|---|
| k-NN 탑1 | 67.8 | 69.3 | 69.2 | 69.7 | 69.1 |

출력 차원이 클수록 성능이 향상됩니다.
l2 정규화 병목 현상을 사용하면 다음과 같은 이점이 있음을 유의하십시오.
적당한 증가율로 큰 출력 차원을 사용하십시오.
총 매개변수 개수입니다. 기본값은 K =1 입니다.
병목 현상의 경우 65536이고 d = 256입니다.

GELU 활성화. 기본적으로 ViT에서 사용되는 활성화는 다음과 같습니다.
GELU는 가우시안 오차 선형 단위입니다. 따라서 일관성을 유지하기 위해 ViT-S

| 에서는 GELU 헤드와 ReLU 헤드를 각각 100 에포크 동안 사용합니다. | | |
|---|---|---|
| k-NN 탑-1 | 69.7 | 68.9 |

아키텍처 내에서 안정성을 확보하기 위해 GELU도 사용하기로 했습니다.
프로젝션 헤드에서 ReLU 활성화 함수를 사용했을 때의 효과를 평가합니다.
이 표에서 GELU 대신 다른 것을 사용하고 변경 사항을 관찰해 보세요.
활성화 단위가 ReLU에 미치는 영향은 상대적으로 미미합니다.

Machine Translated by Google

D. 추가적인 절제술

우리는 본문에서 해당 조합에 대해 자세히 설명했습니다.
중심을 잡고 날카롭게 하는 것은 무너짐을 방지하는 데 중요합니다.
DINO. 다음에서는 이 두 연산에 대한 하이퍼파라미터를 제거합니다 . 또한 훈련이 미치는 영향도 연구합니다.
ViT 네트워크의 길이 및 몇 가지 설계 선택 사항.

온라인 중심화. 평활화의 영향을 연구합니다.
중심 c 에 사용되는 업데이트 규칙의 매개변수
교사 네트워크의 출력입니다. 수렴은 안정적입니다.

| 중 | 0 | 0.9 | 0.99 | 0.999 |
|---|---|---|---|---|
| k-NN 탑1 | 69.1 | 69.7 | 69.4 | 0.1 |

광범위한 평활화에 대해 모델은 붕괴될 뿐입니다.
업데이트 속도가 너무 느릴 때, 즉 m = 0.999일 때.

선명도 향상. 우리는 조정을 통해 선명한 목표를 설정합니다.
교사 소프트맥스 온도 매개변수 τt. 이 표에서,
우리는 0.06 보다 낮은 온도가 필요하다는 것을 관찰했습니다.
붕괴를 방지합니다. 온도가 0.06보다 높으면 ,

| τt | 0 | 0.02 | 0.04 | 0.06 | 0.08 | 0.04 → 0.07 |
|---|---|---|---|---|---|---|
| k-NN top-1 | 43.9 | 66.7 | 69.6 | 68.7 | 0.1 | 훈련 손실은 일관 69.7 |

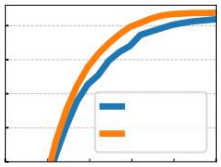
되게 ln(K)로 수렴합니다. 그러나
우리는 0.06 보다 높은 온도를 사용하면 다음과 같은 현상이 나타나는 것을 관찰했습니다.
더 작은 값에서 학습을 시작하더라도 붕괴되지 않습니다.
그리고 초기 에포크 동안 이를 증가시킵니다. 실제로 우리는 다음을 사용합니다.
첫 번째 기간 동안 τt는 0.04 에서 0.07 까지 선형적으로 증가했습니다.
30 에포크의 학습. 마지막으로, τ → 0 (극단값) 임을 유의하십시오.
샤프닝)은 argmax 연산에 해당하며 리드합니다.
원핫 하드 분포로.

더 긴 훈련 시간. 이 표에서 볼 수 있듯이, 더 긴 훈련 시간은 ViT-Small에 적용된 DINO의 성능을 향상시킵니다.
이러한 관찰 결과는 자기지도 학습 결과와 일치합니다.

| DINO ViT-S | 100-ep | 300-ep | 800-ep |
|---|---|---|---|
| k-NN 탑-1 | 70.9 | 72.8 | 74.5 |

합성곱 아키텍처를 통해 얻은 결과입니다 [12]. 우리는 다음을 주목합니다.
ViT-S에서 BYOL을 사용한 실험에서, 더 긴 훈련 시간을 적용했을 때
300 에포크 이상 실행하면 300 에포크 실행 결과 와 비교했을 때 성능이 더 저하되는 것으로 나타났습니다 . 따라서 BYOL(Bring Your Own Language)을 권장합니다.
표 2 에서 300 에포크 동안 SwAV, MoCo-v2 및 DINO를 사용했습니다.
800 에포크 동안 학습됩니다.

교사가 학생보다 뛰어난 성과를 보였습니다. 우리는 이를 입증했습니다 .
그림 6 에서 운동량 교사가 학생보다 더 나은 성과를 보인다는 것을 알 수 있다.
ViT를 사용했을 때도 마찬가지이며, 이 그림에서 그 사실을 확인할 수 있습니다.
ResNet-50을 사용했을 때, 교사가 학생 보다 지속적으로 우수한 성적을 보인다는 사실은 이러한 해석을 더욱 뒷받침합니다.
DINO는 Mean Teacher [65] 자체 증류 의 한 형태입니다 . 실제로 Tarvainen et al. [65] 에서 제시된 것처럼 가중 평균화는



일반적으로 개별 모델보다 더 나은 모델을 생성합니다.
각 반복으로부터 [51]. 를 통해 얻은 목표를 조준함으로써
교사가 학생보다 뛰어나다, 학생의 표현
향상됩니다. 결과적으로 교사도 향상됩니다.
학생들의 몸무게를 직접 기반으로 제작되었습니다.

지도 학습과 자기 지도 학습에서 얻은 셀프 어텐션 맵을 비교 분석하고, 얻어진 마스크를 평가합니다 .
셀프 어텐션 맵에 임계값을 적용하여 80%를 유지합니다.
질량. 우리는 Jaccard 유사도를 비교합니다.

| ViT-S/16 무게 | |
|---|---|
| 랜덤 가중치 | 22.0 |
| 감독된 | 27.3 |
| 디노 | 45.9 |
| DINO w/o 멀티크롭 | 45.1 |
| MoCo-v2 | 46.3 |
| BYOL | 47.8 |
| 스와비 | 46.8 |

정답 데이터와 검증 이미지에 적용된 마스크
다양한 ViT-S 학습을 위한 PASCAL VOC12 데이터셋
서로 다른 프레임워크. 자기 주의의 속성
ViT의 맵에는 장면 레이아웃이 명시적으로 포함되어 있으며,
특히, 객체 경계는 서로 다른 영역에서 관찰됩니다.
자기지도 학습 방법.

ViT-S에서 헤드 수의 영향. 본 연구에서는 다음을 연구합니다.
ViT-S의 헤드 개수가 정확도에 미치는 영향
처리량(추론 시점에 초당 처리되는 이미지 수)
(단일 V100 GPU에서). 우리는 GPU 개수를 늘리면 다음과 같은 결과를 얻을 수 있음을 발견했습니다.

| # 헤드 | 딤 | 딤/헤드 | # 매개변수 | im/sec | k-NN |
|---|---|---|---|---|---|
| 6 | 384 | 64 | 21 | 1007 | 72.8 |
| 8 | 384 | 48 | 21 | 971 | 73.1 |
| 12 | 384 | 32 | 21 | 927 | 73.7 |
| 16 | 384 | 24 | 21 | 860 | 73.8 |

헤드를 추가하면 성능이 향상되지만, 약간의 손실이 발생합니다.
처리량이 더 나빠졌습니다. 저희 논문에서는 모든 실험을 다음과 같이 진행했습니다.
기본 모델 DeiT-S [69], 즉 헤드가 6개만 있는 모델입니다.

E. 다작물

이 부록에서는 DINO의 핵심 구성 요소를 연구합니다.
다작물 훈련 [10].

Machine Translated by Google

다양한 크기의 이미지를 여러 개 겹쳐서 표시할 때 크기 범위를 조절할 수 있습니다.
서로 다른 뷰를 생성하기 위해 RandomResizedCrop 메서드를 사용합니다.
PyTorch의 torchvision.transforms 모듈 에서 가져온 것입니다 .
우리는 이전에 스케일 범위 (s, 1)를 사용하여 두 개의 전역 뷰를 샘플링합니다.

| (0.05, s), (s, 1), s: 0.08 0.16 0.24 0.32 0.48 |
|---|
| k-NN 탑-1 65.6 68.0 69.7 69.8 69.5 |

크기를 2242 로 조정하고 스케일 샘플링을 사용하여 6개의 로컬 뷰를 표시합니다.
(0.05, s) 범위에서 962 픽셀 로 크기가 조정되었습니다 . 참고로,
임의로 겹치지 않는 스케일링 범위를 선택합니다.
원래 디자인을 따르는 글로벌 및 로컬 관점
SwAV. 하지만 범위가 확실히 겹칠 수 있습니다.
더 세밀한 하이퍼파라미터를 사용하여 실험해 볼 수도 있습니다.
보다 최적의 설정으로 이어집니다. 이 표에서는 다중 작물에 사용되는 척도 범위를
제어하는 매개 변수 를 변경합니다.
실험 결과 최적값은 약 0.3 인 것으로 나타났습니다.
우리는 이 값이 SwAV에서 사용되는 매개변수보다 높다는 점에 주목합니다.
이는 0.14입니다.

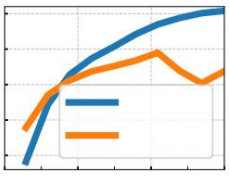
서로 다른 자기지도 학습 프레임워크에서의 다중 작물 재배.
우리는 MoCo-v2 [15], BYOL [30] 및 SwAV [10] 와 같은 다양한 최근 자기지도
학습 프레임워크를 비교합니다 .
ViT-S/16 아키텍처를 사용합니다. 공정한 비교를 위해 모든 모델을 포함합니다.

| 작물 | 2 × 2242 | | 2 × 2242 + 6 × 962 | |
|---|---|---|---|---|
| 평가 | k-NN 선형 | | k-NN | 선의 |
| BYOL 66.6 SwAV 60.5 | | 71.4 | 59.8 | 64.8 |
| MoCo-v2 62.0 DINO | | 68.5 | 64.7 | 71.8 |
| 67.9 | | 71.6 | 65.4 | 73.4 |
| | | 72.5 | 72.7 | 75.9 |

2242 개의 작물 2개를 사용하거나 다중 작물 [10] 훈련, 즉 2242개의 작물 2개와
962개의 작물 6개를 사용하여 사전 훈련됩니다.
각 이미지에 대해 k-NN 및 선형 탐색 평가 결과를 보고합니다.
300 에포크의 학습 후. 멀티크롭이 모든 경우에 이점이 있는 것은 아닙니다.
벤치마크에서 간과되어 온 프레임워크들 역시 마찬가지입니다.
두 가지 작물 설정만 고려하면 [16] 다중 작물의 효과는 고려되는 프레임
워크에 따라 달라집니다.
이는 다중작물 재배를 모델의 핵심 구성 요소로 자리매김하는 것입니다.
단순히 어떤 프레임워크든 성능을 향상시켜 줄 "부가 기능"이 아닙니다.
마찬가지로, 다중 작물 재배를 하지 않으면 DINO의 정확도가 더 높아집니다.
다른 프레임워크보다 약간 더 높지만, 그 차이는 크지 않습니다(1%).
놀랍게도 DINO는 다중 작물 재배 훈련에서 가장 큰 이점을 얻었습니다 ( + 선형 평가에
서 +3.4% ). 또한 흥미로운 점은 다음과 같은 사실을 관찰할 수 있다는 것입니다.
프레임워크 순위는 평가에 따라 달라진다는 점
프로토콜을 검토했습니다.

ViT-S를 사용하여 BYOL에 멀티크롭을 적용하여 학습시킨 결과 , 멀티크롭을 적용
하지 않은 기준 모델보다 전송 성능이 더 높은 것을 확인했습니다.

첫 번째 학습 에포크 동안은 그랬습니다. 하지만 전이 성능은...
성장률은 일정 수준 이후에는 둔화되고 감소합니다.



훈련량. 학습률과 가중치를 적용했습니다.
부패, 이 설정에 대한 다중 작물 매개변수 스윕 및
우리는 동일한 패턴을 체계적으로 관찰합니다. 더 정확히 말하면, 우리는
{1e} 로 실험해 보세요 $^{-5}$ , $3e^{-5}$ , $1e^{-4}$ , $3e^{-4}$ , $1e^{-3}$ , 3e 3} 의 경우
학습률 기본값은 가중치에 대해 {0.02, 0.05, 0.1} 입니다.
부패 및 다양한 수의 소규모 작물: {2, 4, 6}.
모든 실행은 헤드에서 동기화된 배치 정규화를 사용하여 수행됩니다. 낮
은 학습률을 사용할 경우,
성능 변곡점을 관찰하지 못했으며, 즉 훈련 기간 동안 전이 성능이 지속적으로 향상
되었다.
하지만 전반적인 정확도는 낮았습니다. 저희는 다음과 같은 방법으로 실행해 보았습니다.
ResNet-50에서 다중 작물 학습을 수행하면서 다음과 같은 현상도 관찰했습니다.
동일한 행동. 다중 작물 재배 훈련을 통합한 이후로
본 연구의 초점은 BYOL(Bring Your Own Logistics, 집필품 반입 허용)이 아니며, 저희는 그 부분을 강조하지 않았습니다.
더 나아가 방향을 모색해야 합니다. 하지만, 우리는 왜 다작물 재배가 BYOL과
잘 결합되지 않는지 조사해 볼 가치가 있다고 생각합니다.
우리의 실험 결과는 향후 연구 과제로 남겨두겠습니다.

## F. 평가 프로토콜

### F.1 k-NN 분류

Wu et al. [73] 의 설정을 따라 , 우리는 간단한 가중 k 최근접 이웃 알고리즘을 사
용하여 특징의 품질을 평가합니다.
분류기. 사전 학습된 모델을 고정하여 계산합니다.
하위 작업의 훈련 데이터 특징을 저장합니다.
테스트 이미지 x를 분류하기 위해 해당 이미지의 표현을 계산합니다.
그리고 이를 저장된 모든 학습 특징 T 와 비교합니다.
이미지의 표현은 출력 [CLS] 에 의해 제공됩니다.
토큰: ViT-S의 경우 차원 d = 384 이고, 다른 토큰의 경우 d = 768입니다.
ViT-B의 경우 상위 k개의 NN( Nk로 표시됨) 을 사용하여 다음을 생성합니다 .
가중 투표를 통한 예측. 구체적으로, 클래스 c 는 다음과 같은 결과를 얻습니다.

$i \in Nk\ \alpha i 1ci=c$ 의 총 가중치 , 여기서 αi 는 기여도입니다.
가중치. 우리는 $\alpha i = \exp(Tix/\tau)$ 를 사용 하며 , τ 는 0.07 입니다.
[73] 에서 우리는 조정하지 않습니다. 우리는 다양한 값을 평가합니다.
k 에 대해 k=20일 때 일관적으로 최상의 결과가 나온다는 것을 알 수 있습니다.
실행 전반에 걸친 정확도. 이 평가 프로토콜은 그렇지 않습니다.
하이퍼파라미터 튜닝이나 데이터 증강이 필요하지 않습니다.
다운스트림 데이터셋에 대해 한 번만 실행하면 됩니다.

### F.2 선형 분류

자기주도 학습에서 흔히 볼 수 있는 방식을 따라, 우리는
선형 분류기를 사용하여 표현 품질을 평가합니다.
프로젝션 헤드를 제거하고 지도 학습을 진행합니다.
고정된 특징 위에 선형 분류기를 적용했습니다. 이 선형 분류기는 SGD와
1024 의 배치 크기로 학습되었습니다 .

Machine Translated by Google

ImageNet에서 100 에포크 동안 학습했습니다. 가중치 감소는 적용하지 않았습니다.
각 모델에 대해 학습률 값을 순차적으로 변경합니다. 학습 과정에서는
PyTorch의 RandomResizedCrop 함수의 기본 매개변수를 사용하여
무작위 크기 조정 크롭만 적용합니다.
데이터 증강으로 수평 뒤집기를 사용했습니다. 중앙 부분 추출을 통한 상위 1개 정확도
를 보고합니다. 컨볼루션 신경망을 평가할 때 일반적인 방법은 다음과 같습니다.
실제 방법은 최종 결과에 대해 전역 평균 풀링을 수행하는 것입니다.
선형 분류기 이전의 특징 맵입니다. 다음으로,
ViT를 평가할 때 이 설계를 어떻게 적용하는지 설명하십시오.

선형 평가를 위한 ViT-S 표현. 다음은
BERT [18] 의 특징 기반 평가에서 우리는 연결합니다.
마지막 l 개 레이어 의 [CLS] 토큰 입니다 . 우리는 실험합니다.

| 마지막 레이어들을 연결합니다 | 1 | 2 | 4 | 6 |
|---|---|---|---|---|
| 표현이 흐릿함 | 384 | 768 | 1536 | 2304 |
| ViT-S/16 선형 평가 | 76.1 | 76.6 | 77.0 | 77.0 |

서로 다른 개수 l 의 층을 연결하여
[18] 과 유사하게 l = 4가 최적임을 알 수 있습니다.

선형 평가를 위한 ViT-B 표현. ViT-B를 사용하면
표현들을 연결하는 것이 효과가 없다는 것을 발견했습니다.
마지막 l 개 레이어가 성능 향상을 제공하는지 고려하고
최종 레이어만 해당 (l = 1). 이 설정에서 우리는 다음을 적용합니다.

| 풀링 전략 | [CLS] tok. 오직 | [CLS] tok. 연결 그리고 평균 풀링된 패치 토크. |
|---|---|---|
| 표현이 흐릿함 | 768 | 1536 |
| ViT-B/16 선형 평가 | 78.0 | 78.2 |

전역 평균 풀링을 사용하는 컨볼루션 신경망에서 사용되는 파이프라인
출력 패치 토큰입니다. 이러한 통합된 기능을 연결합니다.
최종 [CLS] 출력 토큰까지.

### G. 자기 주의 시각화

그림 8 에서 셀프 어텐션 시각화를 더 자세히 보여줍니다.
그리고 그림 10 에서. 이미지는 무작위로 선택되었습니다.
COCO 검증 세트이며, 학습 과정에서는 사용되지 않습니다.
DINO. 그림 8에서 우리는 마지막부터의 자기주의를 보여줍니다.
DINO ViT-S/8의 여러 참조 지점 레이어.

### H. 클래스 표현

최종 시각화로서, DINO의 특징 공간에서 ImageNet 개념의 분포를 살
펴보는 것을 제안합니다.
우리는 각 ImageNet 클래스를 평균 특징으로 표현합니다.
검증 이미지에 대한 벡터입니다. 차원을 줄입니다.
PCA를 사용하여 이러한 특징들을 30개로 줄이고, t-SNE를 실행합니다.
난이도 20, 학습률 200, 반복 횟수 5000회.
그림 11 에서 결과적인 클래스 임베딩을 제시합니다 .
모델은 클래스 간 구조를 복원합니다: 유사한 동물
종들은 함께 묶여 응집력 있는 군집을 형성합니다.
새(위쪽)나 개, 특히 테리어(맨 오른쪽) 같은 견종.

Machine Translated by Google

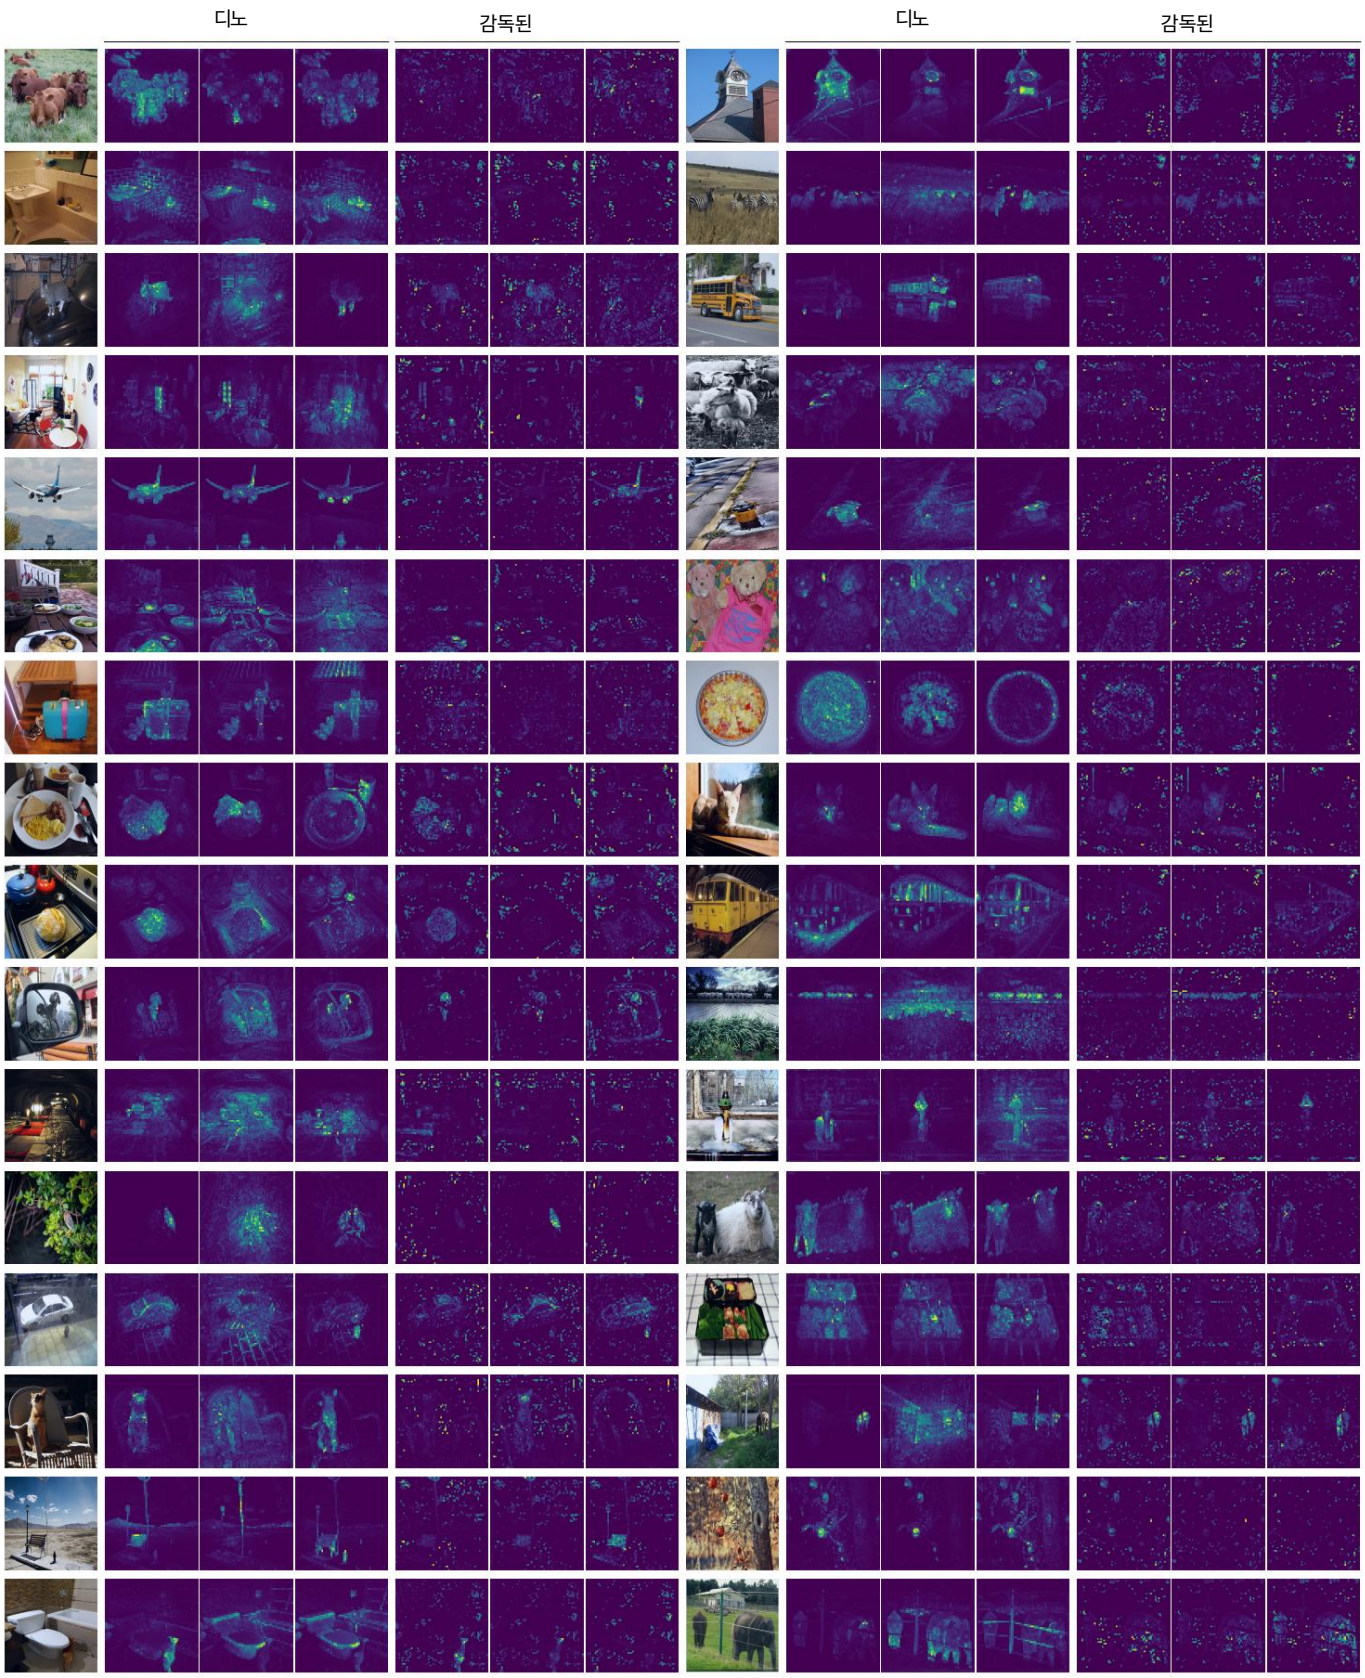



그림 10: 마지막 레이어의 셀프 어텐션 헤드. [CLS] 토큰을 쿼리로 사용하여 다양한 경우에 대한 어텐션 맵을 살펴봅니다.
마지막 레이어에 있는 헤드입니다. [CLS] 토큰은 어떤 레이블이나 감독에도 연결되어 있지 않다는 점에 유의하십시오.

Machine Translated by Google

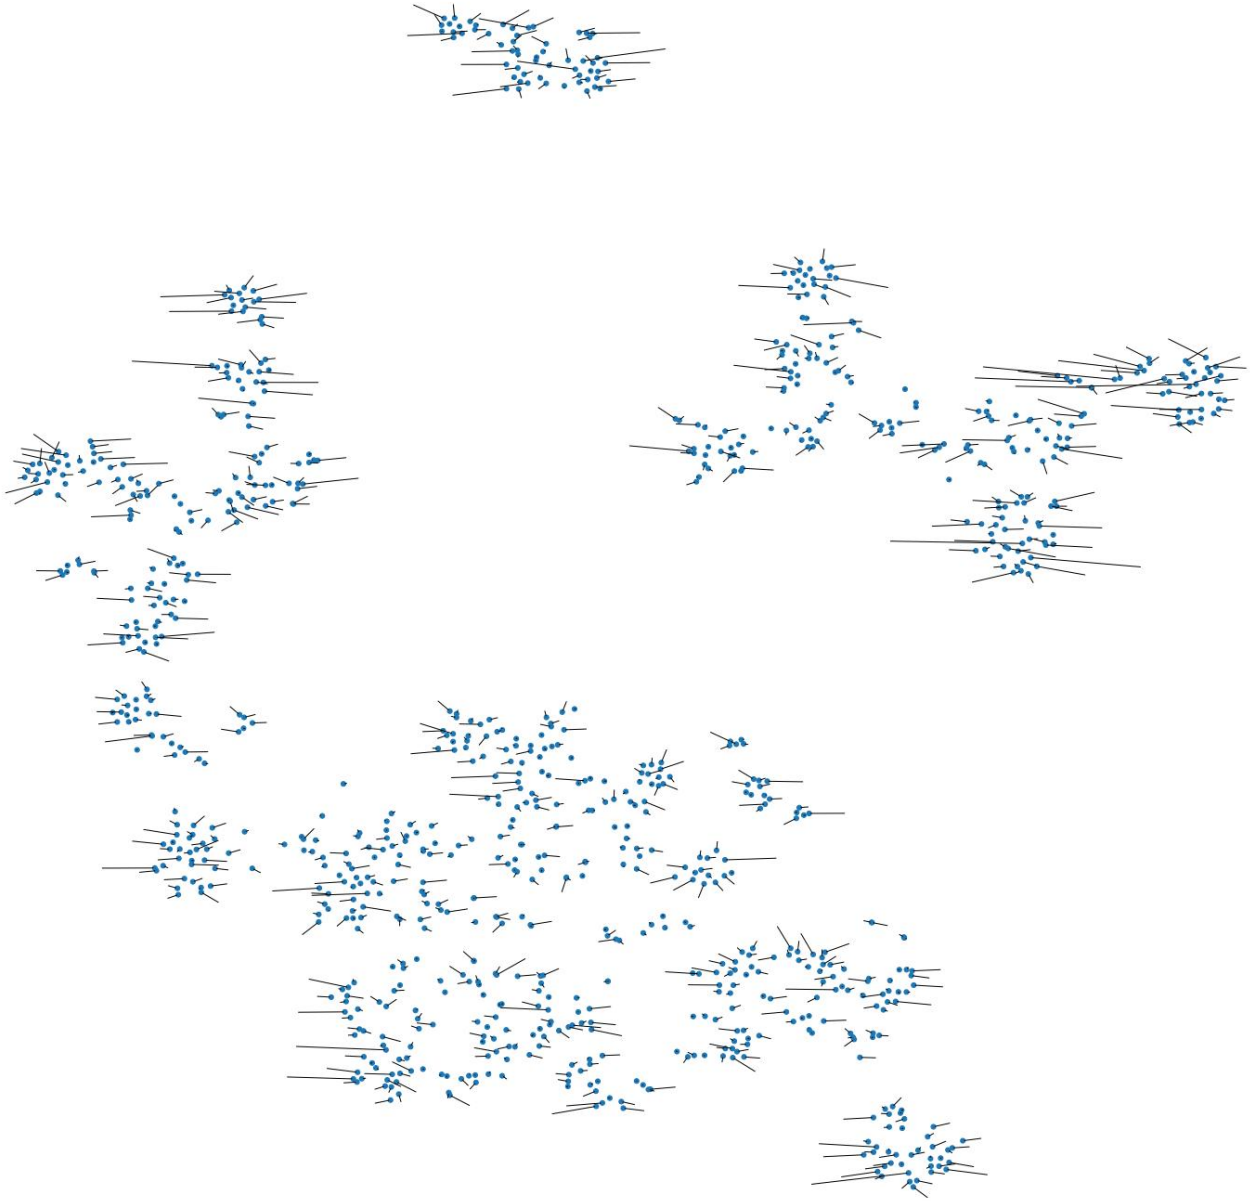


그림 11: DINO를 사용하여 표현된 ImageNet 클래스의 t-SNE 시각화. 각 클래스에 대해 검증 세트에 있는 해당 클래스의 모든 이미지에 대한 특징의 평균을 취하여 임베딩을 얻습니다 .