편집 안내: 문장과 캡션을 한국어로 옮긴 텍스트판입니다. 그림 이미지는 연결된 원문을 보십시오. 수식은 원문 기호 또는 TeX 표기를 유지하며, 참고문헌은 원문 서지를 유지합니다. 저자가 검토한 공식 번역이 아닙니다.

M-SpecGene: RGBT 다중 스펙트럼 비전을 위한 범용 기반 모델

원제: M-SpecGene: Generalized Foundation Model for RGBT Multispectral Vision

저자: Kailai Zhou[1,2], Fuqiang Yang[1], Shixian Wang[1], Bihan Wen[2], Chongde Zi[1], Linsen Chen[1], Qiu Shen[1], Xun Cao[1].

소속: [1]중국 난징, Nanjing University. [2]싱가포르, Nanyang Technological University. 별표는 원문의 저자 표기를 유지했다. 이메일: calayzhou@smail.nju.edu.cn; chenls@nju.edu.cn; caoxun@nju.edu.cn.

원문 판본: arXiv:2507.16318v2, 2025년 7월 28일 수정판, 12쪽. 공식 초록 및 판본 정보 (https://arxiv.org/abs/2507.16318v2) · 번역에 사용한 공식 HTML (https://arxiv.org/html/2507.16318v2) · 공식 PDF (https://arxiv.org/pdf/2507.16318v2) · 보존한 원문 PDF.

비공식 AI 한국어 번역 — 2026년 9월 28일. 이 문서는 저자나 출판사가 승인한 번역이 아니며, 사람의 전문적인 감수를 거치지 않았다. 원문의 초록, 본문 전체, 감사의 글, 모든 그림·표의 설명, 표의 수치 및 수식을 옮긴 전문 번역이다. 참고문헌 83개의 서지 정보는 식별과 검색을 위해 영어 원문으로 유지했다. 그림 이미지는 다시 그리거나 번역하지 않고 해당 원문 PDF 위치로 연결한다. 본문이 언급하는 부록은 이 12쪽 판본에 포함되어 있지 않아 번역 대상에 존재하지 않는다. 원문에서 본문·표 사이의 번호나 수치가 다른 곳은 원문을 보존하고 별도의 '번역자 주'로 구분했다.

원문 라이선스: Creative Commons Attribution–NonCommercial–ShareAlike 4.0 International(CC BY-NC-SA 4.0, 저작자표시–비영리–동일조건변경허락 4.0 국제). 라이선스 안내 (https://creativecommons.org/licenses/by-nc-sa/4.0/) · 라이선스 전문 (https://creativecommons.org/licenses/by-nc-sa/4.0/legalcode). 이 한국어 번역은 원문의 번역·서식 변경을 포함하는 2차 저작물이며, 같은 CC BY-NC-SA 4.0 조건으로 제공한다. 원저자와 원문 출처를 표시하고, 비영리 목적으로 이용하며, 번역을 공유·수정하는 경우 같은 라이선스를 적용해야 한다. 번역 작업: OpenAI의 AI 어시스턴트. 이 안내 이후의 저자 시점 서술은 원문 저자들의 주장이다.

초록

RGB-열화상(RGB-Thermal, RGBT) 다중 스펙트럼 비전은 복잡한 환경에서 강건하게 인지하기 위해 필수적이다. 대부분의 RGBT 과제는 과제별로 따로 연구하는 패러다임을 따르며, 사람이 맞춤 설계한 모델에 의존하여 과제 지향적인 표현을 학습한다. 그러나 이러한 패러다임은 본질적으로 인위적인 귀납적 편향, 모달리티 편향, 데이터 병목에 제약을 받는다. 이러한 한계를 해결하기 위해 우리는 범용 RGBT 다중 스펙트럼 기반 모델(M-SpecGene)을 구축하는 첫 시도를 수행한다. 이 모델은 대규모의 폭넓은 데이터에서 자기지도 방식으로 모달리티에 불변인 표현을 학습하는 것을 목표로 한다. M-SpecGene은 다중 스펙트럼 융합에 새로운 통찰을 제공하고, 기존의 과제별 연구를 하나의 통합된 패러다임으로 묶는다. RGBT 데이터에 고유한 정보 불균형 특성을 고려하여, 두 모달리티 사이의 정보 밀도를 정량화하는 교차 모달리티 구조적 희소성(Cross-Modality Structural Sparsity, CMSS) 지표를 도입한다. 이어서 유연하고 쉬운 단계에서 어려운 단계로 나아가는 객체 중심 사전학습을 촉진하기 위해 GMM-CMSS 점진적 마스킹 전략을 개발한다. 포괄적인 실험을 통해 네 가지 RGBT 후속 과제의 11개 데이터셋에서 M-SpecGene의 일반화 능력을 검증한다. 코드는 https://github.com/CalayZhou/M-SpecGene 에 공개될 예정이다.

1. 서론

RGB 센서만으로는 스모그, 저조도, 넓은 동적 범위의 장면 등 복잡한 환경 조건을 다루기 어렵다. RGBT 다중 스펙트럼 비전은 전천후·상시 감지 능력을 갖추고 있어 자율주행, 군사·국방, 원격탐사, 산업 검사 등의 분야에서 중요한 기술로 부상했다.

현재 대부분의 RGBT 후속 과제는 과제별 연구 패러다임을 따른다. 주어진 과제에 대해 작은 과제 전용 데이터셋으로 완전 지도학습을 수행하여 과제 지향적인 표현을 학습하며, ImageNet에서 사전학습한 모델을 사용하거나 처음부터 모델을 학습하는 경우가 많다. 그림 1(a)와 같이 기존 방법은 보통 두 개의 분기를 사용하여 RGB 영상과 열화상 각각에서 특징을 추출하고, 중간 특징 공간에 채널 어텐션 [80], 공간 어텐션 [69], Transformer [41], 그래프 네트워크 [44] 등 사람이 설계한 복잡한 모듈을 넣는다. 그러나 이 과제별 패러다임에는 몇 가지 한계가 있다. 1) 인위적인 귀납적 편향: 사람이 맞춤 설계한 과제 지향 모델은 주어진 과제에 최적화되어 있으므로 그 과제에는 효과적이지만, 다른 과제에서는 최적에 못 미치는 결과를 낼 수 있다. 따라서 설계한 모델의 확장성과 학습한 표현의 일반화 능력이 모두 제한된다. 2) 모달리티 편향: RGB와 열화상 모달리티의 본질적인 차이 때문에 ImageNet 사전학습 모델로 열화상 분기를 초기화하면 모달리티 편향이 불가피하게 유입된다. 이 편향은 인코딩된 사전 지식을 손상시킬 수 있고 열화상 모달리티에 최적이 아닌 특징 표현을 초래할 수 있다. 3) 데이터 병목: RGBT 다중 스펙트럼 영상은 RGB 영상만을 얻는 것보다 확보하기 어렵다. 또한 대규모 데이터셋에 고품질의 수작업 주석을 작성하는 데는 비용과 시간이 많이 든다.

그림 1. (a) 사람이 맞춤 설계한 모델: 과제별 연구 패러다임 아래 과제 지향적인 표현을 학습한다. (b) 범용 RGBT 다중 스펙트럼 기반 모델은 자기지도학습을 통해 모달리티 불변 표현을 학습하는 것을 목표로 한다. RGB와 열화상 특징의 t-SNE 시각화는 M-SpecGene이 더 우수한 교차 모달리티 정렬을 달성함을 보여준다. 그림 이미지: 원문 PDF 1쪽.

최근에는 방대한 지식을 인코딩할 수 있는 기반 모델 [2]이 위 한계에 대한 잠재적 해결책을 제공한다. 그림 1(b)와 같이, 우리는 사람이 맞춤 설계한 모델을 M-SpecGene이라는 범용 다중 스펙트럼 기반 모델로 전환하는 첫 시도를 수행한다. 이 모델은 자기지도 방식으로 모달리티 불변 표현을 학습하는 새로운 RGBT 융합 패러다임을 탐구한다. 이에 따라 사람이 설계한 모듈이 필요 없어지고, 간단하면서도 효과적으로 여러 모달리티의 특징을 융합할 수 있다. 그러나 대규모 데이터셋의 부족과 RGBT 데이터에 내재한 정보 불균형 때문에 범용 다중 스펙트럼 기반 모델의 자기지도 사전학습은 어렵다. 열화상 영상에는 RGB 영상과 달리 풍부한 질감, 색상, 세밀한 정보가 부족하다. 또한 영상 형성 원리의 큰 차이로 인해 두 모달리티의 정보 밀도가 비대칭이 된다. 아울러 RGBT 데이터셋은 ImageNet [7]처럼 객체 중심으로 구성되지 않는다. 오히려 더 작고 덜 두드러지는 객체를 포함하는 경향이 있고, 정보가 분산되어 불균등하게 분포한다.

이러한 문제를 해결하기 위해 M-SpecGene은 시아미즈(Siamese) 구조와 점진적 마스킹 전략을 사용하여 잠재 공간에서 일관된 표현을 형성하도록 한다. 다중 스펙트럼 영상 내부의 고유한 상관관계를 활용하여, 두 모달리티 사이의 정보 밀도를 정량화하는 교차 모달리티 구조적 희소성을 도입한다. 이어서 전체 사전학습 데이터셋의 전반적인 CMSS 분포를 적합하는 가우시안 혼합 모델(Gaussian Mixture Model, GMM)을 개발한다. 이를 통해 더 쉬운 학습 단계에서 더 어려운 단계로 나아가면서 모달리티 사이의 균형을 유지하는 유연한 마스킹 전략을 구현한다. 우리의 GMM-CMSS 점진적 마스킹 전략은 자기지도 사전학습에서 정보 불균형의 영향을 완화하며, 인코더가 일관되고 모달리티에 불변이며 객체 중심적인 표현에 집중하는 능력을 강화한다.

M-SpecGene은 RGBT 융합 패러다임에 새로운 통찰을 제공하며 다음과 같은 장점이 있다. 1) 간소화된 모델 설계: 하나의 기반 모델로 RGB와 열화상 모달리티를 모두 효과적으로 표현할 수 있다. 이에 따라 사람이 설계한 복잡한 모듈이 필요 없어지고, RGB 단일 모달리티 방법을 RGBT 이중 모달리티 과제에 적용하기 쉬워진다. 2) 범용 표현: 대규모 데이터의 자기지도 사전학습을 통해 M-SpecGene은 인위적인 귀납적 편향과 모달리티 편향에 따른 한계를 극복하는 다목적 표현을 학습하므로 다양한 후속 과제에 적응할 수 있다. 3) 향상된 데이터 활용: M-SpecGene은 사람이 주석을 작성할 필요 없이 기존 RGBT 과제의 자기지도 사전학습 데이터를 충분히 통합한다. 우리의 기여는 다음과 같다.

- 다중 스펙트럼 기반 모델 M-SpecGene을 구축하는 첫 시도를 수행하고, 사람이 설계한 모듈을 필요로 하지 않는 새로운 RGBT 융합 패러다임을 탐구한다.

- 자기지도 사전학습을 위해 고품질 대규모 데이터셋 RGBT550K를 신중하게 구축한다.

- RGBT 데이터셋의 고유한 특성을 고려하여 정보 불균형의 영향을 완화하는 GMM-CMSS 점진적 마스킹 전략을 도입한다.

- M-SpecGene은 기존의 과제별 연구를 하나의 패러다임으로 통합하고, 네 가지 RGBT 후속 과제의 11개 데이터셋에서 강력한 일반화 능력을 보인다.

2. 관련 연구

2.1. 과제 지향 RGBT 다중 스펙트럼 비전

먼저 관련된 RGBT 다중 스펙트럼 비전 과제를 개괄한다. a) 다중 스펙트럼 객체 탐지: 기존 방법은 세 부류로 나뉜다. 1) 영상 수준의 초기 융합, 2) 특징 수준의 중간 융합, 3) 후처리 방식의 후기 융합이다. 중간 융합이 주된 연구 대상이 되었으며, 채널 어텐션 [80], 공간 어텐션 [69, 1, 72], Transformer [41, 26, 42] 등 모달리티 간 상호작용 모듈을 포함한다. b) 다중 스펙트럼 의미 분할: 초기 연구는 RGB와 열화상 특징을 이어 붙이거나 [13], 열화상 특징을 RGB 인코더에 통합하는 [6, 81] 등의 단순한 전략을 채택했다. 최근 연구는 강건한 교차 모달리티 융합을 위해 가중 어텐션 기반 융합 전략을 탐구하며, 다중 스케일 공간·채널 문맥 모듈 [77], 명시적인 상보성 모델링 프레임워크 [22], 경계를 고려한 유도 융합 [82], 시공간 문맥 통합 [23] 등의 기법을 사용한다. c) RGBT 교차 모달리티 특징 매칭: 모달리티 불변 표현은 교차 모달리티 특징 매칭에서 중요한 역할을 한다. 전통적으로 사람이 설계한 방법 [30]은 모달리티 차이에 대해 일정한 강건성을 보이는 신뢰할 수 있는 필터를 설계한다. 반면 최근 딥러닝 방법 [8]은 손실 함수를 활용하여 특징 추출을 지도한다. 그럼에도 기존 방법은 일반화 능력과 강건성이 제한적이다. d) 다중 스펙트럼 현저 객체 탐지: 의미 분할과 비교하면 현저 객체 탐지는 배경의 복잡성과 문맥 이해 등의 어려움에 직면한다. 이를 위해 매니폴드 순위화 알고리즘 [52], 다중 상호작용 블록 [48], 다중 그래프 친화도 상호작용 네트워크 [44] 등의 기술이 제안되었다.

결론적으로, 기존 RGBT 후속 과제는 주로 과제별 연구 패러다임을 따른다. 이 논문에서는 기반 모델의 관점에서 다중 스펙트럼 융합 패러다임의 전환을 탐구한다.

2.2. 스펙트럼 기반 모델

기반 모델은 먼저 대규모의 폭넓은 데이터에서 자기지도 방식으로 사전학습되며, 광범위한 후속 과제에 맞추어 조정할 수 있다. 예를 들어 미세조정을 수행할 수 있다 [2]. 특수한 데이터 유형을 위한 자기지도학습 기반 모델이 여러 분야에 등장했다. 합성개구레이더를 위한 SARATR-X [32], 적외선 영상을 위한 InfMAE [36], X선 영상을 위한 EVA-X [63] 등이 그 예이다. 스펙트럼 기반 모델 연구는 주로 원격탐사의 초분광 영상에 초점을 맞추며, SpectralGPT [16]와 HyperSIGMA [51] 등이 여기에 속한다. 현재 RGBT 다중 스펙트럼 기반 모델에 관한 연구는 부족하다. 최근의 관련 연구인 UniRGB-IR [66]은 ViT-B를 사전학습된 기반 모델로 활용하고, RGB 기반 사전학습 모델에 더 풍부한 RGB-IR 특징을 동적으로 도입한다. 그러나 UniRGB-IR도 여전히 사람이 설계한 융합 모듈을 요구하며, 어댑터 조정 설계가 두 모달리티를 충분히 통합하지 못할 수 있다. 우리는 자기지도 방식으로 대규모 RGBT 데이터를 충분히 활용하여 사람이 설계한 모듈을 없애고자 다중 스펙트럼 기반 모델을 개발하는 첫 시도를 수행한다.

2.3. 정보 인식 마스킹 전략

ImageNet [7]과 비교하면 RGBT 데이터셋은 정보 불균형이라는 뚜렷한 특성을 보인다. 한 가지 해결책은 정보 인식 마스킹 전략으로, 정보적 가치를 바탕으로 영상에서 가릴 부분을 최적으로 선택하는 것을 목표로 한다. 열화상 영상에서는 InfMAE [36]가 명암값에 기반한 정보 인식 마스킹을 구현한다. RGB 영상에서는 기존 방법이 교사–학생 프레임워크 [53, 25], ViT가 학습한 의미 정보 [29], CLIP [17], 또는 분할 과제의 사전학습 [58]에 의존하여 정보 밀도 분포를 측정한다. 그러나 이런 방법은 대체로 추가 구성 요소를 요구하거나 더 많은 계산 비용을 발생시킨다. 또한 단일 모달리티 기반 방법을 다중 스펙트럼 영상에 직접 적용하기 어렵다는 점에 유의해야 한다. 우리는 두 모달리티 사이의 고유한 상관관계를 활용하면 발전된 정보 인식 마스킹에 유용한 단서를 얻을 수 있다고 본다.

3. RGBT550K 데이터셋

강건한 일반화 능력을 갖춘 다중 스펙트럼 기반 모델을 사전학습하기 위해, 우리는 활용할 수 있는 RGBT 데이터셋을 최대한 포괄적으로 수집했다. 그 결과 10개 다중 스펙트럼 과제에 걸친 41개 데이터셋에서 300만 개의 RGBT 샘플을 모았으며, 이를 RGBT3M이라고 부른다. RGBT3M은 영상 수가 상당하지만, 우리는 다양성과 품질이 더 중요하다고 주장한다. RGBT3M 데이터셋에는 다음과 같은 한계가 있다. 1) 데이터셋 간 불균형: RGBT 탐지·분할 데이터셋 [71, 38]은 일반적으로 샘플이 10,000개보다 적지만, RGBT 추적 데이터셋 [28]은 대개 100,000개를 넘는다. 2) 시간적 중복: 추적 데이터셋에는 수십만 개의 샘플이 들어 있지만 고유한 장면은 수백 개에 불과하므로 상당한 시간적 중복이 발생한다. 3) 낮은 영상 품질: 많은 데이터셋은 야간이나 비 오는 장면 등 어려운 조건에서 촬영되어 영상 품질이 낮다.

따라서 다음 절차로 RGBT3M을 정제한다. 1) 데이터셋 균형 확보: 특정 데이터셋 하나가 지나치게 큰 비중을 차지하지 않도록 한다. 2) 중복 제거: RGBT 비디오 데이터셋에 시간축 샘플링을 적용하여 매우 유사한 프레임을 제거한다. 3) 영상 품질 평가: 객관적인 지표를 사용한 결과, SSIM [56]이 RGBT 영상 품질을 측정하는 효과적인 척도임을 발견했다. SSIM 값이 0.80보다 낮은 샘플은 제거한다. 이런 영상은 일반적으로 충분한 객체 정보가 없거나 품질이 낮기 때문이다. 그림 2와 같이, 세심한 전처리를 통해 548,238개의 고품질 샘플로 이루어진 종합적인 데이터셋 RGBT550K를 얻었다. 이 데이터셋은 다양한 장면, 과제, 조명 조건, 해상도, 객체 범주를 포함하여 다중 스펙트럼 기반 모델의 자기지도 사전학습을 위한 견고한 토대를 제공한다. 자세한 내용은 부록에서 확인할 수 있다.

번역자 주: 마지막 문장은 원문 그대로 번역했다. 이 번역의 출처인 arXiv v2 12쪽 PDF 및 HTML에는 별도의 부록이 포함되어 있지 않다.

그림 2. RGBT550K는 다양한 출처의 자료로 구성되며, ImageNet과 비교할 때 불균형한 정보 분포를 보인다. 그림 이미지: 원문 PDF 3쪽.

4. 방법

그림 3(a)와 같이 M-SpecGene은 교차 모달리티 자기지도학습을 위해 마스크드 오토인코더 [14]에 기반한 시아미즈 구조를 채택한다. 먼저 정보 밀도에 따라 가릴 패치를 동적으로 선택하는 GMM-CMSS 점진적 마스킹 전략을 적용한다. 상보적으로 마스킹한 RGB와 열화상 패치를 가중치를 공유하는 ViT [10] 인코더로 처리한다. 이어서 교차 어텐션 층을 사용하여 잠재 공간에서 상보적인 정보가 전달되도록 한다. 마지막으로 자기 어텐션 층을 갖는 모달리티별 디코더 두 개가 RGB와 열화상 모달리티의 가려진 픽셀을 각각 독립적으로 복원한다. 시아미즈 구조는 두 모달리티가 일관된 표현을 생성하도록 유도한다. 자기지도 사전학습이 끝나면 후속 과제의 미세조정에 M-SpecGene ViT 인코더를 사용한다. 이에 대해서는 4.4절에서 자세히 설명한다.

GMM-CMSS 점진적 마스킹 전략은 세 단계로 이루어진다. 1) RGBT 데이터셋의 불균등한 정보 분포를 고려하여, 각 RGBT 영상 쌍의 CMSS 지표를 계산하고 정보 밀도를 정량화한다. 2) 가우시안 혼합 모델링으로 전반적인 CMSS 분포를 추정하고 이를 이후의 정보 인식 마스킹을 위한 지침으로 사용한다. 3) GMM에 기반한 샘플링 함수를 설계하여 점진적 마스킹 전략을 구현한다. 이 절차를 통해 사전학습 동안 가려지지 않은 패치가 전경에서 배경으로 점진적으로 이동한다.

그림 3. (a) M-SpecGene의 자기지도 사전학습. (b) 후속 과제에서 M-SpecGene을 미세조정하는 과정. 그림 이미지: 원문 PDF 4쪽.

4.1. 교차 모달리티 구조적 희소성

그림 2는 RGBT 데이터셋의 두드러진 특성이 심한 정보 불균형임을 보여준다. 이 특성은 객체 크기와 공간적·모달리티별 정보 밀도가 불균등하게 분포하는 데 드러난다. 객체가 대체로 중앙에 있고 영상의 큰 부분을 차지하는 ImageNet [7]과 달리, RGBT 데이터셋은 객체 중심적이지 않다. 더 작고 덜 두드러지는 객체를 포함하는 경향이 있으며 공간 분포도 불균등하다. 또한 영상 형성 원리의 차이는 모달리티 불균형 [80]을 초래한다. 즉, 조건에 따라 RGB와 열화상 모달리티의 정보 밀도가 비대칭적이다. 따라서 MAE [14]가 사용하는 무작위 마스킹 전략은 정보가 희박한 영역에 지나치게 집중하여 효과적인 자기지도학습을 저해할 수 있다. 이에 우리는 모달리티 사이의 정보 밀도 측정에 기반한 적응적 마스킹 전략을 개발하고자 한다. 구체적으로 RGB 영상과 열화상 영상을 각각 겹치지 않는 $p \times p$ 개의 패치 임베딩으로 나누며, 이를 각각 $A_{rgb} = \{a_i\}_{i=1}^{p \times p}$와 $B_t = \{b_i\}_{i=1}^{p \times p}$로 나타낸다. 여기서 $a_i, b_i \in \mathbb{R}^{768}$은 i번째 패치 임베딩의 특징 벡터이다. 각 패치 임베딩 쌍 (a, b)에 대해 교차 모달리티 구조적 희소성을 다음과 같이 정의한다.

$$m = CMSS(a, b) = \frac{1 + \left\langle \frac{a}{|a|}, \frac{b}{|b|} \right\rangle}{2\sigma_a^2 \sigma_b^2}.$$

식 (1)

분자는 RGB와 열화상 패치 임베딩 사이의 코사인 유사도를 나타낸다. 분모는 a와 b의 구조적 분산으로 이루어진다. 후처리를 쉽게 하기 위해 m의 값을 $[0, 1]$ 범위로 정규화한다. 그림 2에서 정보 밀도가 낮은 영역, 예를 들어 하늘에서는 패치 임베딩 쌍 (a, b)이 높은 유사도와 낮은 구조적 분산을 보여 CMSS 값이 상대적으로 높다. 반대로 보행자 등 정보 밀도가 높은 영역에서는 (a, b)의 차이가 더 크기 때문에 유사도는 낮고 구조적 분산은 높다. 따라서 의미적 문맥이 풍부한 영역에서 CMSS는 더 낮은 값을 갖는 경향이 있다. 이에 따라 우리는 RGBT 패치 임베딩 쌍 사이의 정보 밀도를

평가하는 간단하면서도 효과적인 지표로 CMSS를 사용한다.

4.2. CMSS 가우시안 혼합 모델링

사전학습 데이터셋 전체가 N개의 영상 쌍으로 이루어지고 각 영상 쌍이 $p \times p$개의 패치 임베딩을 포함할 때, 전반적인 CMSS 분포는 $\mathbf{m} = \{m_i\}_{i=1}^{N \times p \times p}$로 나타낼 수 있다. 핵심 문제는 이 전체 CMSS 분포 $\mathbf{m}$에 기반하여 효과적인 마스킹 전략을 개발하는 것이다. 이를 해결하기 위해 먼저 가우시안 혼합 모델을 적용하여 최대우도 방식으로 전체 CMSS 분포 $\mathbf{m}$을 추정한다. 가우시안 혼합 모델로 $\mathbf{m}$을 추정한 뒤, 특정 CMSS 분포 구간에 대응하는 가우시안 모델에 기반하여 마스킹할 패치를 동적으로 조정한다. 기저 분포 $\mathbf{m}$에서 얻은 패치 임베딩 (a, b)의 관측 CMSS 값 m을 다음과 같이 모델링한다.

$$p(m) = \sum_{k=1}^{K} \pi_k \mathcal{N}(m \mid \mu_k, \Sigma_k).$$

식 (2)

여기서 $p(m)$은 가우시안 혼합 모델로 추정할 CMSS 확률밀도함수이다. K는 가우시안 성분의 수이며 기본값은 3이다. π_k는 평균이 μ_k이고 분산이 Σ_k인 k번째 가우시안 성분 $\mathcal{N}(m \mid \mu_k, \Sigma_k)$의 가중치이다. 사전학습 데이터셋 전체의 CMSS 지표를 한 번에 계산하려면 계산 비용이 많이 든다. 게다가 학습 가능한 선형 투영 매개변수가 사전학습 동안 계속 갱신된다. 따라서 우리는 에포크마다 사전학습 과정과 동기화하여 가우시안 혼합 모델의 추정치를 동적으로 갱신하고자 한다. 각 사전학습 반복에서 배치마다 B개의 영상 쌍에 대해 $B \times p \times p$개의 CMSS 샘플을 계산하고, 이를 $\mathbf{m}_{iter} = \{m_i\}_{i=1}^{B \times p \times p}$로 나타낸다. 추정 단계에서는 각 CMSS 샘플 m_i가 k번째 가우시안 모델에 속할 사후확률을 다음과 같이 추정한다.

$$\alpha_{ik} = \frac{\pi_k \mathcal{N}(m_i \mid \mu_k, \Sigma_k)}{\sum_{i=1}^{K} \pi_k \mathcal{N}(m_i \mid \mu_k, \Sigma_k)}.$$

식 (3)

번역자 주: 식 (3)의 분모에 있는 합산 첨자 i와 고정된 k 표기는 원문 그대로이다. 합산 첨자와 샘플 첨자가 겹치므로 구현 시 저자 코드 및 일반적인 GMM 사후확률 정의를 함께 확인해야 한다. 이 번역에서 수식을 임의로 교정하지 않았다.

사후확률 α_{ik}를 사용하여 최대화 단계에서 가우시안 혼합 모델의 매개변수 $\{\mu_k, \Sigma_k, \pi_k\}$를 다음과 같이 갱신한다.

$$\mu_k = \frac{\sum_{i=1}^{B \times p \times p} \alpha_{ik} m_i}{\sum_{i=1}^{B \times p \times p} \alpha_{ik}},$$

$$\Sigma_k = \frac{\sum_{i=1}^{B \times p \times p} \alpha_{ik} (m_i - \mu_k)(m_i - \mu_k)^T}{\sum_{i=1}^{B \times p \times p} \alpha_{ik}},$$

$$\pi_k = \frac{\sum_{i=1}^{B \times p \times p} \alpha_{ik}}{B \times p \times p}.$$

식 (4) - 위 식을 함께 적용

이 절차에 따라 각 사전학습 반복에서 가우시안 혼합 모델의 매개변수 $\{\mu_k, \Sigma_k, \pi_k\}$를 반복적으로 갱신하여 CMSS 확률밀도함수 $p(m)$을 근사한다. 관찰 결과, 몇 차례의 에포크가 지나면 분포 $p(m)$은 안정 상태에 이르며 가우시안 혼합 모델이 $p(m)$에 대해 안정적이고 최적인 적합을 제공할 수 있게 된다.

4.3. GMM-CMSS 점진적 마스킹 전략

가우시안 혼합 모델의 매개변수 $\{\mu_k, \Sigma_k, \pi_k\}$로 $p(m)$을 근사한 뒤, GMM-CMSS 점진적 마스킹 전략을 제안한다. 이 전략에서 샘플링 함수 $S(x)$는 다음과 같이 정의된다.

$$S(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}\left(x \mid \hat{\mu}_k + \hat{\mu}_{\text{bias}}, \hat{\Sigma}_k\right), \quad K = 1, 2, \ldots$$

식 (5)

여기서 $\hat{\mu}_k$와 $\hat{\Sigma}_k$는 각각 k번째 가우시안 샘플링 모델의 평균과 분산을 나타내며, $\hat{\mu}_{\text{bias}}$는 모달리티 균형을 위한 평균 샘플링 편향을 나타낸다. 구체적으로, 각 사전학습 반복에서 B개의 영상 쌍으로 이루어진 배치는 $B \times p \times p$개의 영상 임베딩을 포함하며, 샘플링 함수 $S(x)$는 $B \times p \times p$개의 샘플링 지점 $\mathbf{s} = \{x_i\}_{i=1}^{B \times p \times p}$를 생성한다. 현재 반복의 CMSS 분포 $\mathbf{m}_{iter} = \{m_i\}_{i=1}^{B \times p \times p}$에 대해, 생성된 샘플링 지점 $\mathbf{s}$에 가장 가까운 $B \times p \times p \times (r + r_{bias})$개의 마스킹할 패치를 $\mathbf{m}_{iter}$에서 샘플링한다. 여기서 r은 마스킹 비율이며, r_{bias}는 모달리티 손실 차이에 따라 적응적으로 조정하는 편향이다. 그림 4와 같이 K, $\hat{\mu}_k$, $\hat{\Sigma}_k$ 매개변수를 제어하여 점진적 마스킹 전략을 구현한다. 사전학습을 시작할 때는 샘플링 함수 $S(x)$를 $K = 1, \hat{\mu}_1 = 0, \hat{\Sigma}_1 = 0.01$로 초기화하여, 가려지지 않은 패치가 정보 밀도가 높은 영역에 집중되도록 한다. 사전학습이 진행되면서 $\hat{\mu}_1$을 0에서 μ_1까지 점진적으로 증가시키며, 중간 분산 $\hat{\Sigma}_1$은 이중선형 보간으로 구한다. $\hat{\mu}_1 = \mu_1$이 되면 가우시안 성분 하나를 추가하여 샘플링 함수 $S(x)$를 갱신하고 $K = 2, \hat{\mu}_2 = 0, \hat{\Sigma}_2 = 0.01$로 설정한다. $\hat{\mu}_2$, $\hat{\Sigma}_2$에도 $\hat{\mu}_1$, $\hat{\Sigma}_1$과 동일한 연산을 수행한다. 학습 중간에는 매개변수가 $K = 3$ 및 $\{\hat{\mu}_k = \mu_k, \hat{\Sigma}_k = \Sigma_k\}_{k=1,2,3}$로 설정된다. 이 설정에서 샘플링 함수 $S(x)$는 전체 CMSS 분포의 확률밀도함수 $p(m)$을 가깝게 근사하며, 이를 무작위 마스킹으로 볼 수 있다. 사전학습 마지막에는 $\{\hat{\mu}_k = \mu_k\}_{k=1,2,3}$ 매개변수를 하나씩 점진적으로 $\{\hat{\mu}_k = 1.0\}_{k=1,2,3}$으로 조정한다. 이 조정은 가려지지 않은 패치를 정보 밀도가 더 낮은 영역으로 이동시킨다.

그림 4. 샘플링 함수 $S(x)$가 $\hat{\mu} = 0$에서 $\hat{\mu} = 1$로 이동함에 따라(녹색 상자), 가려지지 않은 패치는 정보 밀도가 높은 영역에서 낮은 영역으로 옮겨 간다(파란색 상자). 그림 이미지: 원문 PDF 5쪽.

GMM-CMSS 점진적 마스킹 전략에는 다음과 같은 장점이 있다. 1) 경량성: 사전학습에 필요한 추가 계산 비용은 무시할 수 있을 정도로 작다. 2) 객체 중심성: 사전학습 초기 단계에는 정보 밀도가 높은 영역이 더 많은 주목을 받는다. 3) 점진적 샘플링: 제안 전략은 정보 밀도가 높은 영역에서 낮은 영역으로 이동하므로, 쉬운 단계에서 어려운 단계로 진행하는 자기지도학습 과정을 촉진한다.

4.4. 후속 과제를 위한 M-SpecGene

그림 3(b)는 후속 과제에서 M-SpecGene을 미세조정하는 과정을 보여준다. 먼저 RGB 영상과 열화상 영상을 패치로 나누어 특징 임베딩 $\mathcal{F}_{rgb}, \mathcal{F}_t \in \mathbb{R}^{B \times C \times HW}$으로 만든다. F_{rgb}와 F_t를 배치 차원에서 이어 붙여 $\mathcal{F}_{rgbt} \in \mathbb{R}^{2B \times C \times HW}$를 구성한다. 이어서 RGB와 열화상 모달리티를 모두 표현할 수 있는 M-SpecGene ViT 인코더가 F_{rgbt}를 병렬로 처리한다. 다중 스펙트럼 특징을 간단하게 융합하기 위해 M-SpecGene의 출력 특징 $\mathcal{F}_{rgbt}^{out} \in \mathbb{R}^{2B \times C \times HW}$의 형태를 $\mathcal{F}_{rgbt}^{out} \in \mathbb{R}^{B \times 2C \times H \times W}$로 바꾼다. 마지막으로 F_{rgbt}^{out}를 탐지(ViTDet [34]), 분할(UperNet [59]), 또는 매칭(LoFTR [45])용 후속 과제 헤드에 입력한다. 이 작업 흐름은 두 가지 핵심 장점을 통해 다중 스펙트럼 융합에 새로운 통찰을 제공한다. 1) 단순한 융합 전략이 기반 모델의 능력을 활용하므로 복잡한 수작업 모듈 설계가 필요 없다. 2) RGB 기반 단일 모달리티 방법을 추가 수정 없이 RGBT 이중 모달리티 과제에 원활하게 적용할 수 있다.

5. 실험

5.1. 구현 세부 사항

사용할 수 있는 단일 모달리티 데이터와 정렬된 RGBT 데이터의 활용도를 극대화하기 위해, 먼저 ImageNet [7]과 단일 모달리티 열화상 데이터셋에서 M-SpecGene을 사전학습하여 인코더와 디코더 두 개를 초기화한다. 이어서 일관된 표현을 형성하도록 RGBT550K 데이터셋에서 M-SpecGene을 추가로 사전학습한다. RGB 영상과 열화상 영상에 동일한 전처리를 적용하며, 0.2배에서 1.0배 범위의 자르기와 50% 확률의 무작위 뒤집기를 포함한다. 기본 설정에서는 RGB 영상과 열화상 영상 모두에 초기에 90%의 마스킹 비율을 적용하고, GTX 4090 GPU 8개에서 기본 학습률 1.5×10^{-4} 및 반 주기 코사인 감쇠 스케줄을 사용하는 AdamW 최적화기로 학습한다. 기존 연구 [16, 36, 32]를 따라 자기지도 사전학습 이후 RGBT 다중 스펙트럼 후속 과제에서 M-SpecGene의 전체 매개변수를 미세조정한다.

번역자 주: ‘GTX 4090’은 원문 표기 그대로이며 GPU 제품명을 임의로 바꾸지 않았다.

5.2. RGBT 다중 스펙트럼 객체 탐지

실험 설정: KAIST [21], LLVIP [24], FLIR [71]의 세 데이터셋을 사용하여 다중 스펙트럼 객체 탐지에서 M-SpecGene을 검증한다. KAIST 데이터셋의 보행자 탐지는 영상당 거짓 양성 수에 따른 로그 평균 미검출률(MR^{-2})로 평가한다. LLVIP와 FLIR 데이터셋에서는 평균 정밀도 평균(mean Average Precision, mAP)을 평가에 사용한다. 기본형 비전 트랜스포머의 능력을 충분히 활용하기 위해 ViTDet [34]를 탐지기로 사용한다. RGB 영상과 열화상 영상에는 일관된 데이터 증강을 적용하며, ViT 인코더의 출력을 단순히 이어 붙여 RGBT 특징을 융합한다는 점에 주목할 필요가 있다.

결과와 분석: 표 1(a)와 같이 M-SpecGene은 KAIST 데이터셋의 아홉 개 평가 지표 중 일곱 개에서 가장 좋은 성능을 보이며, '전체(All)' 집합에서 기존 최고 방법인 UniRGB-IR [66]보다 1.47% 우수하다. FLIR와 LLVIP 데이터셋에서 M-SpecGene의 ViT-S 버전은 UniRGB-IR에 견줄 만한 성능을 보인다. 표 1(b)의 ViT-B 버전은 기반 모델의 강점을 더욱 잘 활용하여 기존 방법보다 높은 탐지 정확도를 달성한다. UniRGB-IR의 ViT-B는 먼저 COCO 데이터셋에서 사전학습하는 반면, M-SpecGene은 추가적인 성능 향상을 위해 고품질 RGB 탐지 데이터셋에 의존하지 않는다는 점에 유의해야 한다. 대규모 데이터에서 자기지도 방식으로 학습한 표현을 통해, M-SpecGene은 사람이 설계한 복잡한 모듈 없이 RGB와 적외선 모달리티를 효과적으로 융합할 수 있다.

표 1. 다중 스펙트럼 객체 탐지 과제를 위해 KAIST, FLIR, LLVIP 데이터셋에서 제안한 M-SpecGene을 평가한 결과.

표 1(a). MR^{-2}로 평가한 KAIST 데이터셋의 아홉 개 시험 하위집합 비교 결과. '없음·부분·심함'은 가림 정도이며, 원문의 None·Partial·Heavy에 대응한다.

같은 표의 열을 나누어 표시: 1/2

방법	근거리	중거리	원거리	가림 없음	부분 가림	심한 가림
ACF [20]	28.74	53.67	88.20	62.94	81.40	88.08
Halfway Fusion [37]	8.13	30.34	75.70	43.13	65.21	74.36
IATDNN+IASS [12]	0.04	28.55	83.42	45.43	46.25	64.57
CLAN [74]	3.71	19.04	55.82	30.31	41.57	62.48
MSDS-R-CNN [27]	1.29	16.19	63.73	29.86	38.71	63.37
AR-CNN [75]	0.00	16.08	69.00	31.40	38.63	55.73
MBNet [80]	0.00	16.07	55.99	27.74	35.43	59.14
TSFADet [65]	0.00	15.99	50.71	25.63	37.29	65.67
CMPD [31]	0.00	12.99	51.22	24.04	33.88	59.37
CAGTDet [67]	0.00	14.00	49.40	24.48	33.20	59.35
C2Former [64]	0.00	13.71	48.14	23.91	32.84	57.81
RSDet [79]	0.00	12.13	39.80	20.49	33.25	57.60
UniRGB-IR (ViT-B) [66]	0.00	13.44	38.21	20.26	31.67	55.03
M-SpecGene (ViT-S)	0.03	16.00	40.54	22.70	33.92	55.91
M-SpecGene (ViT-B)	0.00	12.05	34.57	18.20	33.32	55.85

같은 표의 열을 나누어 표시: 2/2

방법	근거리	주간	야간	전체
ACF [20]	28.74	64.31	75.06	67.74
Halfway Fusion [37]	8.13	47.58	52.35	49.18
IATDNN+IASS [12]	0.04	49.02	49.37	48.96
CLAN [74]	3.71	36.02	32.38	35.53
MSDS-R-CNN [27]	1.29	32.06	38.83	34.15

방법	근거리	주간	야간	전체
AR-CNN [75]	0.00	34.36	36.12	34.95
MBNet [80]	0.00	32.37	30.95	31.87
TSFADet [65]	0.00	31.76	27.44	30.74
CMPD [31]	0.00	28.30	30.56	28.98
CAGTDet [67]	0.00	28.79	27.73	28.96
C2Former [64]	0.00	28.48	26.67	28.39
RSDet [79]	0.00	25.83	26.48	26.02
UniRGB-IR (ViT-B) [66]	0.00	25.93	23.95	25.21
M-SpecGene (ViT-S)	0.03	28.28	25.15	27.28
M-SpecGene (ViT-B)	0.00	25.66	19.42	23.74

표 1(b). mAP 기준 FLIR 및 LLVIP 데이터셋 평가.

방법	FLIR mAP	FLIR mAP_{50}	FLIR mAP_{75}	LLVIP mAP	LLVIP mAP_{50}	LLVIP mAP_{75}
Halfway Fusion [37]	35.8	71.5	-	55.1	91.4	-
GAFF [72]	37.4	74.7	31.3	55.8	94.0	60.2
PronEn [5]	37.9	75.5	31.8	51.5	93.4	50.2
CSAA [3]	41.3	79.2	37.4	59.2	94.3	66.6
CALNet [15]	-	-	-	63.9	-	-
TIRDet [57]	44.3	81.4	41.1	64.2	96.3	73.1
MMI-Det [70]	40.5	79.8	35.8	64.4	98.9	73.5
GFL-Res50 [33]	44.0	78.1	-	-	-	-
ICAFusion [42]	41.4	79.2	36.9	-	-	-
CrossFormer [26]	42.1	79.3	38.5	65.1	97.4	75.4
RSNet [79]	41.4	81.1	-	59.2	94.3	-
UniRGB-IR (ViT-B) [66]	44.1	81.4	40.2	63.2	96.1	72.2
M-SpecGene (ViT-S)	43.7	82.4	39.4	63.4	96.3	74.1
M-SpecGene (ViT-B)	44.7	84.8	40.1	65.3	97.4	75.4

5.3. RGBT 다중 스펙트럼 의미 분할

실험 설정: 다중 스펙트럼 의미 분할 과제의 검증에는 최근 공개된 고품질 샘플을 갖춘 데이터셋 세 개를 사용한다. SemanticRT [22], MVSeg [23], FMB [38] 데이터셋은 각각 13개, 26개, 15개 범주를 포함한다. 모든 범주에 대한 교집합 대 합집합 비율의 평균(mean Intersection over Union, mIoU)으로 의미 분할 성능을 평가한다. MAE [14]를 따라 UperNet [59]을 기본 분할 프레임워크로 사용한다. 모델 구조는 그대로 유지하고 단순한 이어 붙이기 연산만 추가한다.

결과와 분석: 표 2(a)의 SemanticRT 데이터셋과 표 2(b)의 MVSeg 데이터셋에서 M-SpecGene을 경쟁 방법들과 비교한다. 정량적인 결과는 두 데이터셋 모두에서 M-SpecGene이 효과적임을 확인해 준다. MVNet [23]은 다중 스펙트럼 비디오 클립을 사용하여 추가적인 시간 정보를 활용하는 단순한 기준 모델이다. 반면 M-SpecGene은 프레임 수준의 정보만 사용하고도 더 높은 mIoU 정확도를 달성한다. 표 5는 FMB 데이터셋에서 M-SpecGene이 다른 경쟁 방법보다 우수하지만 일부 지표에서는 MSRS [73]에 못 미침을 보여준다. FMB는 검증 샘플이 280개뿐인 소규모 데이터셋이다. Segformer [61]에 기반한 복잡한 융합 모듈을 포함하는 MSRS와 UniRGB-IR은 특징 융합에 단순한 이어 붙이기 연산만 사용하는 M-SpecGene보다 FMB에 더 쉽게 적합되는 경향이 있다. M-SpecGene은 특히 범주 다양성이 크고, 데이터셋

규모가 크며, 과제 복잡도가 높은 상황에서 더 우수한 성능을 달성하는 경향이 있다.

번역자 주: 위 문단의 '표 5' 및 'MSRS [73]'는 원문 본문 표기를 유지한 것이다. FMB 결과는 실제로 표 3에 있으며, 해당 표와 참고문헌 [73]의 방법명은 MRFS이다.

표 2. 다중 스펙트럼 의미 분할 과제의 SemanticRT 및 MVSeg 데이터셋에서 M-SpecGene을 비교한 결과.

표 2(a). SemanticRT 시험 집합의 클래스별 정량적 분할 결과. 열 이름은 원문 Bkg·Bike·Bicyclist·Car·Tricycle·Box·Pole·Curve·Person·mIoU 순서이다. 'Curve'라는 원문 클래스 표기도 유지했다.

같은 표의 열을 나누어 표시: 1/2

방법	배경	자전거	자전거 탑승자	자동차	삼륜차	상자
PSTNet [43]	95.03	62.25	58.48	85.41	44.18	83.00
MFNet [13]	96.31	65.87	64.07	89.70	62.10	83.93
RTFNet [46]	96.40	67.96	67.41	90.39	65.96	85.91
EGFNet [82]	96.57	71.26	70.86	90.52	71.51	85.41
ECM [22]	96.55	75.04	75.50	90.26	74.01	85.61
UniRGB-IR (ViT-B) [66]	96.33	68.72	64.79	90.33	69.43	85.57
M-SpecGene (ViT-S)	96.74	73.82	71.17	91.01	73.08	85.87
M-SpecGene (ViT-B)	96.81	75.99	75.51	91.11	76.79	86.05

같은 표의 열을 나누어 표시: 2/2

방법	배경	기둥	Curve	사람	mIoU (%)
PSTNet [43]	95.03	71.65	62.15	72.21	67.98
MFNet [13]	96.31	77.14	66.18	80.29	74.08
RTFNet [46]	96.40	78.02	67.22	78.90	75.48
EGFNet [82]	96.57	76.49	66.92	83.74	77.44
ECM [22]	96.55	77.23	68.28	85.02	79.26
UniRGB-IR (ViT-B) [66]	96.33	76.44	65.56	79.79	75.21
M-SpecGene (ViT-S)	96.74	77.95	68.51	84.64	78.42
M-SpecGene (ViT-B)	96.81	78.41	68.64	85.66	79.84

표 2(b). MVSeg 데이터셋의 정량적 평가.

방법	백본	mIoU (%)
OCRNet [68]	ResNet-50	52.38
LMANet [40]	ResNet-50	52.73
DeepLabv3+ [4]	ResNet-50	51.59
MVNet_DeepLabv3+ [23]	ResNet-50	54.52
DPLNet [9]	MiT-B5	57.90
UniRGB-IR (ViT-B) [9]	ViT-B	56.46
M-SpecGene (ViT-S)	ViT-S	60.49
M-SpecGene (ViT-B)	ViT-B	63.02

표 3. FMB 분할 데이터셋 평가. Vege.는 식생을 뜻한다.

방법	사람	트럭	식생	기둥	mIoU (%)
SegMiF [38]	65.5	42.4	85.1	35.7	58.5
MDRNet+ [78]	67.0	27.0	82.7	45.3	55.5
SGFNet [55]	67.2	34.6	82.7	42.8	56.0
MRFS [73]	71.3	34.4	87.0	53.6	61.2
UniRGB-IR (ViT-B) [66]	66.5	36.3	85.6	42.1	59.8
M-SpecGene (ViT-S)	68.8	22.6	86.2	50.0	56.5
M-SpecGene (ViT-B)	65.6	44.4	86.9	52.8	60.1

5.4. RGBT 교차 모달리티 특징 매칭

실험 설정: 정렬 품질이 높다는 점을 고려하여 LLVIP [24] 데이터셋으로 교차 모달리티 특징 매칭을 평가한다. 곡선 아래 면적(Area Under the Curve, AUC)을 평가 지표로 사용한다. 널리 알려진 LoFTR [45]을 기본 프레임워크로 채택하고 백본을 ViT-S로 바꾼다. 국소성을 강화하기 위해 합성곱 스템 [60]을 포함한다.

결과와 분석: 표 5는 전통적으로 사람이 설계한 특징 기술자가 LLVIP 데이터셋의 복잡한 장면을 다루기 어려움을 보여준다. 또한 검출기 기반 방법은 두 모달리티에서 반복해서 검출되는 키포인트를 추출하기 어려워 만족스럽지 못한 결과를 낸다. M-SpecGene은 다양한 임계값에서 다른 방법보다 상당히 우수하다. 학습된 모달리티 불변 표현이 잠재 공간에서 모달리티의 특성 차이를 줄여 RGBT 특징 매칭을 쉽게 하기 때문이다.

번역자 주: 위 문단의 '표 5'는 원문 표기이며, 실제 RGBT 특징 매칭 결과는 표 4이다.

표 4. RGBT 특징 매칭 평가. 화살표 ↑는 클수록 좋음을 나타낸다. @3°, @5°, @10°은 각각의 각도 임계값에서 평가한 값이다.

분류	방법	@3° ↑	@5° ↑	@10° ↑
검출기 기반	RIFT [30]	0.0	0.0	0.0
검출기 기반	POS-GIFT [18]	0.0	0.0	0.4
검출기 기반	ReDFeat [8]	0.0	0.0	0.0
검출기 기반	SP+LG [35]	1.1	8.4	16.2
검출기 없음	SemLA [62]	0.0	0.2	1.2
검출기 없음	LoFTR [45]	18.8	29.7	46.2
검출기 없음	제안 방법 (ViT-S)	20.5	31.7	48.2

5.5. RGBT 다중 스펙트럼 현저 객체 탐지

실험 설정: 다중 스펙트럼 현저 객체 탐지 평가에는 VT821 [52], VT1000 [47], VT5000 [50], VI-RGBT1500 [44]을 사용한다. F-measure($adpF$, F_β^{max}), E-Measure($adpE$, E_ξ^{max}), S-Measure(S), 평균 절대 오차(Mean Absolute Error, MAE)를 지표로 채택한다. UperNet [59]을 기본 프레임워크로 사용하며, VT5000 데이터셋의 영상 쌍 2,500개를 학습 데이터로 취급하고 나머지 및 다른 데이터셋을 시험 집합으로 사용하는 일반적인 설정을 따른다.

결과와 분석: 표 5와 표 6의 실험은 M-SpecGene이 11개 하위집합 지표에서 기존 방법보다 더 좋은 결과를 달성함을 보여준다. 특히 VT5000보다 VT821, VT1000, VI-RGBT1500 데이터셋에서 두드러진 향상을 보인다. 이는 M-SpecGene의 우수한 일반화 능력을 부각한다.

표 5. VI-RGBT1500 시험 결과. ↑는 클수록, ↓는 작을수록 좋음을 뜻한다.

방법	Eξmax ↑	Fβmax ↑	Sα ↑	MAE ↓
MGFL [19]	0.822	0.727	0.745	0.084

방법	Eξmax ↑	Fβmax ↑	Sα ↑	MAE ↓
MIDD [49]	0.928	0.859	0.867	0.049
CGFNet [54]	0.927	0.870	0.865	0.042
ADF [50]	0.892	0.815	0.830	0.074
MGAI [44]	0.940	0.879	0.881	0.038
제안 방법 (ViT-S)	0.847	0.722	0.781	0.081
제안 방법 (ViT-B)	0.942	0.877	0.888	0.033

표 6. 다중 스펙트럼 현저 객체 탐지 과제의 VT821, VT1000, VT5000 데이터셋에서 M-SpecGene을 비교한 결과.

같은 표의 열을 나누어 표시: 1/3

방법	VT821 S ↑	VT821 adpE ↑	VT821 adpF ↑	VT821 MAE ↓	VT1000 S ↑	VT1000 adpE ↑
S2MA [39]	0.811	0.813	0.709	0.098	0.918	0.912
JLDCF [11]	0.839	0.830	0.726	0.076	0.912	0.899
MTMR [52]	0.725	0.815	0.662	0.109	0.706	0.836
FMSF [76]	0.760	0.796	0.640	0.080	0.873	0.899
MIDD [49]	0.871	0.895	0.803	0.033	0.915	0.933
ADF [50]	0.810	0.842	0.717	0.077	0.910	0.921
LSNet [83]	0.877	0.911	0.827	0.033	0.924	0.936
UniRGB-IR (ViT-B) [66]	0.881	0.895	0.806	0.039	0.939	0.943
M-SpecGene (ViT-S)	0.783	0.826	0.703	0.079	0.867	0.889
M-SpecGene (ViT-B)	0.891	0.919	0.862	0.028	0.935	0.952

같은 표의 열을 나누어 표시: 2/3

방법	VT821 S ↑	VT1000 adpF ↑	VT1000 MAE ↓	VT5000 S ↑	VT5000 adpE ↑	VT5000 adpF ↑
S2MA [39]	0.811	0.848	0.029	0.853	0.864	0.743
JLDCF [11]	0.839	0.829	0.030	0.861	0.860	0.739
MTMR [52]	0.725	0.715	0.119	0.680	0.795	0.595
FMSF [76]	0.760	0.823	0.037	0.814	0.864	0.734
MIDD [49]	0.871	0.880	0.027	0.868	0.896	0.799
ADF [50]	0.810	0.847	0.034	0.864	0.891	0.778
LSNet [83]	0.877	0.887	0.022	0.876	0.916	0.827
UniRGB-IR (ViT-B) [66]	0.881	0.894	0.018	0.906	0.935	0.849
M-SpecGene (ViT-S)	0.783	0.827	0.043	0.853	0.892	0.803
M-SpecGene (ViT-B)	0.891	0.925	0.015	0.892	0.928	0.872

같은 표의 열을 나누어 표시: 3/3

방법	VT821 S ↑	VT5000 MAE ↓
S2MA [39]	0.811	0.053
JLDCF [11]	0.839	0.050
MTMR [52]	0.725	0.114

방법	VT821 S ↑	VT5000 MAE ↓
FMSF [76]	0.760	0.055
MIDD [49]	0.871	0.043
ADF [50]	0.810	0.048
LSNet [83]	0.877	0.036
UniRGB-IR (ViT-B) [66]	0.881	0.027
M-SpecGene (ViT-S)	0.783	0.044
M-SpecGene (ViT-B)	0.891	0.028

5.6. 절제 실험

사전학습 모델 비교: 표 7(a)에서는 KAIST 데이터셋을 이용한 다중 스펙트럼 객체 탐지와 LLVIP 데이터셋을 이용한 교차 모달리티 특징 매칭에서 서로 다른 사전학습 모델의 성능을 비교한다. 처음부터 학습한 ViT는 FLIR에서 mAP 성능이 낮다는 것을 관찰했다. 반면 기본 MAE로 사전학습한 ViT는 지도학습(Sup.)으로 사전학습한 ViT와 비교해 mAP_{50}을 40.6%에서 43.0%로 높인다. M-SpecGene은 mAP_{50}을 44.8%까지 추가로 높여 우수한 성능을 보인다. LLVIP 데이터셋에서 M-SpecGene은 AUC@10°을 41.2에서 48.2로 크게 높이는 반면, 지도학습 및 기본 MAE 사전학습 ViT 모델은 모두 매칭 정확도를 떨어뜨린다. 우리는 이 차이가 탐지 과제와 매칭 과제의 본질적인 차이에서 비롯된다고 본다. 탐지 과제는 두 모달리티를 활용하여 상보적인 특징을 생성하는 것이 목표인 반면, 매칭 과제는 두 모달리티가 공유하는 공통 특징을 식별하는 데 초점을 맞춘다. 따라서 단일 모달리티인 ImageNet 데이터셋의 사전학습은 교차 모달리티 특징 매칭에 필요한 대칭적 표현을 훼손할 수 있다. 종합하면, 모달리티 불변 표현을 위한 효과적인 사전학습은 범용 다중 스펙트럼 기반 모델에 매우 중요하다.

번역자 주: 이 문단에는 원문 내부의 불일치가 있다. 첫 문장은 탐지 데이터셋을 'KAIST'라고 하지만 이어지는 문장은 'FLIR'라고 한다. 또한 40.6 및 43.0은 표 7(a)의 mAP 열 값인데 본문은 이를 mAP_{50}이라고 부르며, 본문의 최종값 44.8과 표의 44.7도 다르다. 번역 본문과 표는 각각의 원문을 그대로 유지했다.

RGBT 표현 구조: RGB와 열화상 모달리티 모두에 효과적인 자기지도 표현 구조를 조사하기 위해 네 가지 접근법을 설계한다. 1) 기본 MAE [14]: 입력 수준에서 RGB 영상과 열화상 영상을 섞고 기본 MAE를 사용한다. 2) 채널 이어 붙이기: RGB 영상과 열화상 영상을 채널 차원에서 이어 붙인다. 3) 보조 분기: 상보적으로 마스킹한 RGB와 열화상 패치를 가중치를 공유하는 인코더로 처리한다. 이후 열화상 특징이 교차 어텐션 층에서 보조 정보 역할을 하여, RGB 디코더가 가려진 영역을 복원하도록 돕는다. 4) 시아미즈 기반: 가중치를 공유하는 인코더를 통해 RGB와 열화상 모달리티가 일관된 표현을 학습하도록 유도하고, 각 모달리티에 독립된 디코더를 적용한다. 표 7(b)는 시아미즈 구조가 가장 좋은 결과를 달성함을 보여준다. 이 구조는 대칭성을 보존하면서 교차 모달리티 상보성을 충분히 활용한다.

마스킹 전략: 표 7(c)에서 서로 다른 마스킹 전략 네 가지를 비교한다. 1) 무작위 마스킹. 2) CMSS가 낮은 영역의 가우시안 마스킹. 3) CMSS가 높은 영역의 가우시안 마스킹. 4) GMM-CMSS 점진적 마스킹이다. 실험 결과, 하나의 정보 밀도 영역에만 집중하면 성능이 떨어진다. 반면 GMM-CMSS 점진적 마스킹은 유연하고 쉬운 단계에서 어려운 단계로 진행하는 객체 중심 학습을 가능하게 하므로 더 강건한 표현을 만든다.

디코더 깊이: 표 7(d)는 디코더 깊이가 4일 때 가장 좋은 결과를 보임을 보여준다. 이는 독립적인 디코더 두 개를 갖는 시아미즈 구조에서는 MAE [14]의 기본 디코더 깊이를 줄일 수 있음을 나타낸다.

마스킹 비율: 표 7(e)는 마스킹 비율을 낮추면 특히 열화상 모달리티의 복원 난도가 줄어들고 mAP가 약간 감소함을 보여준다. 마스킹 비율을 더 높이면 GMM-CMSS 전략의 효과가 저하된다. 따라서 기본 마스킹 비율을 90%로 설정한다.

표 7. 사전학습 모델, 구조, 마스킹 전략, 디코더 깊이, 마스킹 비율에 관한 M-SpecGene의 절제 분석.

표 7(a). 서로 다른 사전학습 모델 비교. IN1K는 ImageNet-1K 표기이며, '처음부터'는 From Scratch, '지도학습'은 Sup.에 대응한다.

방법	mAP	mAP_{50}	mAP_{75}	@3° ↑	@5° ↑	@10° ↑
처음부터 학습	36.0	70.6	32.0	12.5	23.6	41.2
지도학습 (IN1K)	40.6	79.3	34.0	12.5	23.3	40.3
MAE (IN1K)	43.0	82.8	37.8	8.4	18.7	37.0
M-SpecGene	44.7	84.8	40.1	20.5	31.7	48.2

표 7(b). 구조.

구조	mAP_{50}
기본 MAE	83.1
이어 붙이기	80.1
보조 분기	83.5
시아미즈	83.8

표 7(c). 마스킹 방식.

마스킹	mAP_{50}
무작위	83.8
낮은 CMSS	83.6
높은 CMSS	83.4
GMM-CMSS	84.8

표 7(d). 디코더 깊이.

블록 수	mAP_{50}
2	84.1
4	84.8
8	84.5

표 7(e). 마스킹 비율.

비율	mAP_{50}
85%	84.4
90%	84.8
95%	84.1

특징 시각화 및 통계 분석: 먼저 사전학습 모델이 추출한 RGB와 열화상 특징을 이어 붙이고, 이어 붙인 객체 특징과 배경 특징을 시각적으로 분석한다. 그림 5(b–c)와 같이 M-SpecGene이 추출한 객체 특징은 Sup. (IN1K) 사전학습 모델의 객체 특징보다 더 높은 판별력을 보인다. 이어서 세 개의 탐지 데이터셋에서 객체 특징과 배경 특징의 차이를 통계적으로 분석한다. 구체적으로 각 샘플에서 객체와 배경 특징 사이의 바서슈타인(Wasserstein) 거리를 계산하고, 서로 다른 사전학습 모델의 바서슈타인 거리 분포 통계를 제시한다. 그림 5(d–f)는 처음부터 학습한 모델의 전반적인 바서슈타인 거리가 더 작고, MAE (IN1K)와 Sup. (IN1K)의 분포에서는 더 큰 바서슈타인 거리를 보임을 나타낸다. 특히 M-SpecGene의 바서슈타인 거리 분포가 가장 큰 쪽에 위치하며, 이는 객체와 배경 사이의 특징 차이가 더 큼을 나타낸다. 이 결과는 GMM-CMSS 점진적 마스킹 전략이 더욱 객체 중심적인 표현의 학습을 촉진하고, 그에 따라 더 판별력 있는 특징의 생성을 돕는다는 것을 시사한다.

그림 5. (a) 특징 시각화를 위한 샘플. (b–c) 객체 영역과 배경 영역의 이어 붙인 RGBT 특징에 대한 t-SNE 시각화. (d–f) 세 개 탐지 데이터셋에서 객체와 배경 특징 사이의 바서슈타인 거리 통계 분포. 그림 이미지: 원문 PDF 8쪽.

6. 결론

우리는 기존의 과제별 연구를 하나의 패러다임으로 전환하기 위해 다중 스펙트럼 기반 모델을 구축하는 첫 시도를 수행한다. RGBT 데이터셋에 내재한 정보 불균형의 영향을 완화하기 위해, 교차 모달리티 정보 밀도를 측정하는 CMSS 지표를 도입하고 유연하며 쉬운 단계에서 어려운 단계로 나아가는 객체 중심 사전학습을 가능하게 하는 GMM-CMSS 점진적 마스킹 전략을 개발한다. 제안한 M-SpecGene은 잠재 공간에서 RGB와 열화상 모달리티를 모두 효과적으로 표현하므로 사람이 설계한 모듈을 필요로 하지 않으며, 다중 스펙트럼 융합에 새로운 통찰을 제공한다. 네 가지 과제에 걸친 11개 데이터셋의 광범위한 실험을 통해 M-SpecGene의 일반화 능력을 검증했다. M-SpecGene은 신중하게 구축한 고품질 RGBT550K 데이터셋을 자기지도 사전학습에 충분히 활용하고, 추가 수정 없이 RGB 단일 모달리티 방법을 RGBT 이중 모달리티 과제에 원활하게 적용할 수 있다. 이 연구가 범용 기반 모델의 관점에서 다중 스펙트럼 비전의 활용을 발전시키기를 바란다.

감사의 글

이 연구는 National Science Fund for Distinguished Young Scholars(62025108)의 지원을 받았다. 또한 Agency for Science, Technology and Research(A*STAR)의 IAF-ICP Programme I2501E0041 및 Schaeffler-NTU Corporate Lab(SHARE@NTU)에서 일부 지원을 받았으며, National Research Foundation Singapore Competitive Research Program(과제 번호 CRP29-2022-0003)에서도 일부 지원을 받았다. 이 연구는 Nanyang Technological University 전기전자공학부의 Rapid-Rich Object Search(ROSE) Lab에서 수행되었다.

참고문헌

아래 83개 항목의 저자명·제목·학술지/학회명·서지 수치와 원문의 문헌 번호는 영어로 유지한다.

[1] Zijia An, Chunlei Liu, and Yuqi Han. Effectiveness guided cross-modal information sharing for aligned rgb-t object detection. IEEE Signal Processing Letters, 29:2562–2566, 2022.

[2] Muhammad Awais, Muzammal Naseer, Salman Khan, Rao Muhammad Anwer, Hisham Cholakkal, Mubarak Shah, Ming-Hsuan Yang, and Fahad Shahbaz Khan. Foundational models defining a new era in vision: A survey and outlook. arXiv preprint arXiv:2307.13721, 2023.

[3] Yue Cao, Junchi Bin, Jozsef Hamari, Erik Blasch, and Zheng Liu. Multimodal object detection by channel switching and spatial attention. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 403–411, 2023.

[4] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam. Encoder-decoder with atrous separable convolution for semantic image segmentation. In Proceedings of the European conference on computer vision (ECCV), pages 801–818, 2018.

[5] Yi-Ting Chen, Jinghao Shi, Zelin Ye, Christoph Mertz, Deva Ramanan, and Shu Kong. Multimodal object detection via probabilistic ensembling. In European Conference on Computer Vision, pages 139–158. Springer, 2022.

[6] Fuqin Deng, Hua Feng, Mingjian Liang, Hongmin Wang, Yong Yang, Yuan Gao, Junfeng Chen, Junjie Hu, Xiyue Guo, and Tin Lun Lam. Feanet: Feature-enhanced attention network for rgb-thermal real-time semantic segmentation. In 2021 IEEE/RSJ international conference on intelligent robots and systems (IROS), pages 4467–4473. IEEE, 2021.

[7] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In 2009 IEEE conference on computer vision and pattern recognition, pages 248–255. Ieee, 2009.

[8] Yuxin Deng and Jiayi Ma. Redfeat: Recoupling detection and description for multimodal feature learning. IEEE Transactions on Image Processing, 32:591–602, 2022.

[9] Shaohua Dong, Yunhe Feng, Qing Yang, Yan Huang, Dongfang Liu, and Heng Fan. Efficient multimodal semantic segmentation via dual-prompt learning. arXiv preprint arXiv:2312.00360, 2023.

[10] Alexey Dosovitskiy. An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929, 2020.

[11] Keren Fu, Deng-Ping Fan, Ge-Peng Ji, Qijun Zhao, Jianbing Shen, and Ce Zhu. Siamese network for rgb-d salient object detection and beyond. IEEE transactions on pattern analysis and machine intelligence, 44(9):5541–5559, 2021.

[12] Dayan Guan, Yanpeng Cao, Jiangxin Yang, Yanlong Cao, and Michael Ying Yang. Fusion of multispectral data through illumination-aware deep neural networks for pedestrian detection. Information Fusion, 50:148–157, 2019.

[13] Qishen Ha, Kohei Watanabe, Takumi Karasawa, Yoshitaka Ushiku, and Tatsuya Harada. Mfnet: Towards real-time semantic segmentation for autonomous vehicles with multi-spectral scenes. In 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pages 5108–5115. IEEE, 2017.

[14] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 16000–16009, 2022.

[15] Xiao He, Chang Tang, Xin Zou, and Wei Zhang. Multispectral object detection via cross-modal conflict-aware learning. In Proceedings of the 31st ACM International Conference on Multimedia, page 1465–1474, New York, NY, USA, 2023. Association for Computing Machinery.

[16] Danfeng Hong, Bing Zhang, Xuyang Li, Yuxuan Li, Chenyu Li, Jing Yao, Naoto Yokoya, Hao Li, Pedram Ghamisi, Xiuping Jia, et al. Spectralgpt: Spectral remote sensing foundation model. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024.

[17] Zejiang Hou, Fei Sun, Yen-Kuang Chen, Yuan Xie, and Sun-Yuan Kung. Milan: Masked image pretraining on language assisted representation. arXiv preprint arXiv:2208.06049, 2022.

[18] Zhuolu Hou, Yuxuan Liu, and Li Zhang. Pos-gift: A geometric and intensity-invariant feature transformation for multimodal images. Information Fusion, 102:102027, 2024.

[19] Liming Huang, Kechen Song, Jie Wang, Menghui Niu, and Yunhui Yan. Multi-graph fusion and learning for rgbt image saliency detection. IEEE Transactions on Circuits and Systems for Video Technology, 32(3):1366–1377, 2021.

[20] Soonmin Hwang, Jaesik Park, Namil Kim, Yukyung Choi, and In So Kweon. Multispectral pedestrian detection: Benchmark dataset and baseline. In 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pages 1037–1045, 2015a.

[21] Soonmin Hwang, Jaesik Park, Namil Kim, Yukyung Choi, and In So Kweon. Multispectral pedestrian detection: Benchmark dataset and baseline. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 1037–1045, 2015b.

[22] Wei Ji, Jingjing Li, Cheng Bian, Zhicheng Zhang, and Li Cheng. Semanticrt: A large-scale dataset and method for robust semantic segmentation in multispectral images. In Proceedings of the 31st ACM International Conference on Multimedia, pages 3307–3316, 2023a.

[23] Wei Ji, Jingjing Li, Cheng Bian, Zongwei Zhou, Jiaying Zhao, Alan L Yuille, and Li Cheng. Multispectral video semantic segmentation: A benchmark dataset and baseline. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 1094–1104, 2023b.

[24] Xinyu Jia, Chuang Zhu, Minzhen Li, Wenqi Tang, and Wenli Zhou. Llvip: A visible-infrared paired dataset for low-light vision. In Proceedings of the IEEE/CVF international conference on computer vision, pages 3496–3504, 2021.

[25] Ioannis Kakogeorgiou, Spyros Gidaris, Bill Psomas, Yannis Avrithis, Andrei Bursuc, Konstantinos Karantzalos, and Nikos Komodakis. What to hide from your students: Attention-guided masked image modeling. In European Conference on Computer Vision, pages 300–318. Springer, 2022.

[26] Seungik Lee, Jaehyeong Park, and Jinsun Park. Crossformer: Cross-guided attention for multi-modal object detection. Pattern Recognition Letters, 179:144–150, 2024.

[27] Chengyang Li, Dan Song, Ruofeng Tong, and Min Tang. Multispectral Pedestrian Detection via Simultaneous Detection and Segmentation. arXiv e-prints, art. arXiv:1808.04818, 2018.

[28] Chenglong Li, Wanlin Xue, Yaqing Jia, Zhichen Qu, Bin Luo, Jin Tang, and Dengdi Sun. Lasher: A large-scale high-diversity benchmark for rgbt tracking. IEEE Transactions on Image Processing, 31:392–404, 2021.

[29] Gang Li, Heliang Zheng, Daqing Liu, Chaoyue Wang, Bing Su, and Changwen Zheng. Semmae: Semantic-guided masking for learning masked autoencoders. Advances in Neural Information Processing Systems, 35:14290–14302, 2022a.

[30] Jiayuan Li, Qingwu Hu, and Mingyao Ai. Rift: Multi-modal image matching based on radiation-variation insensitive feature transform. IEEE Transactions on Image Processing, 29:3296–3310, 2019.

[31] Qing Li, Changqing Zhang, Qinghua Hu, Huazhu Fu, and Pengfei Zhu. Confidence-aware fusion using dempster-shafer theory for multispectral pedestrian detection. IEEE Transactions on Multimedia, 25:3420–3431, 2022b.

[32] Weijie Li, Wei Yang, Yuenan Hou, Li Liu, Yongxiang Liu, and Xiang Li. Saratr-x: Toward building a foundation model for sar target recognition. IEEE Transactions on Image Processing, 34:869–884, 2025.

[33] Xiang Li, Wenhai Wang, Lijun Wu, Shuo Chen, Xiaolin Hu, Jun Li, Jinhui Tang, and Jian Yang. Generalized focal loss: Learning qualified and distributed bounding boxes for dense object detection. Advances in Neural Information Processing Systems, 33:21002–21012, 2020.

[34] Yanghao Li, Hanzi Mao, Ross Girshick, and Kaiming He. Exploring plain vision transformer backbones for object detection. In European conference on computer vision, pages 280–296. Springer, 2022c.

[35] Philipp Lindenberger, Paul-Edouard Sarlin, and Marc Pollefeys. Lightglue: Local feature matching at light speed. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 17627–17638, 2023.

[36] Fangcen Liu, Chenqiang Gao, Yaming Zhang, Junjie Guo, Jinghao Wang, and Deyu Meng. Infmae: A foundation model in the infrared modality. In European Conference on Computer Vision, pages 420–437. Springer, 2025.

[37] Jingjing Liu, Shaoting Zhang, Shu Wang, and Dimitris N. Metaxas. Multispectral Deep Neural Networks for Pedestrian Detection. arXiv e-prints, art. arXiv:1611.02644, 2016.

[38] Jinyuan Liu, Zhu Liu, Guanyao Wu, Long Ma, Risheng Liu, Wei Zhong, Zhongxuan Luo, and Xin Fan. Multi-interactive feature learning and a full-time multi-modality benchmark for image fusion and segmentation. In Proceedings of the IEEE/CVF international conference on computer vision, pages 8115–8124, 2023.

[39] Nian Liu, Ni Zhang, and Junwei Han. Learning selective self-mutual attention for rgb-d saliency detection. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 13756–13765, 2020.

[40] Matthieu Paul, Martin Danelljan, Luc Van Gool, and Radu Timofte. Local memory attention for fast video semantic segmentation. In 2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pages 1102–1109. IEEE, 2021.

[41] Fang Qingyun, Han Dapeng, and Wang Zhaokui. Cross-modality fusion transformer for multispectral object detection. arXiv preprint arXiv:2111.00273, 2021.

[42] Jifeng Shen, Yifei Chen, Yue Liu, Xin Zuo, Heng Fan, and Wankou Yang. Icafusion: Iterative cross-attention guided feature fusion for multispectral object detection. Pattern Recognition, 145:109913, 2024.

[43] Shreyas S Shivakumar, Neil Rodrigues, Alex Zhou, Ian D Miller, Vijay Kumar, and Camillo J Taylor. Pst900: Rgb-thermal calibration, dataset and segmentation network. In 2020 IEEE international conference on robotics and

automation (ICRA), pages 9441–9447. IEEE, 2020.

[44] Kechen Song, Liming Huang, Aojun Gong, and Yunhui Yan. Multiple graph affinity interactive network and a variable illumination dataset for rgbt image salient object detection. IEEE Transactions on Circuits and Systems for Video Technology, 33(7):3104–3118, 2022.

[45] Jiaming Sun, Zehong Shen, Yuang Wang, Hujun Bao, and Xiaowei Zhou. Loftr: Detector-free local feature matching with transformers. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 8922–8931, 2021.

[46] Yuxiang Sun, Weixun Zuo, and Ming Liu. Rtfnet: Rgb-thermal fusion network for semantic segmentation of urban scenes. IEEE Robotics and Automation Letters, 4(3):2576–2583, 2019.

[47] Zhengzheng Tu, Tian Xia, Chenglong Li, Xiaoxiao Wang, Yan Ma, and Jin Tang. Rgb-t image saliency detection via collaborative graph learning. IEEE Transactions on Multimedia, 22(1):160–173, 2019.

[48] Zhengzheng Tu, Zhun Li, Chenglong Li, Yang Lang, and Jin Tang. Multi-interactive encoder-decoder network for rgbt salient object detection. arXiv e-prints, pages arXiv–2005, 2020.

[49] Zhengzheng Tu, Zhun Li, Chenglong Li, Yang Lang, and Jin Tang. Multi-interactive dual-decoder for rgb-thermal salient object detection. IEEE Transactions on Image Processing, 30:5678–5691, 2021.

[50] Zhengzheng Tu, Yan Ma, Zhun Li, Chenglong Li, Jieming Xu, and Yongtao Liu. Rgbt salient object detection: A large-scale dataset and benchmark. IEEE Transactions on Multimedia, 25:4163–4176, 2022.

[51] Di Wang, Meiqi Hu, Yao Jin, Yuchun Miao, Jiaqi Yang, Yichu Xu, Xiaolei Qin, Jiaqi Ma, Lingyu Sun, Chenxing Li, et al. Hypersigma: Hyperspectral intelligence comprehension foundation model. arXiv preprint arXiv:2406.11519, 2024.

[52] Guizhao Wang, Chenglong Li, Yunpeng Ma, Aihua Zheng, Jin Tang, and Bin Luo. Rgb-t saliency detection benchmark: Dataset, baselines, analysis and a novel approach. In Image and Graphics Technologies and Applications: 13th Conference on Image and Graphics Technologies and Applications, IGTA 2018, Beijing, China, April 8–10, 2018, Revised Selected Papers 13, pages 359–369. Springer, 2018.

[53] Haochen Wang, Kaiyou Song, Junsong Fan, Yuxi Wang, Jin Xie, and Zhaoxiang Zhang. Hard patches mining for masked image modeling. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 10375–10385, 2023a.

[54] Jie Wang, Kechen Song, Yanqi Bao, Liming Huang, and Yunhui Yan. Cgfnet: Cross-guided fusion network for rgb-t salient object detection. IEEE Transactions on Circuits and Systems for Video Technology, 32(5):2949–2961, 2022.

[55] Yike Wang, Gongyang Li, and Zhi Liu. Sgfnet: semantic-guided fusion network for rgb-thermal semantic segmentation. IEEE Transactions on Circuits and Systems for Video Technology, 33(12):7737–7748, 2023b.

[56] Zhou Wang, Alan C Bovik, Hamid R Sheikh, and Eero P Simoncelli. Image quality assessment: from error visibility to structural similarity. IEEE transactions on image processing, 13(4):600–612, 2004.

[57] Zeyu Wang, Fabien Colonnier, Jinghong Zheng, Jyotibdha Acharya, Wenyu Jiang, and Kejie Huang. Tirdet: Mono-modality thermal infrared object detection based on prior thermal-to-visible translation. In Proceedings of the 31st ACM International Conference on Multimedia, page 2663–2672, New York, NY, USA, 2023c. Association for Computing Machinery.

[58] Jiantao Wu and Shentong Mo. Object-wise masked autoencoders for fast pre-training. arXiv preprint arXiv:2205.14338, 2022.

[59] Tete Xiao, Yingcheng Liu, Bolei Zhou, Yuning Jiang, and Jian Sun. Unified perceptual parsing for scene understanding. In Proceedings of the European conference on computer vision (ECCV), pages 418–434, 2018.

[60] Tete Xiao, Mannat Singh, Eric Mintun, Trevor Darrell, Piotr Dollár, and Ross Girshick. Early convolutions help transformers see better. Advances in neural information processing systems, 34:30392–30400, 2021.

[61] Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, Jose M Alvarez, and Ping Luo. Segformer: Simple and efficient design for semantic segmentation with transformers. Advances in neural information processing systems, 34:12077–12090, 2021.

[62] Housheng Xie, Yukuan Zhang, Junhui Qiu, Xiangshuai Zhai, Xuedong Liu, Yang Yang, Shan Zhao, Yongfang Luo, and Jianbo Zhong. Semantics lead all: Towards unified image registration and fusion from a semantic perspective. Information Fusion, 98:101835, 2023.

[63] Jingfeng Yao, Xinggang Wang, Yuehao Song, Huangxuan Zhao, Jun Ma, Yajie Chen, Wenyu Liu, and Bo Wang. Eva-x: A foundation model for general chest x-ray analysis with self-supervised learning. arXiv preprint arXiv:2405.05237, 2024.

[64] Maoxun Yuan and Xingxing Wei. C 2 former: Calibrated and complementary transformer for rgb-infrared object detection. IEEE Transactions on Geoscience and Remote Sensing, 2024.

[65] Maoxun Yuan, Yinyan Wang, and Xingxing Wei. Translation, scale and rotation: cross-modal alignment meets rgb-infrared vehicle detection. In European Conference on Computer Vision, pages 509–525. Springer, 2022.

[66] Maoxun Yuan, Bo Cui, Tianyi Zhao, and Xingxing Wei. Unirgb-ir: A unified framework for visible-infrared downstream tasks via adapter tuning. arXiv preprint arXiv:2404.17360, 2024a.

[67] Maoxun Yuan, Xiaorong Shi, Nan Wang, Yinyan Wang, and Xingxing Wei. Improving rgb-infrared object detection with cascade alignment-guided transformer. Information Fusion, 105:102246, 2024b.

[68] Yuhui Yuan, Xilin Chen, and Jingdong Wang. Object-contextual representations for semantic segmentation. In Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part VI 16, pages 173–190. Springer, 2020.

[69] Jun-Seok Yun, Seon-Hoo Park, and Seok Bong Yoo. Infusion-net: inter-and intra-weighted cross-fusion network for multispectral object detection. Mathematics, 10(21):3966, 2022.

[70] Yuqiao Zeng, Tengfei Liang, Yi Jin†, and Yidong Li. Mmi-det: Exploring multi-modal integration for visible and infrared object detection. IEEE Transactions on Circuits and Systems for Video Technology, pages 1–1, 2024.

[71] Heng Zhang, Elisa Fromont, Sébastien Lefevre, and Bruno Avignon. Multispectral fusion for object detection with cyclic fuse-and-refine blocks. In 2020 IEEE International conference on image processing (ICIP), pages 276–280. IEEE, 2020.

[72] Heng Zhang, Elisa Fromont, Sébastien Lefèvre, and Bruno Avignon. Guided attentive feature fusion for multispectral pedestrian detection. In Proceedings of the IEEE/CVF winter conference on applications of computer vision, pages 72–80, 2021a.

[73] Hao Zhang, Xuhui Zuo, Jie Jiang, Chunchao Guo, and Jiayi Ma. Mrfs: Mutually reinforcing image fusion and segmentation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 26974–26983, 2024.

[74] Lu Zhang, Zhiyong Liu, Shifeng Zhang, Xu Yang, Hong Qiao, Kaizhu Huang, and Amir Hussain. Cross-modality interactive attention network for multispectral pedestrian detection. Information Fusion, 50:20–29, 2019.

[75] Lu Zhang, Xiangyu Zhu, Xiangyu Chen, Xu Yang, Zhen Lei, and Zhiyong Liu. Weakly Aligned Cross-Modal Learning for Multispectral Pedestrian Detection. arXiv e-prints, art. arXiv:1901.02645, 2019.

[76] Qiang Zhang, Nianchang Huang, Lin Yao, Dingwen Zhang, Caifeng Shan, and Jungong Han. Rgb-t salient object detection via fusing multi-level cnn features. IEEE Transactions on Image Processing, 29:3321–3335, 2019.

[77] Qiang Zhang, Shenlu Zhao, Yongjiang Luo, Dingwen Zhang, Nianchang Huang, and Jungong Han. Abmdrnet: Adaptive-weighted bi-directional modality difference reduction network for rgb-t semantic segmentation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 2633–2642, 2021b.

[78] Shenlu Zhao, Yichen Liu, Qiang Jiao, Qiang Zhang, and Jungong Han. Mitigating modality discrepancies for rgb-t semantic segmentation. IEEE Transactions on Neural Networks and Learning Systems, 2023.

[79] Tianyi Zhao, Maoxun Yuan, Feng Jiang, Nan Wang, and Xingxing Wei. Removal and selection: Improving rgb-infrared object detection via coarse-to-fine fusion. arXiv preprint arXiv:2401.10731, 2024.

[80] Kailai Zhou, Linsen Chen, and Xun Cao. Improving multispectral pedestrian detection by addressing modality imbalance problems. In Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XVIII 16, pages 787–803. Springer, 2020.

[81] Wujie Zhou, Xinyang Lin, Jingsheng Lei, Lu Yu, and Jenq-Neng Hwang. Mffenet: Multiscale feature fusion and enhancement network for rgb–thermal urban road scene parsing. IEEE Transactions on Multimedia, 24:2526–2538, 2021.

[82] Wujie Zhou, Shaohua Dong, Caie Xu, and Yaguan Qian. Edge-aware guidance fusion network for rgb–thermal scene parsing. In Proceedings of the AAAI conference on artificial intelligence, pages 3571–3579, 2022.

[83] Wujie Zhou, Yun Zhu, Jingsheng Lei, Rongwang Yang, and Lu Yu. Lsnet: Lightweight spatial boosting network for detecting salient objects in rgb-thermal images. IEEE Transactions on Image Processing, 32:1329–1340, 2023.