# 한국어 본문 자동번역

## RT-DETRv4: Painlessly Furthering Real-Time Object Detection with Vision Foundation Models

비공식 Google 문서 자동번역 · 사람의 전문 교정 미완료

원문 저자: Zijun Liao; Yian Zhao; Xin Shan; Yu Yan; Chang Liu; Lei Lu; Xiangyang Ji; Jie Chen

원문 연도: 2025 · 다운로드/정리일: 2026-09-28

원 논문: https://arxiv.org/abs/2510.25257

번역에 사용한 원문 PDF: https://arxiv.org/pdf/2510.25257v1

라이선스: CC BY 4.0
https://creativecommons.org/licenses/by/4.0/

이 문서는 원문 전체 PDF를 Google 문서 번역에 입력해 얻은 결과입니다. 이 안내 한 쪽만 앞에 추가했으며, 뒤에 오는 자동번역 PDF의 본문·그림·수식은 수정하지 않았습니다.

번역은 원 저자나 출판사가 검토·승인한 공식 번역이 아닙니다. 전문을 사람이 대조·교정하지 않았습니다. 이미지 속 글자, 수식, 표, 참고문헌은 영어로 남거나 순서·배치가 흐트러질 수 있으므로 정확한 인용과 구현에는 원문을 함께 보십시오.

용어 읽기: Abstract는 ‘초록’, YOLO는 ‘You Only Look Once’, NMS는 ‘Non-Maximum Suppression(비최대 억제)’입니다. 번역문에 ‘추상적인’, ‘You Only Live Object’, ‘Non Machine System’으로 나오면 이 뜻으로 읽으십시오. 같은 이름의 TXT 파일에서 지정 제목·용어만 정정했으며 PDF 본문에는 반영하지 않았습니다.

한국어 번역과 이 안내를 추가한 변경을 표시하며, 이 번역·편집본은 CC BY 4.0으로 제공합니다. 별도 권리표시가 있는 제3자 자료의 조건은 유지됩니다.

본문 10쪽 + 안내 1쪽. 페이지 수·한글 텍스트 검사만 자동 수행했으며, 내용의 완전성·번역 정확성을 보증하는 검사가 아닙니다.

Machine Translated by Google

# RT-DETRv4: 실시간 객체 탐지를 더욱 쉽고 간편하게 발전시키다 비전 파운데이션 모델

Zijun Liao1 † Yian Zhao1 † Xin Shan1 Yu Yan1 Chang Liu2
레이루1 샹양지2 첸 지에1
[1]베이징대학교 전자컴퓨터공학과, 중국 선전
2칭화대학교 자동화 및 BNRist 학과, 베이징, 중국
zjliao25@stu.pku.edu.cn zhaoyian@stu.pku.edu.cn

arXiv:2510.25257v1

추상적인

실시간 객체 탐지 기술은 상당한 진전을 이루었습니다.
정교하게 설계된 아키텍처와 최적화 전략을 통해 가능해졌습니다. 하
지만 고속 추론을 추구하는 과정에서 어려움이 발생했습니다.
경량 네트워크 설계는 종종 성능 저하로 이어집니다.
특징 표현 방식은 향후 성능 향상을 저해합니다.
개선 사항 및 실제 기기 배포. 이 글에서는
본 논문에서는 비용 효율적이고 적응성이 뛰어난 솔루션을 제안합니다.
빠르게 진화하는 기술을 활용하는 증류 프레임워크
비전 기반 모델(VFM)의 기능을 향상시키려면
경량 객체 탐지기. VFM과 경량 객체 탐지기 간의 아키텍처 및 학
습 목표의 상당한 차이를 고려할 때
자원이 제한된 검출기에서 안정적이고 작업에 부합하는 의미 전송을 달성
하는 것은 어려운 과제입니다. 이를 해결하기 위해,
한편으로, 우리는 심층 의미 주입기(Deep Semantic Injector, DSI)를 소개합니다.
VFM에서 제공하는 고수준 표현을 검출기의 심층 레이어에 통합하는 것
을 용이하게 하는 모듈입니다.
반면에, 우리는 기울기 유도 적응형 알고리즘을 고안했습니다.
변조(GAM) 전략은 동적으로 조정됩니다.
그래디언트 정규 비율에 기반한 의미 전달 강도 . 배포 및 추론 오버헤드
를 증가시키지 않고,
우리의 접근 방식은 다양한 DETR 기반 모델에서 놀랍고 일관된 성능 향
상을 손쉽게 제공하며 , 실시간 탐지에 대한 실용적인 유용성을 강조합니
다.
RT-DETRv4 모델 제품군은 최첨단 결과를 달성합니다.
COCO에서 AP 점수 49.7/53.5/55.4/57.0 을 획득했습니다 .
이에 상응하는 속도는 273/169/124/78 FPS입니다.

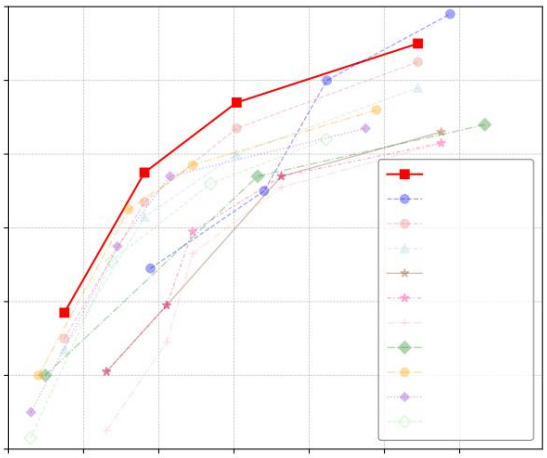


그림 1. 기존의 고급 실시간 객체와 비교
COCO의 검출기 [20]. 당사의 RT-DETRv4 모델은 최첨단 성능을 달성합니다.

## 1. 서론

실시간 객체 탐지는 기본적인 과제입니다.
수많은 인터랙티브 기술의 기반이 되는 컴퓨터 비전 분야에서
자율 주행 [5] 과 같이 즉각적인 인지와 의사 결정이 요구되는 안전 필수
애플리케이션 .
체화된 지능 [21] 및 인간-컴퓨터 상호작용
[ 16]. 지난 10년 동안 놀라운 진전이 있었습니다.
점점 더 효율적인 네트워크 아키텍처에 의해 주도되어 왔습니다.
그리고 엔드투엔드 학습 프레임워크. 특히, YOLO [30] 와 DETR [3]이
라는 두 가지 대표적인 시리즈는 심오한 영향을 미쳤습니다.
객체 탐지 패러다임의 발전에 영향을 미쳤다.
YOLO 제품군은 빠른 단일 단계 탐지를 강조하여 높은 추론 속도와 실용
적인 배포 효율성을 달성합니다.
그리고 DETR 시리즈는 탐지 패러다임을 재편했습니다.
객체 쿼리와 집합 기반 쿼리의 통합 모델링을 통해
예측. 그 변형 중 RT-DETR [38] 은 다음과 같이 표시되었습니다.
최초의 실시간 DETR로서 획기적인 발전을 이루었으며, DETR을 소개합니다.
YOLO를 능가하는 성능으로 가족을 실시간 커뮤니티에 소개합니다.
속도와 정확도 모두에서 우수한 모델입니다.

놀라운 발전에도 불구하고 오랜 과제가 남아 있습니다. 바로 설계와
실제 구현 사이의 본질적인 상충 관계입니다.
경량 모델을 사용하여 높은 추론 속도를 달성하고, 복잡한 아키텍처를 활
용하여 특징 표현력을 향상시킵니다.

†공동 제1저자. 교신 저자. 코드 및 모델은 추후 공개될 예정입니다.
조만간 오픈소스로 공개될 예정입니다.

Machine Translated by Google

실시간 제약 조건을 충족하기 위해 검출기는 일반적으로 다음과 같은 방식을 채택합니다.
경량 백본과 신중하게 설계된 컴퓨팅
모듈은 필연적으로 포착 능력을 저하시킵니다.
고수준 의미론으로 인해 의미론적 병목 현상이 발생합니다.
이러한 제한은 성능 향상을 저해할 뿐만 아니라 실제 기기에서의 구현을 더욱 어렵게 만듭니다.
전개.

본 논문에서는 컴퓨터 비전 분야의 급속한 발전에 영감을 받아 연구를 진행했습니다.
기초 모델(VFMs) [13, 31]을 기반으로, 본 논문에서는 비용 효율적이고 적응성이 뛰어난 증류 프레임워크를 제안합니다.
VFM의 강력한 표현 능력을 활용합니다.
경량 물체 탐지기의 성능을 향상시키기 위해. 전송을 통해
본 연구에서 제시하는 방법은 추론 단계에서 검출기 아키텍처를 변경하지 않고 훈련 단계 에서 VFM의 풍부한 의미론적 정보를 실시간 검출기에 제공함으로써 성능을 크게 향상시킬 수 있습니다.
어떠한 추가적인 추론이나 배포도 도입하지 않고
비용. 이러한 이점은 특히 실용적인 측면에서 중요합니다.
실시간 감지 애플리케이션.

하지만 안정적이고 작업에 맞춰진 의미론적 접근을 달성하려면
건축물의 규모가 크기 때문에 이전이 어렵습니다.
VFM과 리소스 제약형 검출기 간의 학습 목표 차이 문제를 해결하기 위해, 먼저 심층 의미 주입기(Deep Semantic Injector, DSI) 모듈을 도입하여 이를 가능하게 합니다.
VFM에서 가져온 고수준 표현의 통합
검출기의 심층부. 안정적이고 효율적인 작동을 보장하기 위해
최적화를 위해 우리는 경사 유도 적응형 알고리즘을 추가로 설계합니다.
동적으로 조정되는 변조(GAM) 전략
그래디언트 노름 비율에 기반한 의미 주입의 강도
이를 통해 의미 전이 학습과 조화를 이루게 된다.
탐지 목표.

광범위한 실험을 통해 제안된 방식이 효과적임을 입증했습니다.
이 프레임워크는 일관되고 의미 있는 성능을 달성합니다.
기존 DETR 기반 검출기 대비 개선 사항 없음
추론 또는 배포 오버헤드 증가, 강조
그 효과성. 요약하자면, 우리의 주요 기여는 다음과 같습니다.

다음이 아어집니다:

- 본 논문에서는 발전하는 기술력을 활용하는 비용 효율적이고 적응성이 뛰어난 증류 프레임워크를 제안합니다.
  VFM은 실시간 검출기를 손쉽게 향상시키고 기초 수준의 기술을 확장 가능한 방식으로 이전할 수 있는 경로를 제공합니다.
  의미론을 경량 아키텍처로.
- 우리는 심층 의미 주입기(Deep Semantic Injector, DSI)를 제안합니다.
  GAM(Gradient-guided Adaptive Modulation)은 안정적이고 작업에 맞춰 정렬된 의미 전달을 가능하게 합니다.
  아키텍처와 학습 목표가 상당히 다른 VFM 및 탐지기 .

- 우리는 RT-DETRv4라는 새로운 모델군을 개발했습니다.
  S/M/L/X 등급으로, AP 시험에서 각각 49.7/53.5/55.4/57.0 점을 획득했습니다.
  COCO [20] 는 273/169/124/78 FPS 로 새로운 SOTA를 기록했습니다.
  COCO 데이터셋에서.

## 2. 관련 연구

### 2.1. 실시간 객체 탐지

실시간 객체 탐지 기술의 발전은 오랜 역사를 가지고 있습니다.
You Only Look Once(YOLO) 패밀리 [30] 에 의해 주도됨
효율적이고 통합된 탐지 파이프라인을 통해 단일 단계 패러다임을 대중화했습니다 . 지난 몇 년 동안
수년에 걸쳐 이 계통은 급속한 반복을 거치며 새로운 것들을 도입해 왔습니다.
백본 설계, 레이블 할당 및 최적화 전략 의 지속적인 개선 [2, 9, 10, 18, 28, 29, 34, 35].
최근 세대는 설계 공간을 더욱 확장했습니다 . YOLOv10 [33]은 YOLO 시리즈의 NMS를 제거했습니다.
오랫동안 의존해 온 YOLO11 [11]은 아키텍처를 개선했습니다.
계층 구조 및 목 연결성, YOLOv12 [32] 는 더 나은 맥락적 추론을 위해 주의 메커니즘을 통합했습니다 .
그리고 YOLOv13 [17]은 하이퍼그래프 표현을 탐구했습니다.
고차 특징 종속성을 포착합니다. 이러한 발전은
컨볼루션 및 하이브리드 아키텍처의 성능-효율성 한계를 넓혀가며 점차 격차를 좁혀 왔습니다.
실시간 감지기와 고정밀 감지기 사이의 차이.

이와 동시에, 또 다른 연구 분야가 발전해 왔습니다.
DEtection TRansformer(DETR) [3]는 재정의되었습니다.
객체 탐지를 집합 예측 문제로 간주하고 이를 제거했습니다.
앵커 디자인 및 NMS와 같은 수작업 구성 요소.
이 변압기 기반 패러다임은 수많은 변형을 낳았다.
변형 가능한 DETR [39], 조건부 DETR [24]을 포함합니다.
수렴 및 위치 정확도 향상에 중점을 둔 DAB-DETR [22] 이 그 뒤를 이었습니다.
이후 DN-DETR [19], DINO [37], Group-DETR [6] 과 같은 연구에서는 다음과 같은 내용 을 도입했습니다.
노이즈 제거 목표 및 그룹별 감독을 통해 더 나아가
훈련의 안정성과 대표성 품질을 향상시킵니다.

이러한 기반 위에 RT-DETR [38] 이 설립되었습니다.
최초의 실시간 엔드투엔드 변압기 감지기
동시대의 YOLO 모델들과 동등한 수준에 도달했으며, 어떤 경우에는 능가하기도 했습니다 . 이후의 연구들은 이러한 발전을 이어왔습니다.
추론 오버헤드를 발생시키지 않고 훈련 효율성과 표현 학습을 개선하기 위해서입니다 . 예를 들어, RT- DETRv2 [23] 및 RT-DETRv3 [36] 는 보조 기능을 통합했습니다 .
향상된 경사 흐름에 대한 감독을 위해 D-FINE [26] 은 자체 증류를 사용하여 의미 표현을 개선했습니다 .
DEIM [15] 은 보다 정확한 특징 정렬을 위해 밀집 매칭을 도입했습니다. 이러한 발전들을 종합하면 다음과 같습니다.
명확한 추세: 건축 효율성이 포화 상태에 이르면서 교육은 더욱 중요해지고 있다.
감독과 의미 표현이 주요 요소가 됩니다.
더 나은 발전을 위한 동력. 우리의 연구는 이러한 통찰력을 바탕으로 합니다.
심층 의미론을 통해 핵심 표현을 강화함으로써
데이터 전송을 통해 추가적인 배포나 추론 비용 없이 더 높은 정확도를 달성할 수 있습니다 .

### 2.2. 비전 기반 모델

비전 기반 모델(VFM)이 지배적인 모델로 자리 잡았습니다.
대규모 이미지 코퍼스에서 최소한의 또는 전혀 제약 없이 범용 시각 표현을 학습하기 위한 패러다임

Machine Translated by Google

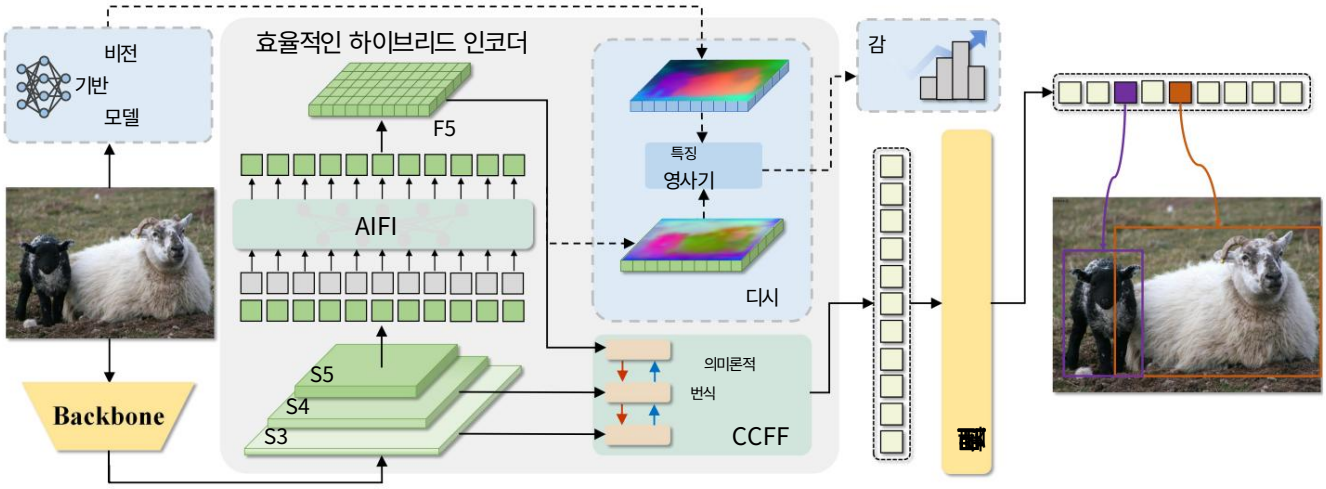



그림 2. RT-DETRv4 개요. 본 연구에서는 고품질 의미 표현을 추출하기 위해 비전 파운데이션 모델(VFM)을 활용하고, 추출된 의미 표현 은 심층 의미 주입기(DSI)의 특징 투영기를 통해 AIFI 모듈의 가장 깊은 특징 맵 (F5) 과 정렬됩니다. 보다 빠르고 안정적인 수렴을 보장하기 위해, 경사 기반 적응 변조(GAM)를 사용하여 학습 중에 DSI 손실을 동적으로 조정합니다.
제안된 프레임워크는 실시간 검출기의 학습 단계(점선 화살표와 파란색 블록으로 표시)에서만 작동하며 추론 및 배포 과정에서는 원래 아키텍처를 변경하지 않아 추가적인 오버헤드 없이 정확도를 향상시킵니다.

인간의 감독이 필요합니다. 초기 발전은 자기 지도 학습 및 약지도 학습 방법에서 비롯되었으며, 이를 통해 모델은 레이블이 지정되지 않았거나 느슨하게 레이블이 지정된 데이터에서 고수준 의미론을 포착할 수 있었습니다 . 대표적인 접근 방식으로는 SimCLR [7] 및 MoCo [12] 와 같은 대조 학습 프레임워크가 있는데, 이는 동일한 이미지의 증강된 뷰 간의 일관성을 유지하면서 다른 뷰와 대조하여 판별 특징을 학습합니다 . CLIP [27] 은 이러한 아이디어를 대규모 이미지-텍스트 대조 학습으로 확장하여 시각적 및 언어적 임베딩을 정렬하고 다양한 작업에 걸쳐 강력한 제로샷 전이성을 입증했습니다.

자연어 처리(NLP)의 마스크 언어 모델링에서 영감을 받아 마스크 이미지 모델링(MIM) 접근 방식이 도입되어 마스크된 이미지 영역을 재구성함으로써 문맥 인식 및 전체적인 표현을 학습합니다. 주목할 만한 방법으로는 MAE [13] 와 BEiT [1]가 있습니다. 이러한 발전을 기반으로 DINO 계열 [4, 25, 31] 은 대조적, 재구성 기반 및 자기 증류 목표를 통합하여 의미론적으로 풍부하고 전이 가능한 특징을 생성합니다. 특히 DINOv3 [31] 는 대규모 자기 지도 학습의 확장성과 효율성을 입증하여 사람의 주석 없이 풍부하고 견고한 표현을 얻습니다.

## 3. 방법

### 3.1. 개요

본 연구에서는 DETR 기반 실시간 객체 검출기, 즉 RT-DETR 모델 [38]에 프레임워크를 적용하는 데 중점을 둡니다.
본 방법의 전체적인 틀은 그림 2에 나타나 있으며, 제안된 모듈들은 파란색으로 강조 표시되어 있습니다.

서론. 본 모델은 RT-DETR 아키텍처, 특히 전체 프레임워크에 설명된 효율적인 하이브리드 인코더를 기반으로 합니다. 인코더는 CNN 백본에서 추출한 멀티스케일 특징 맵 (S3, S4, S5) 을 처리합니다.

이는 두 가지 주요 구성 요소로 이루어져 있습
니다. • 어텐션 기반 스케일 내 특징 상호작용(AIFI): 계산 효율성을 유지하기 위해 셀프 어텐션은 최상위 수준 특징 맵인 S5 ∈ R H/32×W/32×C5 에만 적용됩니다. AIFI는 전역 컨텍스트와 장거리 종속성을 포착하여 F5 로 표시되는 향상된 표현을 생성합니다 .

• CNN 기반 교차 스케일 특징 융합(CCFF): 의미적으로 풍부해진 F5 는 하위 수준 특징 맵 S3 및 S4 와 추가로 융합되어 상위 수준 의미를 더 얕은 특징으로 전파하고, 디코더를 위한 최종 다중 스케일 출력 P3, P4, P5 를 생성합니다 .

동기. 하이브리드 인코더 설계로 인해 특징 맵 F5 의 품질이 특히 중요합니다. 셀프 어텐션이 적용되는 유일한 특징 인 F5는 전체 모델 에 대한 고수준의 전역 의미 정보의 주요 소스 역할을 합니다 . F5의 품질은 CCFF 모듈에서의 후속적인 크로스 스케일 융합, 초기 쿼리 선택 , 그리고 궁극적으로 디코더의 성능에 직접적인 영향을 미칩니다. 이러한 의존성으로 인해 우리는 이를 'F5 의미 병목 현상'이라고 부릅니다 . 그러나 F5를 생성하는 AIFI 모듈은 간접적인 지도 학습만으로 훈련됩니다 . 최종 검출 손실의 기울기가 F5에 도달하기 전에 디코더와 CCFF를 거쳐 역전파되어야 하기 때문입니다 . 이러한 간접적인 지도 학습 만으로는 F5를 완전히 최적화하기에 불충분할 수 있습니다 .

이 문제를 해결하기 위해, 본 논문에서는 경량의 학습 전용 모듈인 심층 의미 주입기( Deep Semantic Injector, DSI)를 제안합니다.

Machine Translated by Google

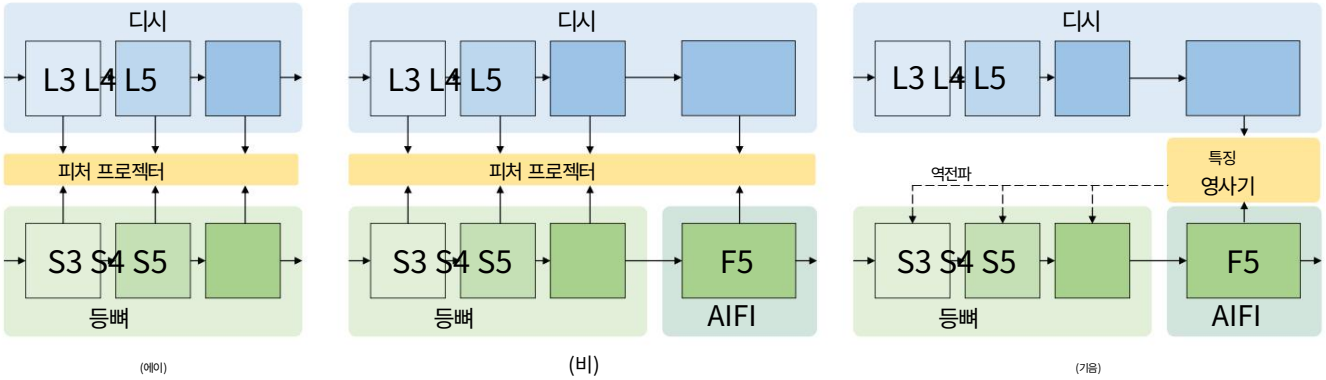



그림 3. 다양한 심층 의미 주입기(DSI) 전략의 예시. (a) 다중 스케일 백본 특징의 직접 정렬
(S3, S4, S5). (b) 백본 특징과 AIFI 출력 특징 (F5)의 하이브리드 정렬. (c) 제안된 방법: 타겟 정렬
최상위 수준의 의미론을 지닌 AIFI 출력 특징 (F5) 만을 사용합니다. 이 설계는 기울기 역전파를 가능하게 하여 성능을 향상시킵니다.
AIFI 모듈과 백본 모두.

심층 특징 F5를 의미적으로 풍부한 특징과 명시적으로 정렬합니다.
비전 기반 모델에서 얻은 표현들. 이러한 목표 지향적인 지도 학습은 의미 표
현력을 향상시킵니다.
F5를 누르면 그라디언트가 AIFI를 통해 다시 흐르게 됩니다.
두 모듈의 시너지 효과를 통해 성능을 향상시키는 핵심 구성 요소입니다.
DSI를 통합하면 전체 교육 목표는 다음과 같이 정의됩니다.

$$L_{total} = L_{det} + \lambda L_{DSI}, \quad (1)$$

여기서 Ldet는 표준 탐지 손실(예: 분류 및 경계 상자 회귀)을 나타내고 ,
LDSI는
제안된 의미 정렬 손실 함수 는 안정적이고 작업에 최적화된 의미 전송을 달
성하는 데 어려움을 겪습니다 .
VFM과 리소스 제약형 탐지기 간의 아키텍처 및 학습 목표의 큰
차이 때문입니다 .
λ 를 부적절하게 선택하면 초기 단계에서 의미론적 감독이 불충분하거나
과도하게 이루어질 수 있습니다.
궁극적으로 후반 단계에서 탐지 목표를 지배하게 됩니다.
수렴을 방해하고 성능을 저하시킵니다. 적응하기 위해
훈련 과정에서 진화하는 최적화 역학에 대해, 우리는
본 논문에서는 경사 유도 적응 변조(GAM)를 제안합니다 .
기울기에 따라 λ를 동적으로 조정하는 메커니즘
통계 분석을 통해 탐지와 최적화 사이의 균형 잡힌 균형을 보장합니다.
그리고 의미론적 감독.

## 3.2. 딥 시맨틱 인젝터

F5 의미론적 병목 현상을 해결하기 위해 다음과 같은 방법을 도입합니다.
심층 의미 주입기(Deep Semantic Injector, DSI)는 명확하고 강력한 지
도 학습을 제공하도록 설계된 학습 전용 모듈입니다.
특징 맵 F5. DSI의 목표는 F5 를 다른 표현들과 정렬하여 의미 론적 품질
을 향상시키는 것입니다.
고용량 의미론적 교사( T 로 표기 ). 입력 이미지가 주어지면 T는 고품질 특징 표현
을 생성합니다.
$F_T \in R^{H' \times W' \times C_T}$ .

특징 투영기. 검출기의 특징 맵을 정렬하기 위해 사용합니다.
$F_5 \in R^{H_5 \times W_5 \times C_5}$ (교사의 표현 $F_T$ 포함 )

공간 해상도와 채널 차원의 차이를 조정해야 합니다. 교사는 일반적으로
ViT [8]입니다.
패치 토큰 시퀀스 $T_p \in R^{N_p \times C_T}$ To를 출력합니다. .
공간적 비교를 가능하게 하기 위해 Tp는 2D 그리드 표현으로 재구성됩니다. 여기
표현 $F^{sp}_{T} \in R^{H_T \times W_T \times C_T}$, 서 $N_p = H_T \times W_T$ 입니다 .
다음으로 경량 특징 투영기 P 를 소개합니다 .
이중 정렬을 달성합니다. 첫째, $F^{sp}_{T}$ 보간됩니다.
F5 의 공간 해상도와 일치합니다 . 한편, P는 조정합니다.
교사의 의미론에 맞춰 F5 채널 차원을 조정합니다.
공간. 전체 투영 과정은 다음과 같이 요약됩니다.
다음이 이어집니다:

$$F^{sp}_{proj\,T} = \text{Reshape}(T_p), \quad F^{sp}_{T} \in R^{H_T \times W_T \times C_T}, \quad (2)$$

$$F'_{proj\,T} = \text{Interp}(F^{sp}_{T}), \quad F' \quad T \in R^{H_5 \times W_5 \times C_T}, \quad (3)$$

$$F_{proj\,5} = P(F_5), \quad F' \quad {}_5 \in R^{H_5 \times W_5 \times C_T} \quad (4)$$

의미론적 주입. 그림 3에서 보는 바와 같이, 우리는 다음과 같이 설계합니다.
의미론을 위한 세 가지 점진적으로 향상된 구성
주입. 구성 (a) 및 (b)에서 DSI 모듈
다양한 계층적 깊이에서 특징점 정렬을 수행합니다.
특징 투영기를 통해 의미론적 지식을 주입합니다.
동결된 VFM에서 검출기의 특징 계층 구조로.
구성 (c)에서 AIFI의 핵심적인 역할을 고려하면
하이브리드 인코더 내의 모듈에서 정렬은 가장 풍부한 의미 정보를 포함
하는 출력 F5 에 대해 수행됩니다.
그래디언트를 분리하지 않으면 DSI 손실이 역방향으로 전파되어 경량
백본이 업데이트됩니다.
결과적으로, 전방 패스는 강화된 F5를 활용 하여
CCFF 모듈에서 다양한 스케일의 융합을 안내하는 동시에 역방향 경로
는 의미론적 일관성을 강화하고
백본의 표현 능력. 이 양방향성
감독은 통합된 의미론적 향상을 달성합니다.
탐지기.

정렬 손실. 검출기가 포착하도록 유도하기 위해
교사 표현의 풍부한 의미론적 특성을 고려하여, 우리는 다음과 같은 방식을 채택합니다.

Machine Translated by Google

코사인 유사도 손실. 우리는 검출기의 투영된 특징 F 와 교사의 투영된 특징 F 사이의 패치별 코사인 유사도를 최대화합니다 . 이는 모든 공간 위치(i, j)에 대해 평균화된 음의 코사인 유사도를 최소화 하는 공식으로 표현됩니다 .

$$\mathrm{LDSI}(F_5', F_{\text{교사}}') = \frac{1}{H5W5} \sum_{i,j} \frac{F_5'(i,j) \cdot F_{\text{티}}'(i,j)}{\| F_5'(i,j) \| \, \| F_{\text{티}}'(i,j) \|}. \tag{5}$$

## 3.3. 경사 유도 적응 변조

안정적이고 적응적인 의미론적 지도 학습을 보장하기 위해, 본 논문에서는 원시 손실 크기가 아닌 기울기 노름 비율 에 따라 AIFI 모듈 의 상대적 기여도를 조절하는 동적 기울기 기반 적응 변조(GAM) 메커니즘을 제안합니다 . 이러한 기울기 기반 조절은 AIFI의 유효 기여도를 원하는 범위 내에서 적응적으로 유지하여 모델 구성 요소 간의 균형 잡힌 최적화를 이끌어냅니다.

구체적으로, 에포크 e 내의 각 훈련 단계 t 에 대해 백본, AIFI, CCFF 및 디코더를 포함한 각 주요 구성 요소의 기울기에 대한 L1 노름을 계산합니다 .

$$C = \{\text{백본}, \text{AIFI}, \text{CCFF}, \text{디코더}\}, \tag{6}$$

$$G_{\text{티}}^{(C)} = \| \nabla_{\theta C} L_{\text{total}} \|_1. \tag{7}$$

전체 기울기 크기는 다음과 같습니다.

$$G_{\text{티}}^{(\text{총})} = \sum_{\text{개}} G_{\text{티}}^{(\text{기음})}, \tag{8}$$

그리고 단계 t 에서의 AIFI의 상대적 기울기 기여도는 다음과 같이 정의 됩니다 .

$$rt = \frac{G_{\text{티}}^{(\text{AIFI})}}{G_{\text{티}}^{(\text{총})}}. \tag{9}$$

그런 다음 에포크 e 내의 모든 훈련 단계에 걸쳐 기울기 비율을 평균하여 다음을 얻습니다.

$$\bar{r}_e = \frac{1}{\text{테}} \sum_{t=1}^{\text{테}} rt, \tag{10}$$

여기서 Te는 에포크 e의 단계 수를 나타냅니다.

변조 프로세스를 제어하는 두 가지 하이퍼파라미터는 다음과 같습니다. • 목표 비율 (ρ): AIFI의 원하는 평균 기울기 비율로, 최적화에 대한 이상적인 상대적 기여도를 나타냅니다 .

• 공차 구간 (δ): 목표 비율을 중심으로 허용 가능한 편차 범위 [ρ δ, ρ + δ] 를 정의하는 여유입니다 .

각 에포크가 끝날 때마다 GAM은 $\bar{r}_e$ 가 목표 구간 내에 있는지 확인합니다. $\bar{r}_e \in [\rho - \delta, \rho+\delta]$ 이면 LDSI 의 가중치 λe는 변경되지 않습니다. 그렇지 않으면 다음 에포크의 AIFI 기울기 비율이 목표 구간으로 향하도록 λe가 조정됩니다.

AIFI의 기울기 중 일부만 LDSI 에서 비롯되므로 목표 범위의 중간점이 아닌 경계를 기준으로 조정하면 평형 점 근처에서 더 안정적인 수렴을 얻을 수 있습니다.

$$\lambda_{e+1} = \begin{cases} \lambda_e \cdot \dfrac{\rho - \delta}{\bar{r}_e}, & \bar{r}_e > \rho + \delta \text{인 경우}, \\ \lambda_e \cdot \dfrac{\bar{r}_e}{\rho + \delta}, & \bar{r}_e < \rho - \delta \text{인 경우}, \\ \lambda_e, & \text{그렇지 않으면.} \end{cases} \tag{11}$$

이 업데이트 규칙은 진동을 방지하면서 AIFI의 유효 기울기 기여도를 원하는 작동 범위 내로 수렴 시킵니다. 하이퍼파라미터 ρ 와 δ 는 훈련 역학에 대한 명시적인 제어를 제공합니다. ρ는 원하는 감독 강도를 정의하고 , δ는 반응성과 안정성 사이의 균형을 조절합니다 . δ 값이 작을수록 적응 속도는 빨라지지만 불안정 해질 위험이 있으며, δ 값이 클수록 수렴 속도는 느려지지만 더 부드러운 결과를 얻을 수 있습니다 . 실제로 GAM은 추가적인 튜닝 오버헤드 없이 안정적인 수렴을 제공하고 의미 정렬을 지속적으로 개선합니다.

# 4. 실험

## 4.1. 설정

데이터셋 및 메트릭. 모든 실험은 COCO 2017 [20] 데이터셋 에서 train2017 분할을 훈련에, val2017 분할을 평가에 사용하여 수행되었습니다. AP(0.50-0.95 범위의 균일하게 샘플링된 IoU 임계값 에 대해 0.05의 단계 크기로 평균화됨), AP50, AP75를 포함한 표준 COCO 메트릭과 APS, APM, APL 과 같은 다양한 스케일의 AP를 보고합니다 .

구현 세부 사항. 본 실험은 RT-DETR 아키텍처 [38]를 기반으로 하며, RT-DETRv2 [23], D-FINE [26], DEIM [15] 의 추가적인 아키텍처 및 학습 개선 사항을 적용했습니다 . 공정한 비교를 위해 핵심 하이퍼파라미터는 해당 기준선과 동일하게 유지했습니다. DSI는 사전 학습되고 고정된 DINOv3-ViT-B 모델을 의미론적 교사로 사용합니다. 모든 평가는 COCO AP 지표를 사용하여 수행되었으며, 추론 지연 시간(밀리초) 은 TensorRT FP16 정밀도에서 단일 NVIDIA T4 GPU를 사용하여 측정했습니다 .

## 4.2. SOTA와의 비교

본 논문에서는 제안하는 RT-DETRv4를 최신 YOLO 시리즈(YOLOv10 [33], YOLOv11 [11], YOLOv12 [32], YOLOv13 [ 17]) 및 DETR 기반 검출기(RT-DETR [38], RT-DETRv2 [23], RT-DETRv3 [36], D - FINE [26 ] , DEIM [ 15 ], DEIMv2 [14])를 포함한 최근 최첨단 실시간 검출기와 비교합니다. 결과는 그림 1에 나타냈으며 , 자세한 통계는 표 1에 제시되어 있습니다. 결과는 RT-DETRv4가 모든 모델 규모에서 일관되게 최고의 성능을 달성함을 보여줍니다.

Machine Translated by Google

표 1. COCO [20] val2017 의 다른 실시간 객체 탐지기와의 비교 . 결과는 공식 출판물에서 가져온 것입니다.
명시적으로 보고되지 않았지만 표준 평가를 통해 공개적으로 이용 가능한 가중치에서 도출된 값은 .R18, R34로 표시됩니다.
R50, R101은 각각 ResNet-18, ResNet-34, ResNet-50, ResNet-101을 나타냅니다.

| 모델 | #에포크 | #매개변수. | GFLOPs | 지연 시간(ms) | APval | APval$^{50}$ | APval$^{75}$ | APval$^{s}$ | APval$^{m}$ | APval$^{l}$ |
|---|---|---|---|---|---|---|---|---|---|---|
| YOLOv10-S [33] | 500 | 7 | 22 | 2.52 | 46.3 | 63.0 | 50.4 | 26.8 | 51.0 | 63.8 |
| YOLO11-S [11] | 500 | 9 | 22 | 2.60 | 47.0 | 63.4 | 50.5 | - | - | - |
| YOLOv12-S [32] | 600 | 9 | 21 | 2.78 | 48.0 | 65.0 | 51.8 | 29.8 | 53.2 | 65.6 |
| YOLOv13-S [17] | 600 | 9 | 21 | 2.98 | 48.0 | 65.2 | 52.0 | 63.8 | - | - |
| RT-DETR-R18 [38] | 120 | 20 | 60 | 4.61 | 46.5 | 50.4 | 63.0 | 28.4 | 49.8 | |
| RT-DETRv2-S [23] | 120 | 20 | 60 | 4.61 | 48.1 | 65.1 | 52.1 | 30.2 | 51.2 | 64.2 |
| RT-DETRv3-R18 [36] | 120 | 20 | 60 | 4.61 | 48.1 | 65.6 | 52.0 | 30.2 | 51.5 | 63.9 |
| D-FINE-S [26] | 120 | 10 | 25 | 3.66 | 48.5 | 65.6 | 52.6 | 29.1 | 52.2 | 65.4 |
| DEIM-S [15] | 120 | 10 | 25 | 3.66 | 49.0 | 65.9 | 53.1 | 30.4 | 52.6 | 65.7 |
| RT-DETRv4-S (당사 제품) | 120 | 10 | 25 | 3.66 | 49.7 | 66.8 | 54.1 | 30.2 | 53.6 | 66.9 |
| YOLOv10-M [33] | 500 | 15 | 59 | 4.74 | 51.1 | 68.1 | 55.8 | 33.8 | 56.5 | 67.0 |
| YOLO11-M [11] | 500 | 20 | 68 | 4.85 | 51.5 | 68.1 | 55.8 | - | - | - |
| YOLOv12-M [32] | 600 | 20 | 68 | 4.96 | 52.5 | 69.6 | 57.1 | 35.7 | 58.2 | 68.8 |
| RT-DETR-R34 [38] | 120 | 31 | 92 | 6.91 | 48.9 | 66.8 | 52.9 | 30.6 | 52.4 | 66.3 |
| RT-DETRv2-M [23] | 120 | 31 | 92 | 6.91 | 49.9 | 67.5 | 54.1 | 32.0 | 53.2 | 66.5 |
| RT-DETRv3-R34 [36] | 120 | 31 | 92 | 6.91 | 49.9 | 67.7 | 53.9 | 31.7 | 54.0 | 66.2 |
| D-FINE-M [26] | 120 | 19 | 57 | 5.91 | 52.3 | 69.8 | 56.4 | 33.2 | 56.5 | 70.2 |
| DEIM-M [15] | 90 | 19 | 57 | 5.91 | 52.7 | 70.0 | 57.3 | 35.3 | 56.7 | 69.5 |
| RT-DETRv4-M (당사 제품) | 90 | 19 | 57 | 5.91 | 53.5 | 71.1 | 58.1 | 34.9 | 57.7 | 72.1 |
| YOLOv10-L [33] | 500 | 24 | 120 | 7.38 | 53.2 | 70.1 | 58.1 | 35.8 | 58.5 | 69.4 |
| YOLO11-L [11] | 500 | 25 | 87 | 6.33 | 53.4 | 69.7 | 58.3 | - | - | - |
| YOLOv12-L [32] | 600 | 27 | 89 | 6.85 | 53.7 | 70.7 | 58.5 | 36.9 | 59.5 | 69.9 |
| YOLOv13-L [17] | 600 | 88 | 28 | 8.63 | 53.4 | 70.9 | 58.1 | - | - | - |
| RT-DETR-R50 [38] | 72 | 42 | 136 | 9.29 | 53.1 | 71.3 | 57.7 | 34.8 | 58.0 | 70.0 |
| RT-DETRv2-L [23] | 72 | 42 | 136 | 9.29 | 53.4 | 71.6 | 57.4 | 36.1 | 57.9 | 70.8 |
| RT-DETRv3-R50 [36] | 120 | 42 | 136 | 9.29 | 53.4 | 71.7 | 57.3 | 35.4 | 57.4 | 69.8 |
| D-FINE-L [26] | 72 | 31 | 91 | 8.07 | 54.0 | 71.6 | 58.4 | 36.5 | 58.0 | 71.9 |
| DEIM-L [15] | 50 | 31 | 91 | 8.07 | 54.7 | 72.4 | 59.4 | 36.9 | 59.6 | 71.8 |
| RT-DETRv4-L (당사 제품) | 50 | 31 | 91 | 8.07 | 55.4 | 73.0 | 60.3 | 37.1 | 60.1 | 72.9 |
| YOLOv10-X [33] | 500 | 30 | 160 | 10.45 | 54.4 | 71.3 | 59.3 | 54.7 | 71.3 | 37.0 |
| YOLO11-X [11] | 500 | 57 | 195 | 11.50 | 59.7 | | | | | - |
| YOLOv12-X [32] | 600 | 59 | 199 | 11.80 | 55.2 | 72.0 | 60.2 | 39.6 | 60.7 | 70.9 |
| YOLOv13-X [17] | 600 | 64 | 199 | 14.67 | 54.8 | 72.0 | 59.8 | - | - | - |
| RT-DETR-R101 [38] | 72 | 76 | 259 | 13.88 | 54.3 | 72.7 | 58.6 | 36.0 | 58.8 | 72.1 |
| RT-DETRv2-X [23] | 72 | 76 | 259 | 13.88 | 54.3 | 72.8 | 58.8 | 35.8 | 58.8 | 72.1 |
| RT-DETRv3-R101 [36] | 120 | 76 | 259 | 13.88 | 54.6 | 73.1 | - | - | - | - |
| D-FINE-X [26] | 72 | 62 | 202 | 12.90 | 55.8 | 73.7 | 60.2 | 37.3 | 60.5 | 73.4 |
| DEIM-X [15] | 50 | 62 | 202 | 12.90 | 56.5 | 74.0 | 61.5 | 38.8 | 61.4 | 74.2 |
| RT-DETRv4-X (당사 제품) | 50 | 62 | 202 | 12.90 | 57.0 | 74.6 | 62.1 | 39.5 | 61.9 | 74.8 |

(S, M, L, X)는 어떠한 추가적인 추론도 도입하지 않고
배포 오버헤드.

구체적으로, 당사의 RT-DETRv4-L은 55.4 AP를 달성합니다 .
COCO는 124 FPS 로 YOLOv13-L(53.4 AP)보다 우수한 성능을 보였습니다.
그리고 DEIM-L(54.7 AP)은 유사하거나 더 낮은 조건에서
계산 예산. 가장 큰 변형은 RT-DETRv4-입니다 .
X는 57.0 AP 에 도달하여 DEIM-X(56.5 AP)를 초과합니다.
추론 오버헤드를 추가하지 않습니다. 소규모 환경에서 RT- DETRv4-
S 와 RT-DETRv4-M은 각각 49.7AP 와 53.5AP를 얻습니다 .
각각 DEIM 대응책을 확실히 능가했습니다.

부품 (49.0 및 52.7 AP).

유사한 지연 시간 내에서 공정한 비교를 보장하기 위해
체제와 관련하여, 우리는 그림 1 에서 DEIMv2 [14] 결과만 보고합니다.
일반적으로 해당 모델 들은 표 1에서 제외됩니다 .
추론 지연 시간이 더 높게 나타납니다. 동일한 추론 속도 조건에서 RT-
DETRv4-M은 DEIMv2-S보다 우수한 성능을 보입니다.
큰 차이 (53.5 AP 대 50.9 AP, 169 FPS 대 173 FPS)
FPS)에서 RT-DETRv4-L은 DEIMv2-M보다 더 뛰어난 성능을 보입니다.
(124 FPS 대 113 FPS에서 55.4 AP 대 53.0 AP).
결과는 그 효과와 뛰어난 잠재력을 완벽하게 입증합니다.

Machine Translated by Google

표 2. 여러 부위에 걸친 DSI 및 GAM에 대한 절제술 결과
검출기. 저희 방법은 일관되고 상당한 성능 향상을 가져옵니다.
추가적인 추론 비용이 전혀 들지 않습니다.

| 방법 | AP | AP50 | AP75 |
|---|---|---|---|
| RT-DETRv2-L | 52.1 | 70.2 | 56.7 |
| DSI 포함 | 52.3 (+0.2) | 70.4 (+0.2) | 56.4 (-0.3) |
| DSI+GAM 사용 시 | 52.6 (+0.5) | 70.7 (+0.5) | 56.8 (+0.1) |
| 디-파인-엘 | 53.1 | 70.8 | 57.4 |
| DSI와 함께 | 53.2 (+0.1) | 70.8 (+0) | 57.7 (+0.3) |
| DSI+GAM 사용 시 | 53.4 (+0.3) | 71.1 (+0.3) | 58.0 (+0.6) |
| DEIM-L | 71.4 (DSI 포함) 53.9 (+0.5) | 53.8 | 71.3 (-0.1) 58.8 (+0.3) |
| DSI+GAM 사용 시 | 54.3 (+0.5) | 71.8 (+0.4) | 59.0 (+0.5) |

제안된 방법의 tial. DEIMv2-X는 달성하지만
성능은 더 뛰어나지만, 지연 시간 또한 더 높습니다.
RT-DETRv4-X를 더욱이, DINOv3를 직접 채택했습니다.
의미적 풍부함을 얻기 위한 핵심은 근본적으로 다음과 같습니다.
모델 크기와 배포 비용에 제약을 받아 제한됩니다.
DINOv3의 Tiny 또는 Small 변형으로 인해 어려움이 발생합니다.
보다 강력한 대규모 모델로 확장하기 위해서입니다. 이와 대조적으로,
저희 프레임워크는 VFM 유형과 규모 모두에 대해 중립적인 입장을 유지합니다.
추론이나 배포 오버헤드를 발생시키지 않고, 다음과 같은 것을 제공합니다.
보다 유연하고 배포가 용이한 솔루션입니다.

## 4.3. 절제술 연구

우리는 이를 검증하기 위해 일련의 절제 실험을 수행합니다.
제안된 모듈의 효과성. 달리 명시되지 않는 한,
모든 어블레이션 실험은 36 에포크 동안 학습됩니다 . 지정 되지 않은 하
이퍼파라미터 또는 구성은 최적값을 따릅니다.
해당 실험 설정에 대한 설정입니다.
DSI 및 GAM에 대한 절제술. 먼저 DSI와 GAM의 효과를 평가합니다 . 표 2에서 볼 수 있듯
이 , DSI를 적용했을 때
약간의 성능 향상을 가져올 수 있으며, 더 나아가
GAM을 적용하면 성능이 크게 향상될 수 있습니다.
(0.5 AP) 이득을 얻게 되는데, 이는 두 가지 모두의 효과를 완벽하게 입증합니다.
본 방법의 일반적인 적용 가능성을 검증하기 위해, 우리는 또한
RT-DETRv2 및 D-FINE에 대한 실험을 수행하고,
결과는 우리의 방법이 다양한 검출기에서 일관된 성능 향상을 가져올 수
있음을 보여줍니다 .
의미 주입 위치에 대한 절제술. 이를 검증하기 위해
주사 위치 선택과 관련하여 제시된 전략들을 비교합니다.
그림 3에서 볼 수 있듯이, 표 3 의 결과는 직접 적용하는 것이
핵심 특징 (S3, S4 또는 S5) 에 대한 의미론적 지도
개별적으로든 공동으로든 개선은 이루어지지 않습니다. 마찬가지로,
핵심과
F5 기능은 이득을 제공하지 않습니다(53.8 AP).
반면, 우리의 설계(전략 (c))는 단지 정렬만 합니다.
AIFI 출력 F5는 0.5 AP 향상이라는 뚜렷한 결과를 보여줍니다.
(54.3 AP). 이는 F5 에서 더 풍부한 의미론적 정보를 유지하는 것이 탐
지 성능 향상에 매우 중요하다는 것을 보여줍니다.
고수준 의미 정보를 전파하는 데 핵심적인 역할을 합니다.

표 3. 의미 주입 위치에 대한 절제술 결과.
DSI를 서로 다른 위치에 적용했을 때의 효과를 비교한다.
그림 3의 전략에 해당합니다. AIFI만 정렬합니다.
출력 (F5) 이 최상의 성능을 제공합니다.

| 위치 | S3 | S4 | S5 | F5 | AP | AP50 | AP75 |
|---|---|---|---|---|---|---|---|
| 기준선 | - | - | - | - | 53.8 | 71.4 | 58.5 |
| 등뼈 | ✓ | - | - | ✓ | - | - | 53.7 71.2 58.4 |
| | - | ✓ | - | 58.5 | | - | 53.7 71.3 58.4 |
| | - | | | | | | 53.8 71.3 53.7 |
| | ✓ | ✓ | ✓ | - | 58.5 | | 71.3 |
| 잡종 | ✓ | ✓ | ✓ | ✓ | 53.8 | 71.4 | 58.4 |
| AIFI | - | - | | - | ✓ | 54.3 | 71.8 59.0 |

표 4. 특징 투영기에 대한 절제술 결과.

| 프로젝터 아치. | AP | AP50 | AP75 |
|---|---|---|---|
| 기준선 | 53.8 | 71.4 | 58.5 |
| 1x1 컨버터 포함 | 53.8 | 71.5 | 58.5 |
| MLP와 함께 | 54.2 | 71.7 | 59.0 |
| 선형 | 54.3 (+0.5) | 71.8 (+0.4) | 59.0 (+0.5) |

표 5. 절제술이 정렬 손실에 미치는 영향 결과. 코사인
유사성 손실은 우수한 성능을 보여줍니다. DEIM-M은
기준선으로 채택되었습니다. 보고된 모든 결과는 다음으로부터 얻은 것입니다.
90 에포크 동안 학습된 모델에 12 에포크의 EMA를 적용했습니다.
DEIM의 교육 프로토콜.

| 손실 함수 | AP | AP50 | AP75 |
|---|---|---|---|
| 기준선 | 52.5 | 69.9 | 57.2 |
| MSE 손실 포함 | 52.7 | 70.0 | 57.4 |
| 코사인 유사도 포함 | 53.5 (+1.0) | 71.1 (+1.2) | 58.1 (+0.9) |

후속 기능 계층 구조에 대한 정보입니다. 또한,
하이브리드 접근 방식의 비효율성은 CNN 기반 백본에서 특징을 동시에
정렬하는 것이 더 효과적임을 시사합니다.
그리고 트랜스포머 기반 AIFI는 최적화를 도입할 수 있습니다.
갈등이나 의미론적 불일치. 우리가 선택한 전략은 다음과 같습니다.
더욱 효과적일 뿐만 아니라 더욱 효율적입니다. 이는 다음과 같은 문제를 방지합니다.
여러 중간 투영 및 보간의 복잡성 과 단일 F5 정렬 에서 발생하
는 기울기
손실은 자연스럽게 AIFI를 시너지 효과적으로 업데이트하는 방향으로 되돌아갑니다.
그리고 핵심은 지속적인 향상을 달성하는 것입니다.
단일하고 명확한 목표.
특수효과 프로젝터의 설계. 특수효과 프로젝터는
학생과 교사를 연결하는 데 필수적인 요소
특징적인 공간들. 우리는 다음과 같은 여러 건축적 선택들을 살펴봅니다.
표 4에 자세히 나와 있습니다 . 선형 기반 프로젝터는 다음과 같은 결과를 생성합니다.
최상의 결과를 얻으려면 표현력과 균형 사이에서 최적의 균형을 이루어야 합니다.
전력 및 매개변수 효율.
손실 함수의 선택. 우리는 정렬에 대해서도 추가로 연구합니다.
DSI 손실. 평균 제곱 오차(MSE)를 비교합니다.
표 5의 손실과 코사인 유사도 손실은 후자와 비교됩니다.

Machine Translated by Google

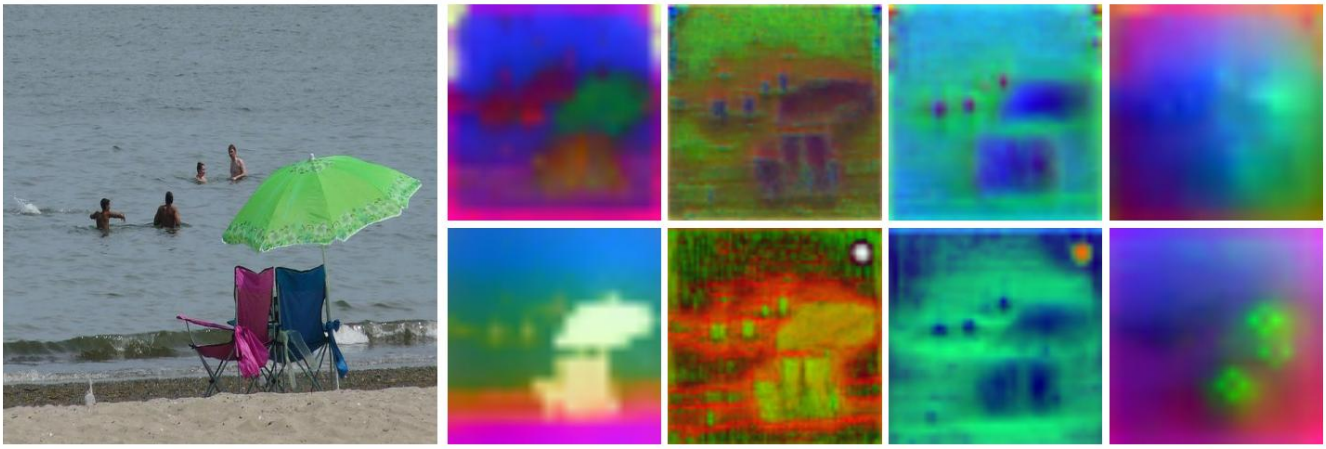


그림 4. 밀집 특징 비교. DEIM-L(위)과 RT-DETRv4-L(아래)의 특징 맵 품질을 투영을 통해 비교합니다 .
PCA를 사용하여 RGB 공간으로 밀집된 출력을 생성합니다. 시각화 결과, DSI 모듈이 의미 표현을 크게 향상시키는 것을 확인할 수 있습니다.
AIFI 특징은 후속 CCFF 특징에 도움이 됩니다. 왼쪽에서 오른쪽으로: 입력 이미지, AIFI 특징 맵 F5, 다중 스케일 CCFF
P3, P4, P5 기능을 제공합니다 .

표 6. 손실 가중 전략에 대한 분석. GAM은 최적의 정적 가중치를 지속적으로 능가합니다. DEIM-L이 채택되었습니다.
기준선. 보고된 모든 결과는 학습된 모델에서 얻은 것입니다.
[15] 에 따라 8 에포크 EMA를 사용하여 50 에포크 동안 .

| λ | 0.1 0.2 0.4 | 1 | 2 | 4 |
|---|---|---|---|---|
| APval | 54.7 54.7 54.8 54.9 55.0 55.0 | | ____ | ____ |

| λ | 10 20 30 50 100 감 |
|---|---|
| APval | 55.0 55.1 55.0 54.9 54.6 55.4 |

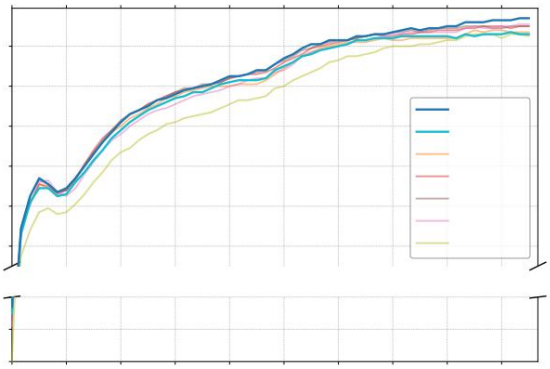


그림 5. 훈련 중 COCO 데이터셋에서의 AP 검증 과정 변화.
본 연구에서는 동적 GAM을 기준 모델 및 여러 다른 모델과 비교합니다.
DSI 손실에 대한 정적 λ 값. GAM 전략은 모든 정적 구성보다 일관되게 우수한
성능을 보여주며, 이를 통해 GAM 전략이 제공하는 능력을 입증합니다.
훈련 과정 전반에 걸쳐 안정적이고 효과적인 감독이 이루어져야 합니다.

이전 모델보다 우수한 성능을 보여줌으로써 우리의 가설을 입증했습니다.
특징점의 방향을 정렬하는 것이 더욱 중요합니다.
GAM과 정적 가중치의 비교. 마지막으로, 제안된 GAM을 정적 가중치와 비교하여
검증합니다.

훈련 과정의 역동성을 파악하는 데 있어 GAM의 우선순위는 다음과 같습니다.
그림 5에서 더 자세히 설명되어 있듯이, 이 그림은 검증 AP를 나타냅니다.
여러 에포크에 걸쳐. 보시다시피, GAM의 곡선은 기준선 및 모든 정적
가중치 구성보다 지속적으로 위에 유지됩니다.
명확하고 안정적인 성능 우위를 입증합니다.

훈련 과정 전반에 걸쳐.
표 6은 정적 가중치와 GAM에 대한 결과를 자세히 보여줍니다.
정적 가중치의 경우, 성능은 λ = 20 에서 최고점인 55.1 AP를 달성 하지만, 이보다 작거나 큰 값에서는 성능이 저하됩니다 . 그러나 그림 5의
훈련 곡선을 살펴보면,
최적의 정적 가중치 (λ = 20) 조차도 다음 과 같은 결과를 초래한다는 것을 알 수 있습니다.

초중반 단계에서 수렴 속도가 느리다는 점이 강조됩니다.
고정된 하이퍼파라미터의 내재적 한계. 저희 실험 결과에 따르면 GAM이 가장 우수한 성능을 보였습니다.

(55.4 AP).
특징 시각화. 그림 4는 DEIM-L과 본 연구의 RT-DETRv4-L의 특징 맵을 시각적으로 비교합니다 . 특히,
본 모델은 AIFI 기능의 의미론적 내용을 풍부하게 합니다.
F5는 이후의 다중 스케일 특징 P3 , P4 및 P5 전반에 걸쳐 더욱 정밀하고 구별 가능한 객체 윤곽과 배경을 생성합니다 . 특히 P5는 현저하게 나타납니다 .
객체 영역에 대한 더욱 강력하고 집중적인 반응.

## 5. 토론

기존 방법 [14, 26]에 비해 우리 프레임워크의 장점을 더욱 강조하기 위해 세 가지 관점에서 논의합니다.

배포 효율성, 확장성 및 교육 효율성.

배포 효율성. 본 방법은 검출기 아키텍처를 전혀 수정하지 않고 추론 파이프라인도 변경하지 않으므로 추가적인 계산 부담이 발생하지 않습니다.

비용이나 지연 시간이 발생합니다. 이러한 배포 친화적인 속성은 실시간 처리가 중요한 산업 응용 분야에 매우 중요합니다.
검출기는 기존 시스템에 긴밀하게 통합되어 있습니다.
하드웨어 제약 환경.

Machine Translated by Google

확장성. 이 프레임워크는 매우 범용적이며 CNN 기반 및 트랜스포머 기반 검출기를 포함하여 다양한 아키텍처를 가진 검출기에 원활하게 적용할 수 있습니다. 이를 통해 모든 유형의 실시간 검출기가 비전 기반 모델(VFM)의 빠른 발전을 신속하게 활용할 수 있습니다.

또한, 이 프레임워크는 특정 유형이나 규모의 VFM에 제한되지 않습니다. DINOv3 [31], MAE [13], CLIP [27] 과 같은 다양한 기반 모델을 유연하게 통합할 수 있으며, 의미론을 실시간 검출기로 추출하기 위해 임의로 큰 모델을 활용할 수도 있습니다. 이러한 유연성은 다중 VFM 의미론 통합을 위한 유망한 방향을 제시하며, 프레임워크의 일반성과 확장성을 더욱 입증합니다.

학습 효율성. 본 논문에서 제시하는 접근 방식은 경량이며 구현이 용이합니다. VFM(가치 함수 모델)을 통합하더라도 검출기 구조나 최적화 파이프라인이 수정되지 않으므로 추가 학습 비용이 최소화됩니다. 이러한 효율성은 본 방법이 대규모 응용 분야 및 실시간 산업 현장 배포에 적합함을 보여줍니다 .

## 6. 결론

본 연구에서는 추론 및 배포 오버헤드를 증가시키지 않고 실시간 DETR 기반 객체 검출기의 성능을 향상시키는 비용 효율적이고 적응 가능한 의미 증류 프레임워크를 제시합니다 . 제안된 심층 의미 주입기(DSI)와 기울기 기반 적응 변조 (GAM)를 통해, 본 방법은 비전 기반 모델(Vision Foundation Models)의 고수준 의미 정보를 경량 검출기로 안정적이고 작업에 최적화된 방식으로 효과적으로 전달합니다. COCO 데이터셋에 대한 광범위한 실험 을 통해 다양한 모델 규모에서 일관되고 유의미한 성능 향상을 입증했으며 , 최종적으로 RT-DETRv4 시리즈에서 최고 성능을 달성했습니다. 이러한 결과는 대규모 기반 모델과 자원 효율적인 검출 아키텍처 간의 격차를 해소하는 데 있어 명시적 의미 지도의 효과를 보여줍니다 . 궁극적으로, 본 연구는 효율적인 시각 인식을 위해 기반 모델의 잠재력을 발휘할 수 있는 실질적인 방안을 제시합니다 .

## 참고 자료


[1] Hangbo Bao, Li Dong, Songhao Piao, and Furu Wei. Beit: 이미지 변환기의 Bert 사전 훈련. 국제 학습 표현 학회(International Conference on Learning Representations). 3 [2] Alexey Bochkovskiy, Chien-Yao Wang, and Hong-Yuan Mark Liao. Yolov4: 객체 탐지의 최적 속도 및 정확도. arXiv 사전 인쇄본 arXiv:2004.10934, 2020. 2

[3] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov 및 Sergey Zagoruyko. 변환기를 사용한 엔드투 엔드 객체 감지. ECCV에서는 2020. 1, 2

[4] 마틸드 카론, 휴고 투브론, 이샨 미스라, Herve J egou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In Proceedings of the IEEE/CVF international conference on computer vision, pages 9650–9660, 2021. 3

[5] Li Chen, Penghao Wu, Kashyap Chitta, Bernhard Jaeger, Andreas Geiger, and Hongyang Li. End-to-end autonomous driving: Challenges and frontiers. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024. 1 [6] Qiang Chen, Xiaokang Chen, Jian Wang, Shan Zhang, Kun Yao, Haocheng Feng, Junyu Han, Errui Ding, Gang Zeng, and Jingdong Wang. Group detr: Fast detr training with group-wise one-to-many assignment. In ICCV, 2023. 2 [7] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In International conference on machine learning, pages 1597–1607. PmLR, 2020. 3 [8] Alexey Dosovitskiy. 이미지는 16x16 단어의 가치가 있다: 대규모 이미지 인식을 위한 변환기. arXiv 사전 공개 논문 arXiv:2010.11929, 2020. 4

[9] Jocher Glenn. Yolov5 릴리스 v7.0. https://github.com/ultralytics/yolov5/tree/v7.0 , 2022. 2 [10] Jocher Glenn. Yolov8. https://docs.ultralytics.com/models/yolov8/ , 2023. 2 [11] Jocher Glenn. Yolo11. https://docs.ultralytics.com/models/yolo11/ , 2024. 2, 5, 6 [12] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie 및 Ross Girshick. 비지도 시각 표현 학습을 위한 모멘텀 대비. IEEE/CVF 컴퓨터 비전 및 패턴 인식 컨퍼런스 프로시딩, 9729–9738페이지, 2020. 3

[13] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollar, Ross Girshick. 마스크드 오토인코더는 확장 가능한 비전 학습기입니다 . IEEE/CVF 컴퓨터 비전 및 패턴 인식 컨퍼런스 프로시딩 , 16000–16009페이지 , 2022. 2, 3, 9

[14] Shihua Huang, Yongjie Hou, Longfei Liu, Xuanlong Yu 및 Xi Shen. 실시간 객체 감지가 dinov3를 만났습니다. arXiv 사전 인쇄 arXiv:2509.20787, 2025. 5, 6, 8

[15] Shihua Huang, Zhichao Lu, Xiaodong Cun, Yongjun Yu, Xiao Zhou, and Xi Shen. Deim: 빠른 수렴을 위한 개선된 매칭을 사용한 Detr. CVPR, 2025. 2, 5, 6, 8 [16] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead , Alexander C Berg, Wan-Yen Lo, et al. 모든 것을 분할합니다. IEEE/CVF 국제 컴퓨터 비전 학회 회의록, 4015–4026페이지, 2023. 1

[17] Mengqi Lei, Siqi Li, Yihong Wu, Han Hu, You Zhou, Xinhu Zheng, Guiguang Ding, Shaoyi Du, Zongze Wu 및 Yue Gao. Yolov13: 하이퍼그래프로 강화된 적응형 시각적 인식을 통한 실시간 개체 감지. arXiv 사전 인쇄 arXiv:2506.17733, 2025. 2, 5, 6

[18] Chuyi Li, Lulu Li, Hongliang Jiang, Kaiheng Weng, Yifei Geng, Liang Li, Zaidan Ke, Qingyuan Li, Meng Cheng, Weiqiang Nie 등. Yolov6: 산업용 애플리케이션을 위한 단일 단계 개체 감지 프레임워크입니다. arXiv, 2022. 2 [19] Feng Li, Hao Zhang, Shilong Liu, Jian Guo, Lionel M Ni 및 Lei Zhang. Dn-detr: 쿼리 노이즈 제거를 도입하여 detr 교육을 가속화합니다 . 컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 컨퍼런스 진행 , 페이지 13619–13627 , 2022. 2

Machine Translated by Google

[20] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollar 및 C Lawrence Zitnick. Microsoft coco: 컨텍스트의 공통 객체. 유럽 컴퓨터 비전 학회, 740-755페이지.

Springer, 2014. 1, 2, 5, 6

[21] Huaping Liu, Xinzhu Liu, Kangyao Huang, Di Guo.
체화된 지능. 『체화된 다중 에이전트 시스템: 지각, 행동 및 학습』, 3~48쪽. 스프링거, 2025. 1

[22] Shilong Liu, Feng Li, Hao Zhang, Xiao Yang, Xianbiao Qi, Hang Su, Jun Zhu 및 Lei Zhang. Dab-detr: 동적 앵커 상자는 detr에 대한 더 나은 쿼리입니다. ICLR, 2022. 2 [23] Wenyu Lv, Yian Zhao, Qinyao Chang,
Kui Huang, Guanzhong Wang 및 Yi Liu. Rt-detrv2: 실시간 감지 변환기를 위한 공짜 가방으로 기준선이 개선되었습니다. arXiv, 2024. 2, 5, 6

[24] Depu Meng, Xiaokang Chen, Zejia Fan, Gang Zeng, Houqiang Li, Yuhui Yuan, Lei Sun, and Jingdong Wang. Conditional detr for fast training convergence. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 3651–3660, 2021. 2 [25] Maxime Oquab, Timothee Darcet, Theo
Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. Dinov2: Learning robust visual features without supervision. arXiv preprint arXiv:2304.07193, 2023. 3 [26] Yansong Peng, Hebei Li, Peixi Wu, Yueyi Zhang, Xiaoyan Sun, and Feng Wu.
D-fine: detrs에서 회귀 작업을 세밀한 분포 정제로 재정의. ICLR, 2024. 2, 5, 6, 8

[27] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark 등. 자연어 지도 학습을 통한 전이 가능한 시각 모델 학습 . 국제 기계 학습 학회, 8748–8763쪽. PmLR, 2021. 3, 9

[28] Joseph Redmon 및 Ali Farhadi. Yolo9000: 더 좋고, 더 빠르고, 더 강력합니다. IEEE/CVF 컴퓨터 비전 및 패턴 인식 컨퍼런스 프로시딩 , 7263–7271페이지, 2017. 2

[29] Joseph Redmon 및 Ali Farhadi. Yolov3: 점진적 개선. arXiv 사전 인쇄본 arXiv:1804.02767, 2018. 2 [30] Joseph Redmon, Santosh Divvala, Ross Girshick 및 Ali Farhadi. 한 번만 보면 됩니다: 통합된 실시간 객체 탐지 . CVPR, 2016. 1, 2

[31] Oriane Simeoni, Huy V Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, 이승은, Michael Ramamonjisoa 등. Di- nov3. arXiv, 2025. 2, 3, 9

[32] 윤지에 티안, 차샹 예, 데이비드 도어만. Yolov12: 주의 중심 실시간 객체 탐지기. NeurIPS, 2025. 2, 5, 6

[33] Ao Wang, Hui Chen, Lihao Liu, Kai Chen, Zijia Lin, Jungong Han 및 Guiguang Ding. Yolov10: 실시간 엔드투엔드 객체 탐지. NeurIPS, 2024. 2, 5, 6 [34] Chien-Yao Wang, Alexey
Bochkovskiy 및 Hong-Yuan Mark Liao. Yolov7: 학습 가능한 bag-of-freebies는 실시간 객체 탐지기의 새로운 최고 성능을 달성합니다. Proceedings of
IEEE/CVF 컴퓨터 비전 및 패턴 인식 학회, 7464–7475쪽, 2023. 2

[35] Chien-Yao Wang, I-Hau Yeh, Hong-Yuan Mark Liao.
Yolov9: 프로그래밍 가능한 기울기 정보를 사용하여 학습하고 싶은 것을 학습합니다 . arXiv, 2024. 2 [36] Shuo Wang, Chunlong Xia, Feng Lv,
Yifeng Shi. Rt-detrv3: 계층적 조밀 양성 감독을 이용한 실시간 엔드투엔드 객체 탐지. 2025 IEEE/CVF 겨울 컴퓨터 비전 응용 컨퍼런스(WACV), 1628–1636페이지. IEEE, 2025. 2, 5, 6 [37] Hao Zhang, Feng Li, Shilong Liu, Lei Zhang, Hang Su, Jun Zhu, Lionel Ni, Heung-Yeung Shum. Dino: 엔드투엔드 객체 탐지를 위한 개선된 노이즈 제거 앵커 박스를 갖춘 Detr . 2022 국제 학습 표현 컨퍼런스 . 2

[38] Yian Zhao, Wenyu Lv, Shangliang Xu, Jinman Wei, Guanzhong Wang, Qingqing Dang, Yi Liu 및 Jie Chen.
Detrs가 실시간 객체 탐지에서 YOLO를 능가했습니다. CVPR, 2024. 1, 2, 3, 5, 6

[39] Xizhou Zhu, Weijie Su, Lewei Lu, Bin Li, Xiaogang Wang 및 Jifeng Dai. Deformable detr: 엔드투엔드 객체 탐지를 위한 변형 가능한 트랜스포머. 2020년 국제 학습 표현 학회(International Conference on Learning Representations). 2