편집 안내: 문장과 캡션을 한국어로 옮긴 텍스트판입니다. 그림 이미지는 연결된 원문을 보십시오. 수식은 원문 기호 또는 TeX 표기를 유지하며, 참고문헌은 원문 서지를 유지합니다. 저자가 검토한 공식 번역이 아닙니다.

VideoMAE: 자기지도 영상 사전학습을 위한 데이터 효율적인 학습기, 마스크드 오토인코더

원제: VideoMAE: Masked Autoencoders are Data-Efficient Learners for Self-Supervised Video Pre-Training

원저자: Zhan Tong, Yibing Song, Jue Wang, Limin Wang

소속: [1] State Key Laboratory for Novel Software Technology, Nanjing University; [2] Tencent AI Lab; [3] Shanghai AI Lab

저자·소속 연결: Zhan Tong[1,2], Yibing Song[2], Jue Wang[2], Limin Wang[1,3]. Zhan Tong의 연구는 Tencent AI Lab 인턴 기간에 수행했다. 교신저자는 Limin Wang이다.

출판: NeurIPS 2022, arXiv:2203.12602v3, 2022-10-18

원문: https://arxiv.org/html/2203.12602v3

원문 PDF: 2022_VideoMAE.pdf · https://arxiv.org/pdf/2203.12602v3

공식 코드: https://github.com/MCG-NJU/VideoMAE

라이선스: 원문은 Creative Commons Attribution 4.0 International(CC BY 4.0)로 제공된다.
https://creativecommons.org/licenses/by/4.0/

번역 표시: 2026-09-28 작성한 비공식 AI 한국어 번역이다. 원저자나 학회가 검수·승인한 번역이 아니다. 원문의 초록, 본문, 부록과 그림·표 캡션을 번역했으며 문장 표현과 표 배치를 한국어 문서에 맞게 변경했다. 참고문헌의 서지사항과 표의 방법·모델·데이터셋 고유명은 영문을 유지한다. 수식, 인용번호, 절·그림·표 번호 및 표 데이터는 원문을 따른다. 그림 이미지는 복제하지 않았으며 번호에 해당하는 이미지는 연결된 원문에서 확인한다. 이 번역에는 원문의 주장과 출판 당시의 성능 비교가 그대로 포함되어 있다.

초록

상대적으로 작은 데이터셋에서 최고 수준의 성능을 얻으려면 일반적으로 매우 큰 데이터셋으로 영상 트랜스포머(video transformer)를 사전학습해야 한다. 이 논문에서는 영상 마스크드 오토인코더(Video Masked Autoencoder, VideoMAE)가 자기지도 영상 사전학습(self-supervised video pre-training, SSVP)을 위한 데이터 효율적인 학습기임을 보인다. 최근의 ImageMAE [31]에서 영감을 받아, 매우 높은 비율을 사용하는 영상 전용 튜브 마스킹(tube masking)을 제안한다. 이 단순한 설계는 영상 복원을 더 어렵고 의미 있는 자기지도 과제로 만들며, 사전학습 과정에서 더 효과적인 영상 표현을 추출하도록 유도한다. VideoMAE를 통해 세 가지 중요한 결과를 얻었다. (1) 극도로 높은 마스킹 비율, 즉 90%에서 95%에서도 VideoMAE는 좋은 성능을 보인다. 영상 내용의 시간적 중복성 때문에 이미지보다 높은 마스킹 비율을 사용할 수 있다. (2) VideoMAE는 추가 데이터를 전혀 사용하지 않고도 매우 작은 데이터셋, 즉 약 3천–4천 개 영상에서도 뛰어난 결과를 얻는다. 이는 부분적으로 어려운 영상 복원 과제가 고수준 구조의 학습을 강제하기 때문이다. (3) VideoMAE는 SSVP에서 데이터의 양보다 질이 더 중요함을 보여준다. 사전학습 데이터셋과 목표 데이터셋 사이의 도메인 변화(domain shift)가 중요한 요인이다. 특히 일반적인 ViT 백본을 사용하는 VideoMAE는 추가 데이터 없이 Kinetics-400에서 87.4%, Something-Something V2에서 75.4%, UCF101에서 91.3%, HMDB51에서 62.6%를 달성한다. 코드는 https://github.com/MCG-NJU/VideoMAE 에서 제공한다.

1 서론

트랜스포머(Transformer) [71]는 자연어 처리 [18, 7, 55]에 상당한 진전을 가져왔다. 비전 트랜스포머(vision transformer) [21]도 이미지 분류 [67, 89], 객체 검출 [8, 38], 의미 분할 [81], 객체 추적 [14, 17], 영상 인식 [6, 3]을 포함한 일련의 컴퓨터 비전 과제를 개선했다. 선형 투영한 이미지·영상 토큰에 적용하는 다중 헤드 자기어텐션(multi-head self-attention)은 시각적 내용 사이의 공간적 또는 시간적 전역 의존성을 모델링할 수 있다. 이 유연한 어텐션 기제는 귀납적 편향(inductive bias)을 효과적으로 줄인다.

그림 1. VideoMAE는 비대칭 인코더–디코더 구조를 사용해 무작위 큐브를 가리고 누락된 큐브를 복원하는 과제를 수행한다. 영상에는 높은 중복성과 시간적 상관성이 있으므로, 매우 높은 비율인 90%–95%를 사용하는 맞춤형 튜브 마스킹을 제안한다. 이 단순한 설계로 더 어렵고 의미 있는 자기지도 과제를 만들 수 있으며, 학습된 표현이 더 유용한 시공간 구조를 포착하도록 한다. (이미지는 원문 그림 1 참조.)

효과적인 비전 트랜스포머(ViT)를 학습하려면 보통 대규모 지도학습 데이터셋이 필요하다. 초기의 사전학습 ViT는 수억 장의 라벨이 있는 이미지를 사용해 좋은 성능을 달성했다 [21]. 영상 트랜스포머 [3, 6]는 대개 이미지 기반 트랜스포머에서 파생되며, ImageNet [58] 같은 대규모 이미지 데이터로 사전학습한 모델에 크게 의존한다. 영상 트랜스포머를 처음부터 학습하려는 기존 시도 [3, 6]는, 강한 귀납적 편향을 갖는 MViT [22]를 제외하면 만족스럽지 않은 결과를 얻었다. 따라서 학습된 영상 트랜스포머에는 자연스럽게 이미지 기반 모델의 편향이 들어간다. 사전학습 모델이나 추가 이미지 데이터를 사용하지 않고 영상 데이터셋 자체만으로 일반적인 비전 트랜스포머를 효과적이고 효율적으로 학습하는 방법은 여전히 과제다. 더욱이 기존 영상 데이터셋은 이미지 데이터셋보다 상대적으로 작아 영상 트랜스포머를 처음부터 학습하기가 한층 어렵다. 한편 자기지도 학습은 대규모 이미지 데이터셋을 사용해 뛰어난 성능을 보여주었다 [15, 9]. 이렇게 학습한 표현은 다운스트림 과제로 전이할 때 지도학습으로 얻은 표현을 능가했다. 이 자기지도 학습 패러다임은 영상 트랜스포머 학습의 문제를 해결할 유망한 방안으로 기대된다.

자연어 처리 [18]와 이미지 [31, 4]에서 마스크드 오토인코딩(masked autoencoding)이 거둔 성공을 따라, 영상 마스크드 오토인코더(VideoMAE)라는 새로운 자기지도 영상 사전학습(SSVP) 방법을 제시한다. VideoMAE는 무작위 큐브를 가리고 누락된 큐브를 복원하는 단순한 처리 과정을 계승한다. 그러나 영상에 추가로 존재하는 시간 차원 때문에 이런 마스크드 모델링에서 영상은 이미지와 다르다. 첫째, 영상 프레임은 촘촘한 간격으로 촬영되는 경우가 많고, 의미는 시간에 따라 천천히 변한다 [88]. 이 시간적 중복성은 고수준의 이해를 거의 하지 않고도 시공간 이웃에서 누락된 픽셀을 복원할 위험을 높인다. 또한 영상은 정적인 외형의 시간적 변화로 볼 수 있으며 프레임 사이에는 대응 관계가 존재한다. 이러한 시간적 상관성 때문에 특정한 마스킹 전략을 고려하지 않으면 복원 과정에서 정보 누출, 즉 가려진 시공간 내용이 다시 나타나는 현상이 발생할 수 있다. 다시 말해 각각의 가려진 큐브에 대응하는 가려지지 않은 복사본을 인접 프레임에서 쉽게 찾을 수 있다. 이 특성으로 인해 학습 모델은 새로운 상황으로 일반화하기 어려운 일종의 '지름길(shortcut)' 특징을 찾아낼 수 있다.

영상 마스크드 모델링을 더 효과적으로 만들기 위해, 이 논문에서는 매우 높은 비율을 사용하는 맞춤형 튜브 마스킹을 VideoMAE에 도입한다. 첫째, 시간적 중복성을 고려하여 다운샘플링한 클립에서 매우 높은 비율로 큐브를 제거한다. 이 단순한 전략은 사전학습 성능을 효과적으로 높일 뿐 아니라 비대칭 인코더–디코더 구조 덕분에 계산 비용도 크게 줄인다. 둘째, 시간적 상관성을 고려하여 단순하면서도 효과적인 튜브 마스킹 전략을 설계한다. 이 전략은 복원 과정에서 움직임이 없거나 무시할 만큼 작은 큐브의 정보 누출 위험을 완화하는 데 도움이 된다. 이처럼 단순하면서도 효과적인 VideoMAE의 설계를 통해 Something-Something [26], UCF101 [61], HMDB51 [35]처럼 상대적으로 작은 영상 데이터셋에서도 일반적인 ViT 백본을 성공적으로 학습할 수 있다. 추가 데이터를 사용하지 않는 조건에서는 기존 최고 수준의 방법보다 성능이 크게 높다. 이 논문의 주요 기여는 세 가지다.

- 영상 인식을 위한 일반적인 비전 트랜스포머의 잠재력을 발휘하는 단순하고 효과적인 영상 마스크드 오토인코더를 제시한다. 저자들이 아는 범위에서는 평범한 ViT 백본만을 사용하는 최초의 마스크드 영상 사전학습 프레임워크다. 마스크드 영상 모델링의 정보 누출 문제를 완화하기 위해 매우 높은 비율의 튜브 마스킹을 제안하며, 이는 VideoMAE의 성능을 높인다.

- 자연어 처리와 이미지의 마스크드 모델링 결과와 일관되게, VideoMAE는 단순한 마스킹·복원 전략이 자기지도 영상 사전학습의 좋은 해결책임을 입증한다. VideoMAE로 사전학습한 모델은 처음부터 학습한 모델이나 대조 학습(contrastive learning) 방법으로 사전학습한 모델보다 성능이 크게 높다.

- 자연어 처리와 이미지에 관한 기존 연구에서 간과했을 수 있는 마스크드 모델링의 중요한 추가 결과를 얻었다. (1) VideoMAE는 영상 3.5천 개만으로도 성공적으로 학습할 수 있는 데이터 효율적인 학습기다. (2) 원천 데이터셋과 목표 데이터셋 사이에 도메인 변화가 있을 때, SSVP에서는 데이터의 양보다 질이 더 중요하다.

2 관련 연구

영상 표현 학습(video representation learning). 좋은 영상 표현을 학습하는 문제는 문헌에서 폭넓게 연구되어 왔다. 지도 학습 방법 [59, 76, 70, 10, 6]은 일반적으로 이미지 백본에 의존한다. 영상 인코더 백본을 먼저 이미지 데이터로 지도 사전학습하고, 이후 사람의 행동을 분류하도록 영상 데이터셋에서 미세조정(fine-tuning)한다. 한편 일부 방법 [68, 23, 22]은 영상을 사용해 영상 백본을 직접 지도학습한다. 지도학습뿐 아니라 준지도 영상 표현 학습도 연구되었다 [60]. 라벨이 있는 학습 표본의 표현을 이용해 라벨이 없는 표본을 위한 감독 신호를 생성한다. 지도·준지도 표현 학습은 주로 하향식 학습 패러다임을 사용하므로 영상 데이터 자체에 내재한 구조를 탐색하는 데 효과적이지 않다. 또한 잡음이 있는 텍스트 감독으로 영상 표현을 학습하기 위한 다중모달 대조 학습 방법 [37, 43, 63]도 개발되었다.

자기지도 학습에서는 시간 정보의 사전지식을 널리 활용해 SSVP의 사전 과제(pretext task)를 설계해 왔다 [79, 45, 83, 5]. 최근에는 더 나은 시각적 표현을 배우기 위해 대조 학습 [29, 46, 30, 53, 25, 28]을 많이 사용한다. 그러나 이러한 방법은 강한 데이터 증강과 큰 배치 크기에 크게 의존한다 [24]. 픽셀 공간에서 오토인코더로 영상 클립을 예측하여 표현을 학습하는 방식은 CNN 또는 LSTM 백본을 사용하거나 [49, 62], 자기회귀 GPT로 영상을 생성하는 방식 [84]으로 탐구되어 왔다. 이에 비해 VideoMAE는 최근의 ViT 백본과 단순한 마스크드 오토인코더를 사용하여 데이터 효율적인 SSVP를 수행하는 것을 목표로 한다.

마스크드 시각 모델링(masked visual modeling). 마스킹과 복원이라는 단순한 처리 과정을 기반으로 효과적인 시각적 표현을 학습하는 마스크드 시각 모델링이 제안되어 왔다. 이러한 연구는 주로 이미지 영역에 집중한다. 초기 연구 [73]는 마스킹을 잡음 제거 오토인코더(denoising autoencoder) [72]의 한 가지 잡음 유형으로 취급하거나, 합성곱을 사용해 문맥을 바탕으로 누락된 영역을 채웠다 [48]. iGPT [11]는 자연어 처리에서 GPT [7, 56]가 거둔 성공을 따라 픽셀 시퀀스에 대해 예측을 수행했다. 최초의 ViT [21]는 자기지도 사전학습을 위한 마스크드 토큰 예측을 탐구했다. 더욱 최근에는 비전 트랜스포머의 성공으로 트랜스포머 기반 마스크드 시각 모델링 구조가 연구되었다 [4, 20, 31, 80, 82, 90]. BEiT [4], BEVT [77], VIMPAC [65]는 BERT [18]를 따라 이산 토큰 [57]을 예측하여 이미지와 영상에서 시각적 표현을 학습하도록 제안했다. MAE [31]는 마스크드 이미지 모델링을 위한 비대칭 인코더–디코더 구조를 도입했다. MaskFeat [80]는 영상의 자기지도 사전학습을 위해 가려진 토큰의 HOG 특징을 복원하도록 제안했다. VideoMAE는 ImageMAE에서 영감을 받아 SSVP에 특화된 구현 설계를 도입한다. 특히 기존 마스크드 영상 모델링 [31, 77, 65]과 비교하면, 픽셀을 직접 복원하는 더 단순하면서도 효과적인 영상 마스크드 오토인코더를 제시한다. VideoMAE는 평범한 ViT 백본만을 사용하는 최초의 마스크드 영상 사전학습 프레임워크다.

3 제안 방법

이 절에서는 먼저 ImageMAE [31]를 다시 살펴본다. 다음으로 영상 데이터의 특성을 분석한다. 마지막으로 VideoMAE를 제시하며 영상 데이터에서 MAE를 어떻게 활용하는지 설명한다.

3.1 이미지 마스크드 오토인코더 다시 살펴보기

ImageMAE [31]는 비대칭 인코더–디코더 구조로 마스킹·복원 과제를 수행한다. 입력 이미지 $I \in \mathcal{R}^{3\times H\times W}$를 먼저 16×16 크기의 일정하고 서로 겹치지 않는 패치로 나누며, 각 패치를 토큰 임베딩으로 표현한다. 이어서 높은 비율인 75%로 일부 토큰을 무작위로 가리고, 나머지 토큰만 트랜스포머 인코더 Φ_{enc}에 넣는다. 마지막으로 인코더에서 나온 보이는 토큰과 학습 가능한 마스크 토큰 위에 얕은 디코더 Φ_{dec}를 두어 이미지를 복원한다. 손실함수는 픽셀 공간에서 정규화한 가려진 토큰과 복원한 토큰 사이의 평균제곱오차(mean squared error, MSE)다.

$$\mathcal{L} = \frac{1}{\Omega} \sum_{p \in \Omega} |I(p) - \hat{I}(p)|^2.$$

식 (1)

여기서 p는 토큰 인덱스, Ω는 가려진 토큰의 집합, I는 입력 이미지, $\hat{I}$는 복원한 이미지다. (식 (1)의 분모 표기는 원문을 그대로 유지했다.)

3.2 영상 데이터의 특성

정적인 이미지와 달리 영상 데이터에는 시간적 관계가 포함된다. 영상의 특성을 분석하여 VideoMAE의 동기를 설명한다.

시간적 중복성(temporal redundancy). 영상에는 높은 빈도로 촬영된 프레임이 존재한다. 의미는 시간 차원에서 천천히 변한다 [88]. 그림 2와 같이 연속 프레임에는 중복이 매우 많음을 관찰했다. 이 특성은 마스크드 영상 오토인코딩에서 두 가지 핵심 문제를 낳는다. 첫째, 사전학습에서 원래의 시간적 프레임률을 유지하면 효율이 떨어진다. 이는 마스크드 모델링에서 정적이거나 느린 움직임에 더 집중하도록 만들 수 있다. 둘째, 시간적 중복성은 움직임 표현을 크게 희석한다. 그러면 통상적인 마스킹 비율, 예를 들어 50%–75%에서는 누락된 픽셀을 복원하는 과제가 어렵지 않게 된다. 인코더 백본은 움직임 표현을 효과적으로 포착하지 못한다.

시간적 상관성(temporal correlation). 영상은 정적인 외형이 시간에 따라 확장된 것으로 볼 수 있으며, 따라서 인접 프레임 사이에는 내재적인 대응 관계가 있다. 이 시간적 상관성은 마스킹·복원 과정에서 정보 누출 위험을 높일 수 있다. 그림 2와 같이 단순한 무작위 마스킹이나 프레임 마스킹을 사용하면, 인접 프레임에서 시공간적으로 대응하는 가려지지 않은 패치를 찾아 가려진 패치를 복원할 수 있다. 이러한 경우 VideoMAE는 내용에 대한 시공간 추론 같은 고수준 정보보다 저수준의 시간적 대응 관계를 학습하도록 유도될 수 있다. 이 현상을 완화하려면 복원을 더 어렵게 만들고 시공간 구조 표현의 효과적인 학습을 장려하는 새로운 마스킹 전략이 필요하다.

그림 2. 느리게 변화한다는 성질(slowness)은 (a) 영상 데이터의 일반적인 사전지식이다 [88]. 이 때문에 시간적 중복성과 시간적 상관성이라는 두 가지 중요한 시간 특성이 생긴다. 시간적 중복성 덕분에 매우 높은 마스킹 비율에서도 픽셀을 복원할 수 있다. 시간적 상관성 때문에 단순한 (b) 프레임 마스킹 또는 (c) 무작위 마스킹에서는 인접 프레임의 대응 패치를 찾아 누락된 픽셀을 쉽게 복원할 수 있다. 이런 쉬운 과제를 피하고 대표성 있는 표현을 배우도록 하기 위해, 모든 프레임이 같은 마스킹 맵을 공유하는 (d) 튜브 마스킹을 제안한다. (이미지는 원문 그림 2 참조.)

3.3 VideoMAE

영상 마스크드 모델링에서 위의 문제를 완화하기 위해 VideoMAE에 맞춤형 설계를 적용한다. 전체 처리 과정은 그림 1과 같다. VideoMAE는 다운샘플링한 프레임을 입력받고 큐브 임베딩(cube embedding)으로 영상 토큰을 만든다. 이후 비대칭 인코더–디코더 구조로 MAE 사전학습을 수행하기 위해 높은 비율의 튜브 마스킹이라는 단순한 설계를 제안한다. 백본은 시공간 결합 어텐션(joint space-time attention)을 사용하는 일반적인 ViT다.

시간적 다운샘플링(temporal downsampling). 연속 프레임의 시간적 중복성에 대한 앞의 분석을 바탕으로, 더 효율적인 영상 사전학습을 위해 간격을 두는 시간적 샘플링(strided temporal sampling) 전략을 제안한다. 형식적으로는 원본 영상 V에서 연속된 t개 프레임으로 구성된 영상 클립 하나를 먼저 무작위로 추출한다. 이어 시간적 샘플링으로 클립을 T개 프레임으로 압축하며, 각 프레임은 $H \times W \times 3$개의 픽셀로 이루어진다. 실험에서는 Kinetics와 Something-Something의 간격 τ를 각각 4와 2로 설정한다.

큐브 임베딩. VideoMAE에는 시공간 결합 큐브 임베딩 [3, 22, 39]을 사용하며, $2 \times 16 \times 16$ 크기의 각 큐브를 하나의 토큰 임베딩으로 취급한다. 따라서 큐브 임베딩 층은 $\frac{T}{2} \times \frac{H}{16} \times \frac{W}{16}$개의 3차원 토큰을 얻고, 각 토큰을 채널 차원 D로 매핑한다. 이 설계는 입력의 공간·시간 차원을 줄여 영상의 시공간 중복성을 완화하는 데 도움이 된다.

매우 높은 비율의 튜브 마스킹. 첫째, 시간적 중복성은 VideoMAE 설계에 영향을 미치는 요인이다. VideoMAE는 ImageMAE보다 매우 높은 마스킹 비율, 예를 들어 90%–95%에 적합함을 발견했다. 영상의 정보 밀도는 이미지보다 훨씬 낮으므로 높은 마스킹 비율로 복원의 난도를 높일 수 있을 것으로 기대한다. 이러한 높은 마스킹 비율은 마스크드 모델링에서 정보 누출을 완화하고, 가려진 영상의 복원을 의미 있는 자기지도 사전학습 과제로 만드는 데 도움이 된다.

둘째, 시간적 상관성도 VideoMAE 설계의 또 다른 요인이다. 마스킹 비율이 매우 높더라도 시간적 튜브 마스킹 기제를 도입하면 마스킹의 효율을 더 높일 수 있음을 발견했다. 시간적 튜브 마스킹은 마스크가 시간축 전체에 걸쳐 확장되도록 강제한다. 즉 서로 다른 프레임이 같은 마스킹 맵을 공유한다. 수학적으로 튜브 마스킹 기제는 $\mathbb{I}[p_{x,y,\cdot} \in \Omega] \sim \mathrm{Bernoulli}(\rho_{\mathrm{mask}})$로 표현할 수 있으며, 서로 다른 시간 t가 같은 값을 공유한다. 이 기제에서는 가려진 큐브의 시간적 이웃도 항상 가려진다. 따라서 움직임이 없거나 작은 일부 큐브, 예를 들어 그림 2(d)의 네 번째 행에 있는 손가락 큐브는 모든 프레임에서 시공간적으로 대응하는 내용을 찾을 수 없다. 이에 따라 VideoMAE는 완전히 누락된 큐브를 복원하기 위해 고수준의 의미를 추론하도록 유도된다. 이 단순한 전략은 움직임이 없거나 무시할 만큼 작은

큐브의 정보 누출을 완화할 수 있으며, 실제 마스크드 영상 사전학습에서도 효과적이다.

백본: 시공간 결합 어텐션. 앞서 설명한 높은 마스킹 비율 때문에 인코더 입력으로 남는 토큰은 소수에 불과하다. 남은 토큰에서 고수준의 시공간 정보를 더 잘 포착하기 위해 일반적인 ViT 백본 [21]과 시공간 결합 어텐션 [3, 39]을 사용한다. 따라서 모든 토큰 쌍은 다중 헤드 자기어텐션 층 [71]에서 서로 상호작용할 수 있다. 인코더와 디코더의 구체적인 구조 설계는 부록에 제시한다. 시공간 결합 어텐션의 이차 계산복잡도는 계산상의 병목이지만, 매우 높은 마스킹 비율을 사용하는 본 설계는 사전학습 중 가려지지 않은 토큰, 예를 들어 10%만 인코더에 넣어 이 문제를 완화한다.

4 실험

4.1 데이터셋

VideoMAE를 널리 사용되는 다섯 영상 데이터셋, 즉 Kinetics-400 [34], Something-Something V2 [26], UCF101 [61], HMDB51 [35], AVA [27]에서 평가한다. Kinetics-400은 400개 클래스의 10초 영상으로 구성되며, 약 24만 개의 학습 영상과 2만 개의 검증 영상이 있다. Something-Something V2도 대규모 영상 데이터셋으로, 약 16만 9천 개의 학습 영상과 2만 개의 검증 영상을 포함한다. Kinetics-400과 달리 이 데이터셋에는 움직임 중심의 행동 클래스 174개가 있다. 두 대규모 영상 데이터셋은 행동 인식에서 서로 다른 시각적 단서에 중점을 둔다. UCF101과 HMDB51은 상대적으로 작은 영상 데이터셋으로, 각각 약 9.5천/3.5천 개와 3.5천/1.5천 개의 학습/검증 영상을 포함한다. 작은 데이터셋에서는 큰 ViT 모델을 학습하기가 더 어렵기 때문에, 이 두 작은 데이터셋은 대규모 영상 데이터셋보다 VideoMAE의 효과를 검증하기에 더 적합하다. 또한 VideoMAE로 학습한 ViT 모델을 다운스트림 행동 검출 과제로 전이한다. 사람 행동의 시공간적 위치를 찾는 AVA를 사용하며, 이 데이터셋에는 학습용 영상 구간 21만 1천 개와 검증용 구간 5만 7천 개가 있다. 다운스트림 과제 실험에서는 사전학습한 VideoMAE 모델을 학습 집합에서 미세조정하고 검증 집합의 결과를 보고한다. 구현 세부사항은 부록 §7에 설명한다.

표 1. Something-Something V2와 Kinetics-400의 절제 실험. 백본은 16프레임을 입력받는 일반적인 ViT-B다. 모든 모델은 마스킹 비율 $\rho = 90\%$로 800에포크 사전학습한 뒤 평가를 위해 미세조정한다. SSV2에서는 TSN [76]의 균등 샘플링, K400에서는 밀집 샘플링 [78, 23]을 수행한다. 모든 모델은 동일한 추론 규약, 즉 SSV2에서는 2클립 × 3크롭, K400에서는 5클립 × 3크롭을 사용한다. 모델의 기본 선택은 원문에서 회색으로 표시한다.

표 1(a). 디코더 깊이. 디코더를 4개 블록으로 구성할 때 가장 좋은 절충을 얻는다. “GPU 메모리”는 사전학습 중의 GPU 메모리 사용량이며, GPU 1개에서 배치 크기를 16으로 설정해 측정했다.

블록 수	SSV2	K400	GPU 메모리
1	68.5	79.0	7.9G
2	69.2	79.2	10.2G
4	69.6	80.0	14.7G
8	69.3	79.7	23.7G

표 1(b). 마스크 샘플링. 서로 다른 마스킹 전략을 비교한다. 제안한 튜브 마스킹에 매우 높은 마스킹 비율을 적용했을 때 가장 좋은 결과를 얻는다. *“87.5”는 16개 프레임 중 14개를 마스킹한다는 뜻이다.

조건	비율	SSV2	K400
튜브	75	68.0	79.8
튜브	90	69.6	80.0
무작위	90	68.3	79.5
프레임	87.5*	61.5	76.5

표 1(c). 복원 대상. $T \times \tau$는 “프레임 수 × 스트라이드”를 뜻한다. “중앙 프레임”은 입력 클립의 중앙 프레임을 가리킨다. T의 기본값은 16이다. τ는 SSV2와 K400에서 각각 2와 4로 설정한다.

입력	복원 대상	SSV2	K400
$T \times \tau$	중앙 프레임	63.0	79.3
$T \times \frac{\tau}{2}$	$T \times \frac{\tau}{2}$	68.9	79.8
$T \times \tau$	$T \times \tau$	69.6	80.0
$T \times \tau$	$2T \times \frac{\tau}{2}$	69.2	80.1

표 1(d). 사전학습 전략. VideoMAE는 추가 데이터를 사용하지 않고 가장 좋은 성능을 얻는다. “sup.”는 지도학습을 뜻한다.

조건	SSV2	K400
처음부터 학습	32.6	68.8
ImageNet-21k 지도학습	61.8	78.9
IN-21k+K400 지도학습	65.2	-
VideoMAE	69.6	80.0

표 1(e). 사전학습 데이터셋. VideoMAE는 원래의 데이터셋에서 모델을 직접 사전학습할 때 가장 좋은 성능을 얻는다.

데이터셋	방법	SSV2	K400
IN-1K	ImageMAE	64.8	78.7
K400	VideoMAE	68.5	80.0
SSV2	VideoMAE	69.6	79.6

표 1(f). 손실 함수. MSE 손실은 VideoMAE의 마스킹 및 복원 과제에서 가장 좋은 성능을 보인다.

조건	SSV2	K400
L1 손실	69.1	79.7
MSE 손실	69.6	80.0
Smooth L1 손실	68.9	79.6

4.2 절제 연구

이 소절에서는 Something-Something V2(SSV2)와 Kinetics-400(K400)에서 16프레임 ViT-B를 기본 백본으로 사용하여 VideoMAE 설계를 심층적으로 절제 분석한다. 인코더·디코더의 구체적인 구조는 부록 §6에 제시한다. 미세조정에서는 SSV2에 TSN [76]의 균등 샘플링을, K400에 밀집 샘플링 [78, 23]을 적용한다. 모든 모델은 동일한 추론 규약, 즉 SSV2에서는 2클립 × 3크롭, K400에서는 5클립 × 3크롭을 사용한다.

디코더 설계. 가벼운 디코더는 VideoMAE의 핵심 구성요소다. 표 1(a)에서는 깊이를 달리하며 실험한다. ImageMAE와 달리 여기서는 깊은 디코더가 더 좋은 성능을 얻는 데 중요하지만, 얕은 디코더는 GPU 메모리 사용량을 줄일 수 있다. 기본적으로 디코더에 블록 4개를 사용한다. 이미지 영역의 설계를 따라 디코더의 너비는 인코더 채널 수의 절반, 예를 들어 ViT-B에서는 384차원으로 설정한다.

마스킹 전략. 표 1(b)에서 서로 다른 마스킹 전략을 비교한다. 튜브 마스킹의 비율을 75%에서 90%로 높이면 SSV2 성능은 68.0%에서 69.6%로 상승한다. 이어 매우 높은 비율에서도 튜브 마스킹이 단순한 무작위 마스킹과 프레임 마스킹보다 더 좋은 성능을 보임을 발견했다. 이러한 흥미로운 관찰은 영상의 중복성과 시간적 상관성에서 비롯된다고 본다. K400의 결론도 SSV2와 일치한다. 다만 K400의 성능 차이는 SSV2보다 작다는 점에 주목할 수 있다. 저자들은 Kinetics 영상이 대체로 정적이고 장면과 관련되어 있어 시간적 모델링의 효과가 뚜렷하지 않다고 본다. 종합하면 기본 설계는 네트워크가 더 유용한 시공간 구조를 포착하도록 강제하고, 그 결과 좋은 자기지도 학습기에 필요한 더 어려운 과제를 VideoMAE에 제공한다.

복원 대상. 먼저 중앙 프레임만 복원 대상으로 사용하면 표 1(c)와 같이 결과가 크게 낮아진다. 샘플링 간격에도 민감하다. 작은 간격 $\frac{\tau}{2}$를 사용한 결과는 기본 간격 τ보다 낮다. SSV2에서 각각 68.9%와 69.6%다. 다운샘플링한 T개 프레임에서 $2T$개 프레임을 복원하는 방식도 시도했으나 SSV2에서는 결과가 조금 더 나빴다. 단순성을 위해 입력 다운샘플링 클립 자체를 기본 복원 대상으로 사용한다.

사전학습 전략. 표 1(d)에서 서로 다른 사전학습 전략을 비교한다. 기존 시도 [3, 6]와 마찬가지로 영상 트랜스포머를 처음부터 학습하면 영상 데이터셋에서 만족스럽지 않은 결과를 얻는다. 대규모 ImageNet-21K 데이터셋으로 사전학습하면 영상 트랜스포머의 정확도가 SSV2에서 32.6%에서 61.8%로, K400에서 68.8%에서 78.9%로 좋아진다. ImageNet-21K와 Kinetics 모두에서 사전학습한 모델을 사용하면 SSV2의 정확도가 65.2%로 더 높아진다. VideoMAE는 추가 데이터 없이 영상 데이터셋 자체에서 영상 트랜스포머를 효과적으로 학습하며 가장 좋은 성능, 즉 SSV2에서 69.6%, K400에서 80.0%를 달성한다.

사전학습 데이터셋. 먼저 [31]의 설정을 따라 ImageNet-1K에서 ViT-B를 1600에포크 사전학습한다. 이어 [10]의 방식으로 2차원 패치 임베딩 층을 본 연구의 큐브 임베딩 층으로 확장하고, 목표 영상 데이터셋에서 모델을 미세조정한다. 표 1(e)에서 보듯 처음부터 학습한 모델보다 결과가 좋다. 또한 ImageMAE로 사전학습한 모델과 영상 데이터셋에서 사전학습한 VideoMAE 모델을 비교한다. VideoMAE 모델은 ImageMAE보다 더 좋은 성능을 달성한다. 그러나 사전학습한 VideoMAE 모델을 다른 영상 데이터셋으로 전이하면, 예를 들어 Kinetics에서 Something-Something으로 전이하면 목표 영상 데이터셋 자체에서 직접 사전학습한 대응 모델보다 결과가 약간 나쁘다. 사전학습 데이터셋과 목표 데이터셋 사이의 도메인 변화가 중요한 문제일 수 있다고 본다.

손실함수. 표 1(f)는 손실함수에 관한 절제 연구를 담는다. MSE 손실이 L1 손실과 Smooth L1 손실보다 더 좋은 결과를 낼 수 있음을 발견했다. 따라서 기본적으로 MSE 손실을 사용한다.

표 2. 여러 데이터셋에서 기존 자기지도 사전학습 방법과 결과를 비교한다. 16프레임 ViT-B를 기본 백본으로 사용한다. 여기서 MoCo v3와 VideoMAE는 모두 각 데이터셋의 학습 집합에 있는 라벨 없는 데이터만 사전학습에 사용하며, 평가를 위해 모두 미세조정한다.

데이터셋	학습 데이터 수	처음부터 학습	MoCo v3	VideoMAE
K400	240k	68.8	74.2	80.0
Sth-Sth V2	169k	32.6	54.2	69.6
UCF101	9.5k	51.4	81.7	91.3
HMDB51	3.5k	18.0	39.2	62.6

표 3. Something-Something V2에서 효율성과 효과를 비교한다. 미세조정(ft) 및 선형 탐침(linear probing, lin)의 정확도(%)를 보고한다. 사전학습의 실제 경과 시간은 Tesla V100 GPU 64개와 PyTorch를 사용하여 측정했다.

방법	에포크	미세조정 정확도	선형 탐침 정확도	시간(h)	속도 향상
MoCo v3	300	54.2	33.7	61.7	-
VideoMAE	800	69.6	38.9	19.5	3.2×

표 4. 더 작은 데이터셋에서 특징의 전이 가능성을 비교한다. 16프레임 ViT-B를 기본 백본으로 사용한다. 여기서 MoCo v3와 VideoMAE는 모두 Kinetics-400 학습 집합의 라벨 없는 데이터로 사전학습한다. 이어 목표 데이터셋에서 사전학습 모델을 미세조정하여 평가한다.

방법	K400 → SSV2	K400 → UCF	K400 → HMDB
MoCo v3	62.4	93.2	67.9
VideoMAE	68.5	96.1	73.3

4.3 주요 결과와 분석

VideoMAE: 데이터 효율적인 학습기. 자기지도 영상 사전학습(SSVP)은 기존 연구에서 폭넓게 다뤄졌으나 주로 CNN 기반 백본을 사용했다. SSVP에서 트랜스포머 기반 백본을 조사한 연구는 드물다. 따라서 트랜스포머 기반 SSVP에서 VideoMAE의 효과를 입증하기 위해, 직접 구현한 두 가지 방법과 비교한다. (1) 처음부터 학습하는 방법, (2) 대조 학습인 MoCo v3 [15]로 사전학습하는 방법이다. 처음부터 학습할 때에는 데이터셋의 학습 집합에서 ViT-Base를 성공적으로 사전학습하도록 하이퍼파라미터를 주의 깊게 조정한다. MoCo v3 사전학습에서는 이미지 버전의 학습 관행을 엄격히 따르고 붕괴(collapse) 문제를 주의 깊게 피한다.

인식 정확도는 표 2에 보고한다. VideoMAE는 다른 두 학습 설정을 크게 능가한다. 예를 들어 가장 큰 데이터셋인 Kinetics-400에서 VideoMAE는 처음부터 학습하는 방법보다 약 10%, MoCo v3 사전학습보다 약 5% 높은 성능을 보인다. 이 우수한 성능은 마스크드 오토인코더가 영상 트랜스포머에 효과적인 사전학습 기제를 제공함을 입증한다. 학습 집합이 작아질수록 VideoMAE와 나머지 두 방법 사이의 성능 차이가 커지는 것도 확인할 수 있다. 특히 HMDB51에서는 학습 클립이 3.5천 개뿐이어도 VideoMAE 사전학습으로 만족스러운 정확도인 약 61%를 얻을 수 있다. 이 새로운 결과는 VideoMAE가 SSVP에 더 데이터 효율적인 학습기임을 보여준다. 이 특성은 사용 가능한 데이터가 제한된 상황에서 특히 중요하며 대조 학습 방법과 구별된다. (원문 본문의 '약 61%'와 표 2의 62.6%를 각각 그대로 보존했다.)

표 3에서 VideoMAE 사전학습과 MoCo v3 사전학습의 효율성을 비교한다. 높은 비율의 마스크드 오토인코딩 과제는 더 어렵기 때문에 학습 에포크가 더 많이 필요하다. 각각 800에포크와 300에포크다. 그러나 VideoMAE의 비대칭 인코더–디코더와 매우 높은 마스킹 비율 덕분에 사전학습 시간은 MoCo v3보다 훨씬 짧다. 각각 19.5시간과 61.7시간이다.

그림 3. (a) Something-Something V2와 (b) Kinetics-400에서 마스킹 비율이 미치는 영향. 16프레임을 입력받는 일반적인 ViT-B를 기본으로 사용한다. 두 영상 데이터셋 모두 매우 높은 마스킹 비율인 90%에서 효율성과 성능 사이의 가장 좋은 절충을 얻는다. (이미지는 원문 그림 3 참조.)

그림 4. VideoMAE 표현의 데이터 효율성. 기본 백본은 16프레임을 입력받는 일반적인 ViT-B다. 초록색 점(•)은 모든 모델을 동일하게 13만 2천 회 반복 학습함을, 파란색 점(•)은 모든 모델을 동일하게 800에포크 학습함을 나타낸다. Something-Something V2의 전체 학습 집합에서 800에포크 사전학습하려면 13만 2천 회 반복이 필요하다. (이미지는 원문 그림 4 참조.)

높은 마스킹 비율. VideoMAE의 핵심 설계 중 하나는 매우 높은 마스킹 비율이다. Kinetics-400과 Something-Something V2 데이터셋에서 이 설계를 조사한다. 결과는 그림 3에 제시한다. 최적의 마스킹 비율은 매우 높으며, 95%에서도 두 데이터셋 모두 좋은 성능을 얻을 수 있다. 이는 자연어 처리의 BERT [18] 및 이미지의 MAE [31]와 다른 결과다. 영상의 시간적 중복성과 상관성이 VideoMAE로 하여금 이처럼 높은 마스킹 비율에서도 그럴듯한 출력을 학습할 수 있게 한다고 분석한다.

부록 §10에서는 복원 예시도 시각화한다. 매우 높은 마스킹 비율에서도 VideoMAE가 만족스러운 복원 결과를 만들어냄을 확인할 수 있다. 이는 VideoMAE가 영상의 전체적인 시공간 구조를 포착하는 유용한 표현을 학습할 수 있음을 시사한다.

전이학습: 질과 양. 표현 학습에서 VideoMAE의 일반화 능력을 더 조사하기 위해 Kinetics-400에서 학습한 VideoMAE를 Something-Something V2, UCF101, HMDB51로 전이한다. 표 4에 결과를 제시하고 MoCo v3 사전학습과 비교한다. VideoMAE로 사전학습한 모델이 MoCo v3로 사전학습한 모델보다 더 좋으며, 이는 VideoMAE가 더 전이하기 좋은 표현을 학습함을 보여준다.

표 2와 표 4를 비교하면 UCF101과 HMDB51에서는 전이한 표현이 해당 데이터셋 자체로 학습한 원래의 VideoMAE 모델보다 더 좋다. 반면 Something-Something V2에서는 전이한 표현이 더 나쁘다. 이 일관되지 않은 결과가 Something-Something V2의 큰 규모 때문인지 알아보기 위해, 사전학습 영상 수를 줄이는 상세 조사를 추가로 수행한다. 이 조사에서는 (1) 같은 에포크 수로 사전학습, (2) 같은 시간 예산으로 사전학습이라는 두 실험을 실시한다. 결과는 그림 4와 같다. 사전학습 집합의 크기를 줄일 때 반복 학습 횟수가 많으면 성능 개선에 기여함을 확인할 수 있다. 놀랍게도 사전학습 영상이 4만 2천 개뿐이어도 24만 개 영상으로 Kinetics 사전학습을 수행한 모델보다 높은 정확도를 얻을 수 있다. 각각 68.7%와 68.5%다. 이는 도메인 변화가 또 다른 중요한 요인이며, 사전학습 데이터셋과 목표 데이터셋이 다를 때 SSVP에서는 데이터의 양보다 질이 더 중요함을 시사한다. 또한 VideoMAE가 SSVP를 위한 데이터 효율적인 학습기임을 보여준다.

표 5. AVA v2.2에서 최고 수준의 방법과 비교한다. 모든 모델은 이미지 크기 224^2에서 사전학습하고 미세조정한다. 검증 집합의 평균 정밀도 평균(mean Average Precision, mAP)을 보고한다. '추가 라벨 ✗'는 사전학습 단계에서 라벨 없는 데이터만 사용하고 사전학습 모델을 AVA로 직접 전이함을 뜻한다. '추가 라벨 ✓'는 AVA로 전이하기 전에 사전학습 데이터셋의 라벨을 사용해 모델을 추가로 미세조정함을 뜻한다. $T \times \tau$는 프레임 수와 해당 샘플링 간격을 나타낸다.

방법	백본	사전학습 데이터셋	추가 라벨	$T \times \tau$	GFLOPs	파라미터 수	mAP
지도학습 [23]	SlowFast-R101	Kinetics-400	✓	8×8	138	53	23.8
CVRL [54]	SlowOnly-R50	Kinetics-400	✗	32×2	42	32	16.3
ρBYOLρ=3 [24]	SlowOnly-R50	Kinetics-400	✗	8×8	42	32	23.4
ρMoCoρ=3 [24]	SlowOnly-R50	Kinetics-400	✗	8×8	42	32	20.3
MaskFeat↑312 [80]	MViT-L	Kinetics-400	✓	40×3	2828	218	37.5
MaskFeat↑312 [80]	MViT-L	Kinetics-600	✓	40×3	2828	218	38.8
VideoMAE	ViT-S	Kinetics-400	✗	16×4	57	22	22.5
VideoMAE	ViT-S	Kinetics-400	✓	16×4	57	22	28.4
VideoMAE	ViT-B	Kinetics-400	✗	16×4	180	87	26.7
VideoMAE	ViT-B	Kinetics-400	✓	16×4	180	87	31.8
VideoMAE	ViT-L	Kinetics-400	✗	16×4	597	305	34.3
VideoMAE	ViT-L	Kinetics-400	✓	16×4	597	305	37.0
VideoMAE	ViT-H	Kinetics-400	✗	16×4	1192	633	36.5
VideoMAE	ViT-H	Kinetics-400	✓	16×4	1192	633	39.5
VideoMAE	ViT-L	Kinetics-700	✗	16×4	597	305	36.1
VideoMAE	ViT-L	Kinetics-700	✓	16×4	597	305	39.3

표 6. Something-Something V2에서 최고 수준의 방법과 비교한다. VideoMAE는 정규화한 큐브 픽셀을 복원하며 마스킹 비율 90%로 2400에포크 사전학습한다. '추가 라벨 ✗'는 사전학습 단계에서 라벨 없는 데이터만 사용함을 뜻한다. 'N/A'는 저자들이 해당 수치를 확보하지 못했음을 나타낸다.

같은 표의 열을 나누어 표시: 1/2

방법	백본	추가 데이터	추가 라벨	프레임 수	GFLOPs	파라미터 수
TEINetEn [40]	ResNet50×2	ImageNet-1K	✓	8+16	99×10×3	50
TANetEn [41]	ResNet50×2	ImageNet-1K	✓	8+16	99×2×3	51
TDNEn [75]	ResNet101×2	ImageNet-1K	✓	8+16	198×1×3	88
SlowFast [23]	ResNet101	Kinetics-400	✓	8+32	106×1×3	53
MViTv1 [22]	MViTv1-B	Kinetics-400	✓	64	455×1×3	37
TimeSformer [6]	ViT-B	ImageNet-21K	✓	8	196×1×3	121
TimeSformer [6]	ViT-L	ImageNet-21K	✓	64	5549×1×3	430
ViViT FE [3]	ViT-L	IN-21K+K400	✓	32	995×4×3	N/A
Motionformer [51]	ViT-B	IN-21K+K400	✓	16	370×1×3	109
Motionformer [51]	ViT-L	IN-21K+K400	✓	32	1185×1×3	382
Video Swin [39]	Swin-B	IN-21K+K400	✓	32	321×1×3	88

방법	백본	추가 데이터	추가 라벨	프레임 수	GFLOPs	파라미터 수
VIMPAC [65]	ViT-L	HowTo100M+DALLE	✗	10	N/A×10×3	307
BEVT [77]	Swin-B	IN-1K+K400+DALLE	✗	32	321×1×3	88
MaskFeat↑312 [80]	MViT-L	Kinetics-600	✓	40	2828×1×3	218
VideoMAE	ViT-B	Kinetics-400	✗	16	180×2×3	87
VideoMAE	ViT-L	Kinetics-400	✗	16	597×2×3	305
VideoMAE	ViT-S	외부 데이터 없음	✗	16	57×2×3	22
VideoMAE	ViT-B	외부 데이터 없음	✗	16	180×2×3	87
VideoMAE	ViT-L	외부 데이터 없음	✗	16	597×2×3	305
VideoMAE	ViT-L	외부 데이터 없음	✗	32	1436×1×3	305

같은 표의 열을 나누어 표시: 2/2

방법	백본	Top-1	Top-5
TEINetEn [40]	ResNet50×2	66.5	N/A
TANetEn [41]	ResNet50×2	66.0	90.1
TDNEn [75]	ResNet101×2	69.6	92.2
SlowFast [23]	ResNet101	63.1	87.6
MViTv1 [22]	MViTv1-B	67.7	90.9
TimeSformer [6]	ViT-B	59.5	N/A
TimeSformer [6]	ViT-L	62.4	N/A
ViViT FE [3]	ViT-L	65.9	89.9
Motionformer [51]	ViT-B	66.5	90.1
Motionformer [51]	ViT-L	68.1	91.2
Video Swin [39]	Swin-B	69.6	92.7
VIMPAC [65]	ViT-L	68.1	N/A
BEVT [77]	Swin-B	70.6	N/A
MaskFeat↑312 [80]	MViT-L	75.0	95.0
VideoMAE	ViT-B	69.7	92.3
VideoMAE	ViT-L	74.0	94.6
VideoMAE	ViT-S	66.8	90.3
VideoMAE	ViT-B	70.8	92.4
VideoMAE	ViT-L	74.3	94.6
VideoMAE	ViT-L	75.4	95.2

전이학습: 다운스트림 행동 검출. Kinetics-400에서 학습한 VideoMAE를 다운스트림 행동 검출 데이터셋 AVA로도 전이한다. 표준 설정 [27]을 따라 자주 등장하는 상위 60개 클래스에서 평가하며, IoU 임곗값 0.5에서 mAP를 측정 지표로 사용한다. 결과는 표 5와 같다. Kinetics-400에서 자기지도 사전학습한 뒤 일반적인 ViT-B를 사용하는 VideoMAE는 AVA에서 26.7 mAP를 달성하며, 이는 VideoMAE의 강한 전이 가능성을 보여준다. 사전학습한 ViT-B를 라벨이 있는 Kinetics-400에서 추가로 미세조정하면 전이학습 성능이 약 5 mAP, 즉 26.7에서 31.8로 더 높아진다. 더욱 주목할 점은 더 큰 영상 데이터셋, 예를 들어 Kinetics-700이나 더 강력한 백본, 예를 들어 ViT-Large와 ViT-Huge를 사용하도록 사전

학습 설정을 확장하면 VideoMAE의 성능이 더 좋아진다는 것이다. 예를 들어 Kinetics-700에서 사전학습한 ViT-L VideoMAE는 39.3 mAP, Kinetics-400에서 사전학습한 ViT-H VideoMAE는 39.5 mAP를 달성한다. 이 결과는 자기지도 사전학습 모델이 행동 분류뿐 아니라 더 복잡한 행동 검출 과제로도 잘 전이됨을 보여준다.

표 7. Kinetics-400에서 최고 수준의 방법과 비교한다. VideoMAE는 정규화한 큐브 픽셀을 복원한다. 여기서 모델은 Kinetics-400에서 마스킹 비율 90%로 1600에포크 자기지도 사전학습한다. VideoMAE↑320은 224^2 해상도의 대응 모델로 초기화한 뒤 평가를 위해 미세조정한다. '추가 라벨 ✗'는 사전학습 단계에서 라벨 없는 데이터만 사용함을 뜻한다. 'N/A'는 저자들이 해당 수치를 확보하지 못했음을 나타낸다.

같은 표의 열을 나누어 표시: 1/2

방법	백본	추가 데이터	추가 라벨	프레임 수	GFLOPs	파라미터 수
NL I3D [78]	ResNet101	ImageNet-1K	✓	128	359×10×3	62
TANet [41]	ResNet152	ImageNet-1K	✓	16	242×4×3	59
TDNEn [75]	ResNet101	ImageNet-1K	✓	8+16	198×10×3	88
TimeSformer [6]	ViT-L	ImageNet-21K	✓	96	8353×1×3	430
ViViT FE [3]	ViT-L	ImageNet-21K	✓	128	3980×1×3	N/A
Motionformer [51]	ViT-L	ImageNet-21K	✓	32	1185×10×3	382
Video Swin [39]	Swin-L	ImageNet-21K	✓	32	604×4×3	197
ViViT FE [3]	ViT-L	JFT-300M	✓	128	3980×1×3	N/A
ViViT [3]	ViT-H	JFT-300M	✓	32	3981×4×3	N/A
VIMPAC [65]	ViT-L	HowTo100M+DALLE	✗	10	N/A×10×3	307
BEVT [77]	Swin-B	IN-1K+DALLE	✗	32	282×4×3	88
MaskFeat↑352 [80]	MViT-L	Kinetics-600	✗	40	3790×4×3	218
ip-CSN [69]	ResNet152	외부 데이터 없음	✗	32	109×10×3	33
SlowFast [23]	R101+NL	외부 데이터 없음	✗	16+64	234×10×3	60
MViTv1 [22]	MViTv1-B	외부 데이터 없음	✗	32	170×5×1	37
MaskFeat [80]	MViT-L	외부 데이터 없음	✗	16	377×10×1	218
VideoMAE	ViT-S	외부 데이터 없음	✗	16	57×5×3	22
VideoMAE	ViT-B	외부 데이터 없음	✗	16	180×5×3	87
VideoMAE	ViT-L	외부 데이터 없음	✗	16	597×5×3	305
VideoMAE	ViT-H	외부 데이터 없음	✗	16	1192×5×3	633
VideoMAE↑320	ViT-L	외부 데이터 없음	✗	32	3958×4×3	305
VideoMAE↑320	ViT-H	외부 데이터 없음	✗	32	7397×4×3	633

같은 표의 열을 나누어 표시: 2/2

방법	백본	Top-1	Top-5
NL I3D [78]	ResNet101	77.3	93.3
TANet [41]	ResNet152	79.3	94.1
TDNEn [75]	ResNet101	79.4	94.4
TimeSformer [6]	ViT-L	80.7	94.7
ViViT FE [3]	ViT-L	81.7	93.8
Motionformer [51]	ViT-L	80.2	94.8

방법	백본	Top-1	Top-5
Video Swin [39]	Swin-L	83.1	95.9
ViViT FE [3]	ViT-L	83.5	94.3
ViViT [3]	ViT-H	84.9	95.8
VIMPAC [65]	ViT-L	77.4	N/A
BEVT [77]	Swin-B	80.6	N/A
MaskFeat↑352 [80]	MViT-L	87.0	97.4
ip-CSN [69]	ResNet152	77.8	92.8
SlowFast [23]	R101+NL	79.8	93.9
MViTv1 [22]	MViTv1-B	80.2	94.4
MaskFeat [80]	MViT-L	84.3	96.3
VideoMAE	ViT-S	79.0	93.8
VideoMAE	ViT-B	81.5	95.1
VideoMAE	ViT-L	85.2	96.8
VideoMAE	ViT-H	86.6	97.1
VideoMAE↑320	ViT-L	86.1	97.3
VideoMAE↑320	ViT-H	87.4	97.6

4.4 최고 수준 방법과 비교

Kinetics-400 및 Something-Something V2 데이터셋에서 기존 최고 수준의 성능과 비교한다. 결과는 표 6과 표 7에 보고한다. VideoMAE는 더 강력한 백본, 예를 들어 ViT-Large와 ViT-Huge, 그리고 더 많은 프레임, 예를 들어 32프레임으로 쉽게 확장할 수 있다. VideoMAE는 추가 데이터 없이 Something-Something V2에서 top-1 정확도 75.4%, Kinetics-400에서 87.4%를 달성한다. Something-Something V2에서 기존 최고 수준의 방법은 모두 외부 데이터에 의존하여 사전학습한다. 반대로 외부 데이터를 전혀 사용하지 않는 VideoMAE는 같은 입력 해상도의 기존 방법보다 약 5% 높은 성능을 보인다. ViT-H VideoMAE는 추가 데이터 없이도 Kinetics-400에서 매우 경쟁력 있는 성능을 달성하며, JFT-300M에서 사전학습한 ViViT-H보다도 높다. 각각 86.6%와 84.9%다. 더 큰 공간 해상도와 더 많은 입력 영상 프레임으로 미세조정하면 ViT-H VideoMAE의 성능은 86.6%에서 87.4%로 더 높아진다.

5 결론

이 논문에서는 영상 트랜스포머 사전학습을 위한 단순하고 데이터 효율적인 자기지도 학습 방법인 VideoMAE를 제시했다. VideoMAE는 영상 복원 과제를 더 어렵게 만드는 두 가지 핵심 설계, 즉 매우 높은 마스킹 비율과 튜브 마스킹 전략을 도입한다. 이 더 어려운 과제는 VideoMAE가 더 대표성 있는 특징을 배우도록 하고 정보 누출 문제를 완화한다. 실험 결과 이 단순한 알고리즘은 여러 규모의 영상 데이터셋에서 잘 작동한다. 특히 영상 클립 수천 개만으로도 효과적인 VideoMAE를 학습할 수 있으며, 이는 사용 가능한 데이터가 제한된 상황에서 실용적 가치가 크다.

향후 연구. 더 큰 웹 수집 데이터셋, 더 큰 모델, 예를 들어 ViT-G, 그리고 더 높은 입력 영상 공간 해상도, 예를 들어 384^2를 사용하면 VideoMAE를 더 개선할 수 있다. VideoMAE는 추가 음성이나 텍스트 스트림 없이 RGB 영상 스트림만 활용한다. 영상 데이터의 음성과 텍스트가 자기지도 사전학습에 더 많은 정보를 제공할 수 있을 것으로 기대한다.

더 넓은 영향. VideoMAE의 잠재적인 부정적 사회 영향은 주로 에너지 소비와 관련된다. 사전학습 단계는 많은 양의 탄소 배출을 유발할 수 있다. 사전학습은 에너지를 소비하지만 모델의 사전학습은 한 번만 수행하면 된다. 이후 서로 다른 다운스트림 과제가 추가 미세조정을 통해 같은 사전학습 모델을 공유할 수 있다. VideoMAE는 영상 분석에서 일반적인 비전 트랜스포머의 큰 잠재력을 발휘하게 한다. 이로 인해 영상 이해 모델이나 그 출력이 무단 감시 같은 잘못된 용도로 사용될 위험이 커질 수 있다.

감사의 말 및 연구비 공개. 도움을 준 Ziteng Gao, Lei Chen, Chongjian Ge에게 감사한다. 본 연구는 중국 국가자연과학기금(No. 62076119, No. 61921006), 중앙대학 기본연구비(No. 020214380091), Tencent AI Lab Rhino-Bird Focused Research Program(No. JR202125), Collaborative Innovation Center of Novel Software Technology and Industrialization의 지원을 받았다.

참고문헌

서지사항의 정확성을 위해 아래 참고문헌 90건은 원문 영문 표기를 유지한다.

[1] Jean-Baptiste Alayrac, Adria Recasens, Rosalia Schneider, Relja Arandjelovic, Jason Ramapuram, Jeffrey De Fauw, Lucas Smaira, Sander Dieleman, and Andrew Zisserman. Self-supervised multimodal versatile networks. In Advances in Neural Information Processing Systems, 2020.

[2] Humam Alwassel, Dhruv Mahajan, Bruno Korbar, Lorenzo Torresani, Bernard Ghanem, and Du Tran. Self-supervised learning by cross-modal audio-video clustering. In Advances in Neural Information Processing Systems, 2020.

[3] Anurag Arnab, Mostafa Dehghani, Georg Heigold, Chen Sun, Mario Lučić, and Cordelia Schmid. Vivit: A video vision transformer. In IEEE/CVF International Conference on Computer Vision, 2021.

[4] Hangbo Bao, Li Dong, Songhao Piao, and Furu Wei. BEit: BERT pre-training of image transformers. In International Conference on Learning Representations, 2022.

[5] Sagie Benaim, Ariel Ephrat, Oran Lang, Inbar Mosseri, William T. Freeman, Michael Rubinstein, Michal Irani, and Tali Dekel. Speednet: Learning the speediness in videos. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020.

[6] Gedas Bertasius, Heng Wang, and Lorenzo Torresani. Is space-time attention all you need for video understanding? In International Conference on Machine Learning, 2021.

[7] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel Ziegler, Jeffrey Wu, Clemens Winter, Chris Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners. In Advances in Neural Information Processing Systems, 2020.

[8] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In European Conference on Computer Vision, 2020.

[9] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In IEEE/CVF International Conference on Computer Vision, 2021.

[10] João Carreira and Andrew Zisserman. Quo vadis, action recognition? A new model and the kinetics dataset. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2017.

[11] Mark Chen, Alec Radford, Rewon Child, Jeffrey Wu, Heewoo Jun, David Luan, and Ilya Sutskever. Generative pretraining from pixels. In International Conference on Machine Learning, 2020.

[12] Mark Chen, Alec Radford, Rewon Child, Jeffrey Wu, Heewoo Jun, David Luan, and Ilya Sutskever. Generative pretraining from pixels. In International Conference on Machine Learning, 2020.

[13] Peihao Chen, Deng Huang, Dongliang He, Xiang Long, Runhao Zeng, Shilei Wen, Mingkui Tan, and Chuang Gan. Rspnet: Relative speed perception for unsupervised video representation learning. In Proceedings of the AAAI Conference on Artificial Intelligence, 2021.

[14] Xin Chen, Bin Yan, Jiawen Zhu, Dong Wang, Xiaoyun Yang, and Huchuan Lu. Transformer tracking. In CVPR, 2021.

[15] Xinlei Chen, Saining Xie, and Kaiming He. An empirical study of training self-supervised vision transformers. In IEEE/CVF International Conference on Computer Vision, 2021.

[16] Ekin D Cubuk, Barret Zoph, Jonathon Shlens, and Quoc V Le. Randaugment: Practical automated data augmentation with a reduced search space. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 2020.

[17] Yutao Cui, Cheng Jiang, Limin Wang, and Gangshan Wu. Mixformer: End-to-end tracking with iterative mixed attention. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022.

[18] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In North American Chapter of the Association for Computational Linguistics, 2019.

[19] Ali Diba, Vivek Sharma, Reza Safdari, Dariush Lotfi, Saquib Sarfraz, Rainer Stiefelhagen, and Luc Van Gool. Vi2clr: Video and image for visual contrastive learning of representation. In IEEE/CVF International Conference on Computer Vision, 2021.

[20] Xiaoyi Dong, Jianmin Bao, Ting Zhang, Dongdong Chen, Weiming Zhang, Lu Yuan, Dong Chen, Fang Wen, and Nenghai Yu. Peco: Perceptual codebook for bert pre-training of vision transformers. arXiv preprint arXiv:2111.12710, 2021.

[21] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. In International Conference on Learning Representations, 2021.

[22] Haoqi Fan, Bo Xiong, Karttikeya Mangalam, Yanghao Li, Zhicheng Yan, Jitendra Malik, and Christoph Feichtenhofer. Multiscale vision transformers. In IEEE/CVF International Conference on Computer Vision, 2021.

[23] Christoph Feichtenhofer, Haoqi Fan, Jitendra Malik, and Kaiming He. Slowfast networks for video recognition. In IEEE/CVF International Conference on Computer Vision, 2019.

[24] Christoph Feichtenhofer, Haoqi Fan, Bo Xiong, Ross Girshick, and Kaiming He. A large-scale study on unsupervised spatiotemporal representation learning. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021.

[25] Chongjian Ge, Youwei Liang, Yibing Song, Jianbo Jiao, Jue Wang, and Ping Luo. Revitalizing cnn attentions via transformers in self-supervised visual representation learning. In Advances in Neural Information Processing Systems, 2021.

[26] Raghav Goyal, Samira Ebrahimi Kahou, Vincent Michalski, Joanna Materzynska, Susanne Westphal, Heuna Kim, Valentin Haenel, Ingo Fründ, Peter Yianilos, Moritz Mueller-Freitag, Florian Hoppe, Christian Thurau, Ingo Bax, and Roland Memisevic. The "something something" video database for learning and evaluating visual common sense. In IEEE/CVF International Conference on Computer Vision, 2017.

[27] Chunhui Gu, Chen Sun, David A Ross, Carl Vondrick, Caroline Pantofaru, Yeqing Li, Sudheendra Vijayanarasimhan, George Toderici, Susanna Ricco, Rahul Sukthankar, et al. Ava: A video dataset of spatio-temporally localized atomic visual actions. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018.

[28] Sheng Guo, Zihua Xiong, Yujie Zhong, Limin Wang, Xiaobo Guo, Bing Han, and Weilin Huang. Cross-architecture self-supervised video representation learning. In CVPR, 2022.

[29] Tengda Han, Weidi Xie, and Andrew Zisserman. Memory-augmented dense predictive coding for video representation learning. In European Conference on Computer Vision, 2020.

[30] Tengda Han, Weidi Xie, and Andrew Zisserman. Self-supervised co-training for video representation learning. In Advances in Neural Information Processing Systems, 2020.

[31] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022.

[32] Elad Hoffer, Tal Ben-Nun, Itay Hubara, Niv Giladi, Torsten Hoefler, and Daniel Soudry. Augment your batch: Improving generalization through instance repetition. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020.

[33] Kai Hu, Jie Shao, Yuan Liu, Bhiksha Raj, Marios Savvides, and Zhiqiang Shen. Contrast and order representations for video self-supervised learning. In IEEE/CVF International Conference on Computer Vision, 2021.

[34] Will Kay, Joao Carreira, Karen Simonyan, Brian Zhang, Chloe Hillier, Sudheendra Vijayanarasimhan, Fabio Viola, Tim Green, Trevor Back, Paul Natsev, Mustafa Suleyman, and Andrew Zisserman. The kinetics human action video dataset. arXiv preprint arXiv:1705.06950, 2017.

[35] Hildegard Kuehne, Hueihan Jhuang, Estíbaliz Garrote, Tomaso Poggio, and Thomas Serre. Hmdb: a large video database for human motion recognition. In IEEE/CVF International Conference on Computer Vision, 2011.

[36] Hsin-Ying Lee, Jia-Bin Huang, Maneesh Singh, and Ming-Hsuan Yang. Unsupervised representation learning by sorting sequence. In IEEE/CVF International Conference on Computer Vision, 2017.

[37] Tianhao Li and Limin Wang. Learning spatiotemporal features via video and text pair discrimination. arXiv preprint arXiv:2001.05691, 2020.

[38] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. In IEEE/CVF International Conference on Computer Vision, 2021.

[39] Ze Liu, Jia Ning, Yue Cao, Yixuan Wei, Zheng Zhang, Stephen Lin, and Han Hu. Video swin transformer. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022.

[40] Zhaoyang Liu, Donghao Luo, Yabiao Wang, Limin Wang, Ying Tai, Chengjie Wang, Jilin Li, Feiyue Huang, and Tong Lu. TEINet: Towards an efficient architecture for video recognition. In Proceedings of the AAAI Conference on Artificial Intelligence, 2020.

[41] Zhaoyang Liu, Limin Wang, Wayne Wu, Chen Qian, and Tong Lu. Tam: Temporal adaptive module for video recognition. In IEEE/CVF International Conference on Computer Vision, 2021.

[42] Ilya Loshchilov and Frank Hutter. Sgdr: Stochastic gradient descent with warm restarts. arXiv preprint arXiv:1608.03983, 2016.

[43] Antoine Miech, Jean-Baptiste Alayrac, Lucas Smaira, Ivan Laptev, Josef Sivic, and Andrew Zisserman. End-to-end learning of visual representations from uncurated instructional videos. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020.

[44] Antoine Miech, Jean-Baptiste Alayrac, Lucas Smaira, Ivan Laptev, Josef Sivic, and Andrew Zisserman. End-to-End Learning of Visual Representations from Uncurated Instructional Videos. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020.

[45] Ishan Misra, C Lawrence Zitnick, and Martial Hebert. Shuffle and learn: unsupervised learning using temporal order verification. In European Conference on Computer Vision, 2016.

[46] Tian Pan, Yibing Song, Tianyu Yang, Wenhao Jiang, and Wei Liu. Videomoco: Contrastive video representation learning with temporally adversarial examples. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021.

[47] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Kopf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. Pytorch: An imperative style, high-performance deep learning library. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, editors, Advances in Neural Information Processing Systems, 2019.

[48] Deepak Pathak, Philipp Krähenbühl, Jeff Donahue, Trevor Darrell, and Alexei A. Efros. Context encoders: Feature learning by inpainting. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2016.

[49] Viorica Patraucean, Ankur Handa, and Roberto Cipolla. Spatio-temporal video autoencoder with differentiable memory. arXiv preprint arXiv:1511.06309, 2015.

[50] Mandela Patrick, Yuki M. Asano, Polina Kuznetsova, Ruth Fong, João F. Henriques, Geoffrey Zweig, and Andrea Vedaldi. Multi-modal self-supervision from generalized data transformations. In IEEE/CVF International Conference on Computer Vision, 2021.

[51] Mandela Patrick, Dylan Campbell, Yuki Asano, Ishan Misra, Florian Metze, Christoph Feichtenhofer, Andrea Vedaldi, and Joao F. Henriques. Keeping your eye on the ball: Trajectory attention in video transformers. In Advances in Neural Information Processing Systems, 2021.

[52] AJ Piergiovanni, Anelia Angelova, and Michael S Ryoo. Evolving losses for unsupervised video representation learning. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020.

[53] Rui Qian, Tianjian Meng, Boqing Gong, Ming-Hsuan Yang, Huisheng Wang, Serge Belongie, and Yin Cui. Spatiotemporal contrastive video representation learning. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021.

[54] Rui Qian, Tianjian Meng, Boqing Gong, Ming-Hsuan Yang, Huisheng Wang, Serge J. Belongie, and Yin Cui. Spatiotemporal contrastive video representation learning. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021.

[55] Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. Improving language understanding by generative pre-training. OpenAI blog, 2018.

[56] Alec Radford, Jeff Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. OpenAI blog, 2019.

[57] Aditya Ramesh, Mikhail Pavlov, Gabriel Goh, Scott Gray, Chelsea Voss, Alec Radford, Mark Chen, and Ilya Sutskever. Zero-shot text-to-image generation. In International Conference on Machine Learning, 2021.

[58] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, et al. Imagenet large scale visual recognition challenge. International Journal of Computer Vision, 2015.

[59] Karen Simonyan and Andrew Zisserman. Two-stream convolutional networks for action recognition in videos. Advances in Neural Information Processing Systems, 2014.

[60] Ankit Singh, Omprakash Chakraborty, Ashutosh Varshney, Rameswar Panda, Rogerio Feris, Kate Saenko, and Abir Das. Semi-supervised action recognition with temporal contrastive learning. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021.

[61] Khurram Soomro, Amir Roshan Zamir, and Mubarak Shah. Ucf101: A dataset of 101 human actions classes from videos in the wild. arXiv preprint arXiv:1212.0402, 2012.

[62] Nitish Srivastava, Elman Mansimov, and Ruslan Salakhutdinov. Unsupervised learning of video representations using lstms. International Conference on Machine Learning, 2015.

[63] Jonathan C. Stroud, David A. Ross, Chen Sun, Jia Deng, Rahul Sukthankar, and Cordelia Schmid. Learning video representations from textual web supervision. CoRR, abs/2007.14937, 2020.

[64] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2016.

[65] Hao Tan, Jie Lei, Thomas Wolf, and Mohit Bansal. Vimpac: Video pre-training via masked token prediction and contrastive learning. arXiv preprint arXiv:2106.11250, 2021.

[66] Jiajun Tang, Jin Xia, Xinzhi Mu, Bo Pang, and Cewu Lu. Asynchronous interaction aggregation for action detection. In European Conference on Computer Vision, 2020.

[67] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In International Conference on Machine Learning, 2021.

[68] Du Tran, Lubomir Bourdev, Rob Fergus, Lorenzo Torresani, and Manohar Paluri. Learning spatiotemporal features with 3d convolutional networks. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2015.

[69] Du Tran, Heng Wang, Matt Feiszli, and Lorenzo Torresani. Video classification with channel-separated convolutional networks. In IEEE/CVF International Conference on Computer Vision, 2019.

[70] Du Tran, Heng Wang, Lorenzo Torresani, Jamie Ray, Yann LeCun, and Manohar Paluri. A closer look at spatiotemporal convolutions for action recognition. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018.

[71] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In Advances in Neural Information Processing Systems, 2017.

[72] Pascal Vincent, Hugo Larochelle, Yoshua Bengio, and Pierre-Antoine Manzagol. Extracting and composing robust features with denoising autoencoders. In International Conference on Machine Learning, 2008.

[73] Pascal Vincent, Hugo Larochelle, Isabelle Lajoie, Yoshua Bengio, and Pierre-Antoine Manzagol. Stacked denoising autoencoders: Learning useful representations in a deep network with a local denoising criterion. Journal of Machine Learning Research, 2010.

[74] Jiangliu Wang, Jianbo Jiao, and Yun-Hui Liu. Self-supervised video representation learning by pace prediction. In European Conference on Computer Vision, 2020.

[75] Limin Wang, Zhan Tong, Bin Ji, and Gangshan Wu. TDN: Temporal difference networks for efficient action recognition. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021.

[76] Limin Wang, Yuanjun Xiong, Zhe Wang, Yu Qiao, Dahua Lin, Xiaoou Tang, and Luc Van Gool. Temporal segment networks for action recognition in videos. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019.

[77] Rui Wang, Dongdong Chen, Zuxuan Wu, Yinpeng Chen, Xiyang Dai, Mengchen Liu, Yu-Gang Jiang, Luowei Zhou, and Lu Yuan. Bevt: Bert pretraining of video transformers. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022.

[78] Xiaolong Wang, Ross Girshick, Abhinav Gupta, and Kaiming He. Non-local neural networks. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018.

[79] Xiaolong Wang and Abhinav Gupta. Unsupervised learning of visual representations using videos. In IEEE/CVF International Conference on Computer Vision, 2015.

[80] Chen Wei, Haoqi Fan, Saining Xie, Chao-Yuan Wu, Alan Yuille, and Christoph Feichtenhofer. Masked feature prediction for self-supervised visual pre-training. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022.

[81] Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, Jose M Alvarez, and Ping Luo. Segformer: Simple and efficient design for semantic segmentation with transformers. In Advances in Neural Information Processing Systems, 2021.

[82] Zhenda Xie, Zheng Zhang, Yue Cao, Yutong Lin, Jianmin Bao, Zhuliang Yao, Qi Dai, and Han Hu. Simmim: A simple framework for masked image modeling. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022.

[83] Dejing Xu, Jun Xiao, Zhou Zhao, Jian Shao, Di Xie, and Yueting Zhuang. Self-supervised spatiotemporal learning via video clip order prediction. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019.

[84] Wilson Yan, Yunzhi Zhang, Pieter Abbeel, and Aravind Srinivas. Videogpt: Video generation using VQ-VAE and transformers. arXiv preprint arXiv:2104.10157, 2021.

[85] Ceyuan Yang, Yinghao Xu, Bo Dai, and Bolei Zhou. Video representation learning with visual tempo consistency. arXiv preprint arXiv:2006.15489, 2020.

[86] Sangdoo Yun, Dongyoon Han, Seong Joon Oh, Sanghyuk Chun, Junsuk Choe, and Youngjoon Yoo. Cutmix: Regularization strategy to train strong classifiers with localizable features. In IEEE/CVF International Conference on Computer Vision, 2019.

[87] Hongyi Zhang, Moustapha Cisse, Yann N Dauphin, and David Lopez-Paz. mixup: Beyond empirical risk minimization. arXiv preprint arXiv:1710.09412, 2017.

[88] Zhang Zhang and Dacheng Tao. Slow feature analysis for human action recognition. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2012.

[89] Daquan Zhou, Bingyi Kang, Xiaojie Jin, Linjie Yang, Xiaochen Lian, Qibin Hou, and Jiashi Feng. Deepvit: Towards deeper vision transformer. arXiv preprint arXiv:2103.11886, 2021.

[90] Jinghao Zhou, Chen Wei, Huiyu Wang, Wei Shen, Cihang Xie, Alan Yuille, and Tao Kong. iBOT: Image bert pre-training with online tokenizer. International Conference on Learning Representations, 2022.

부록

이 부록에서는 다음 측면에서 VideoMAE를 더 자세히 설명한다.

- 상세한 구조 설명은 §6에 있다.

- 구현 세부사항은 §7에 있다.

- 실험 결과는 §8에 있으며, Something-Something V2와 Kinetics-400의 절제 연구 및 다운스트림 평가 과제인 행동 검출을 포함한다. UCF101과 HMDB51에서 최고 수준의 방법과 비교한 추가 결과도 포함한다.

- 결과 분석은 §9에 있다.

- 복원한 표본의 시각화는 §10에 있다.

- 데이터셋의 라이선스는 §11에 있다.

6 구조

영상 자기지도 사전학습에는 비대칭 인코더–디코더 구조를 사용하며 미세조정 단계에서는 디코더를 버린다. 16프레임을 입력받는 일반적인 ViT-Base를 예로 들어, 인코더와 디코더의 구체적인 구조 설계를 표 8에 제시한다. 남은 토큰의 고수준 시공간 정보를 더 잘 포착하도록 시공간 결합 어텐션 [3, 39]을 사용한다.

표 8. VideoMAE의 구조 세부사항. 16프레임을 입력받는 일반적인 ViT-Base를 예로 든다. 여기서 MHA는 시공간 결합 자기어텐션을 뜻한다. 출력 크기는 채널·시간·공간 크기를 나타내는 $\{C \times T \times S\}$로 표기한다.

단계	비전 트랜스포머(Base)	출력 크기
데이터	간격 4×1×1 (K400)	3×16×224×224
데이터	간격 2×1×1 (SSV2)	3×16×224×224
큐브	2×16×16, 768	768×8×196
큐브	간격 2×16×16	768×8×196
마스킹	튜브 마스크	768×8×[196×(1-ρ)]
마스킹	마스킹 비율 = ρ	768×8×[196×(1-ρ)]
인코더	$[\mathrm{MHA}(768); \mathrm{MLP}(3072)] \times 12$	768×8×[196×(1-ρ)]
투영기	MLP(384) &	384×8×196
투영기	학습 가능한 토큰 연결	384×8×196
디코더	$[\mathrm{MHA}(384); \mathrm{MLP}(1536)] \times 4$	384×8×196
투영기	MLP(1536)	1536×8×196
형태 변환	1536에서 3×2×16×16으로 변환	3×16×224×224

7 구현 세부사항

Something-Something V2와 Kinetics-400의 사전학습 및 미세조정 실험에는 GPU 64개를 사용한다. 더 작은 UCF101과 HMDB51의 실험에는 GPU 8개를 사용하여 학습한다. AVA 실험에는 GPU 32개를 사용한다. 전체 배치 크기에 비례하도록 기본 학습률을 선형 조정한다.

$$\mathrm{lr} = \text{base learning rate} \times \frac{\text{batch size}}{256}.$$

더 빠른 학습을 위해 PyTorch [47] 및 DeepSpeed[^2] 프레임워크를 사용한다. 향후 자기지도 영상 사전학습 연구를 촉진하고자 코드[^3]와 사전학습 모델[^4]을 공개했다.

[^2]: https://github.com/microsoft/DeepSpeed [^3]: https://github.com/MCG-NJU/VideoMAE [^4]: https://github.com/MCG-NJU/VideoMAE/blob/main/MODEL_ZOO.md

표 9. 사전학습 설정.

설정	Sth-Sth V2	Kinetics-400
최적화기	AdamW	AdamW
기본 학습률	1.5e-4	1.5e-4
가중치 감쇠	0.05	0.05
최적화기 모멘텀	$\beta_1, \beta_2 = 0.9, 0.95$ [12]	$\beta_1, \beta_2 = 0.9, 0.95$ [12]
배치 크기	1024	1024
학습률 스케줄	코사인 감쇠 [42]	코사인 감쇠 [42]
워밍업 에포크	40	40

설정	Sth-Sth V2	Kinetics-400
뒤집기 증강	아니요	예
증강	MultiScaleCrop [76]	MultiScaleCrop [76]

표 10. 표 6과 표 7의 종단간(end-to-end) 미세조정 설정.

설정	Sth-Sth V2	Kinetics-400
최적화기	AdamW	AdamW
기본 학습률	1e-3(S), 5e-4(B,L)	1e-3
가중치 감쇠	0.05	0.05
최적화기 모멘텀	$\beta_1, \beta_2 = 0.9, 0.999$	$\beta_1, \beta_2 = 0.9, 0.999$
배치 크기	512	512
학습률 스케줄	코사인 감쇠 [42]	코사인 감쇠 [42]
워밍업 에포크	5	5
학습 에포크	40 (S,B), 30 (L)	150 (S), 75 (B), 50 (L,H)
반복 증강	2	2
뒤집기 증강	아니요	예
RandAug [16]	(9, 0.5)	(9, 0.5)
라벨 평활화 [64]	0.1	0.1
mixup [87]	0.8	0.8
cutmix [86]	1.0	1.0
드롭 패스	0.1 (S,B), 0.2 (L,H)	0.1 (S,B), 0.2 (L,H)
드롭아웃	0.5 (L)	0.5 (L,H)
층별 학습률 감쇠 [4]	0.7 (S),0.75 (B,L)	0.7 (S),0.75 (B,L,H)

표 11. 선형 탐침(linear probing) 설정.

설정	Sth-Sth V2
최적화기	SGD
기본 학습률	0.1
가중치 감쇠	0
최적화기 모멘텀	0.9
배치 크기	1024
학습률 스케줄	코사인 감쇠
워밍업 에포크	10
학습 에포크	100
증강	MultiScaleCrop

표 12. 표 5의 종단간 미세조정 설정.

설정	AVA v2.2	AVA v2.2
Kinetics 추가 미세조정	✗	✓
최적화기	AdamW	AdamW

설정	AVA v2.2	AVA v2.2
기본 학습률	1e-3 (S), 2.5e-4 (B, L), 5e-4 (H)	5e-4
가중치 감쇠	0.05	0.05
최적화기 모멘텀	$\beta_1, \beta_2 = 0.9, 0.999$	$\beta_1, \beta_2 = 0.9, 0.999$
배치 크기	128	128
학습률 스케줄	코사인 감쇠 [42]	코사인 감쇠 [42]
워밍업 에포크	5	5
학습 에포크	30 (S, B, L), 20 (H)	30 (S, B) 20 (L, H)
반복 증강	아니요	아니요
뒤집기 증강	예	예
드롭 패스	0.2	0.2
층별 학습률 감쇠 [4]	0.6 (S), 0.75 (B, L), 0.8 (H)	0.6 (S), 0.75 (B), 0.8 (L, H)

Something-Something V2. 기본적으로 VideoMAE를 Something-Something V2에서 800에포크 사전학습한다. 미세조정 단계에서는 TSN [76]을 따라 균등 샘플링한다. 평가 시 모든 모델은 동일한 추론 규약인 2클립 × 3크롭을 사용한다. 사전학습·미세조정·선형 탐침의 기본 설정은 표 9, 표 12, 표 11에 제시한다. 지도학습에서는 [22]의 설정을 따라 100에포크 동안 처음부터 학습한다. 사전학습과 미세조정 단계 모두 뒤집기 증강을 사용하지 않는다는 점에 유의해야 한다. 표 6의 미세조정 단계에서는 반복 증강(repeated augmentation) [32]도 추가로 사용하며, 이는 top-1 정확도를 0.1%–0.3% 더 높일 수 있다.

Kinetics-400. 기본적으로 VideoMAE를 Kinetics-400에서 800에포크 사전학습한다. 미세조정 단계에서는 SlowFast [23]를 따라 밀집 샘플링한다. 평가 시 모든 모델은 동일한 추론 규약인 5클립 × 3크롭을 사용한다. 사전학습 및 미세조정의 기본 설정은 표 9와 표 12에 제시한다. 처음부터 지도학습할 때에는 [22]의 설정을 따라 200에포크 학습한다. 표 7의 미세조정 단계에서 반복 증강 [32]을 사용하며, 이는 top-1 정확도를 0.8%–1.0% 더 높일 수 있다.

번역자 주: 위 두 문단의 '표 12'는 PDF 원문 17쪽의 교차참조를 그대로 유지한 것이다. 영상 분류의 미세조정 설정표 자체는 표 10에, AVA 설정은 표 12에 제시되어 있다.

UCF101. 사전학습에는 Kinetics와 유사한 설정을 따른다. VideoMAE를 마스킹 비율 75%로 3200에포크 사전학습한다. 배치 크기와 기본 학습률은 각각 192와 3e-4다. 여기서는 시간적 간격 4로 프레임 16개를 샘플링한다. 미세조정에서는 반복 증강 [32]과 배치 크기 128을 사용해 100에포크 학습한다. 기본 학습률, 층별 감쇠(layer decay), 드롭 패스(drop path)는 각각 5e-4, 0.7, 0.2다. 평가에는 5클립 × 3크롭 추론 규약을 사용한다.

HMDB51. VideoMAE를 마스킹 비율 75%로 4800에포크 사전학습한다. 배치 크기와 기본 학습률은 각각 192와 3e-4다. 여기서는 시간적 간격 2로 프레임 16개를 샘플링한다. 미세조정에서는 반복 증강 [32]과 배치 크기 128을 사용해 50에포크 학습한다. 기본 학습률, 층별 감쇠, 드롭 패스는 각각 1e-3, 0.7, 0.2다. 평가에는 10클립 × 3크롭 추론 규약을 사용한다.

AVA. SlowFast [23]의 행동 검출 구조를 따르고 AIA [66]에서 검출한 사람 박스를 사용한다. 미세조정 기본 설정은 표 12에 제시한다. 데이터 증강을 위해 입력 프레임의 짧은 변을 256픽셀로 조정한다. 학습 중 입력 프레임에 224×224 픽셀 무작위 크롭과 무작위 뒤집기를 적용한다. 학습에는 정답 사람 박스만 사용하고, 추론에는 신뢰도가 ≥ 0.8인 검출 박스를 사용한다.

8 추가 결과

8.1 학습 스케줄

그림 5는 Something-Something V2와 Kinetics-400에서 더 긴 사전학습 스케줄이 미치는 영향을 보여준다. 사전학습 스케줄을 늘리면 두 데이터셋 모두 소폭 개선된다. 본문에서는 기본적으로 VideoMAE를 800에포크 사전학습한다.

그림 5. (a) Something-Something V2와 (b) Kinetics-400에서 학습 스케줄이 미치는 영향. 각 점은 하나의 완전한 학습 스케줄에 해당한다. 기본 ViT-B 백본은 표 8에 설명되어 있다. (이미지는 원문 그림 5 참조.)

그림 6. UCF101과 HMDB51에서 VideoMAE, MoCo v3 [15], Vi2CLR [19]를 비교한다. (이미지는 원문 그림 6 참조.)

8.2 최고 수준 방법과 비교

표 13은 UCF101과 HMDB51에서 최고 수준의 방법과 상세히 비교한 결과다. 그림 6은 ImageNet 사전학습 없이도 제한된 영상 데이터, 예를 들어 UCF101의 9.5천 클립과 HMDB51의 3.5천 클립만으로 영상 트랜스포머를 효과적으로 학습할 수 있도록 하는 데이터 효율적인 학습기가 VideoMAE임을 추가로 보여준다. 이러한 소규모 영상 데이터셋에서 추가 데이터 없이 VideoMAE를 사용하면 처음부터 학습하는 방법, MoCo v3 사전학습 [15], 기존 최고 성능인 Vi2CLR [19]를 크게 능가한다. 작은 데이터셋에서는 큰 ViT 모델을 학습하기가 더 어렵기 때문에, 이 두 작은 데이터셋은 대규모 영상 데이터셋보다 VideoMAE의 효과를 검증하기에 더 적합하다.

표 13. UCF101과 HMDB51에서 최고 수준의 방법과 비교한다. VideoMAE는 정규화한 큐브 픽셀을 복원하며, 마스킹 비율 75%로 UCF101에서는 3200에포크, HMDB51에서는 4800에포크 사전학습한다. 평가를 위해 미세조정 정확도를 보고한다. V는 시각 정보만 사용함을, A는 음성을, T는 텍스트 내레이션을 뜻한다. N/A는 저자들이 해당 수치를 확보하지 못했음을 나타낸다.

방법	백본	추가 데이터	프레임 수	파라미터 수	모달리티	UCF101	HMDB51
OPN [36]	VGG	UCF101	N/A	N/A	V	59.6	23.8
VCOP [83]	R(2+1)D	UCF101	N/A	N/A	V	72.4	30.9
CoCLR [30]	S3D-G	UCF101	32	9M	V	81.4	52.1
Vi2CLR [19]	S3D	UCF101	32	9M	V	82.8	52.9
VideoMAE	ViT-B	외부 데이터 없음	16	87M	V	91.3	62.6
SpeedNet [5]	S3D-G	Kinetics-400	64	9M	V	81.1	48.8
VTHCL [85]	SlowOnly-R50	Kinetics-400	8	32M	V	82.1	49.2
Pace [74]	R(2+1)D	Kinetics-400	16	15M	V	77.1	36.6
MemDPC [29]	R-2D3D	Kinetics-400	40	32M	V	86.1	54.5
CoCLR [30]	S3D-G	Kinetics-400	32	9M	V	87.9	54.6
RSPNet [13]	S3D-G	Kinetics-400	64	9M	V	93.7	64.7
VideoMoCo [46]	R(2+1)D	Kinetics-400	16	15M	V	78.7	49.2
Vi2CLR [19]	S3D	Kinetics-400	32	9M	V	89.1	55.7
CVRL [54]	SlowOnly-R50	Kinetics-400	32	32M	V	92.9	67.9
CVRL [54]	SlowOnly-R50	Kinetics-600	32	32M	V	93.6	69.4
CVRL [54]	Slow-R152 (2×)	Kinetics-600	32	328M	V	94.4	70.6
CORPf [33]	SlowOnly-R50	Kinetics-400	32	32M	V	93.5	68.0
ρSimCLRρ=2 [24]	SlowOnly-R50	Kinetics-400	8	32M	V	88.9	N/A
ρSwAVρ=2 [24]	SlowOnly-R50	Kinetics-400	8	32M	V	87.3	N/A
ρMoCoρ=2 [24]	SlowOnly-R50	Kinetics-400	8	32M	V	91.0	N/A
ρBYOLρ=2 [24]	SlowOnly-R50	Kinetics-400	8	32M	V	92.7	N/A
ρBYOLρ=4 [24]	SlowOnly-R50	Kinetics-400	8	32M	V	94.2	72.1
MIL-NCE [44]	S3D	HowTo100M	32	9M	V+T	91.3	61.0
MMV [1]	S3D-G	AS+HTM	32	9M	V+A+T	92.5	69.6

방법	백본	추가 데이터	프레임 수	파라미터 수	모달리티	UCF101	HMDB51
CPD [37]	ResNet50	IG300k	16	N/A	V+T	92.8	63.8
ELO [52]	R(2+1)D	Youtube8M-2	N/A	N/A	V+A	93.8	67.4
XDC [2]	R(2+1)D	Kinetics-400	32	15M	V+A	84.2	47.1
XDC [2]	R(2+1)D	IG65M	32	15M	V+A	94.2	67.1
GDT [50]	R(2+1)D	Kinetics-400	32	15M	V+A	89.3	60.0
GDT [50]	R(2+1)D	IG65M	32	15M	V+A	95.2	72.8
VideoMAE	ViT-B	Kinetics-400	16	87M	V	96.1	73.3

9 모델 결과 분석

이 절에서는 모델 결과에 관한 분석을 추가한다. 그림 7과 그림 8에서 보듯, VideoMAE는 SSV2의 대부분 범주에서 큰 개선을 가져온다. 이는 VideoMAE가 ImageMAE 및 ImageNet-21k 지도 사전학습 모델보다 더 많은 시공간 구조 표현을 포착할 수 있음을 시사한다. 한편 일부 범주에서는 VideoMAE가 다른 두 모델보다 조금 못한 성능을 보인다는 점도 발견했다. 모델의 작동 방식을 더 잘 이해하기 위해 검증 집합에서 몇 가지 예시를 선택했다. 그림 9에 그 예시를 제시한다. 첫 번째 행의 예시에서는 VideoMAE가 매우 작은 물체의 움직임 정보를 포착하지 못할 수 있음을 발견했다. 매우 높은 마스킹 비율 때문에 작은 움직임을 담은 토큰이 전부 가려졌을 수 있으며, 그러면 VideoMAE가 가려진 작은 움직임 패턴을 복원하기 어려울 것이라고 추측한다. 두 번째 행의 예시에서는 VideoMAE가 손으로 쥐어짜면서 생기는 물체의 변형과 움직임을 포착할 수 있지만 이미지 사전학습은 이를 구별하지 못함을 발견했다. VideoMAE에 대한 더 상세한 분석은 향후 연구로 남긴다.

그림 7. Something-Something V2의 ImageMAE(64.8%)와 VideoMAE(69.6%) 비교. (a)는 VideoMAE가 ImageMAE를 능가하는 범주이며, 개선 폭이 10%보다 큰 범주만 표시한다. (b)는 ImageMAE가 VideoMAE를 능가하는 범주다. (이미지는 원문 그림 7 참조.)

그림 8. Something-Something V2의 ImageNet-21k 지도 사전학습 모델(61.8%)과 VideoMAE(69.6%) 비교. (a)는 VideoMAE가 ImageNet-21k 지도 사전학습 모델을 능가하는 범주이며, 개선 폭이 15%보다 큰 범주만 표시한다. (b)는 ImageNet-21k 지도 사전학습 모델이 VideoMAE를 능가하는 범주다. (이미지는 원문 그림 8 참조.)

그림 9. Something-Something V2에서 서로 다른 모델의 예측 예시. 검증 데이터셋에서 뽑은 각 예시에 대해 파란색 글씨는 올바른 예측을, 빨간색 글씨는 잘못된 예측을 나타낸다. GT는 해당 예시의 정답을 뜻한다. (이미지는 원문 그림 9 참조.)

10 시각화

그림 10과 그림 11에 복원의 몇 가지 예시를 제시한다. 영상은 모두 검증 집합에서 무작위로 선택했다. 마스킹 비율이 매우 높더라도 VideoMAE는 만족스러운 복원 결과를 만들어낼 수 있다. 이러한 예시는 VideoMAE가 영상의 전체적인 시공간 구조를 포착하는 더 대표성 있는 특징을 학습할 수 있음을 시사한다.

11 데이터 라이선스

사용한 데이터셋은 모두 학술 목적으로 널리 사용하는 데이터셋이다. Something-Something V2[^5]와 UCF101[^6]의 라이선스는 자체 조건(custom)이다. Kinetics-400[^7], HMDB51[^8], AVA[^9]의 라이선스는 CC BY-NC 4.0[^10]이다.

[^5]: 원문 URL: https://developer.qualcomm.com/software/ai-datasets/something-something [^6]: 원문 URL: https://www.crcv.ucf.edu/data/UCF101.php [^7]: 원문 URL: https://www.deepmind.com/open-source/kinetics [^8]: 원문 URL: https://serre-lab.clps.brown.edu/resource/hmdb-a-large-human-motion-database [^9]: 원문 URL: https://research.google.com/ava/index.html [^10]: 원문 URL: https://creativecommons.org/licenses/by/4.0

번역자 주: 이 절은 원 논문의 데이터셋 라이선스 설명을 번역한 것이다. 원문은 ‘CC BY-NC 4.0’이라고 쓰면서 각주 10에는 CC BY 4.0 주소를 연결한다. 이 불일치를 임의로 수정하지 않았다. 본 논문 텍스트 자체의 CC BY 4.0 표기와는 별개의 항목이다.

그림 10. Kinetics-400 검증 집합에서 별도 선별 없이 무작위로 뽑은 영상. 원래 영상 시퀀스와 서로 다른 마스킹 비율에서의 복원 결과를 보여준다. 영상 복원 결과는 마스킹 비율 90%로 사전학습한 VideoMAE가 예측한 것이다. (이미지는 원문 그림 10 참조.)

그림 11. Something-Something V2 검증 집합에서 별도 선별 없이 무작위로 뽑은 영상. 원래 영상 시퀀스와 서로 다른 마스킹 비율에서의 복원 결과를 보여준다. 영상 복원 결과는 모두 마스킹 비율 90%로 사전학습한 VideoMAE가 예측한 것이다. (이미지는 원문 그림 11 참조.)